



单位代码 10635

学 号 112018321001483

西南大學

硕士学位论文

基于用户序列和社交网络的推荐算法研究

论文作者：黄可心

指导教师：李莉

学科专业：计算机应用技术

研究方向：深度学习

提交论文日期：2021 年 5 月 20 日

论文答辩日期：2021 年 5 月 23 日

学位授予单位：西南大学

中 国 • 重 庆

2021 年 5 月

目 录

摘 要	I
Abstract.....	III
1 绪论	1
1.1 研究背景与意义	1
1.2 国内外研究现状	2
1.3 本文的研究方法和内容	5
1.4 论文组织结构	5
2 相关理论和技术基础	7
2.1 推荐算法相关基础	7
2.1.1 基于用户交互矩阵的推荐模型	7
2.1.2 基于用户行为序列的推荐模型	9
2.1.3 基于图的推荐算法模型	10
2.2 深度学习相关基础	10
2.2.1 深度学习概述	10
2.2.2 卷积神经网络	12
2.2.3 门线型单元	14
2.2.4 基于图的深度学习模型	14
2.3 本章小结	18
3 基于成对编码和门控网络的序列推荐研究	19
3.1 基于成对编码和门控网络的序列推荐框架	20
3.1.1 问题定义	20
3.1.2 嵌入层	20
3.1.3 成对编码层	21
3.1.4 双层门控层	22
3.1.5 预测层	24
3.1.6 模型训练	24
3.2 实验设计与结果分析	25
3.2.1 实验数据	25
3.2.2 对比方法	26
3.2.3 评价指标	27
3.2.4 参数设置	28
3.2.5 模型表现对比	28

3.2.6 超参数对模型性能的影响	31
3.3 本章小结	32
4 基于社交网络的序列推荐研究	33
4.1 基于社交网络的序列推荐模型	34
4.1.1 问题定义	34
4.1.2 用户行为的时序特征挖掘	35
4.1.3 用户的社交特征嵌入	37
4.1.4 基于社交网络的序列推荐框架	38
4.2 实验设计与结果分析	39
4.2.1 实验数据	40
4.2.2 评价指标	40
4.2.3 对比方法	41
4.2.4 参数设置	42
4.2.5 模型表现对比	42
4.2.6 超参数对模型性能的影响	43
4.3 本章小结	45
5 总结与展望	47
5.1 本文工作总结	47
5.2 未来工作展望	48
参考文献	51
致 谢	57
攻读硕士期间的学术成果	59

基于用户序列和社交网络的推荐算法研究

摘要

随着移动互联网的普及和迅猛发展,互联网用户数量增势显著,随之而来的海量数据给用户和服务平台造成了巨大的影响。服务平台所面临的挑战是如何利用这些数据为用户和自身创造价值,而解决此问题最有效的途径就是推荐算法。推荐算法是通过建模用户的画像、用户的行为数据、项目本身的特征以及相关的上下文信息来预测用户的偏好,并为用户提供推荐服务。在学术界有众多研究人员致力于推荐算法的研究,并提出了丰富的推荐算法预测框架。工业界也对推荐算法进行了深入探索,使得在特定场景下推荐算法不仅能提高用户的满意度,也能给平台带来了不菲的收入。

建立推荐模型最经典的方法是基于用户评分,比如利用协同过滤、矩阵分解及因子分解等传统方法预测用户可能喜欢的物品,但是此类方法会受到一些限制,例如冷启动问题、数据稀疏问题都会导致模型运行效率低下。近些年,深度学习模型以其优秀的数据处理能力和模型泛化能力受到了各个领域的关注,当然在推荐领域中也是如此。在本文中,我们同样基于深度学习模型对推荐算法进行研究,主要的工作内容和贡献可以总结为以下几点:

1) 提出基于成对编码和门控网络的序列推荐算法框架(HPGM)。我们在序列推荐场景下观察到以下现象:用户历史行为序列中的各个项目对用户下一步决策的影响强度不同,因为并非所有项目对建模用户偏好都同等重要。其次,由于吸引用户的往往是一个项目的某个特征或着某些方面,所以用户会给同一个项目的各个特征分配不同的关注度。此外,许多方法没有对用户历史动作之间的复杂关系进行有效建模,本文提出了一种新的基于门控机制的推荐方法来解决上述问题。具体来说,我们先将用户和项目映射到潜在的向量空间并对其进行嵌入表示,接着引入成对编码层来构建一个三维张量,此张量用于存储用户交互历史中项目之间的关系,我们还设置了两个门控层过滤更重要的项目特征,使得模型能够有效建模项目间的转化关系,捕获用户的短期偏好。此外,用户的潜在嵌入向量还被用来表示用户的长期偏好,最后结合用户的长期偏好和短期偏好进行推荐预测;

2) 提出基于社交网络的序列推荐算法框架(SASE)。冷启动问题和稀疏数据集是推荐系统中不可避免的问题,解决这些问题的方法不是孤立地预测它们,而是利用用户历史行为中的附加信息。因此,我们可以使用用户历史行为中的时序数据和用户的社交关系来提高模型在冷启动场景下的性能。在本文中,我们提出了基于社交网络的序列推荐算法框架,该框架的核心思想是在用户的社交网络中寻找用

户的亲密朋友，同时从用户的历史交互序列中确定哪些项目与用户下一阶段的动作相关，然后根据这些特征进行推荐预测。具体来说，我们利用卷积神经网络中不同大小的滤波器捕获用户序列嵌入中的动态转化模式，同时采用图嵌入模型从社交网络中学习用户的社交特征，最后通过融合这两种特征使 SASE 更擅长处理推荐系统中的冷启动问题；

3) 为了验证 HPGM 的有效性，我们通过比较 HPGM 和其他七个基线模型在 Amazon 等真实数据集上的表现，得出所提出模型能够有效挖掘用户的偏好；其次为了证明 SASE 在冷启动场景下的可行性，我们在三个推荐数据集的基础上构造出对应的冷启动数据集，通过对比 SASE 和其他对照模型在冷启动数据集上的表现，得出了我们的方法能够有效作用在冷启动场景下；最后我们还对所提出模型的超参数进行了讨论。

综上，本文是针对序列推荐问题进行研究，并将深度学习相关技术引入其中以实现更好的推荐效果。同时，我们进行了多组对照实验，实验结果体现出本文提出模型的有效性和可行性

关键词：推荐算法；序列模式；深度学习；卷积神经网络；社交网络

Recommendation System Based on User Sequence and Social Network

Abstract

The number of Internet users is enlarging due to the success and rapid growth of mobile Internet. The massive data generated by users has a huge impact on users and service platforms. The challenge for service platforms is finding out how to use these data to generate value for both customers and themselves, and the most efficient way to handle above problems is recommendation algorithms. The recommendation system predicts users' preference by modeling their portrait, behavior data, the feature of the item and the relevant context data, then make recommendation for the user. In academic research, several researchers have devoted to the study of recommendation system and have developed numerous recommendation models. The industry has also made an in-depth exploration of the recommendation system so that the recommendation method cannot only improve user satisfaction, but also bring much revenue to the platform.

The most conventional recommendation model is based on user rating and they utilize traditional methods such as collaborative filtering, matrix factorization and factorization machines to make prediction. But these methods have some limitations such as cold start problem and data sparsity, which will lead to inefficient performance. In recent years, deep learning models have attracted more attention from various fields with their excellent capabilities of data processing and model generalization, and there are many novel recommendation models based on deep learning technology in the research field of recommendation systems. In this paper, we also study recommendation algorithms based on deep learning models. Our main work and contributions can be summarized as follows:

1) We propose a sequential recommendation framework based on Hierarchical Pairwise Gating Model (HPGM). We observed the following phenomenon in sequential recommendation scenario: First, each item in user's historical behavior sequence has different influence on the user's next action, because not all items are equally important for modeling user preferences. Secondly, since it is often a feature or aspect of an item that attracts user, user will assign various attention to each feature of an item. In addition, many methods do not effectively model the complex relationship between items in user

historical behaviors. This paper proposes a new recommendation model based on gating mechanism to solve above problems. Specifically, we map users and items to a latent vector space and embed them. Then we introduce a pairwise encoding layer to construct a 3-way tensor, which is utilized to store the relations between items in user interaction history. We also construct two gating layers to filter item features, so that the model can effectively model transition relationships and capture user's short-term preferences. In addition, the user embedding is also used to model user's long-term preferences. Finally, we make recommendation by combining the user's long-term and short-term preferences;

2) We propose a sequential recommendation algorithm based on social network (SASE). Cold start problem and sparse dataset are inevitable problems in recommendation system. The way to solve these problems is not to predict them in isolation, but to leverage additional signals of user's historical behavior. Therefore, we can improve the performance of recommendation model in the cold start scenario by using sequential data of user actions and social network. The core idea of the proposed model is to find user's intimate friends based on social network and determine which items are related to the user's next behavior in item sequences, and then make prediction with these features. Specifically, we utilize convolutional filters with different sizes to capture sequential patterns in user interaction sequence, and learn users' social features from social networks through graph embedding model, so that SASE can be better at dealing with the cold start issue in the recommendation system by fusing two features;

3) In order to verify the effectiveness of HPGM, we compare the performance of HPGM and seven baselines on Amazon and other real-world datasets, and conclude that the proposed model can efficiently mine user preferences; Secondly, we construct the corresponding cold start datasets on the basis of three recommendation datasets for proving the feasibility of SASE in the cold start scenario. By comparing the AUC of SASE and other baselines on three cold start datasets, we can conclude that our method can effectively work in the cold start scenario. Finally, we also discuss the hyper-parameters of the proposed model.

To sum up, this paper focuses on the sequential recommendation system and introduce deep learning technology into the recommendation system for achieving better performance. At the same time, we conduct a series of comparative experiments and the metrics indicate the validity and feasibility of the proposed model.

Keywords: Recommendation System, Sequential Pattern, Deep Learning, Convolutional Neural Network, Social Network

1 绪论

1.1 研究背景与意义

移动互联网的迅速发展和普及降低了普通大众使用互联网的成本,在最新发布的《第 47 次中国互联网络发展状况统计报告》^[1]中,中国互联网信息中心统计出截止 2020 年底,我国网民总数为 9.89 亿,网络普及率增长至 70.4%。随之而来的是激增的用户数据和各种各样的用户诉求,然而软件公司基于平台成本以及用户体验的考量,不能将所有的候选项展示到用户面前,与此同时,用户也没有耐心从海量数据中寻找自己喜欢的内容,因此如何准确匹配用户和内容成为服务平台亟待解决的问题。

在门户网站时代,用户通过索引分类从网络上获取信息,在这一过程中需要付出很大的人工成本。随着搜索引擎的发展,用户可以直接在搜索引擎上输入相应的查询词(Query)来快速获取自己想要的信息,然而以上两种信息获取方式都要求用户必须带有明确意图才能进行操作。用户的需求是高效率获取信息,如果用户处于无目的或无意图的状态下,搜索引擎将不能满足用户的需求。

推荐算法作为目前解决上述问题最为有效的方法受到了越来越多的关注。Varian 和 Resnick^[2]于上世纪 90 年代引入了推荐算法,这两位研究者也给出了被大家所广泛接受的定义:推荐算法是利用用户对物品的反馈信息,帮助用户找到适合自己的物品的一种方式。这种方式不仅可以给用户千人千面的服务,还能够帮助平台实现商业价值(例如:为用户推荐符合其偏好的广告以完成购买转化,平台从交易中抽成)。

推荐算法的应用场景也非常丰富,例如电商、音视频、新闻信息流、社交社区等等。网络用户产生的丰富数据推动了推荐算法的发展,推荐引擎带来的巨大收益和社会影响,使得无论是在学术研究领域还是实际落地场景中,推荐算法成为众多从业人员着力研究和探索的方向之一。

一些传统的推荐模型在学术领域中获得了出色的预测结果,在实际应用场景中也能体现出自身优势,例如:基于用户或项目的协同过滤推荐算法^{[3][4]}、隐语义模型^[5]、贝叶斯个性化排序模型^[6]等。随着神经网络的发展以及人们对推荐算法性能的不断追求,研究人员开始探索通过深度学习技术提高推荐结果的命中率,包括解决推荐系统中经常出现的问题,例如冷启动问题、稀疏数据集。实践证明,基于神经网络的推荐模型^{[7][8][9]}取得了比较好的效果,但还是可以从一些角度入手优化模型,以获得更准确的推荐结果。

用户在消费时是按照时间顺序进行的,且用户将要购买的商品会和用户上次所购买的商品产生联系,因此可以通过挖掘这种关系来预测用户的偏好。此类偏好严

格来说是用户的短期偏好，因为我们仅考虑特定长度的交互序列来预测用户未来可能会喜欢的项目，除此之外，用户的短期兴趣是随时间动态变化的。用户的长期偏好可以理解为用户的固有偏好，这种偏好能从用户的全部行为中学习而来。传统的推荐模型是从用户的评分矩阵中挖掘用户的长期兴趣，但是这些模型没有考虑用户评分之间的序列关系，而用户的短期兴趣和长期兴趣在推荐任务中同等重要。例如某一用户在两年前观看了神探夏洛克、名侦探柯南等悬疑类剧集，但在该用户最近的观影记录中出现大秦帝国、雍正王朝、三国演义等剧集。对当前的推荐任务而言，我们可以从用户近期的观影记录中得出：用户最近更加偏好政治历史类的剧集，所以历史类剧集为用户的短期偏好。相比于悬疑类剧集，历史类剧集对用户下一步动作的影响更大。而用户的长期兴趣可能是经典剧目或评分高的剧集，因此我们可以从用户的历史行为中同时挖掘用户的长期兴趣和短期兴趣，从而使用户得到更加满意的推荐结果。

1.2 国内外研究现状

作为一项能够解决信息过载问题的技术，推荐算法对提高用户满意度以及平台方的收益具有重要价值。在过去二十多年间，国内外研究人员提出了各式各样的推荐模型，这些模型大致可以分为三类：协同过滤模型、基于用户或项目属性信息的推荐模型、基于深度学习的推荐模型。

协同过滤算法是最经典的推荐方法，在很多互联网产品的个性化推荐模块中也能看到它的应用。协同过滤可以分为基于邻域模型、隐语义模型（LFM）、基于图的随机游走模型^{[10][11][12]}（Random Walk）。其中基于邻域的推荐模型主要包含基于用户的协同过滤模型（User-based Collaborative Filtering, UserCF）和基于项目的协同过滤模型（Item-based Collaborative Filtering, ItemCF）。UserCF 是通过挖掘用户之间的相似度为用户进行推荐，ItemCF 也是类似逻辑，即对项目之间的相似性进行建模，以预测用户的兴趣。隐语义模型源于统计的思想，主要是利用隐式的用户特征和项目特征来计算用户对某一项目的偏好。基于图的随机游走推荐模型需要以用户交互数据为基础构造对应的二分图，然后在用户和项目组成的交互图中进行随机游走，随机游走的结果构成最终的推荐列表。

协同过滤模型依赖用户的显示交互数据，因此当用户的评分数据非常稀疏或者面临冷启动（面向新用户或新项目的推荐）问题时，协同过滤模型就不能有效运作，反之，用户的行为数据越丰富意味着预测的准确率越高。此外，用户的偏好也可以从隐式的用户反馈（如点击、购买）中挖掘而来，研究人员基于用户的隐式行为对传统推荐模型做了扩展，例如贝叶斯个性化排序模型（BPR-MF）^[6]。贝叶斯个性化排序模型是利用用户的隐性反馈建立成对（Pair-wise）排序模型，并且存在以下

假设：（1）各个用户之间的反馈行为相互独立，同一用户对不同项目的偏好相互独立（2）对用户而言，正反馈应该比未观察到的反馈更可取。一些方法还从用户的历史交互行为中学习项目之间的相似关系，推荐效果也优于很多先进的推荐模型，例如，Kabbur^[13]等人利用相似度矩阵作为两个低维潜在因子矩阵的乘积，以此捕捉项目之间的关系。Ning^[14]等人提出了稀疏线性方法（Sparse linear methods, SLIM），该算法学习了一种类似项目相似度矩阵的稀疏聚合系数矩阵，用于优化最终的个性化排序列表。

基于用户或项目属性信息的推荐模型是对用户或项目的显性描述信息进行建模，并从中挖掘用户的偏好。基于用户属性信息的推荐模型^{[15][16][17]}是从用户的画像统计数据（年龄、性别、所在地、学历、收入等）中捕捉用户的兴趣特征，基于项目属性信息的推荐模型^{[18][19][20]}是对项目的描述信息进行建模，例如项目的图片、描述文本、评论文本等。建模用户或项目信息最常用的方法是借鉴自然语言处理（NLP）和计算机视觉（CV）领域的相关模型来提取相应特征，但此类模型依然受制于数据缺失问题以及推荐系统中的冷启动问题。

由于用户的社交网络会影响用户的下一步决策，因此可以将用户的社交信息融合进推荐模型，此类方法亦被证实可以达到不错的推荐效果^{[21][22][23]}。此外，有很多研究者利用社交网络来缓解推荐系统中的冷启动问题和长尾问题。例如，Cai^[24]等人提出了一种基于社交关系的个性化马尔可夫链模型（SPMC），该算法不仅在冷启动的场景下取得了较好的结果，而且在序列推荐任务中也表现得非常出色。同时，一些研究^{[25][26]}还融合了因子分解的方法，比如通过联合因子分解得到社交网络矩阵因子，以至于对用户的社交关系进行表示有利于解释并建模用户的兴趣。还有一些模型将正则化方法^{[27][28]}应用于社交推荐任务，这些模型假设用户的偏好与他们的社交圈相同，再通过正则化使用户的偏好因子接近其朋友的偏好。社交推荐模型的灵感还可以来自于传统的排序推荐模型，例如基于社交网络的贝叶斯个性化排序模型（SBPR）^[29]。

基于神经网络的推荐模型^{[30][31][32]}通常作用于用户的隐式行为数据上，例如用户的购买、点击、浏览、打卡等行为。相对于用户的评分数据，用户的隐式行为数据会更加丰富，因此用户隐式交互行为之间的关系更值得探究，这也吸引了诸多学者致力于利用用户的隐式数据建立推荐模型。经典的推荐算法习惯假定用户的交互数据是无序的，而忽视了用户行为之间的序列关系，这种序列关系也是具有实际意义，因为用户是按照一定的时间顺序进行操作，用户在未来可能喜欢的项目依赖于用户近期的交互行为，例如：用户前几天购买了一部手机，在未来就有可能购买手机钢化膜。

一些研究人员还试图联合神经网络和传统的推荐算法以提高模型的性能。NeuMF^[9]在用户的隐式行为数据的基础上,融合多层感知机模型(MLP)^[33]和矩阵因子分解(MF)^[34]来学习用户的偏好。Sedhain 等人提出 Autorec 模型^[35],该模型是通过自动编码器框架建模用户对候选项目的兴趣。此外,神经因式分解机模型^[36]结合神经网络与因子分解机^[37]提取用户交互行为中的高阶特征和非线性特征。Xin 等人提出一种基于关系协同过滤的两层注意网络(RCF)^[38]来捕捉多个项目之间的关系,并考虑了特定关系值和不同关系类型对建模用户偏好的贡献。

对于序列推荐任务,马尔可夫链(MCs)^[39]可以捕捉项目序列中的动态转化。因子化个性化马尔可夫链(FPMC)^[40]是一种经典的序列推荐模型,其核心思想是利用因子分解和马尔可夫链同时对用户偏好和项目序列关系进行建模。层次表示模型(HRM)^[41]通过引入聚合操作(如 Max Pooling)来扩展 FPMC,使其能捕捉更为复杂的用户偏好特征。He 等人的模型(TransRec)^[42]引入了度量嵌入方法建模序列项之间的三阶交互关系。此外,由于基于神经网络的序列推荐模型表现突出,所以采用深度学习技术建模用户的行为序列成为近几年比较流行的方法^{[43][44][45]}。卷积序列嵌入模型^[30](Caser)是将卷积神经网络(CNN)^[46]引入到序列推荐任务中,即利用卷积运算和可变的滤波器从上一个项目序列表示中学习序列转换关系,再引入潜在的用户向量来学习用户的固有偏好。由于循环神经网络(RNN)善于捕捉序列中的动态变化,所以也被用来建模用户的顺序交互行为^{[47][48]}。注意力机制同样被应用在序列推荐任务中^[49],利用注意力机制可以过滤掉无用的特征,留下更为重要的序列特征。自我注意力的序列推荐模型(SASRec)^[50]基于 Transformer 框架来捕捉用户的长期偏好和短期偏好,再以此预测用户的下一个动作,这也是第一次在序列推荐任务中引入自我注意力模型。

通过调研现有序列推荐模型的核心思路和实现方法,我们发现这些序列推荐模型主要存在以下问题:

1) 传统基于神经网络的序列推荐模型是将用户的行为序列作为一个整体进行建模,很难捕捉到不同位置上的项目对用户下一步决策的影响。由于用户可能只关注一个项目的某个方面,所以用户会对同一项目的各个方面分配不同的注意力。此外,用户交互过的项目对用户未来决策的影响具有多样性和动态性。但现有的序列推荐模型未能考虑到不同项目自身特征的影响,也忽略了用户顺序行为中特定项目的重要性。

2) 当用户的行为数据非常稀疏或处于冷启动场景时,如何对用户的偏好进行有效建模是一个难题。除此之外,大多数推荐方法没有很好地融合额外的上下文信息(例如用户的社交网络和行为序列),使得模型在冷启动场景中表现不佳。

1.3 本文的研究方法和内容

本文针对序列推荐算法进行了深入研究，并致力于解决前文所提出的问题。我们引入了不同的深度学习框架来构建有效且实用的推荐算法模型，并以此捕捉用户的兴趣偏好。本文的研究内容和核心思想主要包含以下两点：

第一，显性数据的缺失使得一些传统模型不能发挥很好的效果。此外，用户的购买、评分、浏览等行为记录都是按照时间顺序进行排列，并非是无序的数据，所以我们可以将用户的历史反馈按照时间戳转换成对应的动作序列。我们可以从用户的动作序列中探究相邻项目之间的转换关系，以此建模用户的短期偏好。此外，通过调研现有的基于神经网络的推荐模型，我们发现这些模型在一些问题上没有得到很好地解决：首先用户历史交互的项目对用户下一步行为的影响强度可能不同，因为并非所有的项目对建模用户偏好都同等重要。其次，用户可能会为项目的某些特征分配不同关注度，因为吸引用户的往往是某些特定的属性。最后，许多方法忽略了用户序列中项目之间复杂的转化关系。针对上述问题，本文提出了一种具有门控机制和成对编码模块的推荐框架，不仅引入成对编码层建模用户交互历史中项目之间的关系，而且采用了两个门线性模块来过滤有用的信息，并从项目本身和项目的属性特征两个层面建模用户的短期偏好，最后融合用户的隐性嵌入向量来学习用户的长期偏好，使得所提出模型可以同时学习用户的长期偏好和短期偏好。

第二，冷启动问题和稀疏数据集是推荐系统中无法规避的难题，解决这些问题的办法不是孤立地利用仅有的用户数据进行建模，而是要合理地使用用户交互行为产生过程中的额外信息，例如用户的社交信息、用户历史行为的时序信息。在本文中，我们提出了一种新的基于社交网络的序列推荐框架，主要利用卷积滤波器捕捉用户的序列偏好特征，同时从社交网络中学习用户的社交特征。所提出框架的核心思想是确定哪些项目与用户的历史行为相关，并寻找谁是用户的亲密朋友，然后根据这些特征进行推荐。此外，通过融合这两种特征还可以解决冷启动问题。

在本文中，我们均采用现实世界中的数据集来评估所提出模型的有效性和实用性，并且在同一数据集上与其他推荐模型进行比较，我们还探讨了超参数的不同取值对模型性能的影响。

1.4 论文组织结构

本文总共分为以下五个章节，全文的组织方式见图 1-1，各个章节的组织逻辑如下：


第一章，绪论。阐明了推荐算法以及序列推荐问题的研究背景和意义，同时对国内外关于此领域的研究现状进行梳理概括，并归纳总结了现存序列推荐模型的缺陷，由此引出本文的主要研究内容。

第二章，相关理论与技术基础。该章节针对本文研究内容所涉及到的传统推荐理论、序列推荐相关概念以及深度学习中的基础模型进行介绍。

第三章，基于成对编码和门控网络的序列推荐算法研究。主要提出了一个基于成对编码和门控网络的推荐算法框架，该框架考虑到每个项目及其不同属性对用户偏好的影响程度，并结合了成对编码机制、三维卷积神经网络以及门线形单元，使得所提出模型在提取序列特征的同时，还能有效地对用户的固有偏好进行建模。此外，我们还通过大量实验来证明该算法的有效性。

第四章，基于社交网络的序列推荐算法研究。主要提出一种考虑到用户社交网络的序列推荐算法框架。该框架同时考虑了用户行为中的序列特征和用户的社交特征，并分别利用卷积神经网络和图嵌入方法对其建模。最后通过该算法在冷启动数据集上的表现来验证模型的效果。

第五章，总结与展望。总结本文当前的研究工作，同时基于现有的工作成果展望未来研究思路 and 方向。



2 相关理论和技术基础

本章主要介绍研究工作中涉及到的相关概念和基础模型，并根据序列推荐任务的特性从两个方面引入相关理论及技术：推荐算法基础模型以及深度学习模型。由于本文的工作集中在序列推荐任务和神经网络模型，所以仅介绍与研究内容相关的基础推荐模型和深度学习技术。

2.1 推荐算法相关基础

推荐算法是从用户的交互数据中挖掘用户的兴趣特征并以此进行预测，用户交互数据的组织形式决定了模型的组成模块。根据不同的数据组织形式可以将用户交互数据分为以下三种：用户交互矩阵、用户交互序列、用户和项目的交互图，同样也可以从这三个角度引出相关的推荐算法及理论基础。

2.1.1 基于用户交互矩阵的推荐模型

传统推荐算法更关注用户反馈本身，而评分数据最能直观展现用户的偏好，因此这些推荐模型都是从用户的评分数据入手。用户的历史评分数据一般以矩阵的形式组织，如图 2-1 所示，在用户的评分矩阵中，数字 $\{1, 2, 3, 4, 5\}$ 代表用户 u 对项目 i 的打分结果，分值越高说明用户越喜欢该项目，“？”被定为用户 u 没有为项目 i 评分。因此可以将推荐任务具体化为：从用户已有的交互数据中挖掘用户的兴趣，并将交互矩阵补充完整，最后将用户未打分且评分高的项目推荐给用户。要特别指出的是，在推荐任务中“项目”指代一切能与用户产生交互的事物，例如电影、商品、视频、新闻等等。

	i_1	i_2	i_3	i_4
u_1	1	?	3	?
u_2	4	?	?	2
u_3	?	5	?	?
u_4	?	3	?	3
u_5	2	?	5	?

图 2-1 用户评分矩阵

矩阵分解模型（Matrix Factorization）也叫隐语义模型（Latent Factor Model, LFM），它是作用于用户评分矩阵上最经典有效的模型，其核心想法是从用户的评分矩阵中学习能够分别表示用户和项目的隐含特征向量，通过这些隐含特征将用

户的偏好和项目相连接，并以此为用户推荐。由于矩阵分解模型的可扩展性很强，所以其应用场景非常广泛，不仅出现在传统的推荐模型中，在基于深度学习的推荐模型中我们也能看到矩阵分解的应用。很多研究者基于矩阵分解模型做了很多扩展，例如贝叶斯个性化排序算法（BPR-MF）、概率矩阵分解模型（PMF）等，这些模型在推荐任务上都取得了较好的效果。最原始的矩阵分解算法可以表示为：

$$r_u^i = p_u^T Q_i = \sum_{k=1}^N p_u^k * q_k^i \quad (2-1)$$

其中 r_u^i 表示用户 u 对项目 i 的评分， p_u^k 是用户的隐式特征向量，表示用户 u 的偏好和第 k 个隐藏类别的关系， q_k^i 是项目的隐式特征向量，代表项目 i 和第 k 个隐藏类别的关系， N 表示隐藏类别的数量。矩阵分解模型首先把用户和项目映射到 N 维的隐式嵌入空间中，利用隐藏类别 k 对用户偏好特征与项目特征之间的关系进行建模，最后通过对用户和项目的隐式向量做内积来拟合用户评分矩阵中缺失的分值。可以通过下图 2-2 直观看到整个过程：




图 2-2 矩阵分解模型示意图

对于一个由用户和项目组成的集合 $N\{(u, i)\}$ ，矩阵分解模型的损失函数被定义为：

$$L = \sum_{(u,i) \in N} \left(r_u^i - \sum_{k=1}^N p_u^k q_k^i \right)^2 + \lambda (\|p_u\|^2 + \|q_i\|^2) \quad (2-2)$$

其中 λ 表示正则化超参数，可通过预先设定，再进行实验得到最优值。 $\|p_u\|^2$ 表示对 p_u 进行 L2 正则化，目的是防止模型过拟合。其中 α 是超参数，被定义为学习率， p_u^k 和 q_k^i 两个隐含向量是利用梯度下降的方法训练得到，训练过程如下：

$$\begin{cases} p_u^k = p_u^k + \alpha \left(q_k^i \left(r_u^i - \sum_{k=1}^N p_u^k q_k^i \right) - \lambda p_u^k \right) \\ q_k^i = q_k^i + \alpha \left(p_u^k \left(r_u^i - \sum_{k=1}^N p_u^k q_k^i \right) - \lambda q_k^i \right) \end{cases} \quad (2-3)$$

此外，一般基于潜在因子的推荐模型是由矩阵分解模型扩展而来，定义如下：

$$r_u^i = p_u^T q_i^T + \gamma + \beta_u + \beta_i \quad (2-4)$$

其中 p_u 和 q_i 为原始矩阵分解模型中的隐含用户向量和隐含项目向量, γ 表示全局偏移量, β_u 表示用户的特定偏好或评分习惯偏差, 例如有些用户习惯给历史类文章打高分而给情感类文章打低分, β_i 代表项目的特殊权重, 例如标题党文章常常被打低分。通过增加这两种不同的偏好特征可以丰富推荐的依据, 使得推荐模型能够达到更好的预测效果。

2.1.2 基于用户行为序列的推荐模型

在实际应用场景中, 用户产生的行为数据是按照时间顺序排列, 用户在前一阶段的交互行为会对后一阶段的交互行为产生影响, 因此可以通过挖掘相邻时间段内用户行为之间的关系来建模用户的兴趣, 这就是序列推荐任务所研究的内容。序列推荐算法作为推荐算法研究领域的一个分支, 所采取的数据组织行为与用户交互矩阵不同, 如图 2-3 所示, 主要是以时间顺序组织用户的历史交互记录, 这使得序列推荐模型在现实应用中, 能够作用在更密集的隐性交互数据上, 例如浏览、点击等等, 这在很大程度上缓解了稀疏评分数据集的问题。特别指出, 在处理用户的评分数据时, 我们只关心是否有评分以及用户评分的时间顺序, 而不关注具体的分值。




图 2-3 序列推荐示意图

现有的序列推荐算法可以分成两类：传统的序列推荐算法和基于神经网络的序列推荐算法。基于马尔可夫链的序列推荐算法是最传统也是最具代表性的方法, 马尔可夫链的特性是“无记忆性”, 即下一个状态的概率分布只由与之相邻的上一个状态决定, 与其他历史状态无关, 这一特性可以被应用在基于时间序列的推荐模型中。

假设给定序列状态 $X_0, X_1, \dots, X_t, X_{t+1}$ 一阶马尔可夫链可以表示为:

$$p(X_{t+1} | X_0, X_1, \dots, X_t) = p(X_{t+1} | X_t) \quad (2-5)$$

根据马尔可夫链能够得到序列中任意两个状态之间的转移概率, 转移概率可以组成一个转移概率矩阵, 从矩阵中可以得到状态之间一步到多步的转化概律, 由此进行预测。为解决序列推荐问题, 有研究者将马尔可夫链和矩阵分解模型相结合, 提出了基于马尔可夫链的个性化转移矩阵, 并在所构造出的三维矩阵上应用矩阵分解方法, 使得模型不仅可以解决数据稀疏性问题, 还能同时捕捉用户的固有偏好以及行为序列之间的转化关系^[40]。

由于序列推荐问题中的项目排列类似自然语言处理中的词排列,所以也能从中得到一些思路,例如我们可以利用深度学习相关模型挖掘用户行为序列中的偏好信息。具体而言,我们可以从相邻的序列间得到用户的短期偏好,再利用用户的整个动作序列对用户的长期偏好进行建模。虽然基于深度学习的序列推荐算法取得了非常优秀的效果,但是模型的不可解释性也受到了一些研究者的质疑。

2.1.3 基于图的推荐算法模型

用户的交互数据除了可以构造为矩阵、序列之外还可以构造成图,也就是将用户和项目作为图上的节点,用户对项目的交互构成两个节点之间的边,从而可以得到一张包含用户交互数据的图,见图 2-4。此外,还可以通过增加边和节点的方式表示用户和用户之间的社交关系,项目和项目之间的绑定关系等。




图 2-4 用户-项目交互示意图

在把用户行为数据构造成图之后,成熟的解决方案有图神经网络模型、图嵌入模型,本文中所涉及到的图相关模型会在下一节进行阐述。

2.2 深度学习相关基础

深度学习框架依托于自身的灵活性、优秀的特征捕获能力、出色的泛化能力以及强大的高维度数据处理能力,吸引了越来越多的领域开始利用深度学习模型解决实际问题,例如推荐算法、自然语言处理等。本文所探究的问题同样依赖于深度学习框架,并以此捕获用户的兴趣特征。因此在本节中我们不仅对深度学习技术的发展历史进行阐述,还梳理了深度学习的基础模型及相关概念。除此之外,我们将重点对本文研究内容所涉及到的深度学习模型进行论述。

2.2.1 深度学习概述

深度学习模型^{[51][52]}是一项以神经网络为基础对数据进行表征学习的技术。最早的神经网络是 Warren S. McCulloch 和 Walter Pitts 所提出的 M-P 模型^[53],该模

型来源于生物学中人脑神经网络对信息的响应机制，并通过网络拓扑理论对人脑神经网络的处理方式进行抽象模拟。M-P 模型的示意图如下：




图 2-5 M-P 模型示意图

从图 2-5 中可以看出，每个神经元 i 可以接受 n 个输入，因为每个输入 x_j 对神经元造成的影响存在差异，所以需要增加权重值 w_{ji} 来表示输入的影响程度，并且存在一个偏置值或阈值 b 调节模型。接着要将所有的输入累加整合，最后通过激活函数 $f(\cdot)$ 获得神经元的输出 y_i 。激活函数也是对人脑神经网络的模拟，即神经元是否发出信号的判断条件是输入信号的累加值在某一阈值内或超过某个阈值。最后神经元的输出 y_i 表示如下：

$$y_i = f\left(\sum_{j=1}^n x_j w_{ji} + b\right) \quad (2-6)$$

心理学家 Donald Olding Hebb 于 1949 年提出了一个假设：神经元之间突触的连接强度与其前后神经元有关，前后神经元的变化会影响它们之间突触的连接强度，此假设发展为著名的 Hebb 规则^[54]，它是使神经网络拥有记忆能力和学习能力的基础。基于 M-P 模型和 Hebb 规则，Frank Rosenblatt 在 1957 年提出历史上第一个具有真实意义的神经网络模型^[55]：感知机模型。感知机模型包含两层神经元，分别是输入神经元和输出神经元，主要是通过连接这两层神经元完成模型对输入的分类。单层感知机的分类能力仅针对线性问题，对于非线性问题束手无策，因此多层感知机（Multilayer Perceptron, MLP）被提出。多层感知机包含输入层、隐含层以及输出层，并且随着隐含层数的增加，模型能够解决更为复杂的分类问题，但是在此神经网络中隐含层的权值训练问题成为其发展瓶颈。

在 1986 年，Geoffrey Hinton 等人研究出反向传播算法^[34]，这一方法可以训练多层感知机，使得多层感知机具有强大的学习能力和分类能力。反向传播算法需要和梯度下降一起作用在多层感知机上，该模型的学习过程分为两个阶段：正向传播和反向传播。在正向传播过程中，输入数据被依次传送到输入层、隐含层以及最后的输出层，如果最终输出的结果不是期望值，那么将输入值和期望值差的平方和作

为损失函数从而进入反向传播，在反向传播过程中对每一层计算出损失函数对各神经元权值的偏导，偏导数则为梯度，并以此不断优化权值直到误差在一定范围内，学习过程结束。

循环神经网络（Recurrent Neural Network, RNN）源起于霍普菲尔神经网络^[56]，该网络架构作用于序列数据并可以对之前的信息进行记忆，但存在长期依赖的缺陷。Sepp Hochreiter 和 Jürgen Schmidhuber^[57]于 1997 年在循环神经网络的基础上提出长短时记忆网络模型（Long Short-Term Memory, LSTM），长短时记忆网络通过引入门控结构来解决循环神经网络中出现的长期依赖问题。随着计算机性能的发展，Transformer^[58]、BERT^[59]等模型也被提出，并且在机器翻译、推荐算法等实际应用场景下取得了优异的成果。

另一个经典的神经网络模型：卷积神经网络（Convolutional Neural Network, CNN）^[46]在 1998 年被 Yann LeCun 等研究者提出，该神经网络是一种含有卷积运算的深层前馈神经网络，此网络架构被广泛应用在计算机视觉的任务中。

深度学习模型在各类应用场景中展现了其出众的能力，学术界和工业界也在不断探索深度学习模型更多的可能性，在本文所研究的推荐算法领域，深度学习模型也有着非常优秀的表现，因此通过深度学习框架来优化推荐模型是一个值得深入研究的方向。

2.2.2 卷积神经网络

卷积神经网络最先应用在计算机视觉领域，它解决了传统多层感知机模型在处理图像时由于参数过多导致计算效率低下以及过拟合的问题。作为前馈神经网络，卷积神经网络主要包含六层：数据输入层（Input layer）、卷积层（Convolutional layer）、线性整流层（Rectified Linear Units layer, ReLU layer）、池化层（Pooling layer）、全连接层（Full-connected Layer）以及输出层（Output Layer）。具体架构见图 2-6。




图 2-6 卷积神经网络架构图

首先需要在数据输入层对原始的图像数据进行归一化、均值化以及降维处理，其次将处理完成的数据输入到卷积神经网络的核心层——卷积层，通过卷积层来提取相应特征。

由于每张图像的局部特征是区分不同图像的依据，因此将所有局部像素的感知结合起来就可以得到全部的信息，卷积操作也是基于此逻辑。为减少模型参数、缓解模型的耗时问题，在卷积层引入了局部感受野机制，即每个隐含单元仅连接输入图像的一部分，感受野的大小和卷积核（滤波器）的尺寸一致。在对数据做卷积操作时，需要将卷积核与输入图像的局部进行矩阵内积计算再加上相应的偏置值，然后通过不断移动卷积核并重复卷积操作，最终可以得到特征图（Feature map）。此外，在一个过程中共享同一组权重和偏置值，参数共享可以缩减自由参数的个数，使得网络架构的复杂性下降，还能够高效提取特征。在卷积过程中，卷积核的深度与输入图像的深度保持一致，且需要在输入矩阵上增加填充值（Padding）以保证输入数据全部能被卷积核遍历。除此之外卷积核的大小、移动的步长、填充值为超参数，需要预先指定或通过实验得到最优值。

线性整流层的目的是使用激活函数 ReLU（Rectified Linear Unit）对经过卷积层的数据进行非线性映射。修正线型单元 ReLU 的优点是收敛速度快且求梯度简单，因此一般情况下通过 ReLU 为卷积层之后的结果加入非线性特征。

池化层是通过降采样（Subsampling）的方法压缩数据、减少参数量、仅保留重要的信息以及防止过拟合。一般采用两种方法进行池化操作：最大池化（Max pooling）和均值池化（Mean pooling），最大池化是利用该池化区域内的最大值来表示此区域，同理均值池化是计算该池化区域内的平均值，并以此均值代表池化后的结果。

在全连接层之前，会对数据进行 Flatten 操作，把多维矩阵形式的数据“拍平”为一维。全连接层的主要操作是将本层的所有神经元与上一层的全部神经元进行权重连接，再输入到分类器中完成相应任务，全连接层的权重需要在训练数据集中学习得到。

卷积神经网络优秀的泛化能力和特征提取能力使得其应用场景非常丰富，不仅可以作用在计算机视觉领域，也可以通过变换输入数据的组织形式和卷积方式来完成其他任务，比如以文本分类为代表的自然语言处理任务和推荐算法任务。此外，研究者在卷积神经网络的基础上进行了许多拓展，例如 VGG 网络^[60]、GoogLeNet^[61]和残差网络^[62]都展现出了强大的性能。

2.2.3 门线型单元

门控机制是一种对信息流向进行调节的控制机制，这种机制在神经网络模型中也体现出了重要价值，例如长短时记忆网络（LSTM）和门控循环单元（GRU）。长短时记忆网络模型利用输入门、输出门以及遗忘门处理循环神经网络中存在的长期依赖问题，使得模型可以同时捕捉长期记忆和短期记忆。门控循环单元引入了重置门和更新门来解决 RNN 中存在的梯度消失问题。

除此之外，卷积神经网络模型中也可以引入门控机制来调节信息在网络中的传播，门线型单元（Gate Linear Unit, GLU）^[63]是一种最典型的门控机制。由于门线型单元可以缓解梯度传播，因此可以利用门控单元来解决卷积神经网络中出现的梯度不稳定问题。不仅如此，在卷积神经网络中，由于当前时刻的输出不依赖上一时刻的输入，所以还能实现模型的并行化，从而提升模型的计算速度。

综上所述，在卷积神经网络中引入门线型单元不仅能保留模型非线性的能力，还可以有效缓解梯度弥散，具体操作见图 2-7 所示：




图 2-7 基于门线型单元的卷积神经网络架构图

门线型单元的核心思想是在卷积层用以下公式代替原始的卷积输出：

$$h_l(X) = (E * W + b) \otimes \delta(E * V + c) \quad (2-7)$$

其中 E 是 h_l 层的输入， W 和 V 为卷积核， b 和 c 为偏差， δ 表示 sigmoid 激活函数， $\otimes$ 被定义为矩阵中对应元素的相乘运算（element-wise）， $*$ 表示卷积操作，且 W, V, b, c 表示通过训练得到的参数。整个门线型单元通过 sigmoid 函数控制 $E * W + b$ 中有哪些信息可以传进下一层，然后堆叠门线型单元来捕捉长期记忆，以提取更为抽象复杂的特征。

2.2.4 基于图的深度学习模型

图是一种最基础的数据结构，现实世界中的许多关系都可以通过图结构对其进行抽象，例如引文网络、海陆空交通网络、用户的社交网络、推荐系统中用户和项目组成的交互网络等。图相关模型可以被分成三类：经典的图数据结构、概率图模型（Probabilistic Graphical Model, PGM）、图神经网络（Graph Neural Network,

GNN)。关键路径、拓扑排序和最小生成树都属于经典的图结构及相关方法。概率图模型主要是用图结构来建模相关变量的联合概率分布以及依赖关系，代表模型包含贝叶斯网络（Bayesian Network, BN）、马尔可夫网络（Markov Network, MN）以及隐马尔可夫网络（Hidden Markov Model, HMN）。图神经网络^[64]是以图作为输入的一种神经网络架构，核心思想是对不规则的空间结构数据进行建模，挖掘非欧式空间数据直接的依赖关系。图神经网络可以被划分成五种：图卷积网络（Graph Convolutional Networks）、图注意力网络（Graph Attention Networks）、图自编码器（Graph Auto-encoder）、图生成网络（Graph Generative Networks）、图时空网络（Graph Spatial-Temporal Networks）。

本文所涉及到图嵌入模型（Graph Embedding）是将图数据中的网络拓扑结构、节点以及节点之间的边等高维度向量映射为低维度向量的方法，目的是将转化后的低维向量输入到下游任务中做后续处理，简化运算的同时还能提高计算速度。图嵌入模型可以分为：因子分解、随机游走和基于神经网络的方法。基于深度学习的图嵌入模型也属于图神经网络，可以看出图嵌入模型和图神经网络紧密相关，图嵌入模型和图神经网络模型的关系可以理解为相交关系，即图神经网络是完成图嵌入任务的多种方法之一，图嵌入是图神经网络所完成的多种任务之一。

在介绍图嵌入方法之前，我们首先对基于图的随机游走算法进行介绍。随机游走的基础是深度优先遍历方法，并且能够重复访问已访问节点。在图上进行随机游走时，首先给定一初始节点，下一个目标节点需按照随机游走的概率 α 来确定是否继续游走，如果继续游走，那么下个目标节点是按照均匀分布的方式随机地在当前节点所指向节点中进行选择，重复这个过程，最后随机游走途中每个节点被访问的概率会收敛到一个值，此过程可以用以下公式表示：

$$P(v) = \frac{1-\alpha}{N} + \alpha \sum_{u \in in(v)} \frac{p(u)}{out(u)} \quad (2-8)$$

其中 $P(v)$ 表示节点 v 被访问的概率， α 是继续游走的概率， N 代表图中全部节点的数量， $in(v)$ 表示指向节点 v 的节点集合， $out(u)$ 指的是节点 u 指向其他节点的集合。

由于图嵌入相关模型借鉴了 Word2vec^[65]模型的思想，所以我们接下来将对 Word2vec 模型进行简单介绍。Word2vec 模型解决的问题是如何将文本中的单词转化为对应的词向量，由于两个相似的单词具有相似的向量表示，因此可以通过句子中词与词之间的共现关系得到单词的向量表示。该算法以词的 one-hot 表示作为输入，通过仅包含一层隐含层的神经网络 Skip-gram 模型训练并预测该词的上下文，隐含层没有激活函数，且输出层的维度和输入层相同，同时输出层用 softmax 函数，

最后将模型训练得到的参数也就是把 Skip-gram 的权重作为词向量。由于单词在进行 one-hot 后，在输入到隐含层的权重中只有对应位置为 1 的权重被激活，且权重的个数和隐层的节点数保持一致，此外每个单词 one-hot 表示中 1 的位置不同，因此该模型训练出的权重可以唯一代表某一单词。

DeepWalk^[66]模型是经典的图嵌入模型，其核心思想类似 Word2vec，主要是通过图中节点和节点之间的共现关系来学习节点的向量表示，模型的具体架构如图 2-8 所示。




图 2-8 DeepWalk 模型架构图

DeepWalk 使用随机游走方法对图中的节点进行采样，以此来描述节点和节点的共现关系。模型的核心思路是：首先选择某一特定节点作为起始节点，然后通过随机游走获得充足数量的节点访问序列，其次利用 skip-gram 神经网络对图上离散的节点进行向量化表示，两个向量之间的距离表示两个节点在图中邻近点的多少，邻近点越多则两个向量之间的距离越短。

Node2vec^[67]是在 DeepWalk 的基础上扩展而来，区别是 Node2vec 进行随机游走时，需要在广度优先（BFS）和深度优先（DFS）搜索之间进行权衡（如图 2-9 所示），使得最终学习到的向量所包含的信息比 DeepWalk 更多。




图 2-9 基于节点 u 的 BFS 和 DFS 搜索策略（步长为 3）

Node2vec 模型的任务是：预先给定图的每个节点，使其邻接节点出现的概率最大，可以用以下公式来表示：

$$\max_f \sum_{u \in V} \log P(N_A(u) | f(u)) \quad (2-9)$$

其中 $f(u)$ 表示将节点 u 映射为嵌入向量的映射函数， $N_A(u)$ 为经过采样策略 A 得到的关于节点 u 的邻近节点的集合。为了使得上述公式可以求得最优解，存在

两个假设：第一个假设是条件独立性假设，假设在给定的源节点的情况下，其邻近节点出现的概率与邻近集合中的其他节点无关，该假设可以表示为：

$$P(N_A(u)|f(u)) = \prod_{n_i \in N_A(u)} P(n_i|f(u)) \quad (2-10)$$

第二个假设是特征空间对称性假设，假设一个节点同时作为源节点和邻近节点时共享一个嵌入向量，这个假设的条件概率公式如下：

$$P(n_i|f(u)) = \frac{\exp(f(n_i) \cdot f(u))}{\sum_{u \in V} \exp(f(v) \cdot f(u))} \quad (2-11)$$

综上两个假设，我们最终要优化的目标函数为：

$$\max_f \sum_{u \in V} (-\log \Phi_u + f(n_i) \cdot f(u)) \quad (2-12)$$

其中 Φ_u 表示归一化因子 $\sum_{n_i \in N_A(u)} \exp(f(n_i) \cdot f(u))$ ，但由于其计算代价高，因此利用改进的随机游走算法完成节点的采样。如果当前节点为 v ，那么通过随机游走访问下一个节点 c 的概率为：

$$P(b_i = c | b_{i-1} = v) = \begin{cases} \frac{\pi_{vc}}{\Phi} & \text{当 } (v, c) \in E \\ 0 & \text{其他} \end{cases} \quad (2-13)$$

其中 π_{vc} 表示节点 v 到节点 c 未归一化的转移概率， b_i 代表在游走过程中的第 i 个节点， Φ 被定义为归一化常数， E 指的是图中所有边的集合。在 Node2vec 中，超参数 p 和 q 被引入来控制随机游走的策略， p 表示随机游走过程中返回至前一个节点的概率，即在更微观的视角控制当前节点周围视图的发现，而 q 表示在随机游走过程中发现网络中未被发现部分的概率，即在更宏观的角度上控制比较大邻域的发现。

在进行随机游走时，需要决定下一步到哪个节点，因此我们需要计算从 v 节点开始的边 (v, c) 上的转移概率 π_{vc} ，并将未归一化的转移概率定义为：

$$\pi_{vc} = \gamma_{pq}(x, c) \cdot w_{vc} \quad (2-14)$$

其中为 w_{vc} 节点 v 和节点 x 之间边的权重， $\gamma_{pq}(x, c)$ 被定义为：

$$\gamma_{pq}(x, c) = \begin{cases} 1/p & \text{当 } d_{xc} = 0 \\ 1 & \text{当 } d_{xc} = 1 \\ 1/q & \text{当 } d_{xc} = 2 \end{cases} \quad (2-15)$$

其中 d_{xc} 表示节点 x 和节点 c 之间的最短路径。Node2vec 模型的剩余步骤和 Deepwalk 模型相同，因此不再赘述。

2.3 本章小结

本章主要介绍了序列推荐模型和深度学习相关模型的基础概念。针对本文所研究的内容，我们依次介绍了基于用户交互矩阵的推荐模型、基于用户交互序列的推荐模型、基于图的深度学习模型。其次，我们叙述了深度学习模型的发展历史和基础理论。最后针对本文涉及到的深度学习技术，我们依次梳理了卷积神经网络、门线性单元以及基于图的深度学习模型。

3 基于成对编码和门控网络的序列推荐研究

推荐算法是解决信息爆炸问题最可行的方法之一，大多传统的推荐算法更关注用户的显式行为例如评分数据，当然从评分数据中挖掘用户偏好具有较强的解释性，但这些方法都忽略了用户交互数据中的时序动态信息，即用户的行为是按照时间顺序进行的，用户在当前时间间隔中的行为和他在上一个时间段内行为密切相关。近几年利用用户的历史交互序列进行推荐变得越来越流行，本章的工作也是针对序列推荐这一分支进行研究。在序列推荐任务中，通常是从两个方面挖掘用户行为中的偏好特征：用户的长期兴趣和短期兴趣。一些经典的 Top- N 推荐方法是对用户的固有兴趣进行挖掘，例如矩阵分解模型、协同过滤模型。在另一方面，由于用户的大部分需求与时间顺序密不可分，所以挖掘用户的序列偏好有利于提升模型的推荐效果，那么如何从序列数据中捕捉用户的长期兴趣和短期兴趣成为我们重点关注的问题。

对用户序列进行建模的常见思路有两个，一是利用马尔可夫链的思想来挖掘相邻项目之间的序列关系，但是基于马尔可夫链的推荐模型在捕捉更复杂、更高阶的特征时，其性能不够强大；第二种思路是利用神经网络模型对用户的序列偏好和固有偏好进行建模，其效果优于基于马尔可夫链的推荐模型。然而，一般的神经网络方法是将序列作为一个整体来计算它对下一个项目的影响，很难收集到不同位置上项目之间的关系特征。我们还观察到用户在进行决策时可能会更加关注项目的某个方面或某个特征，即用户会对同一项目的各个方面分配不同的关注度。此外，不同项目对用户决策的影响强度呈现出多样性和动态性，而现有的序列推荐模型既没有考虑项目的某个特征对建模用户偏好的影响，也忽视了用户连续动作中特定项目的重要性。

本章工作受启发于门控卷积网络^{[63][68]}，核心目标是从用户最近交互项目所组成的序列中挖掘用户的序列偏好，并解决上述问题。我们将本章的主要贡献总结成以下三点：1) 针对序列推荐任务，我们基于成对编码模块、卷积神经网络以及门线型单元提出了一种序列推荐模型 (HPGM)，该模型可以同时捕捉用户的长期固有兴趣和短期动态偏好；2) 为了更好地提取相关特征，我们不仅将用户的历史行为序列作为整体来计算其对用户未来决策的影响，还考虑到历史交互序列中每个单独的项目和每个项目的具体特征对用户偏好的影响；3) 为了验证所提出模型的泛化能力，我们在常用的推荐数据集上进行了大量实验并与其他先进的推荐模型做出对比。此外，我们还讨论了所提出模型的重要超参数。

3.1 基于成对编码和门控网络的序列推荐框架

在本节，我们首先形式化定义所研究的序列推荐问题。其次，我们从新提出方法的架构出发深入模型的细节，分别从嵌入层、成对编码层、双层门控层以及预测层对模型展开介绍。最后阐述模型训练的相关步骤。

3.1.1 问题定义

序列推荐任务的目标是根据用户先前的顺序行为来预测用户下一步的动作，因此首先需要将用户的历史行为按照时间戳排列，且只考虑用户的隐式交互动作，例如浏览、购买、评论等等。在序列推荐任务中， U 代表系统中所有用户组成的集合， I 为所有项目组成的集合，给定用户 $u \in U$ 的行为序列 $S^u = (S_1^u, S_2^u, \dots, S_m^u)$ ，其中 $S^u \in I$ 指的是用户 u 在时间间隔 t 内产生过行为的项目， m 被定义为 $|S^u|$ 。为了方便对模型进行训练，我们从用户的历史动作序列中提取 L 个连续的项目 $(S_1^u, S_2^u, \dots, S_L^u)$ 作为模型的输入，预期的输出是来自同一序列的后续 T 个项目 $(S_{L+1}^u, S_{L+2}^u, \dots, S_{L+T}^u)$ 。本章工作所涉及到的符号及其解释见表 3-1。

表 3-1 符号定义

符号	定义/解释
U, I	用户集合，项目集合
u	用户 $u \in U$
S^u	由用户 u 的行为所组成的项目序列， $S^u \in I$
m	与用户 u 产生交互的项目序列的总长度
L, T	输入序列的长度；输出序列的长度
E_i	表示序列中第 i 个项目的嵌入向量
P_u	表示用户 u 的嵌入向量
$X^{(u,t)}$	用户 u 在时间间隔 t 内产生交互的项目所组成的输入矩阵
$T^{(u,t)}$	成对编码后的三维项目张量
W_1, W_2, W_3, W_4	模型的权重
d	潜在向量的维度
Θ	模型参数的集合
$\sigma(\cdot)$	Sigmoid 函数； $\sigma(z)=1/(1+e^{-z})$
$I(\cdot)$	Indicator 函数；当 b 为真时， $I(b)=1$

3.1.2 嵌入层

对输入数据进行嵌入（向量化）表示是深度学习中最基础的操作，其核心思想是将高维度的稀疏向量映射到低维度密集的向量空间中，方便模型做后续处理。在推荐算法中，对用户交互动作进行嵌入表示的方法可以分成两种：第一种方法先是根据输入数据的维度随机初始化嵌入向量，接着将此向量输入到模型的后续模块

中进行处理,最后利用评分矩阵分解的思想一起训练嵌入向量和模型中的参数;另一种方法是先对项目集合中所有的项目进行 one-hot 表示(当用户和某个项目产生过交互行为,那么该项目位置上的值为 1,否则为 0),再通过全连接层将高维稀疏的向量嵌入为一个低维且稠密的向量,即项目嵌入向量是由全连接层的权重所组成。

我们用 $E_i \in \mathbf{R}^d$ 表示项目序列嵌入中第 i 个项目对应的嵌入表示,其中 d 为潜在向量的维度。嵌入查找(embedding look-up)操作将检索前 L 个项的嵌入,并将它们堆叠在一起,形成用户 u 在时间间隔 t 的输入矩阵 $X^{(u,t)} \in \mathbf{R}^{L \times d}$:

$$X^{(u,t)} = \begin{bmatrix} E_{i-L} \\ \vdots \\ E_{i-2} \\ E_{i-1} \end{bmatrix} \quad (3-1)$$

其中 L 可以理解为卷积神经网络滑动窗口的大小。在对项目进行嵌入表示的同时,我们还对用户进行嵌入表示,即利用 $P_u \in \mathbf{R}^d$ 表示用户在潜在空间中的偏好特征。值得说明的是,项目序列的嵌入向量和用户嵌入向量在初始化时随机赋值,然后通过模型训练得到最终的嵌入值。

3.1.3 成对编码层




图 3-1 成对编码操作示例

为了捕捉用户行为序列中复杂的项目关系,提高模型的灵活性,我们引入成对编码层来构建序列张量 $T^{(u,t)} \in \mathbf{R}^{L \times L \times 2d}$,使得 $T^{(u,t)}$ 可以存储序列中项目之间的动态转化关系。如图 3-1 所示, $T^{(u,t)}$ 是由项目子序列中的项目对 (i, j) 组成,是将项目 i 和 j 的嵌入向量串联拼接起来组成一个能存储更多项目关系的三维向量。经过成对编码层的张量形状和基于卷积神经网络的计算机视觉模型中的“图像特征映射”类似,且 $T^{(u,t)}$ 可以代替序列项目嵌入向量 $X^{(u,t)}$ 作为下游层的输入。注意,我们用“1”

填充用户嵌入向量，并生成具有相同维数 $T^{(u,i)}$ 的用户张量 $\widehat{P}_u$ ，使其能够输入到后续模块中。

3.1.4 双层门控层

原始的门线型单元集成了卷积运算和简化的选通机制进行预测^[63]，当然也有一些研究者将门线型单元应用在推荐任务中^[68]，该推荐模型同样取得了非常出色的效果。在本章中，我们也采用了类似的想法来建模用户的交互序列。

在用户的历史交互序列中，每个项目在用户未来决策中的权重不同，例如用户在前一个时间间隔内购买了一部手机、饮料、卫生纸，那么后续时间间隔内购买手机壳、手机保护膜的可能性就会更大，因为手机和手机壳等附属物品具有绑定关系，因此在这个行为序列中，手机对用户后续决策的影响就比其他物品大，可以理解为手机的权重大于其他物品的权重。除此之外，用户会对项目的某些特征有强烈倾向或兴趣，例如特定的颜色、品牌会对用户的行为产生一定导向，因此可以从用户历史动作序列中捕捉到某一项目的特性对用户兴趣的影响。如图 3-2 所示，虚线框内的矩形组成一个项目序列，紫色表示要推荐的目标项目。在进行预测时用户会被项目的某一隐含特征所影响，即深橘色的矩形表示这些隐含特征对目标项目的影响。与此同时，用户交互序列中的某一项目对用户决策的影响也至关重要，黄色越重表示该项目对目标项目的影响越大。




图 3-2 特征级影响（左）和项目级影响（右）

不仅注意力机制可以建模上述特定项目的影响以及项目特征的影响，门线性单元也表现出了非常优秀的预测性能。门线型单元控制着在推荐下一个项目时应该重点传递什么信息，所以我们可以通过门线型单元选择项目的特征以及与未来项目相关的特定历史项目。综上，我们通过两层门控结构：特征级选通层和项目选通层捕捉用户的短期兴趣，如图 3-3 所示。




图 3-3 双层门控层示意图

用户经常会通过寻找项目本身能吸引自己的特征来决定是否与项目进行交互，例如品牌、服务、颜色等。因此在特征级选通层中，我们修改门线性单元并基于用户特征级的偏好来捕获序列转化模式。此外，为减少模型的参数，我们用内积运算替代了卷积操作，用户的特征级的兴趣偏好可以通过以下公式产生：

$$T_A^{(u,t)} = T^{(u,t)} * \sigma(W_1 \cdot T^{(u,t)} + W_2 \cdot \widehat{P}_u + b) \quad (3-2)$$

其中 $*$ 表示对应元素相乘， $\cdot$ 为内积运算， $W_1, W_2 \in \mathbb{R}^{1 \times 2d \times 2d}$ 和 $b \in \mathbb{R}^{1 \times 1 \times 2d}$ 是对应的三维权重项和偏差项。 $\sigma(\cdot)$ 指的是 sigmoid 函数。接着，通过特征级门控层的向量将被传递到网络的下一层做后续处理。

在现实生活中，用户还会对某个特定项目给予更高的关注度，例如用户经常会购买某一种食物，而现有的模型在建模用户的短期偏好时会忽略项目的重要性。门线性模块是一种能够成功捕获特定项目影响的方法，因此除特征级门控层外，我们还采用了一个项目级的门控层，此层的输出结果可表示为：

$$T_I^{(u,t)} = T_A^{(u,t)} * \sigma(W_3 \cdot T_A^{(u,t)} + W_4 \cdot \widehat{P}_u) \quad (3-3)$$

其中 $W_3 \in \mathbb{R}^{1 \times 1 \times 2d}$ ， $W_4 \in \mathbb{R}^{1 \times L \times 2d}$ 是可学习的权重参数。 $\sigma(\cdot)$ 被定义为 sigmoid 函数。通过这一层运算，与用户未来决策相关的项目对预测结果的贡献度更大，而无关的项目将被忽略。

通过对项目序列嵌入进行特征级和项目级的门控操作，我们保留下有价值的项目以及项目的具体特征，同时剔除不相关的特征和项目。最后我们在项目级门控层后的序列嵌入上应用平均池化操作对向量进行聚合降维：

$$\widehat{E}^{(u,t)} = \text{average}\{T_I^{(u,t)}\} \quad (3-4)$$

通过平均池化操作，用户的序列嵌入中的有用信息将被聚合，由此可以通过 $\widehat{E}^{(u,t)}$ 代表用户的序列动态偏好，也可以理解为用户的短期兴趣。

3.1.5 预测层

通过前面的操作计算出用户的短期兴趣后，我们引入一个隐含的用户嵌入向量 P_u 来捕捉用户的固有偏好，接着使用传统的潜在因子模型（矩阵分解）得到预测值，最终的预测值通过如下公式计算：

$$y_j^{(u,t)} = \hat{E}^{(u,t)} v_j + P_u v_j \quad (3-5)$$

其中 $y_j^{(u,t)}$ 可以被理解为用户 u 在时间间隔 t 会和项目 j 交互的概率， $y_j^{(u,t)}$ 的值越大表示用户接下来越有可能和 j 产生交互。 v_j 表示项目的嵌入向量，值得指出的是我们在预测前还采用了全连接层来降低维度。

综上，本章所提出模型的完整架构见图 3-4，一共由四个模块组成：嵌入层（Embedding layer）、成对编码层（Pair-wise encoding layer）、双层门控层（Hierarchical gating layer）和预测层（Prediction layer）。在图 3-4 中， $(S_1^u, S_2^u, \dots, S_L^u)$ 是模型的输入，它表示用户的历史行为序列， S_i^u 表示在一个时间戳内用户交互过的项目。接着这些用户交互数据被嵌入层映射至一个相同维度的向量空间中，并且得益于隐语义模型的思想，我们将用户的交互序列转化成能够表示用户长期偏好的用户嵌入向量 P_u 和包含序列信息的项目嵌入向量 $X^{(u,t)}$ ，然后一个连续的项目嵌入向量被传送到成对编码层，通过成对的编码层构建三维序列向量 $T^{(u,t)}$ ，合并后的三维向量和用户嵌入向量被传递到双层门控层 (G_A, G_I)，最后结合原始的用户嵌入向量和经过双层门控层后的序列嵌入向量来预测下一个时间间隔内用户会喜欢的项目。




图 3-4 HPGM 模型预测框架

3.1.6 模型训练

为了对模型进行训练，我们采用二元贝叶斯个性化排序损失（Binary Bayesian Personalized Ranking loss）^[6]作为目标函数：

$$L = \sum_{(u,i,j) \in D} -\ln \sigma(y_i^u - y_j^u) + \lambda_{\Theta} (\|\Theta\|^2) \quad (3-6)$$

其中 λ_{Θ} 表示正则化参数, $\sigma(x)=1/(1+e^{-x})$, $\Theta=\{X, P_u, W_1, W_2, W_3, W_4, b\}$ 为模型的参数, 通过在训练集上最小化目标函数, 可以得到相应的参数值。在训练网络时, 我们基于 PyTorch 来学习这些模型参数。 D 是训练过程中的三元组集合:

$$\{(u, i, j) | u \in U \wedge i \in I_u^+ \wedge j \in I_u^-\} \quad (3-7)$$

在每个时间间隔 t 中, 我们从每个用户的候选集中随机生成一个负项 j , 每个用户的候选集由 $\{j \in I^- | I^- = I - S^u\}$ 定义, 并运用 Adam 优化方法^[69]来优化本章的序列推荐模型。

3.2 实验设计与结果分析

为了评估所提出模型的效果, 我们在三个大规模的真实世界数据集上进行了多组对比实验, 这些数据集涵盖了不同的领域, 它们的稀疏程度也存在差异。此外, 我们使用的所有数据集以及对比模型的代码都可以在网络上获取到。

在本节中, 我们首先简单介绍了对照实验所采用的三个数据集: Amazon 数据集、MovieLens 数据集和 GoodReads 数据集, 并对数据集的处理做出说明。其次我们对实验中涉及到的七种对比模型进行介绍。接着我们引入能够评估实验效果的评价指标, 并对模型中重要的超参数进行说明。最后, 我们重点剖析了 HPGM 和对照模型表现以及超参数的影响。

3.2.1 实验数据

我们在三个真实的数据集上验证所提出模型的性能, 这些数据集在所属领域、稀疏性和平台方面差异很大:

- 1) **Amazons¹**: Amazons 数据集是一个被广泛使用在推荐研究中的公开数据集。这个数据集包含了从 1996 年 5 月至 2014 年 7 月这一时间段内亚马逊网站上的 8300 万个评分、评论以及其他一些特征, 例如项目的元数据(元数据包括用户的人口统计信息, 商品的描述信息等)和商品的视觉信息。Amazon 数据集以其高度稀疏性而著名, 它提供了一个有用的基准来评估推荐模型在稀疏数据集上的性能。在本章中, 我们选择 CDs 类别来衡量所提出模型的表现。
- 2) **MovieLens²**: 多年来, MovieLens 数据集被用来评估各种各样的推荐模型, 这个数据集是由 Minnesota 大学的 GroupLens 研究小组从 MovieLens 网站上爬取而来。MovieLens 网站允许用户对他们所看过的电影提交评分和评论, 并为用户推荐他们可能会喜欢的电影。在本章工作中, 我们使用

¹ <http://jmcauley.ucsd.edu/data/amazon/>

² <https://grouplens.org/datasets/movielens/>

MovieLens-100k 基准数据集，与 Amazon 数据集相比，这个数据集具有更大的用户密度和项目密度。

- 3) **GoodReads³**: 这个数据集是由 Mengting Wan 等人^[70]从书评网站 GoodReads.com 收集并整理而来，该数据集包含从 876145 个用户的公共书架收集的 229154523 条记录，涵盖 2360655 本书（详细的元数据包括作者、系列、版本、出版商、页数、图书内容语言、类似书籍以及用户为这些图书添加的书架名称）。该数据集记录了一个用户关于一本图书的多个交互信息，包括添加到书架的日期、阅读进度、评分分数和评论文本，从而为推荐问题提供了“搁置-阅读-评分-推荐”的一系列动作数据。在本文中，我们选择 GoodReads 数据集中的漫画类别数据来评估所提出的模型。

针对上述三个数据集，我们均遵循与现有研究相同的预处理方法^[30]：首先将星级评分转换为隐式交互数据（评过分为 1，否则为 0），并按照反馈数据对应的时间确定用户操作的顺序。此外，我们认为交互动作数量小于 5 不足以构成序列，因此我们放弃少于 5 个交互行为的用户及其项目。我们还将每个用户 u 的序列 S^u 分为三个部分：（1） S^u 中前 70% 的交互数据作为训练集。（2）紧挨着的 10% 的行为数据用于验证。（3）其余的 20% 的交互数据用作评估模型性能的测试集。预处理后相关数据集的统计信息被展示在表 3-2。

表 3-2 数据集统计信息

数据集	用户数量	项目数量	用户行为数量
Amazons CDs	17.0K	35.1K	0.47M
MovieLens	129.9K	13.6K	9.9M
GoodReads Comics	34.4K	33.1K	2.4M

3.2.2 对比方法

为了验证 HPGM 的实用性，我们在相同数据集上对比 HPGM 和其他三组推荐模型的表现，第一组是经典的推荐模型，它们只关注用户反馈本身，而忽视了用户反馈之间的序列关系。

- 1) **基于项目热度的推荐模型 (Popular Recommendation, PopRec)**: 项目的受欢迎程度（热度值）是推荐排名的重要组成部分，它可以量化成所有用户对该项目产生过行为的数量。因此我们只需使用训练集中每个项目的正向反馈数量作为项目的热度值，再根据项目的热度值从高到低进行排序，并给用户推荐高热度值的项目。
- 2) **贝叶斯个性化排序模型 (Bayesian Personalized Ranking, BPR-MF)**^[6]:

³ <https://sites.google.com/eng.ucsd.edu/ucsdbookgraph/home>

BPR-MF 是一个以用户隐式反馈为基础的成对排序模型。该模型联合矩阵分解和贝叶斯个性化排序来学习用户的隐式行为,并针对用户动作所构成的三元组进行排序优化。

下一组模型通过建模用户的历史交互序列来探索用户在序列推荐场景中的兴趣偏好,这组模型都是以马尔可夫链模型为基础,亦是解决序列推荐问题最经典的算法:

- 1) **基于因子分解的马尔可夫链模型 (Factorized Markov Chains, FMC)** [40]: 这是一种非个性化的序列推荐模型,核心思想是将一阶马尔可夫转移矩阵分解为全局序列特征,但忽略了用户的个性化交互行为。
- 2) **基于因子分解的个性化马尔可夫链 (Factorized Personalized Markov Chains, FPMC)** [40]: FPMC 结合了矩阵分解和因子分解马尔可夫链来构建模型,在此基础上将三维的用户序列反馈张量因子化,使得模型能够同时捕捉到序列中项目之间的转换模式和用户的全局偏好。

最后一组模型考虑到用户历史访问过的项目,并将其按照时间顺序构造成项目序列,再通过深度学习技术对序列进行建模。

- 1) **卷积序列嵌入模型 (Convolutional Sequence Embeddings, Caser)** [30]: Caser 是基于卷积神经网络的序列推荐模型,核心思想是对长度为 L 的项目序列嵌入矩阵进行水平和垂直的卷积运算,以此捕获高阶的序列特征,与此同时融合用户的潜在嵌入向量提取用户的固有偏好。这使得算法能够同时学习用户的固有兴趣和序列动态特征,从而达到更优秀的推荐效果。
- 2) **基于门循环单元的推荐模型 (GRU4Rec)** [71]: 该模型是将门控循环单元引入到基于会话的推荐 (session-based recommendation) 任务中,它将用户的历史交互序列看作是一个会话,并通过 RNN 对用户和项目组成的交互序列进行建模,以此挖掘用户的序列偏好。
- 3) **基于门循环单元的推荐模型 (GRU4Rec+)** [72]: GRU4Rec+是在 GRU4Rec 基础上通过应用不同的损失函数和采样策略扩展而来,同样得到了出色的序列推荐结果。

3.2.3 评价指标

为了衡量序列推荐模型的效果,我们使用了两种被广泛使用的 Top- N 评估指标: 归一化折损累计增益 (Normalized Discounted Cumulative Gain, NDCG@ N) 和 Recall@ N , 并以此衡量所有模型对前 N 项进行排序的性能,较大的指标值意味着更好的模型表现。NDCG@ N 是一种位置感知的排序指标,可以为排序列表中排名靠前的项目分配更高的分数。Recall@ N 通过计算命中真值的次数在前 N 项中所占

的比例来评估 Top- N 推荐效果。给定用户预期的项目排序列表，Recall@ N 和 NDCG@ N 定义如下：

$$\text{Recall@}N = \frac{\sum_{c=1}^N I(u, i_c)}{\min(N, |y_u^{\text{test}}|)} \quad (3-8)$$

$$\text{DCG@}N = \sum_{c=1}^N \frac{2^{I(u, i_c)} - 1}{\log_2(c+1)} \quad (3-9)$$

$$\text{NDCG@}N = \frac{\text{DCG@}N}{\text{IDCG@}N} \quad (3-10)$$

其中， $I(\cdot)$ 被定义为指标函数，当第 i 个项目在原始数据集的 Top- N 排序列表中排名为 c 时返回 1，否则返回 0。 c 表示该项目在排序列表中的位置， y_u^{test} 指的是与用户 u 产生过交互的项目数量，分母IDCG@ N 是理想排序中DCG的最大值。

3.2.4 参数设置

在进行模型构建时需要确定关键的超参数，分别是潜在嵌入向量的维度 d 、训练的批量大小、模型的学习率、边际值 λ_Θ 、马尔可夫阶数 L 以及预测项目的数量 T 。潜在维度 d 的取值范围为 $\{10, 20, 30, 40, 50\}$ ，模型的学习率在 $\{0.001, 0.005, 0.01, 0.02, 0.05\}$ 中进行调整，我们还从 $\{16, 32, 64, 128, 256\}$ 中得出最合适的批量大小，并在 $\{0.001, 0.005, 0.01, 0.02\}$ 设置相应的边际值。通过在验证集上对以上超参数进行调整，我们得到了最优的取值：学习率被设定为 0.001，嵌入向量的潜在维度 $d=5$ ， $\lambda_\Theta=0.001$ ，训练批次大小为 256。此外，马尔可夫阶数 L 被设置为 5，预测项目的个数 $T=3$ 。实验中其他对照算法的超参数取值我们均遵循原文中的设定。

3.2.5 模型表现对比

表 3-3、3-4、3-5 和图 3-5、3-6 展示了本章研究的模型（HPGM）和其他七种对照模型在三个数据集上的表现。此外，表中的最佳结果以粗体突出显示(指标值越高表示效果越好)，我们将对照模型的最佳表现和我们的方法进行对比得到了相应的提升值。所有的实验结果清楚地表明 HPGM 在序列推荐任务中的优势，且所有取值 N 在召回率和 NDCG 这两个评价指标上都取得了不错的结果。我们还可以从对比实验中得到以下观察结果：

首先基于贝叶斯个性化排序的推荐算法（BPR-MF）的性能优于基于流行度的推荐模型（PopRec），但不如基于马尔可夫链的因子分解推荐模型（FMC），这说明在序列推荐场景下，局部相邻的序列信息起着至关重要的作用。与传统的基于评

分的推荐算法相比，项目与项目之间的序列关系对理解用户的历史反馈是非常必要的。此外，实验结果表明，我们提出的模型 HPGM 在真实数据集上能够有效地捕捉项目关系、序列动态以及用户的长期偏好。

另一个观察结果是，基于神经网络的序列推荐方法 GRU4Rec 和 Caser 比传统的基于马尔可夫链的序列推荐模型(如 FPMC)的预测效果更好，可以看出，神经网络适合对用户历史反馈与未来行为之间的复杂转换进行建模。但对比模型的局限性导致其性能弱于 HPGM，例如 Caser 是基于卷积神经网络的序列推荐模型，通过水平和垂直滤波器来捕捉用户的兴趣，但是该模型仅考虑了组级别的影响，即只计算了整个序列对用户兴趣的作用，而忽略了用户历史序列中特定项目以及项目的具体特征对用户偏好的影响，而我们的模型通过两个门线性单元来捕捉这些影响，从而达到了更好的效果。值得补充的是，我们的方法在稀疏数据集和密集数据集上的性能与对照模型相比有过之而无不及，这表明 HPGM 能够在不同数据集上自适应地捕获复杂的序列转化模式。

综上所述，我们的方法在各个数据集上都优于对照模型，并在挖掘项目关系、序列动态捕捉和用户全局（长期）偏好建模方面表现较好。




图 3-5 HPGM 和对照模型在 GoodReads-Comics 上的排序效果




图 3-6 HPGM 和对照模型在 Amazons-CDs 上的排序效果

表 3-3 Amazon-CDs 数据集上的 Top-N 推荐结果

模型	Recall@10	NDCG@10
PopRec	0.0181	0.0095
BPR-MF	0.0233	0.0145
FMC	0.0240	0.0149
FPMC	0.0245	0.0151
GRU4Rec	0.0302	0.0164
GRU4Rec+	0.0336	0.0171
Caser	0.0297	0.0163
HPGM	0.0347	0.0181
提高(%)	3.36	6.08

表 3-4 MovieLens 数据集上的 Top-N 推荐结果

模型	Recall@10	NDCG@10
PopRec	0.0560	0.0487
BPR-MF	0.0774	0.0685
FMC	0.0819	0.0724
FPMC	0.0847	0.0751
GRU4Rec	0.0924	0.0815
GRU4Rec+	0.1004	0.0946
Caser	0.1139	0.1016
HPGM	0.1150	0.1087
提高(%)	0.97	7.01

表 3-5 GoodReads-Comics 数据集上的 Top-N 推荐结果

模型	Recall@10	NDCG@10
PopRec	0.0426	0.0503
BPR-MF	0.0688	0.0613
FMC	0.0745	0.0778
FPMC	0.0813	0.0833
GRU4Rec	0.0958	0.0912
GRU4Rec+	0.1088	0.1128
Caser	0.1273	0.1329
HPGM	0.1320	0.1430
提高(%)	3.67	7.56

3.2.6 超参数对模型性能的影响

在本小节中，我们分析了两个关键超参数对模型效果的影响：嵌入向量的潜在维度 d 和连续项的长度 L 。我们仅探讨 d 和 L 在 Amazon 数据集和 GoodReads 数据集上对模型性能的影响，并且在 MovieLens 数据集上，这两个超参数对模型效果的影响趋势相同。图 3-7, 3-8 展示了本模型的超参数之一：嵌入向量的潜在维度 d 对评价指标 NDCG@10 和 Recall@10 大小的影响，维度 d 的取值从 10 到 50，其他最优超参数保持不变，从图中可以得出，我们的模型通常受益于更大维度的项目嵌入向量，较小维度的潜在向量无法完全表示其潜在特征，并且随着 d 的增加，能够表示的信息量增加，使得该模型可以在实际数据集上实现更好的性能。




图 3-7 嵌入向量的潜在维度 d 对模型性能的影响 (Amazon-CDs)




图 3-8 嵌入向量的潜在维度 d 对模型性能的影响 (GoodReads-Comics)

先前的实验可以证明，挖掘用户历史交互行为中的序列关系对建模用户的偏好至关重要，因此序列的长度也是决定模型表现的重要因素。我们研究了连续项的不同长度 L 对模型的影响，其他参数同样固定不变。图 3-9, 3-10 显示该模型不能始终受益于 L 的增加，较大的 L 可能致使较差的结果，因为较大的 L 可能会引入更多的噪音。在大部分情况下， $L = 5$ 可以在两个实验数据集上取得最突出的结果。




图 3-9 连续项长度 L 对模型性能的影响 (Amazon-CDs)




图 3-10 连续项长度 L 对模型性能的影响 (GoodReads-Comics)

3.3 本章小结

在本章，我们提出了一种基于成对编码和门控机制的序列推荐模型，它可以提取用户历史行为序列中的深层转化特征，同时能对用户的短期决策偏好进行有效建模，此外，我们学习个性化的用户嵌入向量来捕捉用户的长期偏好，并将其融合到模型中得到最终的预测结果。从另一个角度来说，我们是从用户的连续行为中学习个性化的用户表示向量和项目表示向量，并融合用户的固有偏好特征和短期兴趣特征计算出推荐排名。为了评估所提出模型的效果，我们在三个推荐数据集上做了多组对比实验，实验结果表明，我们的模型不仅显著优于经典的评分推荐模型以及基于马尔可夫链的序列推荐模型，而且优于先进的基于神经网络的序列推荐模型。

本章所提出方法的重点是从时序的角度建模用户的短期兴趣，并未把用户的社交网络纳入考虑。用户的社交关系会影响用户的决策，如果两个用户之间存在社交连接，那么他们兴趣偏好相同的可能性会更大。此外，引入用户的社交关系有助于化解推荐系统中的冷启动问题。因此我们将在第 4 章中引入用户的社交特征，使得推荐模型在冷启动的场景下，其效果同时受益于用户的序列交互行为和用户的社交关系。

4 基于社交网络的序列推荐研究

推荐算法是信息检索领域中的一项重要研究内容，并且在实际应用中扮演着至关重要的角色，例如电子商务、音视频播放、新闻阅读以及广告推荐等等。推荐算法可以提供千人千面的服务，这能满足用户在特定场景下的需求，与此同时帮助平台实现商业化目标，比如向用户推荐符合其偏好的广告并引导其完成后续转化，平台从中收取广告主的佣金。用户的人口统计信息、行为数据、社交信息以及项目的描述信息越多意味着推荐结果越准确，但现实世界中可能会缺失这些数据记录，如何有效地从稀疏的数据集中挖掘用户兴趣是一项挑战性很大的工作。此外，冷启动问题是推荐算法研究中不可规避的难题，最常见的解决方案是从用户的社交网络中挖掘用户的偏好，并假设用户下一步的决策会受其朋友的影响，因为他们可能有相似的兴趣。

在本章，我们继续研究另一个更具挑战的序列推荐预测任务：基于社交关系和用户行为序列的冷启动推荐。我们要解决的问题可以描述为：在冷启动的场景中，给定用户的历史行为序列的和社交网络，预测用户在下一个时间间隔内会进行的动作。传统的序列推荐算法是通过马尔可夫链建模用户的序列偏好，但在用户数量和项目数量较少的情况下，这些模型的性能较差。一些研究者在马尔可夫链模型的基础上结合用户的社交信息和序列信号来处理序列推荐中的冷启动问题。还有一些方法是对用户先前的行为序列进行嵌入表示，再运用深度学习方法预测用户的下一步动作。这些基于深度学习的序列推荐模型的性能优于传统的序列推荐模型，但在项目和用户观测值太少的情况下，它们无法改善预测结果，另外这些模型也很少从额外的上下文信息中挖掘用户的兴趣。

本章研究内容与社交推荐算法的最大区别在于：我们的方法在挖掘用户历史交互中的序列偏好的同时，还建模了用户社交关系对用户下一步决策的影响，这使得我们提出的模型不仅能捕捉用户行为中的序列特征，还能有效提取用户的社交特征。此外，通过结合这两种不同的特征还可以帮助我们解决推荐系统中的冷启动问题。

在本章中我们提出了一个基于用户社交关系的序列推荐模型 SASE。在该算法中，我们同样通过卷积神经网络（Convolutional Neural Network, CNN）来提取用户行为序列中的动态转化特征，同时使用一种网络嵌入模型（Node2vec）来建模用户的社交关系。在 4.1 节，我们对本章所研究的问题进行形式化定义，并从用户序列行为和社交网络两个部分介绍相应的处理方法，最后引入完整的推荐模型。在 4.2 节中，我们依次对实验所采用的数据集、对照模型以及实验设置进行介绍，其次将

我们的模型与其他推荐方法进行比较，实验结果证实了本章新提出算法可以有效作用在冷启动场景下。

4.1 基于社交网络的序列推荐模型

在本节，首先我们对序列推荐以及用户的社交网络进行形式化定义。接着，我们分别介绍预测模型是如何作用于用户的历史行为序列和用户的社交网络。最后，我们阐述完整的模型架构。

4.1.1 问题定义

序列推荐任务基于用户反馈产生的时间顺序，其主要目标是从用户的历史交互动作中挖掘用户的固有偏好以及与时序相关的短期偏好，并以此为用户进行推荐预测。因此首先需要将用户的历史交互数据按照时间顺序依次排列，此外，相对于用户的显示反馈数据，用户的隐式行为数据更加稠密，所以我们能从中挖掘出更加丰富的用户偏好特征。总之我们仅考虑用户的隐性交互行为，也就是只把用户的购买、点击等隐式行为作为正反馈而忽略用户评分等显性数据。

除了用户的历史行为序列是预测用户偏好的决定性因子之外，用户的下一步决策也会受其社交网络的影响，因此在预测时将用户的社交网络纳入考虑是合理的。推荐系统中的冷启动问题是阻碍推荐性能的重要因素之一，当用户数据和项目数据太稀疏而无法单独建模时，通过合理地融合用户的社交网络和序列行为数据可以提升推荐效果。如图 4-1 所示，我们可以通过同时建模用户和他们的朋友的序列动作来预测用户的下一个动作，例如图中用户 A 在下一时间段内的行为会同时受来自于 A 本身的喜好(服饰)、B 最近的购买行为(帽子、裤子等)以及 B 的朋友 C 近期消费物品（眼镜）的影响。因此本章要处理的任务是：在稀疏数据集和冷启动场景下，给定用户的行为序列数据和社交网络数据，预测用户接下来的动作。




图 4-1 问题定义

首先我们用 U 和 I 分别代表数据集中的用户集合和项目集合, 用户 $u \in U$ 的历史交互序列用 $S^u = (S_1^u, S_2^u, \dots, S_m^u)$ 表示, 其中 S^u 被定义为用户 u 在时间间隔 t 中产生过交互的项目, m 为序列的长度 $|S^u|$, 我们的目的是预测下一个符合用户偏好的项目。和上一章节相同, 为了方便对模型进行训练, 我们从用户的历史行为序列中提取 L 个连续的项目 $(S_1^u, S_2^u, \dots, S_L^u)$ 作为模型的输入, 而我们预期的输出是同一序列中紧挨着输入项目的 T 个项目 $(S_{L+1}^u, S_{L+2}^u, \dots, S_{L+T}^u)$ 。

接着我们对用户的社交关系数据进行定义, $G = (V, E')$ 被定义为用户的社交关系图, 用来存储用户和用户之间的社交连接。其中 $V = U$ 是社交关系图上的节点, 是由数据集中的全部用户构成, $E' \in V \times V$ 被定义为社交关系图的边, 指的是用户 u 和用户 v 之间有社交连接(即用户 u 和 v 是朋友关系)。本章所涉及到的符号及其解释如表 4-1 所示。

表 4-1 符号定义

符号	定义/解释
U, I	用户集合, 项目集合
u	用户 $u \in U$
S^u	由用户 u 的行为所组成的项目序列, $S^u \in I$
m	与用户 u 产生交互的项目序列的总长度
L, T	输入序列的长度; 输出序列的长度
X_i	表示序列中第 i 个项目的嵌入向量
$E^{(u,t)}$	用户 u 在时间间隔 t 内产生交互的项目所组成的输入矩阵
l	滤波器的数量
h	滤波器的高度
W^k, W'	模型的权重
b, b'	模型的偏置值
d, d'	潜在向量的维度
G	用户的社交关系图
F_u	用户的社交特征向量
$\sigma(\cdot)$	Sigmoid 函数: $\sigma(z)=1/(1+e^{-z})$
$I(\cdot)$	Indicator 函数: 当 b 为真时, $I(b)=1$

4.1.2 用户行为的时序特征挖掘

由于用户的历史交互数据非常稀疏, 而深度学习模型的结构特征限制了其对稀疏向量的处理, 因而第一步需要通过嵌入操作对用户行为数据进行向量化表示, 以完成高维稀疏向量到低维密集向量的映射转化。

我们利用向量嵌入层把用户的历史交互数据转化成相应的项目嵌入矩阵 $X_I \in \mathbb{R}^{m \times d}$, 其中 d 表示潜在嵌入向量的维度。 $X_i \in \mathbb{R}^d$ 被定义为 X_I 中第 i 行的元素。因此对于每个用户 u 在时间间隔 t 中, 我们都可以通过嵌入查找(embedding look-

up) 操作在项目嵌入矩阵 X_I 中检索前 L 个项目的嵌入向量 $(X_{i-L}, \dots, X_{i-1})$, 并将它们堆叠在一起得到序列嵌入矩阵 $E^{(u,t)} \in \mathbb{R}^{L \times d}$:

$$E^{(u,t)} = \begin{bmatrix} X_{i-L} \\ \vdots \\ X_{i-2} \\ X_{i-1} \end{bmatrix} \quad (4-1)$$

其中 L 可以理解为滑动窗口的大小。对项目序列进行嵌入表示的方法和上一章节相同, 即在初始化时对项目序列嵌入随机赋值, 再通过模型训练得到最终的嵌入向量。




图 4-2 序列卷积操作示意图

受自然语言处理任务中语句嵌入模型的启发^[73], 我们利用卷积神经网络来捕捉用户历史序列中的局部特征。如图 4-2 所示, 我们将先前的序列嵌入矩阵 $E^{(u,t)}$ 视为潜在空间中 L 个项目组成的“图像”, 然后通过滑动不同高度的卷积滤波器搜索该“图像”的局部特征, “图像”的局部特征也就是我们要提取的序列特征。总之我们利用卷积操作捕捉用户历史交互中的序列转化特征, 然而与图像识别不同的是, 该“图像”没有在输入中给出, 而是需要先随机初始化, 再由所有滤波器同时学习得到。因此我们首先利用 l 个不同高度的滤波器 $W^k \in \mathbb{R}^{h \times d}$ 进行卷积运算, 在不考虑位置的情况下有效捕捉序列转化特征, 其中 $h \in [1, L]$, 滤波器移动的步长固定为 1。因此每层的变换定义为:

$$c_i = f(E_{i:i+h-1} * W^k + b^k) \quad (4-2)$$

其中 $f(\cdot)$ 被定义为该层的激活函数, 在此我们使用线型整流单元 (ReLU) 激活函数。* 被定义为卷积操作, b^k 是偏差项。同时, $E_{i:i+h-1}$ 是指用户历史序列中由项目 $(E_i, E_{i+1}, \dots, E_{i+h-1})$ 组成的项目子矩阵, 用户行为序列中每个可能大小的子矩阵都会通过滤波器得到最终的卷积结果:

$$\mathbf{c} = [c_1^k, c_2^k, \dots, c_{L-h+1}^k] \quad (4-3)$$

然后我们在最终的卷积结果 $\mathbf{c}$ 上应用最大池化操作提取更为显著的特征, 某个特定的卷积结果经过最大池化操作可以表示为:

$$\mathbf{e} = \max\{\mathbf{c}\} \quad (4-4)$$

所提出的方法能在不同大小的序列子矩阵上利用多个滤波器获得多个时序转化特征, 通过应用不同尺寸的滤波器可以提取更为重要的序列模式, 而忽略不重要的特征。因此我们在该层中使用 k 个滤波器得到的输出结果为:

$$\hat{\mathbf{e}} = \{\mathbf{e}^{(1)}, \mathbf{e}^{(2)}, \dots, \mathbf{e}^{(k)}\} \quad (4-5)$$

4.1.3 用户的社交特征嵌入

由于用户在进行下一步决策时, 会受到社交兴趣和从众心理的影响, 所以我们可以挖掘用户的社交网络优化推荐模型。此外, 用户的社交关系作为重要的上下文信息可以有效解决推荐系统中的冷启动问题, 即面对一个新用户, 我们可以把他/她朋友的兴趣偏好作为依据进行推荐, 因此我们希望通过学习用户的社交特征进一步捕捉社交关系对用户下一步决策的影响。

在本章中, 我们使用 Node2vec^[66] 对用户的社交网络进行表示, 以便将用户节点之间的关系编码成低维向量, 并以此学习用户的社交嵌入向量, 具体步骤见下图 4-3。Node2vec 的核心思想是通过图中节点之间的共现关系来学习当前节点的向量表示, 具体的步骤可以分为以下两个部分: 随机游走和 Skip-gram 神经网络。首先选择某一特定的用户节点作为随机游走的起始节点, 再通过随机游走策略获取足够数量的节点访问序列, 接着利用 Skip-gram 神经网络模型学习相应的模型参数, 最后再把训练得到的权重作为图中离散节点的向量化表示, 两个向量之间的距离表示图中两个节点的邻近点的数量, 邻近点越多向量距离越短。




图 4-3 Node2vec 模型架构图

在随机游走途中，我们定义了两个新的超参数 p 和 q ，这两个参数可以使随机游走的结果在深度优先搜索和广度优先搜索中达到平衡，因此最终的嵌入向量能够同时考虑到社交网络的局部信息和全局信息，这让我们的方法不仅学习到更多信息，同时也提高了模型的适应性。

在进行随机游走时，需要决定下一步到哪个节点，所以我们需要计算从 $v \in V$ 节点开始的边 (v, c) 上的转移概率 π_{vc} ，并将未归一化的转移概率定义为：

$$\pi_{vc} = \gamma_{pq}(x, c) \cdot w_{vc} \quad (4-6)$$

其中 w_{vc} 为节点 v 和节点 x 之间边的权重， $\gamma_{pq}(x, c)$ 被定义为：

$$\gamma_{pq}(x, c) = \begin{cases} 1/p & \text{当 } d_{xc} = 0 \\ 1 & \text{当 } d_{xc} = 1 \\ 1/q & \text{当 } d_{xc} = 2 \end{cases} \quad (4-7)$$

其中 d_{xc} 表示节点 x 和节点 c 之间的最短路径。

其次我们通过仅包含一层隐含层的神经网络 Skip-gram 模型预测用户社交关系图中相邻的节点，Skip-gram 神经网络的隐含层没有激活函数，输出层的维度和输入层相同，并在输出层引入了 softmax 函数，最终，Skip-gram 神经网络的权重就是我们学习到的社交嵌入向量。

通过上述操作，我们学习到 d' 维的特征 F_u ， F_u 表示用户兴趣受图 G 中朋友的影响程度。最后，我们将预先训练好 F_u 输入到后续网络中进行预测。

4.1.4 基于社交网络的序列推荐框架

为了同时捕获用户历史序列中的时序关系和用户的社交特征，我们将序列卷积模块的输出 $\hat{e}$ 和用户的社交网络嵌入 F_u 拼接起来组成完整的特征向量，并将其输入到下游预测层中，其中 $\oplus$ 表示级联操作：

$$O = \hat{e} \oplus F_u \quad (4-8)$$

本章工作的目标是在给定最近的项目序列 $(S_1^u, S_2^u, \dots, S_L^u)$ 和用户的社交网络，预测后续的项目 $(S_{L+1}^u, S_{L+2}^u, \dots, S_{L+T}^u)$ ，因此我们将级连后的向量 O 输入到全连接层以得到更高阶更抽象的特征，并且还可以通过全连接层降低特征向量的维度，最终的预测结果可以表示为：

$$y_i^{(u,t)} = \sigma(W'O_u + b') \quad (4-9)$$

其中 W' 和 b' 是可学习的权重参数和偏差值， $\sigma(\cdot)$ 是 sigmoid 函数，被定义为 $\sigma(x) = 1/(1+e^{-x})$ ， $y_i^{(u,t)}$ 可以解释为给定用户 u 在时间区间 t 中的交互项，下一个交互项目是 i 的可能性。 $y_i^{(u,t)}$ 的值越大，表明用户 u 接下来更倾向于与项目 i 产生交互。

此外，为了捕捉用户的长期偏好，我们考虑在全连接层之前插入用户嵌入，但是通过实验我们发现引入用户嵌入并不能提高模型的性能（可能是所提出的模型受到了冷启动设定的影响）。




图 4-4 SASE 模型架构图

本章所提出模型的架构见图 4-4。模型主要分为两个部分：从用户的历史交互序列中建模用户的序列偏好特征，从用户的社交关系图中提取用户的社交特征，接着通过级联操作把这两种特征向量聚合起来，再将其输入到全连接层进行降维，最后利用预测层获得最终的推荐结果。其中紫色的虚线表示滑动窗口，用户行为序列中的历史交互动作和目标动作分别用黄色正方形和灰色正方形表示。红色圆圈和绿色圆圈指的是运用各种滤波器（ $h=2,3$ ）得到的卷积结果，带有圆圈的矩形框表示对嵌入向量进行级联操作（Concat）。

最后我们对所提出的模型进行训练，在此采用交叉熵损失作为目标函数，具体定义如下：

$$L = - \sum_{(i,j) \in S^u} y_j^{(u,t)} \log(y_i^{(u,t)}) \quad (4-10)$$

在本章中我们利用 Adam（Adaptive moment estimation）优化器来优化所提出的模型，该方法是随机梯度下降（SGD）的一个变种，可以快速收敛。为了避免过拟合、控制模型的时间复杂度，我们还在全连接层上采用了下降率为 0.5 的 Dropout 方法^[74]。

4.2 实验设计与结果分析

我们首先介绍本章所使用的推荐数据集，并对数据集的处理方式做出说明。其次，我们梳理了实验中所采用的对照模型和评价指标。我们还阐述了如何设置模型

的超参数。最后，我们从多个角度分析了模型在不同条件下的表现，并对社交嵌入向量的维度 d' 大小和“滑动窗口”的尺寸 L 进行了讨论。

4.2.1 实验数据

为了评估所提出模型的有效性，我们在三个包含大量用户反馈、时间戳以及用户社交关系的真实数据集上进行了实验。

- 1) **Epinions⁴**: 这个数据集是研究者^[29]从 Epinions.com 上爬取整理而来，其中包括从 2001 年年初到 2013 年年底这一时间段内用户对物品的评论，时间戳以及用户的社交信息。Epinions.com 是一个顾客在线点评网站，用户可以在该网站上浏览信息并对物品作出点评，类似国内的大众点评 APP。
- 2) **Ciao⁴**: Ciao 数据集来自 Ciao.co.uk 在线网站，它是位于欧洲的在线购物平台，用户也可以对购买的商品进行评论^[75]。该数据集同样包括用户评分反馈，用户的社交关系和时间信息等。
- 3) **Flixster⁵**: Flixster 是一个关于电影的网站，主要帮助用户发现符合其偏好的电影，并为用户提供分享评论的渠道。由于 Flixster 数据集包括用户评分，社交信息和时间信息，所以该数据集也符合我们实验的需求。

在序列推荐任务中，我们仅把用户隐式行为（购买、点击）考虑在内，而不考虑用户评级的影响，因此我们将所有观察到的显示交互行为（例如：评分、评价）转化为正实例，实验的最终结果是排序后的推荐列表。我们采用与先前研究中类似的评估方式，首先选择每个用户最近的两个动作来构造验证集和测试集，一个用于验证，另一个用于测试，其余的数据用于训练。数据集统计如表 4-2 所示。

表 4-2 数据集统计信息

数据集	用户数量	项目数量	行为数量	社交关系数量
Epinions	5,261	25,996	46,732	23,915
Ciao	1,708	16,485	34,494	35,753
Flixster	60,692	48,549	7956,727	840,141

4.2.2 评价指标

AUC（ROC 曲线下面积）是评价分类模型有效性的重要指标之一，它也可以对推荐模型的性能进行评估。我们的任务是给定的用户历史行为序列，预测用户将与哪些项目进行交互，这意味着所提出的模型需要将基本事实（ground-truth）项目排在其他项目前面。因此，对于留出（held-out）的用户行为，一个合理的评估方

⁴ <https://www.cse.msu.edu/~tangjili/trust.html>

⁵ <https://www.cs.ubc.ca/~jamalim/datasets/>

法是计算每个用户的基本事实项排名。综上所述，我们使用的 AUC 来评估测试集上所有方法的性能，这个指标可以被表示成如下公式：

$$AUC = \frac{1}{|U|} \sum_{u \in U} \frac{1}{|I \setminus S^u|} \sum_{i \in I \setminus S^u} I(y_{j,l}^{(u,t)} > y_{i,l}^{(u,t)}) \quad (4-11)$$

其中 j 代表用户 u 在最近的时间间隔 t 内的基本事实项。 l 指的是用户反馈历史中在测试项目之前的项目。 $I(\cdot)$ 被定义为指示函数，如果基本事实项 j 排在未观测项 i 之前，则返回 1，否则返回 0。

4.2.3 对比方法

为了验证推荐方法的可行性和实用性，我们使用了 4 种对照模型，下面是这些模型的简要介绍：

- 1) 基于因子分解的个性化马尔可夫链 (FPMC) [40]：FPMC 模型由 Rendle 等人提出。主要的思想是将矩阵分解和因子分解马尔可夫链结合起来作为推荐因子，使得模型既能捕捉用户的长期偏好，又能获得项目之间的连续性特征。
- 2) 基于社交的个性化马尔可夫链 (SPMC) [24]：SPMC 模型假设用户的下一步行动受用户近期反馈序列以及朋友偏好的影响，并充分挖掘了用户社交网络中的社交特征和用户历史动作中的序列转化特征。
- 3) 贝叶斯个性化排名 (BPR-MF) [6]：BPR-MF 是 Rendle 等人提出的经典推荐模型，该模型从隐含的两两反馈中建模用户的个性化行为。在对比实验中，我们使用有偏置的矩阵因子分解作为推荐器。
- 4) 基于社交的贝叶斯个性化排名 (SBPR) [29]：SBPR 是一种最先进的社交推荐模型，该模型假设用户倾向于与朋友喜欢的项目进行交互，SBPR 主要是对用户的社交关系进行建模，并以此进行推荐预测。

以上所有比较方法均在训练集上进行训练，并通过验证集调整最优超参数，最后将训练好的模型作用在测试集上得到最终的预测结果。我们将所提出的模型 SASE 和上述模型进行对比实验，证明了 SASE 的性能优于 (1) 传统的矩阵分解模型 (BPR-MF) (2) 对用户固有偏好和序列动态进行建模但没有考虑用户社交特征的方法 (FPMC) (3) 关注社交信息对用户决策的影响但忽略用户序列动态的模型 (SBPR)。

4.2.4 参数设置

为了公平起见,所有模型中序列嵌入向量的维度 d 都是相同的,因为这些数据集非常稀疏,更大的维度不会对比较方法产生显著的改进,所以我们按照经验把潜在向量的维度统一设置为 64。为了使模型表现出最佳效果,我们使用不同的学习速率 α ,并从以下的取值范围 $\alpha=\{0.001, 0.005, 0.01, 0.02, 0.05\}$ 中进行实验,我们还从 $\{16, 32, 64, 128, 256\}$ 中得出最适合的批量大小。社交向量的潜在维度 d' 的取值包括 $\{10, 25, 50, 75, 100\}$, 滑动窗口的大小 L 在 $\{4, 5, 6, 7, 8, 9\}$ 中调整。通过实验我们得到了这些超参数的最佳取值:学习率为 0.001, 批量大小设置成 256, 社交向量的潜在维度为 75, 滑动窗口的大小为 4。其余对照模型的超参数设置和初始化方法我们均遵循原文。

4.2.5 模型表现对比

冷启动是推荐系统中无法避免的情景,而本章工作围绕着冷启动问题展开。为此,我们在三个推荐数据集的基础上引入一个阈值 N 来得到一系列冷启动数据集, N 被定义为每个用户可以在其反馈历史中保留最多的项目数量。首先我们忽略交互行为少于 4 个的用户,因为对于一个用户,至少需要 4 个交互项目才可以在训练集中组成一个序列。如果用户 u 的交互数量超过了原始数据集中的阈值 N ,则只保留最近的 N 个实例。

表 4-3 Epinions 数据集上各模型的表现对比

模型	阈值		
	5	10	15
FPMC	0.503011	0.519503	0.527076
BPR-MF	0.514541	0.532994	0.545447
SBPR	0.525640	0.526204	0.538011
SPMC	<u>0.595317</u>	<u>0.589500</u>	<u>0.580287</u>
SASE	0.640591	0.649204	0.640234
提高(%)	7.6	10.1	10.3

表 4-4 Ciao 数据集上各模型的表现对比

模型	阈值		
	5	10	15
FPMC	0.491940	0.551231	0.569248
BPR-MF	0.504614	0.576186	<u>0.610123</u>
SBPR	0.509185	0.548679	0.562466
SPMC	<u>0.593383</u>	<u>0.588934</u>	0.591176
SASE	0.687785	0.688069	0.683316
提高(%)	15.9	16.8	11.9

表 4-5 Flixster 数据集上各模型的表现对比

模型	阈值	
	5	10
FPMC	0.887483	0.927250
BPR-MF	0.898370	0.929493
SBPR	0.894095	<u>0.939176</u>
SPMC	<u>0.900146</u>	0.939046
SASE	0.945161	0.944662
提高(%)	5.0	0.5

我们的模型和对照模型在冷启动数据集上的平均 AUC 展现在表 4-2、4-3、4-4 中,在表中我们还总结了所提出方法 SASE 相对于最佳基线模型(每行用下划线突出显示)的提升效果。通过分析 SASE 和其他对照模型在不同阈值 N 下的实验结果,我们能够得到以下结论:

我们的模型在冷启动设定下优于其他方法。SASE 的性能优于最先进的序列模型 FPMC 和基于社交网络的序列模型 SPMC,这意味着项目的时序信息和用户的社交关系在冷启动场景中起着举足轻重的作用,因此有必要对这些信号进行充分挖掘。阈值 N 越大意味着数据集中的序列信息越丰富,所以我们还得出另外一个结论:我们的模型不仅在冷启动的场景中优于其他的对照模型,在非冷启动数据集上也表现不错,这表明我们的方法能够有效作用在稀疏数据集上。此外,实验结果还证实,相较于基于马尔科夫链的传统推荐模型,利用神经网络框架(例如卷积神经网络)对用户的行为序列和社交网络进行建模可以极大地提高模型的性能。实验中我们采用了不同稀疏程度的数据集,从实验结果可以看出,我们的方法可以作用在不同信息量的数据集上,并能够自适应提取特征。

在接下来的实验中,我们讨论了社交嵌入向量的潜在维数 d' 和滑动窗口 L 对模型性能的影响。

4.2.6 超参数对模型性能的影响

由于我们已经在前面的工作中讨论过序列嵌入维度对模型性能的影响,因此我们不再赘述。在本章的实验中,阈值 N 设置为 5。我们通过计算所提出模型的 AUC 讨论社交向量维度 d' 会对模型性能造成何种影响,在此仅调整 d' 的取值,其他最优超参数固定不变。如图 4-3 所示,当 d' 为 75 左右时,它在所有数据集上的结果都是最好的。在另一方面我们还可以看到,虽然我们模型性能得益于更大维度的潜在向量,但过大的维度($d' > 75$)对 SASE 的性能影响不大,因为如果 d' 大于 75,引入的噪音会使模型效果变差。此外,向量维度越小模型表现越差,因为维度小的向量并不能充分囊括用户的社交特征。




图 4-3 社交向量维度 d' 的影响

接下来我们讨论“滑动窗口”尺寸 L 的影响，主要是探讨当模型中的其他最佳超参数保持不变时，SASE 能从用户交互序列中获得多少高阶特征。




图 4-4 滑动窗口 L 的影响

因为在进行冷启动数据集构造时我们忽略了用户反馈少于 4 个的实例，并且所使用的数据集是高度稀疏的，所以我们的模型在较大的 L 下不能很好地工作，这是合理的，因为高稀疏数据集可能会引入额外的噪声信息。从图 4-4 可以看出，当 L 在 4 左右时，模型的性能最好，这意味着相邻的项对当前项的影响更大。

4.3 本章小结

在本章中，我们提出了一种基于社交网络的序列推荐算法框架 SASE。该模型同时提取了用户历史交互中的序列特征和用户的社交网络特征。由于卷积神经网络在处理图像时具有优势，所以我们将用户的序列嵌入看作是待处理的“图像”，然后使用卷积神经网络建模用户的历史交互序列，以捕捉用户交互序列中的动态转化特征。由于 Node2vec 擅长对图结构进行向量表示，所以我们使用 Node2vec 模型来建模用户的社交特征。最后为了评估 SASE 的性能，我们在构造的冷启动数据集上做了大量实验，实验结果证明我们的方法优于现有的基线推荐算法，并且在冷启动场景下表现良好。

5 总结与展望

在本章，我们先从以下几个方面简要回顾本文的研究内容：序列推荐的理论基础、本文所提出的模型框架以及新模型的创新点。其次，我们对未来工作的优化方向进行了发散和展望，方便后续工作的顺利进行。

5.1 本文工作总结

移动互联网的普及和发展为更多人低门槛上网提供了便利条件，随之而来的数据爆炸问题不仅增加了软件服务商的维护成本，也提高了用户获取信息的成本，搜索引擎和推荐算法的出现为解决上述问题提供了新的思路 and 方向。和搜索引擎不同的是，推荐算法适用于用户被动获取信息的场景，主要是通过用户的画像统计数据（例如年龄、职业、籍贯以及社交网络等）、项目的描述信息（文本信息、图片、类别等）以及用户的历史反馈（评分、评论文本、浏览、购买等）来挖掘用户的兴趣偏好，并为用户推荐符合其偏好的项目。

深度学习相关模型是目前最流行的方法之一，越来越多的应用场景引入了深度学习技术，例如自然语言处理领域中的机器翻译问题、计算机视觉领域中的图像识别问题。深度学习算法的优势是：模型框架灵活多变、高维数据处理能力强以及其优秀的泛化能力。一些出众的深度学习框架也被应用在推荐系统中，本文同样引入深度学习方法来解决推荐场景下的诸多问题。本文的研究工作和主要贡献包含以下四个方面：

1) 推荐算法及序列推荐问题的研究综述。首先我们介绍了本文工作的研究背景及意义，其次我们归纳总结了海内外研究者针对推荐算法以及序列推荐问题的研究方向和具体工作，并从传统的推荐算法模型以及基于深度学习的推荐模型两个方面进行阐述。最后，我们对现有的推荐方法进行分析，得出这些推荐模型还未解决的痛点。

2) 对现有推荐算法模型和深度学习技术进行介绍。首先我们对推荐算法的研究基础作出概述，并且根据不同的数据组织形式把推荐模型分为三类：基于用户交互矩阵的推荐算法、序列推荐算法以及基于图的推荐算法。其次我们梳理了本文所涉及到的深度学习技术，包括深度学习的基础概念、卷积神经网络、门线性单元以及图嵌入表示模型。

3) 提出基于成对编码和门控网络的序列推荐算法框架。马尔可夫链和深度学习框架都能够有效解决序列推荐问题，但是这些序列推荐模型没有考虑到用户对特定项目以及项目特殊属性的兴趣偏好，此外许多方法无法有效地对用户交互序列中更高阶更复杂的特征进行建模。我们提出了一种基于成对编码和门控网络的

序列推荐模型来解决上述问题,该框架通过成对的编码层、门线型单元以及卷积神经网络来挖掘用户历史行为序列中的短期偏好。此外,我们还引入用户的潜在嵌入向量来建模用户的长期兴趣,最后结合用户的短期偏好和长期偏好来进行推荐预测。我们还在三个真实世界的数据集上对我们的方法和其他 7 种对照模型(PopRec, BPR-MF, FPMC, FMC, GRU4Rec, GRU4Rec+, Caser)进行实验,实验结果表明,所提出模型的 NDCG@N 和 Recall@N 均优于对照模型,这说明该模型的性能和现有的序列模型相比,能更好地为用户进行推荐。

4) 提出了基于社交网络的序列推荐模型。冷启动以及稀疏数据集是所有推荐算法中不可避免的问题,解决冷启动问题的一般思路是融合有效的上下文信息,通过对这些额外信息进行建模可以提高推荐结果的命中率。我们针对冷启动问题提出了基于社交网络的序列推荐模型,主要通过融合用户历史行为中的时序信息以及用户的社交信息来挖掘用户的口味偏好。首先我们在序列推荐任务中引入卷积神经网络,通过不同尺寸的滤波器来捕捉用户交互数据中的序列转化特征,与此同时,我们利用图嵌入模型 Node2vec 对用户的社交网络进行建模,最终使得所提出的模型可以有效捕捉用户的序列偏好特征和社交特征。我们还在多个冷启动数据集上与其他基线模型进行比较,实验结果验证了所提出的方法在处理冷启动问题时的优越性。

5.2 未来工作展望

推荐算法的目标是在任何条件下让每一个进入系统的用户可以获得符合自己偏好的项目,但是推荐算法也会面临种种限制,例如:数据集的稀疏性、冷启动问题、长尾项目的挖掘以及信息茧房问题等,这些限制都会导致推荐结果不能达到用户的期望。本文所提出的推荐方法也存在一定局限性,在某些方面还有可以提升的空间,我们也会在后续的研究工作中继续完善。接下来的研究工作可以从以下几个方面着手:

1) 用户的偏好是会受各种各样因素的影响,我们在未来会将更多的影响因子纳入到模型中。具体来说,在挖掘用户的序列偏好时,用户的周期性消费行为也应该考虑在内,例如用户会定期购买卫生纸等生活用品、用户每月读完一本书等等。通过对用户的周期性行为进行建模也可以达到更出色的推荐效果^{[76][77]}。其次我们还可以引入丰富的上下文数据,例如评论数据、当前的时节、用户所处的地理位置等等。此外,关键意见领袖(KOL)对用户下一步的决策也至关重要,每个 KOL 对每个用户的影响也不相同,所以未来还可以从此处入手来丰富我们的推荐模型。

2) 本文采用了一些经典的深度学习方法来建模用户的历史行为序列,但是近几年来越来越多的高性能模型出现我们的视野中,例如 Transformer 模型^[58]、GAN^[78]

（对抗生成网络）等，这些模型也被引入到推荐任务中^{[50][79]}，可以看出这些模型还是有很大的想象空间。不仅如此，针对本文第3章所提出的“用户的偏好会受特定项目和项目的特殊特征的影响”，我们还可以通过注意力机制、记忆网络模型等等对其进行建模，使得算法能够捕捉用户的长期偏好和短期偏好。总之未来我们也会从此处着手，不断优化序列推荐模型。

3) 针对推荐任务中的用户社交关系，第4章只采用了图嵌入模型捕捉用户的社交特征，但是我们还可以将图神经网络（Graph Neural Network, GNN）^[80]作为基础模型来提取用户之间的社交特征。此外，还可以通过图神经网络建模用户和项目之间的交互关系，因此对图神经网络的探索也是我们接下来的重点工作。

4) 本文所提出的模型都是基于深度学习技术，深度学习模型和传统的推荐模型相比，优势在于其能高效运作，但其劣势成为一些研究者予以诟病的方面，也就是深度学习模型的不可解释性、黑盒特征。当然也有很多的研究者致力于研究深度学习的解释性^{[81][82]}，试图从不同的角度解释深度学习的原理。接下来我们也会持续关注此问题，并根据最新的研究不断优化我们所提出的模型。

参考文献

- [1] 中国互联网络发展状况统计报告 [EB/OL].
<https://www.cnnic.net.cn/hlwfzyj/hlwxzbg/hlwtjbg/>.
- [2] Resnick P, Varian H R. Recommender systems. Commun ACM[J]. 1997, 40(3):56–58.
- [3] Schafer J B, Frankowski D, Herlocker J, et al. Collaborative filtering recommender systems[M]//The adaptive web. Springer, Berlin, Heidelberg, 2007: 291-324.
- [4] Linden G, Smith B, York J. Amazon. com recommendations: Item-to-item collaborative filtering[J]. IEEE Internet computing, 2003, 7(1): 76-80.
- [5] 项亮. 推荐系统实践[M]//人民邮电出版社, 2012.
- [6] Rendle S, Freudenthaler C, Gantner Z, et al. BPR: Bayesian personalized ranking from implicit feedback[J]. arXiv preprint arXiv:1205.2618, 2012.
- [7] He X, Chua T S. Neural factorization machines for sparse predictive analytics[C]//Proceedings of the 40th International ACM SIGIR conference on Research and Development in Information Retrieval. 2017: 355-364.
- [8] Ying H, Zhuang F, Zhang F, et al. Sequential recommender system based on hierarchical attention network[C]//IJCAI International Joint Conference on Artificial Intelligence. 2018.
- [9] He X, Liao L, Zhang H, et al. Neural collaborative filtering[C]//Proceedings of the 26th international conference on world wide web. 2017: 173-182.
- [10] Jamali M, Ester M. Trustwalker: a random walk model for combining trust-based and item-based recommendation[C]//Proceedings of the 15th ACM SIGKDD international conference on Knowledge discovery and data mining. 2009: 397-406.
- [11] Ye M, Liu X, Lee W C. Exploring social influence for recommendation: a generative model approach[C]//Proceedings of the 35th international ACM SIGIR conference on Research and development in information retrieval. 2012: 671-680.
- [12] Yang X, Yang G, Yong L, et al. A survey of collaborative filtering based social recommender systems[J]. Computer Communications, 2014, 41(5):1-10.
- [13] Kabbur S, Ning X, Karypis G. Fism: factored item similarity models for top-n recommender systems[C]//Proceedings of the 19th ACM SIGKDD international conference on Knowledge discovery and data mining. 2013: 659-667.
- [14] Ning X, Karypis G. Slim: Sparse linear methods for top-n recommender systems[C]//2011 IEEE 11th International Conference on Data Mining. IEEE, 2011:

497-506.

- [15]Pazzani M J, Billsus D. Content-based recommendation systems[M]//The adaptive web. Springer, Berlin, Heidelberg, 2007: 325-341.
- [16]Gao L, Wu J, Zhou C, et al. Collaborative dynamic sparse topic regression with user profile evolution for item recommendation[C]//Thirty-First AAAI Conference on Artificial Intelligence. 2017.
- [17]Song L, Bi Y, Yao M, et al. DREAM: A Dynamic Relation-Aware Model for Social Recommendation[C]//Proceedings of the 29th ACM International Conference on Information & Knowledge Management. 2020: 2225-2228.
- [18]Fu W, Peng Z, Wang S, et al. Deeply fusing reviews and contents for cold start users in cross-domain recommendation systems[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2019, 33: 94-101.
- [19]Kang W C, Fang C, Wang Z, et al. Visually-aware fashion recommendation and design with generative image models[C]//2017 IEEE International Conference on Data Mining (ICDM). IEEE, 2017: 207-216.
- [20]Zhao Z, Yang Q, Lu H, et al. Social-aware movie recommendation via multimodal network learning[J]. IEEE Transactions on Multimedia, 2017, 20(2): 430-440.
- [21]Chaney A J B, Blei D M, Eliassi-Rad T. A probabilistic model for using social networks in personalized item recommendation[C]//Proceedings of the 9th ACM Conference on Recommender Systems. 2015: 43-50.
- [22]Jamali M, Ester M. A matrix factorization technique with trust propagation for recommendation in social networks[C]//Proceedings of the fourth ACM conference on Recommender systems. 2010: 135-142.
- [23]高琳. 基于社交圈的在线社交网络朋友推荐算法[J]. 计算机学报, 2014.
- [24]Cai C, He R, McAuley J. SPMC: socially-aware personalized markov chains for sparse sequential recommendation[J]. arXiv preprint arXiv:1708.04497, 2017.
- [25]Tang J, Gao H, Hu X, et al. Exploiting homophily effect for trust prediction[C]//Proceedings of the sixth ACM international conference on Web search and data mining. 2013: 53-62.
- [26]Ma H, Yang H, Lyu M R, et al. Sorec: social recommendation using probabilistic matrix factorization[C]//Proceedings of the 17th ACM conference on Information and knowledge management. 2008: 931-940.
- [27]Jamali M, Ester M. A matrix factorization technique with trust propagation for recommendation in social networks[C]//Proceedings of the fourth ACM conference

- on Recommender systems. 2010: 135-142.
- [28]Ma H, Zhou D, Liu C, et al. Recommender systems with social regularization[C]//Proceedings of the fourth ACM international conference on Web search and data mining. 2011: 287-296.
- [29]Zhao T, McAuley J, King I. Leveraging social connections to improve personalized ranking for collaborative filtering[C]//Proceedings of the 23rd ACM international conference on conference on information and knowledge management. 2014: 261-270.
- [30]Tang J, Wang K. Personalized top-n sequential recommendation via convolutional sequence embedding[C]//Proceedings of the Eleventh ACM International Conference on Web Search and Data Mining. 2018: 565-573.
- [31]李太松, 贺泽宇, 王冰, 等. 基于循环时间卷积网络的序列流推荐算法[J]. 计算机科学, 47(3): 103-109.
- [32]陈细玉, 林穗. 一种融合注意力和记忆网络的序列推荐算法[J]. 信息技术与网络安全, 2020, 39(5): 37-41.
- [33]Rumelhart D E, Hinton G E, Williams R J. Learning representations by back-propagating errors[J]. Nature, 1986.
- [34]Koren Y, Bell R, Volinsky C. Matrix factorization techniques for recommender systems[J]. Computer, 2009, 42(8): 30-37.
- [35]Sedhain S, Menon A K, Sanner S, et al. Autorec: Autoencoders meet collaborative filtering[C]//Proceedings of the 24th international conference on World Wide Web. 2015: 111-112.
- [36]He X, Chua T S. Neural factorization machines for sparse predictive analytics[C]//Proceedings of the 40th International ACM SIGIR conference on Research and Development in Information Retrieval. 2017: 355-364.
- [37]Rendle S. Factorization machines[C]//2010 IEEE International Conference on Data Mining. IEEE, 2010: 995-1000.
- [38]Xin X, He X, Zhang Y, et al. Relational collaborative filtering: Modeling multiple item relations for recommendation[C]//Proceedings of the 42nd International ACM SIGIR Conference on Research and Development in Information Retrieval. 2019: 125-134.
- [39]Kemeny J G, Snell J L. Markov chains[M]//Springer-Verlag, New York, 1976.
- [40]Rendle S, Freudenthaler C, Schmidt-Thieme L. Factorizing personalized markov chains for next-basket recommendation[C]//Proceedings of the 19th international

- conference on World wide web. 2010: 811-820.
- [41]Wang P, Guo J, Lan Y, et al. Learning hierarchical representation model for nextbasket recommendation[C]//Proceedings of the 38th International ACM SIGIR conference on Research and Development in Information Retrieval. 2015: 403-412.
- [42]He R, Kang W C, McAuley J. Translation-based recommendation[C]//Proceedings of the eleventh ACM conference on recommender systems. 2017: 161-169.
- [43]Yan A, Cheng S, Kang W C, et al. CosRec: 2D convolutional neural networks for sequential recommendation[C]//Proceedings of the 28th ACM International Conference on Information and Knowledge Management. 2019: 2173-2176.
- [44]赵串串, 游进国, 李晓武. 用于下一项推荐的序列感知深度网络[J]. 小型微型计算机系统, 2020, 41(7): 1389-1394.
- [45]张岩, 郭斌, 王倩茹, 等. SeqRec: 基于长期偏好和即时兴趣的序列推荐模型[J]. 浙江大学学报 (工学版), 2020, 54(6): 1177-1184.
- [46]LeCun Y, Bottou L, Bengio Y, et al. Gradient-based learning applied to document recognition[J]. Proceedings of the IEEE, 1998, 86(11): 2278-2324.
- [47]Yu Z, Lian J, Mahmood A, et al. Adaptive User Modeling with Long and Short-Term Preferences for Personalized Recommendation[C]//IJCAI. 2019: 4213-4219.
- [48]Xu C, Zhao P, Liu Y, et al. Recurrent convolutional neural network for sequential recommendation[C]//The World Wide Web Conference. 2019: 3398-3404.
- [49]Zhou C, Bai J, Song J, et al. Atrank: An attention-based user behavior modeling framework for recommendation[J]. arXiv preprint arXiv:1711.06632, 2017.
- [50]Kang W C, McAuley J. Self-attentive sequential recommendation[C]//2018 IEEE International Conference on Data Mining (ICDM). IEEE, 2018: 197-206.
- [51]LeCun Y, Bengio Y, Hinton G. Deep learning[J]. nature, 2015, 521(7553): 436.
- [52]Schmidhuber J. Deep learning in neural networks: An overview[J]. Neural networks, 2015, 61: 85-117.
- [53]McCulloch W S, Pitts W. A logical calculus of the ideas immanent in nervous activity[J]. The bulletin of mathematical biophysics, 1943, 5(4): 115-133.
- [54]Hebb D O. The organization of behavior: A neuropsychological theory[M]//Psychology Press, 2005
- [55]Rosenblatt F. The perceptron, a perceiving and recognizing automaton Project Para[M]//Cornell Aeronautical Laboratory, 1957.
- [56]Hopfield J J. Neural networks and physical systems with emergent collective computational abilities[J]. Proceedings of the national academy of sciences, 1982,

- 79(8): 2554-2558.
- [57]Hochreiter S, Schmidhuber J. Long short-term memory[J]. Neural computation, 1997, 9(8): 1735-1780.
- [58]Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30: 5998-6008.
- [59]Devlin J, Chang M W, Lee K, et al. Bert: Pre-training of deep bidirectional transformers for language understanding[J]. arXiv preprint arXiv:1810.04805, 2018.
- [60]Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition[J]. arXiv preprint arXiv:1409.1556, 2014.
- [61]Szegedy C, Liu W, Jia Y, et al. Going deeper with convolutions[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2015: 1-9.
- [62]Lim B, Son S, Kim H, et al. Enhanced deep residual networks for single image super-resolution[C]//Proceedings of the IEEE conference on computer vision and pattern recognition workshops. 2017: 136-144.
- [63]Dauphin Y N, Fan A, Auli M, et al. Language modeling with gated convolutional networks[C]//International conference on machine learning. PMLR, 2017: 933-941.
- [64]Wu Z, Pan S, Chen F, et al. A comprehensive survey on graph neural networks[J]. IEEE transactions on neural networks and learning systems, 2020.
- [65]Mikolov T, Chen K, Corrado G, et al. Efficient estimation of word representations in vector space[J]. arXiv preprint arXiv:1301.3781, 2013.
- [66]Perozzi B, Al-Rfou R, Skiena S. Deepwalk: Online learning of social representations[C]//Proceedings of the 20th ACM SIGKDD international conference on Knowledge discovery and data mining. 2014: 701-710.
- [67]Grover A, Leskovec J. node2vec: Scalable feature learning for networks[C]//Proceedings of the 22nd ACM SIGKDD international conference on Knowledge discovery and data mining. 2016: 855-864.
- [68]Ma C, Kang P, Liu X. Hierarchical gating networks for sequential recommendation[C]//Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. 2019: 825-833.
- [69]Kingma D P, Ba J. Adam: A method for stochastic optimization[J]. arXiv preprint arXiv:1412.6980, 2014.
- [70]Wan M, McAuley J. Item recommendation on monotonic behavior chains[C]//Proceedings of the 12th ACM Conference on Recommender Systems. 2018: 86-94.

- [71]Hidasi B, Karatzoglou A, Baltrunas L, et al. Session-based recommendations with recurrent neural networks[J]. arXiv preprint arXiv:1511.06939, 2015.
- [72]Hidasi B, Karatzoglou A. Recurrent neural networks with top-k gains for session-based recommendations[C]//Proceedings of the 27th ACM International Conference on Information and Knowledge Management. 2018: 843-852.
- [73]Kim Y. Convolutional neural networks for sentence classification[J]. arXiv preprint arXiv:1408.5882, 2014.
- [74]Srivastava N, Hinton G, Krizhevsky A, et al. Dropout: a simple way to prevent neural networks from overfitting[J]. The journal of machine learning research, 2014, 15(1): 1929-1958.
- [75]Tang J, Gao H, Liu H. mTrust: discerning multi-faceted trust in a connected world[C]//Proceedings of the fifth ACM international conference on Web search and data mining. 2012: 93-102.
- [76]Bai T, Zou L, Zhao W X, et al. CTRec: A Long-Short Demands Evolution Model for Continuous-Time Recommendation[C]//Proceedings of the 42nd International ACM SIGIR Conference on Research and Development in Information Retrieval. 2019: 675-684.
- [77]Zhu Y, Li H, Liao Y, et al. What to Do Next: Modeling User Behaviors by Time-LSTM[C]//IJCAI. 2017, 17: 3602-3608.
- [78]Goodfellow I, Pouget-Abadie J, Mirza M, et al. Generative adversarial nets[C]//Advances in neural information processing systems. 2014: 2672-2680.
- [79]Bharadhwaj H, Park H, Lim B Y. RecGAN: recurrent generative adversarial networks for recommendation systems[C]//Proceedings of the 12th ACM Conference on Recommender Systems. 2018: 372-376.
- [80]Wu S, Tang Y, Zhu Y, et al. Session-based recommendation with graph neural networks[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2019, 33: 346-353.
- [81]Mahendran A, Vedaldi A. Understanding deep image representations by inverting them[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2015: 5188-5196.
- [82]Lei N, Su K, Cui L, et al. A geometric view of optimal transportation and generative model[J]. Computer Aided Geometric Design, 2019, 68: 1-21

致 谢

三年时光匆匆，又到了说告别的时候，情绪很复杂，有些伤感又有些解脱。三年前踏进校园，只觉得意气风发、一身冲劲，想要在学生时代最后的学习阶段大展身手。三年后在这付诸心血的地方来回忆这几年的点点滴滴，我想也不愧当初的自己。时间无论长短，都是人生中一段短暂的旅程，下个人生的岔路口都是要说再见，但这段旅程中遇到的人、经历的事情、取得的成果都将成为我一生的财富。

首先我要感谢我的研究生导师——李莉老师。很开心也很幸运能够师从李老师，李老师就像是前方的灯，一直照亮着我们前行的路。无论是在科研学术还是生活中，李老师都能全身心的投入，她坚忍不拔的精神和严谨细致的态度感染着我们每个人。李老师的责任心和科研使命感也让我感触颇深，未来我也会以李老师为榜样不断迭代自己。感谢李老师在这几年中对我的教导、对我所做诸多选择的支持，祝福李老师身体健康，一切顺利！

其次我要感谢我的父母。这几年离开家乡求学，和父母相处的时间非常少，这样的现状在未来工作后也会是常态。其实一直以来父母对我的关心只增不减，但我对他们的关心会因为日常忙碌而变得敷衍，感谢父母给予我的爱，也感谢父母对我人生选择的支持，未来我也会继续努力，不负所望！不忘关怀！

三年前选择保研的时候就希望自己三年后不后悔，可是刚进校的迷茫、孤独、不安、想象和现实的差距让我一度想要放弃，除了李老师之外，这几年中遇到的朋友们也给了我很大能量。在此我想感谢实验室已经毕业的王静远师兄、许梹飞师兄、曹宇坤师弟在学术上给予我的帮助，让我能迅速适应研究生生活，快速入门。感谢我的同门张楠、舒森林、何秋香，我们一起上课、一起进行学术交流、一起吃喝玩乐，感谢种种陪伴。还想要感谢同级的小伙伴王春雨、刘琳琳、王云峰、谭奕欣，感谢一路上的欢声笑语，因为有你们才会有这三年的愉快时光。祝各位此去前程似锦，归来仍少年！

每个研究生可能都会经历自信入学、自我崩溃、自我修复与重建、再到充满信心毕业、一路艰辛一路惊喜！愿我们都能想自己所想，愿自己所愿。毕业快乐！

黄可心

2021年3月于西南大学

攻读硕士期间的学术成果

发表论文:

- [1] **Huang K**, Cao Y, Li L, et al. Social-Aware and Sequential Embedding for Cold-Start Recommendation[C]//International Conference on Knowledge Science, Engineering and Management. Springer, Cham, 2019: 60-71.
- [2] **Huang K**, Du Y, Li L, et al. Pairwise-Based Hierarchical Gating Networks for Sequential Recommendation[C]//International Conference on Knowledge Science, Engineering and Management. Springer, Cham, 2020: 64-75.

参与课题:

- [1] 国家自然科学基金面上项目: 人工智能支持的自适应微开放学习研究 (主研)