

中图分类号: TP301

学校代码: 10081

U D C:

密 级: 公开



硕 士 学 位 论 文

基于用户行为的推荐算法研究与应用

论文作者: 周雕

学生类别: 全日制专业型

学科专业: 计算机技术

学位类别: 工程硕士

指导教师: 郝胜男 副教授

企业导师: 王欣 高级工程师

唐山 华北理工大学

2021 年 3 月

Research and Application of Recommendation Algorithm Based on User Behavior

Dissertation Submitted to

North China University of Science and Technology

in partial fulfillment of the requirement

for the degree of

Master of Engineering(ME)

by

Zhou Diao

(Computer Technology)

Supervisor: **Hao Sheng Nan**
Wang Xin

March, 2021

摘要

基于传统协同过滤和基于内容的推荐算法具有运算速度快、可解释性强等特点，是目前主流的推荐算法，但是由于泛化能力较差、个性化程度偏低等局限性，使得推荐性能难以进一步提升。随着人工智能的快速发展，使用深度学习技术解决推荐系统问题成为了一种可行途径。研究工作基于互联网中的点击、浏览、评分等用户行为数据和神经网络算法展开，重点如下：

针对显性评分行为，提出了一种基于空间维度距离度量和用户显性行为的推荐算法（Recommendation Algorithm based on Spatial Dimension Distance Measurement and User Explicit Behavior, SDDM-UEB）。首先，对 Item2Vec 模型进行了改进，采用随评分等级动态变化的窗口来提高项目特征训练的准确性；其次，将所提的空间维度距离度量方法用于用户与项目的特征融合阶段，通过度量用户与项目在潜在空间中不同维度上的距离来获得二者的交互特征，并经全连接层对预测评分进行输出；最后，针对由于长期推荐同类项目而导致的用户兴趣疲劳问题，采用一种基于余弦相似度的 Top-K 列表重排序方法，以实现兴趣疲劳的有效缓解。

针对隐性行为，采用融合标签信息与用户隐性行为的方式挖掘用户兴趣方向，并通过神经网络实现点击预测。特别的，在用户特征表示阶段，引入时间衰减函数来捕捉用户的兴趣变化，从而实现点击预测性能的提升。

SDDM-UEB 算法在 MovieLens 1M 和 MovieLens 100K 两个数据集上的 RMSE 指标分别为 0.820 和 0.867，MAE 指标分别为 0.641 和 0.677。融合标签信息与用户隐性行为的推荐算法在 MovieLens 1M 数据集上的召回率达到了 0.37（推荐长度为 100）。所提两种算法均优于传统算法。

最后，对电影推荐系统应用进行了系统需求分析，并基于 PyQt 框架和 MySQL 数据库对系统的客户端和服务端进行了设计和实现。

图 28 幅；表 12 个；参 64 篇。

关键词：推荐系统；用户行为；神经网络；Item2Vec；特征融合；

分类号：TP301

Abstract

Traditional collaborative filtering and content-based recommendation algorithms are the mainstream recommendation algorithms at present, which have the characteristics of fast operation and strong explanation. It is difficult to obtain satisfactory recommendations due to the limitations of poor generalization ability and low degree of personalization. With the rapid development of artificial intelligence, it has become a feasible way to use deep learning technology to solve the problem of recommendation system. The research work is based on user behavior data such as clicks, browses, and ratings on the Internet and neural network algorithms, with the following highlights:

For the explicit scoring behavior, a recommendation algorithm based on spatial dimensional distance measurement and user explicit behavior (SDDM-UEB) is proposed. First of all, the Item2Vec model is improved by using a window that changes dynamically with the rating level to improve the accuracy of item feature training; secondly, the proposed spatial dimension distance measurement method is used in the feature fusion phase of user and item, and the interactive characteristics of user and item are obtained by measuring the distance between user and item in different dimensions in the potential space, and the predicted rating is output through the full connection layer. Finally, a Top-K list reordering method based on cosine similarity is adopted to alleviate the problem of user interest fatigue caused by long-term recommendation of similar items.

For the implicit behavior, a combination of labels and implicit behavior is used to mine user preferences, and click prediction is realized through neural network. In particular, in order to achieve the purpose of improving the click prediction performance, a time decay function is introduced in the user feature representation to capture the user's preference changes.

The RMSE of SDDM-UEB algorithm on MovieLens 1M and MovieLens 100K data sets is 0.820 and 0.867 respectively, and the MAE is 0.641 and 0.677 respectively. The Recall of the recommendation algorithm which combines label information and user implicit behavior on MovieLens 1M dataset is 0.37 (recommendation length is 100). The two proposed algorithms are better than the traditional algorithms.

Finally, the system requirements of the application of the film recommendation system are analyzed, and the client and server of the system are designed and implemented based on PyQt framework and MySql database.

Figure 28; Table 12; Reference 64

Keywords: recommendation system; user behavior; neural network; item2vec; feature fusion;

Chinese books catalog: TP301

目次

第1章 绪论	1
1.1 研究背景和意义	1
1.1.1 研究背景	1
1.1.2 研究意义	3
1.2 国内外研究现状分析	4
1.2.1 基于用户行为的推荐系统研究	4
1.2.2 用户兴趣动态变化的研究	6
1.3 研究内容及创新点	6
1.3.1 研究内容	6
1.3.2 创新点	7
1.4 文章结构安排	7
第2章 推荐系统相关理论	9
2.1 技术难题概述	9
2.1.1 “个性化”问题	9
2.1.2 冷启动问题	10
2.1.3 稀疏性问题	10
2.1.4 扩展性问题	11
2.2 基于用户行为的推荐系统	12
2.2.1 显性行为和隐性行为	12
2.2.2 传统的协同过滤	13
2.2.3 矩阵分解算法	14
2.3 基于标签的推荐系统	15
2.4 深度学习下的推荐系统	16
2.4.1 NCF 框架	17
2.4.2 Word2Vec	18
2.5 召回与排序	23
2.6 本章小结	23
第3章 基于空间维度距离度量和用户显性行为的推荐算法	25

3.1 Item2Vec 的改进	25
3.2 SDDM-UEB 模型与方法流程	27
3.2.1 项目特征与用户初始特征表示	27
3.2.2 用户特征学习	29
3.2.3 基于空间维度距离度量的特征融合	30
3.2.4 评分预测	31
3.3 Top-K 排序优化	31
3.4 实验	33
3.4.1 数据集	33
3.4.2 主要评估标准	33
3.4.3 实验过程与分析	33
3.5 本章小结	36
第 4 章 融合标签信息与用户隐性行为的推荐算法	38
4.1 算法模型架构	38
4.2 方法流程	39
4.2.1 初始特征表示	39
4.2.2 融入时间衰减	41
4.2.3 特征的 Embedding 操作	43
4.2.4 评分预测	43
4.3 实验	44
4.3.1 数据集及预处理	44
4.3.2 主要评估标准	44
4.3.3 实验过程与分析	45
4.4 本章小结	48
第 5 章 电影推荐系统应用设计	49
5.1 系统架构与需求分析	49
5.2 系统设计	50
5.2.1 数据库存储设计	50
5.2.2 客户端设计	52

5.2.3 推荐列表生成模块	54
5.3 本章小结	54
结 论	55
参考文献	56
致 谢	62
在学期间研究成果	63

第 1 章 绪论

1.1 研究背景和意义

1.1.1 研究背景

如今，中国已成功步入信息高速公路，成为了全球互联网大国。据有关中国互联网发展状况的报告^[1]指出，截至 2019 年 12 月，国内的域名总数达到了 5000 多万个，截至 2020 年 3 月，网民规模达到了 9 亿多，将近占中国人口总数的 65%（如图 1 所示）。在高度信息化的今天，人们实现了足不出户便可尽知天下事。诸如移动支付、网上购物、网上外卖订餐、线上协同办公等应用，为人们的生活工作带来了便利，对经济的发展带来了很大的推动作用。




图 1 中国网民数量变化趋势

在互联网中，随着网民数量的急剧增加，每时每刻都会产生大量的信息数据，因此，如今人们已经处于大数据时代，而信息过载是大数据时代所面临的一个重大问题。回归人们在网上冲浪的目的，大多数情况下，无非是想获取一些有价值、感兴趣的信息。但是，要从如此庞大的互联网信息库中获取想要的信息却不是一件容易的事情，而推荐系统成为了解决这类问题的一种有效工具。

1997 年，Resnick 等人^[2]提出的推荐系统这一概念被大众广泛接受，他们把推荐系统概念建立于电子商务行业的基础上，并将它理解为“模拟销售人员为用户提供

购买建议”的一个过程。而事实上，推荐系统的雏形在 1992 年的时候就已经形成^[3]，当时被用来过滤电子邮件。后来，随着电子商务以及在线视频网站的快速发展，推荐系统也开始被广泛应用于各种互联网场景，推荐系统的应用对大数据背景下的互联网发展起到了很大的推进作用。

目前，推荐系统已经被广泛应用于各种互联网平台。比如国内的淘宝、今日头条、爱奇艺，国外的 Youtube、亚马逊等客户端和网站都应用到了推荐系统，推荐系统的应用在为这些平台带来丰厚广告收益的同时，也为用户在获取个性化信息方面提供了有价值的建议。并且，近几年在国内随着诸如抖音、快手等短视频行业的发展，推荐系统的应用更是上了一个新的台阶。

具体来说，推荐系统的应用一般包括电子商务、新闻推荐、音视频推荐、网络社交、广告精准推送等领域。从中国手机网民在各类应用上的使用频率^[1]（图 2，2019 年 12 月数据）可以看出，推荐系统已经覆盖了大部分互联网应用场景。




图 2 手机网民在各类应用上使用时长占比

比如在电子商务中（如图 3 所示），应用推荐系统可以帮助网站了解用户的购物习惯，从而更准确地判断用户的偏好走向。更进一步地，推荐系统可以根据用户行为来判断商品之间的关联程度或相似程度，比如，当用户购买手机时，往往还会购买手机保护壳，那么推荐系统便可以挖掘到手机与手机壳之间的关联性，在下次某个用户购买了手机时，就可以向其推荐手机壳。而在近几年流行的短视频应用中，推荐系统可以根据用户刷每个视频的时长、点赞和评论等行为来判断用户的兴趣偏好。比如某个用户经常对科普类短视频点赞，而对于其他视频只是一扫而过，

那么推荐系统便可以捕捉到“用户对科普类视频感兴趣”这一关键点，从而增加该类视频的展现量，实现精准推荐。

总的来说，推荐系统可以根据用户的行为数据来判断其兴趣走向，从海量互联网信息数据中迅速筛选出对用户有价值的信息，是对抗信息过载问题的一种有效工具。



图3 电子商务网站的推荐页面

结合目前的推荐系统背景现状，本文的工作重点是对互联网中的用户行为数据进行研究，通过对用户行为数据进行深入分析来获得用户的兴趣方向，从而实现个性化推荐。具体来说，分别对用户的显性反馈行为和隐性反馈行为进行兴趣建模，对用户对象和项目对象进行向量化，并通过神经网络实现用户对项目的评分预测。总之，本文的研究工作主要着力于推进推荐系统领域的发展和进步。

1.1.2 研究意义

从实际应用价值上来看，推荐系统是解决信息过载问题的一种有效工具，能够帮助人们在信息海洋中迅速获取到有价值或者感兴趣的信息，能够帮助服务商为客户提供有价值的服务，从而稳定客户量。推荐系统在用户和服务商之间扮演者“桥梁”的角色，使互联网变得更加活跃。

从学术意义上来看，推荐系统虽然已经成功应用到实际当中，但是目前仍有一些难题待解决。如新上线用户或项目引起的冷启动问题，用户项目数量巨大、评分矩阵过于稀疏引起的稀疏性问题，以及推荐系统无法适应用户和项目的快速增长而引起的扩展性问题。研究、解决这些棘手问题对于整个推荐系统领域的发展有着重要意义。另外，目前主流的推荐算法仍然或多或少存在一些弊端。比如，传统的协同过滤算法很少考虑到标签数据的应用，从而使得推荐精度不够高，基于内容的推荐过于贴合用户特征而不具备较强的泛化能力，基于神经网络等深度学习技术的推荐系统能取得较好的推荐效果，但却存在计算资源开销过大的问题。因此，研究、

优化推荐算法有着重要的学术意义。

1.2 国内外研究现状分析

推荐系统自从上世纪九十年代诞生至今，无论是国内还是国外，一直受到许多计算机学者的关注，本小节将对已有的部分研究工作进行分析。

1.2.1 基于用户行为的推荐系统研究

用户行为是推荐系统中实现准确推荐的重要依据来源，从目前来看，基于用户行为的推荐系统实现可划分为使用传统推荐算法和使用深度学习算法两大类。

1) 使用传统推荐算法

使用用户行为数据进行推荐的传统算法中最经典的莫过于协同过滤^[4]，目前大多数基于用户行为数据进行推荐的主流算法都包含了协同过滤思想。协同过滤根据用户过去的行为历史寻找用户最近邻或项目最近邻，从而实现近邻推荐。由于其较好的推荐性能和较强的可解释性，受到了许多学者的关注和研究。Xue 等人^[5]提出了一种新的推荐系统算法，通过采取平滑处理的方式结合基于内存和基于模型的协同过滤的优点，提升了推荐效率。Liang 等人^[6]将变分自编码器（Variational Autoencoders, VAES）扩展到用于隐性反馈的协同过滤中，他们提出了一个多项式似然生成模型，并用贝叶斯推理进行参数估计，验证了非线性模型相比线性模型的优势性。Li 等人^[7]提出了一种跨域协同过滤的评分矩阵生成模型（RMGM），该模型通过找到一个共享的隐性集群级评分矩阵来建立多个评分矩阵之间的相关性，并对缺失的评分项进行填充，有效缓解了稀疏性问题。Lemire 等^[8]提出了著名的 SlopeOne 系列算法，该算法将协同过滤的回归函数简化，相比于原始基于近邻的推荐算法，在较大程度上降低计算时间的同时，还提升了推荐效果，缓解了可扩展性问题。

大量研究工作证明了协同过滤的优秀性能，但是在使用用户行为数据进行推荐的算法中，还有一种经典的算法，即“矩阵分解”。矩阵分解同样基于协同过滤思想，其将用户和项目映射到同一个潜在空间中，通过内积计算的方式能够实现对任意用户与项目组合进行评分预测，相比协同过滤中最基础的 ItemCF 和 UserCF 算法，推荐性能有了明显的提升。目前广泛使用的矩阵分解算法有 SVD^[9]，SVD++^[10]等。矩阵分解算法有着较强的潜在特征挖掘能力，因此受到了广泛关注，许多学者试图对矩阵分解算法进行优化以获得更好的推荐性能。Jiao 等人^[11]提出了一种新颖的自适应学习率（ALR）函数，其结合了指函数和线性函数的特性，并应用于 SVD++

推荐算法,加快了计算的收敛速度,Kumar 等人^[12]在 SVD++中融入社会流行因素作为隐性反馈,提升了推荐模型的准确性与扩展性。Pongpaichet 等人^[13]将随机梯度下降应用到 SVD 算法中,加快了模型的收敛,提升了模型性能。Koren 等人^[14]在 SVD 中考虑时间因素引起的兴趣变化,有效提高了评分预测的准确性。

2) 使用深度学习技术的推荐算法

近年来,随着深度学习在计算机视觉和自然语言处理等领域的快速发展^[15-16],许多学者将神经网络运用到了推荐系统,试图解决数据稀疏性问题和冷启动问题,大量研究工作证明了这种做法的可行性。

Bansal 等^[17]提出了一种基于深度递归神经网络的文本编码方法,针对内容推荐和项目元数据预测的组合进行训练,缓解了冷启动问题和稀疏性问题。Zheng 等人^[18]提出一种深层协同神经网络模型,该模型由两个平行的神经网络(分别被用来学习用户特征和项目特征)经一个共享网络耦合在一起,用于对评论数据进行文本信息挖掘,从而缓解了数据稀疏问题。Liu 等人^[19]提出了一种异构图神经推荐器模型,该模型通过使用基于异构图的图卷积网络来学习用户和物品的嵌入,缓解了冷启动问题。He 等人^[20]提出了一种基于神经网络的协同过滤通用框架(Neural Collaborative Filtering, NCF),在隐性反馈的基础上进行实验,利用神经网络来学习传统推荐算法所无法学习的特征,提高了推荐效率。Wu 等人^[21]提出了基于会话的图神经网络推荐 SR-GNN,通过把会话序列建模为具有图形结构的数据,使用 GNN 解决了传统顺序方法无法描述复杂项目转换的难题。Zhou 等人^[22]提出了一种全路径学习推荐模型,该模型基于聚类 and 机器学习,并训练一个长短期记忆(LSTM)模型,以预测的学习路径和表现。Pyo 等人^[23]基于 LDA 模型,提出了一个基于相似电视用户分组和将电视节目推荐为社交电视服务的统一主题模型。Torres 等人^[24]提出了一种基于 Seq2Seq 神经体系结构的推荐模型,该模型使用递归神经网络的多种变体对用户的个人资料文本和对话上下文进行编码,获得了较高的召回率。Barkan 等人^[25]基于协同过滤的思想,利用 Word2Vec^[26-27]的原理提出了 Item2Vec 方法,并与传统的 SVD 算法对比,证明了该方法的优势。

事实上,在基于神经网络的推荐系统的实际应用研究上,一些大型互联网公司取得了不错的成果。如 Google 提出了 Wide&deep 模型^[28],该模型由 Wide 模块与 Deep 模块构成,同时具有逻辑回归模型与神经网络模型的优点,即拥有较好的记忆能力与泛化能力。Youtube 公开了他们用于视频推荐的模型^[29],该模型基于神经网络构建,由候选集生成模块和排序模块组成,适用于大型数据筛选推荐场景,在 Youtube 视频网站的实际应用中证明了该模型的优势性。

1.2.2 用户兴趣动态变化的研究

推荐系统的核心是向用户展示他们可能感兴趣的项目。但是，人的兴趣偏好并非一成不变，往往受时间、空间场景等因素的影响，而推荐系统本身又难以适应用户的兴趣变化，或者难以捕捉用户的兴趣变化规律。因此，为了提升推荐系统的“智能性”，许多研究者对基于用户兴趣动态变化的推荐系统进行了深入研究。

Yuan 等人^[30]综合考虑地理位置与时间信息，认为用户在不同的时间点有不同的地理位置偏好，提出了一种能够融合时间信息的协同过滤模型。Yu 等人^[31]提出了短期用户兴趣模型，通过分析用户最近的浏览内容和行为来表示用户的实时兴趣，进而实行推荐。Wu 等人^[32]提出了一种基于兴趣遗忘曲线的协同过滤算法。他们对用户兴趣变化的规律进行了探索，使用最近评分的项目来表示用户当前的兴趣，对于每个历史访问的项目，根据兴趣遗忘曲线和评分矩阵来计算综合数据权重，该模型提高了推荐的准确率和召回率。Song 等人^[33]提出了基于深度神经网络的模型，该模型对长期静态和短期临时用户偏好的组合进行建模，以提高推荐性能。Cui 等人^[34]提出了一种基于分层上下文注意的网络模型，该模型结合递归神经网络和注意力机制，主要关注近期的兴趣方向。Alibaba 提出了 DIN 模型^[35]，该模型通过引入注意力机制捕捉用户的兴趣方向从而收获较好的推荐效果。这些模型紧贴推荐系统的实际应用场景，在数据稀疏环境下仍然有着不错的推荐性能表现。

但是在解决用户兴趣变化的问题上，并不局限于上述研究方向，还有很多工作从推荐系统的多样性入手，试图通过推荐“新鲜”的项目来获得用户的好感。Ziegler 等人^[36]引入列表内相似度度量来评估推荐列表的主题程度，并通过主题多样化的方法来降低列表内的相似度。Shi 等人^[37]通过用户潜在因素的方差来捕捉用户的兴趣范围和用户偏好的不确定性，以实现推荐结果的适应性多样化。Wasilewski 等人^[38]将意向感知框架引入到基于物品的推荐算法中，通过在物品相似度度量中引入个性化内容感知协方差来提高推荐系统的多样性。

更进一步地，还有些研究工作从社会关系网络入手。如 Medo 等人^[39]提出了一种社会过滤机制，该机制基于适应性网络实现，可以提高用户体验。Cantador 等人^[40]引入社会化网络领域中的兴趣社交理论，提高了个性化推荐的多样性。

1.3 研究内容及创新点

1.3.1 研究内容

本文的研究工作基于互联网场景下的用户行为数据开展，并以真实数据集为例进行实验。研究内容可以概括如下：

- 1) 传统推荐算法的分析：对推荐系统中的一些经典推荐算法进行分析研究，如 ItemCF、UserCF、SVD 算法、基于内容的推荐算法等，并总结了这些算法的优劣性。
- 2) 基于深度学习的推荐算法分析：研究近几年深度学习技术在推荐系统领域的发展趋势、并选择一些优秀算法进行探讨。包括神经网络在推荐系统中的应用、NLP（Natural Language Processing）技术^[41]在推荐系统中的应用等。
- 3) 针对用户显性行为的研究：从用户对项目的历史评分序列入手，对 Item2Vec 模型进行了改进，提出了一种新的特征融合方法。
- 4) 针对用户隐性行为的研究：将隐性行为序列与用户、项目标签相结合，并对推荐系统中用户偏好随时间的动态变化进行了研究。
- 5) 对推荐系统的 Top-K 排序层进行了研究。
- 6) 对电影推荐系统应用进行了设计和实现。

1.3.2 创新点

- 1) 对 Item2Vec 模型进行了改进，采用随评分等级动态变化的窗口，提高了项目特征向量化的准确性。
- 2) 提出了一种基于空间维度距离度量和显性行为的推荐算法，将所提的空间维度距离度量方法用于用户与项目的特征融合阶段，以得到二者的交互特征，并将交互特征经全连接层映射得到预测评分。实验结果表明该方法提升了模型的收敛速度和评分预测性能。
- 3) 针对用户兴趣疲劳问题，采用了一种基于余弦相似度的 Top-K 重排序方法，通过降低部分与用户特征过于相似的项目的排名，达到缓解用户兴趣疲劳的目的。
- 4) 构建了一种结合标签信息和隐性行为的推荐算法模型，特别的，通过引入时间衰减函数捕捉用户兴趣的动态变化，提高了推荐性能。

1.4 文章结构安排

第 1 章为绪论，首先介绍了研究背景和意义，并且对国内外的研究现状做了介绍总结。

第 2 章主要介绍推荐系统的相关理论，包括推荐系统技术难题的概述、基于用户行为的推荐系统、基于深度学习的推荐系统框架等，其中重点介绍了 Word2Vec 模型的基本原理。

第 3 章主要介绍基于空间维度距离度量和用户显性行为的推荐算法，对该算法的理论进行了推导、分析，并介绍了实验过程与实验结果。

第 4 章主要介绍融合标签信息与隐性行为的推荐算法，对该算法的理论进行了推导、分析，其中重点阐述了时间衰减的引入。最后对实验过程与实验结果进行了介绍。

第 5 章以 MovieLen 数据集为例，使用 PyQt 框架和 MySQL 数据库，通过编写客户端和服务端程序对电影推荐系统应用进行了设计和实现

最后对本文工作的重点和不足之处进行了总结。

第2章 推荐系统相关理论

2.1 技术难题概述

2.1.1 “个性化”问题

“一千个人眼中有一千个哈姆雷特”这句谚语很好的说明了不同的人对于同一个事物往往存在着不同的观点。类比到推荐系统中，对于同一个项目，不同偏好或不同需求的人也往往存在不一样的看法。在同一个推荐场景下，如何为不同的人分别推荐适合他们的项目是个性化推荐系统要解决的问题。

不同于线下商场的销售员或导购，在线上推荐场景，不可能通过太多的问答方式去了解用户的需求。对于推荐系统来说，只能通过用户数据的深度分析来得到推荐的依据，而要从这些用户较少的相关数据中了解用户的偏好是一项富有挑战性的工作。虽然直接向用户推荐热门项目有时候也能获得较好的反馈效果，但是，这种做法却没有“个性化”可言，因为个性化的目的是要实现“量身定制”。

个性化推荐系统通过深度分析用户的画像信息（如年龄、性别、职业）、社交关系、地理上下文信息、行为数据（如评分、点击）等来获得用户的综合个性化特征，这些特征在潜在特征空间中有着各自的一席之地（图4为不同用户特征在潜在空间的分布示例）。但是，特征并非为静态不变的，因为随着时间的推移，人的兴趣可能发生改变，比如，某人在过去非常喜欢战争题材的电影，但是过一段时间，可能对科幻题材的电影更加感兴趣。从这个简单的例子可以看出，人的兴趣变化有着不规律性。对推荐系统来说，如何适应用户偏好特征的变化也是一个要重点考虑的问题。




图4 潜在空间中的用户特征分布

在“个性化”推荐上，还存在新颖性问题。以基于内容的推荐算法为例，该算法完全参照用户过去喜欢的项目来推荐与之相似的项目，而不会拓展不同类型的项目进行推荐，这就造成了推荐系统的“固化”，推荐结果没有新颖性，这很容易引起用户的兴趣疲劳，从而导致用户流失。

2.1.2 冷启动问题

在推荐系统中，对于一个拥有大量历史行为数据的用户，比较容易从这些行为中分析出用户的偏好并实行推荐。然而，对于一个新注册的用户，由于没有历史行为作为参考，甚至没有任何画像信息，从而无法获得推荐依据，这便产生了用户冷启动问题。在应对用户冷启动问题上，许多应用或网站采用问卷方式来获得用户的偏好，进而实现较为准确的推荐，这是目前对付用户冷启动的一种常见手段。与用户冷启动相对应的是项目冷启动。项目冷启动是指新上线的项目没有任何与用户互动的记录，从而难以获取项目特征，无法实现推荐。在应对项目冷启动问题上，目前主要通过采用人工标注的方式解决，即通过给项目打标签来赋予项目特征信息。除此之外，可以通过项目原始数据的深层次分析来获得项目特征。如图 5 所示，在音乐推荐中，可以通过分析歌曲的频谱信息得到对应的特征序列^[42]，进而制定推荐方案，但是这种方法往往有着较高的空间复杂度和时间复杂度。




图 5 音频特征提取

2.1.3 稀疏性问题

在现实应用中，用户数量与项目数量往往是十分庞大的，尤其是在电子商务网站上，用户和商品数量往往是千万乃至上亿级别。然而对于每个用户来说，他们的行为记录中的商品数量要远小于总的商品数量，同样，对于每件商品来说，购买过或点击浏览过的用户数也要远小于总的用户数，这就造成了用户-商品评分矩阵的稀疏问题。表 1 为一个稀疏行为记录示例。

表1 稀疏行为表

User	Item			
	i_1	i_2	i_3	i_4
u_1	1	0	1	1
u_2	0	0	1	1
u_3	0	1	0	0
u_4	1	1	0	0

表中，1 表示对应的用户 u_j 与项目 i_k 有交互信息，0 则表示没有交互信息。进行算法设计时，为了方便，一般将行为表以矩阵的形式表示，因此上表中的数据可以表示为：

$$r_{U,I} = \begin{pmatrix} 1 & 0 & 1 & 1 \\ 0 & 0 & 1 & 1 \\ 0 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 \end{pmatrix} \quad (1)$$

从上述行为矩阵 $r_{U,I}$ 可以看出来，该矩阵具有较高的稀疏程度。稀疏程度 s_r 可以通过以下公式计算得到：

$$s_r = 1 - \frac{n_{u,i}}{n_u * n_i} \quad (2)$$

式中：

$n_{u,i}$ —用户项目交互行为总数；

n_u —用户总数；

n_i —项目总数。

然而，在现实应用中行为矩阵往往更加稀疏，比如在淘宝和亚马逊等电子商务网站上，稀疏程度高达 99% 以上^[43]。在这种情况下，推荐系统需要以少量的已知数据去预测大量的未知数据，其难度不言而喻。因此，稀疏性问题一直是推荐系统中的一大难题。

2.1.4 扩展性问题

实际应用中的推荐系统模型一般至少需要经过模型设计、模型训练、离线测试、线上运行等几个阶段。在离线测试中，往往可以通过参数调整来使模型达到较好的效果，但是当放到线上运行时，模型效果往往随着时间的推移而下降，这是因为实际中用户、项目是不断增加、变化的，适应于之前数据的模型不一定能适应之后的

用户和项目，这便产生了扩展性问题。另外，随着用户与项目数量的增加，大型数据计算下时间复杂度和空间复杂度的增大也是造成扩展性问题的一个原因。

2.2 基于用户行为的推荐系统

用户行为数据是推荐系统中重要的推荐依据，在实际应用中，一般以日志的方式保存于网站的服务器中。比如在短视频应用中的点赞、评论行为以及每个短视频的浏览时长，在电子商务网站上的收藏、加购物车、下单等行为，都被记录于对应的服务器上。在基于用户行为的推荐系统中，通过定期的用户行为分析和模型训练，用户特征、项目特征以及模型参数都会得到更新。目前，大多数推荐算法都是基于用户行为数据设计，比如传统的协同过滤推荐算法、矩阵分解算法等。

2.2.1 显性行为 and 隐性行为

按类型来分，用户行为一般可分为显性行为 and 隐性行为。

显性行为能够确切的反应用户对项目的喜欢与否。以显性行为中的评分行为为例，评分的高低可以直观的反应出用户对项目的态度，许多用到了推荐系统的场景都提供了评分选项，如购物网站、外卖客户端、视频网站等。而在短视频应用中，通过点赞也可以反应出用户对项目的态度。

对于隐性行为，则往往无法直接显示出用户对项目的态度。常见的隐性行为有点击、浏览时长等。这些行为不但不能表明用户对项目的感兴趣程度，而且还有可能存在很大的噪声。比如某用户在一个网页上停留了很久，这并不一定说明该用户对页面的内容感兴趣，有可能停在该页面的时候该用户在处理其他事情，因此，如果将该情形误判为用户是对该页面信息感兴趣的话，在日后对该用户的推荐服务中，有可能会提供错误的推荐。

表 2 显示了显性行为 and 隐性行为的对比情况，从表中可以看出，显性行为虽然可以准确反应用户的偏好，但是可利用的数据往往很少，而隐性行为数据虽然丰富，但却无法直接反应用户的兴趣偏好。

表 2 行为数据的特点

对比项	显性行为	隐性行为
行为示例	评分、点赞	点击、浏览、评论
兴趣反应	明确	不明确
行为数据量	少	多

2.2.2 传统的协同过滤

传统的协同过滤算法包括基于用户的协同过滤（UserCF）与基于项目的协同过滤（ItemCF）两种^[44]，而这两种算法的核心都是基于最近邻居算法，即认为互为邻居的用户或项目具有较高的相似性。

关于 UserCF，该算法通过寻找偏好相似的用户（最近邻居）来获得推荐建议。如表 3 所示，在电影历史评分数据中，用户 A 和用户 B 的评分记录序列有着高度的相似性，那么便可以认为二者具有相似的偏好，从而可以把用户 A 喜欢的电影推荐给用户 B，把用户 B 喜欢的电影推荐给用户 A。在这里，用户 A 和用户 B 互为最近邻居。

表 3 历史评分数据示例

用户	电影			
	i_1	i_2	i_3	i_4
A	5	5	2	1
B	4	5	1	1
C	3	4	5	4

一般通过余弦相似度或 Jaccard 相似度^[45-46]计算用户的最近邻居。

以表 3 中的用户 A 和用户 B 为例，其余弦相似度的计算公式为：

$$simc_{AB} = \frac{u_A \cap u_B}{\sqrt{|u_A| |u_B|}} \quad (3)$$

同样，Jaccard 相似度的计算公式为：

$$simj_{AB} = \frac{|u_A \cap u_B|}{|u_A \cup u_B|} \quad (4)$$

上述两式中：

$u_A = \{i_1, i_2\}$ —用户 A 的偏好电影集合；

$u_B = \{i_1, i_2\}$ —用户 B 的偏好电影集合。

通过所有用户之间的两两计算，便能得到所有用户的最近邻，从而可以完成对每个用户的推荐工作。

关于 ItemCF，与 UserCF 类似，通过寻找特征相似的项目来获得推荐依据。当某一部分用户给电影 1 的评分与给电影 2 的评分相似时，便可以认为电影 1 与电影 2 是相似的。根据这个规则，从表 3 中可以看到 i_1 和 i_2 具有高度相似性， i_3 和 i_4 具有高度相似性，若已知某一用户喜欢 i_1 ，那么便可以将 i_2 推荐给他。

在计算项目之间的相似度时，同样可以用余弦相似度和 Jaccard 相似度来计算。事实上，还有许多用于 UserCF 和 ItemCF 的相似度计算方法，如皮尔逊系数^[47]、欧式距离等^[48]。

以 ItemCF 为例，项目 a 和项目 b 的皮尔逊系数计算公式为：

$$\text{simp}(a, b) = \frac{\sum_{u \in U_{ab}} (R_{a,u} - \bar{R}_a)(R_{b,u} - \bar{R}_b)}{\sqrt{\sum_{u \in U_{ab}} (R_{a,u} - \bar{R}_a)^2} \sqrt{\sum_{u \in U_{ab}} (R_{b,u} - \bar{R}_b)^2}} \quad (5)$$

式中：

U_{ab} —对项目 a 和项目 b 都进行过评价的用户集合；

$R_{a,u}$ —用户 u 对项目 a 的评分；

$\bar{R}_a$ —项目 a 的平均得分；

$R_{b,u}$ —用户 u 对项目 b 的评分；

$\bar{R}_b$ —项目 b 的平均得分。

项目 a 和项目 b 的欧式距离计算公式为：

$$\text{dist}(a, b) = \sqrt{\sum_{u \in U_{ab}} (R_{a,u} - R_{b,u})^2} \quad (6)$$

式中：

U_{ab} —对项目 a 和项目 b 都进行过评价的用户集合；

$R_{a,u}$ —用户 u 对项目 a 的评分；

$R_{b,u}$ —用户 u 对项目 b 的评分。

2.2.3 矩阵分解算法

在推荐系统领域，矩阵分解算法是一种典型的基于用户行为的推荐算法，并且包含了协同过滤的思想，该算法无论是在学术界还是在工业界，都有大量的研究。目前，影响力较大的矩阵分解算法与 SVD^[9]、SVD++^[10]、timeSVD^[14]等等。

矩阵分解算法中，评分矩阵是核心所在。对于所有用户集合 U 和所有项目集合 I ，其中的任意用户 u 和任意项目 i 的交互可以产生一个评分 $r_{u,i}$ ，但是在实际应用中，不可能每个用户对每个项目都有评分，因此，预测没有过交互行为的评分 $r_{u,i}$ 便是矩阵分解算法的目的。

以 SVD 为例，设用户数量为 j ，项目数量为 k ，评分稀疏矩阵为 $R^{j \times k}$ ，并假设对于每一个用户与每一个项目，都对应存在一个潜在特征向量，向量维度均为 m ，这

些潜在向量处于同一潜在空间。将所有用户组成的特征矩阵记为 p , $p \in R^{m \times j}$, 所有项目组成的特征矩阵记为 q , $q \in R^{m \times k}$ 。那么关于用户 u 对项目 i 的评分预测, 可以通过下式计算:

$$\hat{r}_{u,i} = q_i^T \cdot p_u \quad (7)$$

式中:

p_u —用户 u 的潜在特征向量;

q_i —项目 i 的潜在特征向量。

但需要注意的是, 对于每一个用户来说, 评分的标准是不一样的, 并且对于不同的项目, 获得评分也会有所标准差异。因此, 加入用户偏置项与项目偏置项来调整评分值, 调整后的评分预测公式为:

$$\hat{r}_{u,i} = q_i^T \cdot p_u + b_u + b_i + \bar{r} \quad (8)$$

式中:

b_u —用户偏置项;

b_i —项目偏置项;

$\bar{r}$ —平均评分。

实现准确推荐的关键是特征矩阵的准确性以及偏置项的准确性, 而特征矩阵以及偏置项需要通过训练得到。在训练过程中, 首先, 随机初始用户特征矩阵和项目特征矩阵, 通过损失函数计算预测值与真实值之间的偏差, 并通过梯度下降算法实现对特征矩阵进行更新。

事实上, 还可以在上述算法中融入隐性反馈, 以获得更加精准的推荐效果。融入隐性反馈后, 预测评分的计算公式变为:

$$\hat{r}_{ui} = \bar{r} + b_u + b_i + q_i^T \cdot (p_u + \frac{1}{\sqrt{|R(u)|}} \sum_{j \in R(u)} y_j) \quad (9)$$

式中:

$R(u)$ —用户 u 交互过的所有项目的集合;

y_j —与项目 j 相关的一个潜在向量。

加入了隐性反馈考虑的矩阵分解算法即为 SVD++ 算法, 该算法相比只考虑显性行为反馈的 SVD 算法有着一定的性能提升。

2.3 基于标签的推荐系统

标签是描述一个事物的最简单、直接的文本数据, 它能够从某些方面概述一个事物的特征。事实上, 标签几乎是深度学习技术中不可缺少的辅助信息, 在神经网络

络中它可以用来判断样本预测的准确性。在推荐系统中，标签更是有着重要的作用，简单的基于标签的推荐系统几乎不需要复杂的算法过程，而且有着非常强的可解释性。

在推荐系统中，标签可以分为用户标签和项目标签。关于用户标签，一般包括性别、年龄、职业、爱好等信息。在电子商务中，推荐系统可以根据用户标签推荐用户可能感兴趣的物品，在视频推荐中，可以推荐用户可能感兴趣的视频。而在社交网络领域，可以利用用户之间标签的相似性来快速找到用户“邻居”。图6为QQ中的标签的应用实例，通过标签能够找到拥有共同爱好的朋友，并且，新注册用户通过给自己标注标签，可以有效的缓解冷启动问题。



图6 QQ中的标签应用实例

项目标签与用户标签相似，可以较好的描述项目特征。结合用户的行为历史，通过项目标签相似度计算可以快速找到用户可能感兴趣的项目，因此，项目标签在推荐系统中也是非常重要的推荐依据来源。

2.4 深度学习下的推荐系统

近年来，深度学习技术飞速进步，尤其在图像处理、自然语言处理等领域，取得了非常大的发展。在推荐系统中引入深度学习方法是近年来的流行趋势，已有大量工作证明了这种做法的可行性^[49-51]。与传统的推荐方法相比，使用深度学习的模型一般具有更强的特征表达及泛化能力，在实际推荐应用场景，也往往能够带来更惊喜的效果。

2.4.1 NCF 框架

NCF (Neural Collaborative Filtering) 即为神经协同过滤^[20], 是一种结合了神经网络与协同过滤的推荐系统框架。在 2.2 节中, 已经介绍过矩阵算法, 矩阵分解在最后的评分估计环节通过将用户特征向量和项目特征向量进行内积操作得到, 然而, 简单的内积操作往往不具备较好的特征表达能力, 从而容易使模型欠拟合。因此, 针对这种缺陷, NCF 框架被提出来。NCF 框架基于矩阵分解等协同过滤模型, 在评分预测环节, 使用多层感知机进行特征映射实现评分预测。简单来说, 在矩阵分解中结合 NCF 框架, 只需要将多层感知机代替内积操作即可。NCF 框架的基本结构如图 7 所示。




图 7 NCF 框架

NCF 框架事实上可以看作作为一种通用框架, 它可以被方便地修改。在神经网络层之前的特征输入部分, 可以采用其他形式获得 Embedding 向量, 而不仅仅局限于使用矩阵分解得到, 另外, 在神经网络层部分, 也可以使用不同于普通多层感知机的其他网络结构。

关于模型的神经网络部分, 具体的, 由于神经网络的隐含层之中一般使用如 Sigmoid、ReLU 等激活函数, 这些函数都是非线性的, 神经元并非任何时候都能被激活, 因此, 使用神经网络的模型具有更强的非线性表达能力。理论上, 在神经元数量和网络层数量不受限制的情况下, 神经网络可以拟合任何非线性函数。基于这些特点, 使用神经网络进行评分输出, 效果要好于简单的内积操作。但是需要注意的是, 模型的拟合能力并非越强越好, 因为模型在训练集上的拟合能力强并不能证

明在测试集上也能达到同等的效果，如果训练集上表现很好，而测试集上表现很差，则表明模型存在过拟合问题。因此，选择适当的网络层数与神经元数非常重要，因为网络过复杂容易造成过拟合，而过简单又容易出现欠拟合。一般，采用适中的网络结构，并采用正则化，可以使模型达到较好的效果。

2.4.2 Word2Vec

Word2Vec 是一种词向量模型^[26-27]，该模型的功能是将词语映射到一个潜在空间，使每个词语以向量的形式表示出来。Word2Vec 不仅在自然语言处理领域有着较为广泛的应用，并且在推荐系统领域也有应用^[52]。

简单来说，Word2Vec 是将词语转化为计算机能够读懂的数字形式，并且不同词语的“数字特征”不能相同，以保证词语之间的差异性。

将词语转化为数字形式的最简单的一种方法是使用 one hot 向量，one hot 向量中，只有某一维度的值为 1，其余均为 0。假设有两个语句，分别为“我国的首都是北京”以及“你去过首都北京吗”，这两句话共包含 8 个词，分别为‘我国’、‘的’、‘首都’、‘是’、‘北京’、‘你’、‘去过’、‘吗’，那么，如果使用 one hot 向量形式表示，则每个词语为一个 8 维向量，具体表示形式如表 4 所示。

表 4 词语的 one hot 表示

词语	One hot 向量	词语	One hot 向量
我国	(1,0,0,0,0,0,0,0)	你	(0,0,0,0,0,1,0,0)
的	(0,1,0,0,0,0,0,0)	去过	(0,0,0,0,0,0,1,0)
首都	(0,0,1,0,0,0,0,0)	首都	(0,0,1,0,0,0,0,0)
是	(0,0,0,1,0,0,0,0)	北京	(0,0,0,0,1,0,0,0)
北京	(0,0,0,0,1,0,0,0)	吗	(0,0,0,0,0,0,0,1)

One hot 向量虽然能够差异性的表示每一个不同的词语，但是也存在两个问题。第一，存储空间需求大、某些场景下计算量大。对于大型的语料库，词语数可能是上万级别，如果使用 one hot 向量来表示每个词语，那么，向量维度极大，极为稀疏，因此存储这些词语需要耗费较大的空间，并且，在某些计算场景下，向量维度大也会带来计算资源消耗大的问题。第二，词语之间无法表现关联性或相似性。以表 4 为例，表中的两个句子中均有“首都”和“北京”两个词语，并且在语境中的位置靠得很近，仅通过简单的观察便能看出这两个词语存在某些关联性，但是 one hot 向量却没有考虑这种关联性。而经 Word2Vec 模型生成的词向量便可以很好的解决上述两个问题。

Word2Vec 模型的输入为一个含有大量句子的语料库，输出为每个词语对应的潜在特征向量。由于每个词语都有较为固定的实际意义，词语的出现语境一般不会有太大的差异，因此，Word2Vec 的核心思想是通过分析词语的上下文来捕捉词语之间的相似性，在任意一个句子中，通过滑动窗口来完成句子中词语特征的训练，某一时刻，处于同一窗口内的词语被认为是有关联的。

对于一个长度为 T 的句子 $S = [w_1, w_2, w_3, \dots, w_{T-1}, w_T]$ ，认为距离靠得越近的词语往往越相似，或者说越具有关联性。因此，Word2Vec 通过词预测进行模型训练，即根据给定词预测周边词。比如，在之前的训练过程中，如果词语 w_1 和 w_2 经常同时出现，那么在某种情况下对 w_1 进行周边词预测时，预测为 w_2 的概率会比较大。Word2Vec 有两种预测方式，一种为 CBOW 方式，该方式通过输入的周边词对中心词进行预测，而另一种是 Skip-gram 方式，该方式与 CBOW 相反，通过输入中心词对周边词进行预测。两种方式的结构如图 8 所示，其中， $w(t)$ 为中心词，其余为周边词，根据经验，Skip-gram 的效果要优于 CBOW。




图 8 CBOW 结构和 Skip-gram 结构

无论是 Skip-gram 还是 CBOW，实际上都是基于神经网络结构的，并且网络结构非常简单，并没有使用深层网络。以 Skip-gram 为例，其神经网络结构如图 9 所示。




图 9 Skip-gram 神经网络结构

从 Skip-gram 的网络结构可以看出，该网络包含输入层、输出层、以及一个隐含层。输入词的向量维度为 V ，首先通过权重矩阵 $W_{V \times N}$ 映射成 N 维向量，然后再经权重矩阵 $W'_{N \times V}$ 映射成 V 维向量输出。

前面已经提到，Word2Vec 通过滑动窗口来确定窗口内的词语具有相关性，因此，对于某一时刻的窗口内的所有词的组合，可以看作为一个训练样本，在 Skip-gram 中，优化目标是使中心词与所有周边词的关联性最大化，用公式可以表示为：

$$aim = \frac{1}{T} \sum_{t=1}^T \sum_{-c \leq j \leq c, j \neq 0} \log p(w_{t+j} | w_t) \quad (10)$$

式中：

T —句子长度；

c —左窗口或右窗口大小；

w_{t+j} —上下文词（周边词）；

w_t —中心词；

$p(\cdot)$ —条件概率。

因此从数学角度来看，目标是使得 aim 最大化。那么，接下来的问题便是确定概率 $p(w_{t+j} | w_t)$ 的取值。事实上，对于周边词的预测可以看作为一个多分类问题，语料库中的每个独立词代表一个类别，而在神经网络中处理多分类问题的一种简单而又有效的方法便是使用 Softmax 函数。Softmax 函数可以将神经网络的输出组合变换为概率形式输出，即为每一个类别都对应输出一个概率值，概率最大的类便为分类结果。Softmax 函数的表达式为：

$$Softmax(y_i) = \frac{e^{y_i}}{\sum_{c=1}^C e^{y_c}} \quad (11)$$

式中：

y_i —输出的第 i 个元素值；

C —类别总数。

在 Skip-gram 中，词语之间的关联性通过词向量的内积表示，因此，结合 Softmax 函数， $p(w_{t+j} | w_t)$ 的计算公式为：

$$p(w_o | w_l) = \frac{\exp(v'_{w_o} \cdot v_{w_l})}{\sum_{w=1}^W \exp(v'_w \cdot v_{w_l})} \quad (12)$$

式中：

w_o —窗口内的周边词；

w_l —中心词；

v'_w — w 的输出向量；

v_w — w 的输入向量；

W —总词数。

上述即为 Skip-gram 的标准多分类训练过程。然而在实际训练中，这种方式的计算复杂度是非常高的。上面已经提到，语料库中的每一个独立词即代表一个类别，使用 Softmax 进行多分类时，为了输出每个类别的预测概率值，输出层的神经元数应与语料库中独立词的总数相等。当语料库比较小时，这种做法带来的效率或许是可以接受的，但当面对大型语料库时，独立词数量上万级别，输出层的神经元也是上万级别，计算量非常大，因此使用标准多分类变得不太现实。“负采样”训练成了解决该问题的一种有效方法。

在负采样训练中，正样本为周边词，负样本为噪声词，负样本是所有词的子集，并且一般只取非常少数量的噪声词作为负样本，因此使用负采样不需要再对语料库中的每个词进行概率输出，只需要将周边词与噪声词区分开来即可，并不关心负样

本之间的差异性。使用负采样后，模型的优化目标变为：

$$aim' = -\log \sigma(v'_{w_o}{}^T h) - \sum_{w_j \in W_{neg}} \log \sigma(-v'_{w_j}{}^T h) \quad (13)$$

式中：

$\sigma(\cdot)$ —Sigmoid 函数；

v'_{w_o} —正样本词的向量；

h —隐层向量；

W_{neg} —负样本集合。

上式中，Sigmoid 函数的具体表达式为：

$$sigmoid(x) = \frac{1}{1 + e^{-x}} \quad (14)$$

使用负采样后，训练速度能够得到大幅提升。另外，在谷歌所公开的 Word2Vec 源代码中，还有许多可以自定义的参数（如表 5 所示），通过反复对这些参数进行调节，并进行训练，最终可以获得一个较好的词向量输出结果。

表 5 Word2Vec 模型中的部分训练参数

参数	功能	参数	功能
sentences	语料库输入	min_count	词频最低限制
sg	训练算法选择	sample	高频词负采用阈值
size	特征向量维度	negative	负采样（噪声词数）
window	窗口大小	iter	迭代次数
alpha	学习率	seed	随机初始词向量

上面已经重点介绍了 Word2Vec 中 Skip-gram 的基本原理，其简单的神经网络结构，配合负采样训练方法，能够高效的将词语映射为潜在空间的词向量，事实上，Word2Vec 也能在推荐系统中高效的应用，不过在推荐系统中，Word2Vec 有了新的名字，称为 Item2Vec^[25]。

Item2Vec 与 Word2Vec 原理几乎完全一致，Item2Vec 可以根据用户或项目的共现情况分别将用户或项目映射到潜在空间，实现用户或项目的向量表示。以本章的表 1 为例，根据用户的共现情况，可以将每个用户视为一个词语，把与同一个项目有过交互行为的所有用户组成一个句子，从而可以产生 4 个句子，分别为： $S_1 = [u_1, u_4]$ ， $S_2 = [u_3, u_4]$ ， $S_3 = [u_1, u_2]$ ， $S_4 = [u_1, u_2]$ 。同理，根据项目共现的情况，将每一个项目视为一个词语，把与同一个用户有过交互行为的所有项目组成一个句子，也可以产生 4 个句子，分别为 $S_1 = [i_1, i_3, i_4]$ ， $S_2 = [i_3, i_4]$ ， $S_3 = [i_2]$ ， $S_4 = [i_1, i_2]$ 。

最后通过对这些句子的训练，便可以生成对应的向量。

第3章中将会对 Item2Vec 做进一步介绍。

2.5 召回与排序

找到用户可能感兴趣的东西，并展现给用户，这是推荐系统与用户进行交互的核心步骤。对于轻量级的用户、项目库，通过全库搜索对比并完成推荐任务仅需要毫秒级的运算时间。但是现实应用中，用户、项目量往往都是十分庞大，这时候如果完整的计算点击预估并进行排序，由此耗费的时间是无法令人接受的。

因此，在实际应用中，可将推荐过程拆分为召回和排序两个阶段。其中，召回层的功能是完成对候选集的快速筛选。在这一部分工作中，推荐系统并不逐一对所有特征进行计算，即不将用户的完整特征与每个项目的完整特征去进行评分或相似性计算，比如仅根据年龄与性别等信息便可以过滤掉大部分项目，达到快速粗选的目的。经过召回层的粗选，推荐的项目集可以迅速从百千万级别降至百千级别，此时再进行精细计算便可完成推荐。

排序阶段的目的是召回的项目进行精细计算，由于召回的项目数量比较少，因此在排序阶段可以将所有的特征因素考虑进去进行计算，按照预估评分或各种相似性算法来完成 Top-K 列表的生成。图 10 为 YouTube 视频网站^[29]的召回与排序策略。




图 10 YouTube 的召回排序策略

2.6 本章小结

在本章中，首先介绍了推荐系统中存在的技术难题，包括个性化问题、稀疏性问题、冷启动问题、以及扩展性问题等；然后，对用户行为中的显性行为 and 隐性行为分别进行了概述，并介绍了基于用户行为的推荐算法，包括传统的协同过滤算法

和矩阵分解算法；介绍了基于标签的推荐系统，包括用户标签和项目标签在推荐系统中作用；介绍了深度学习技术在推荐系统中的应用，包括 NCF 框架和 Word2Vec 词向量模型；最后介绍了推荐系统的召回与排序阶段。一个好的推荐系统离不开好的理论算法支撑，在后面章节，将基于本章节的理论基础构建推荐系统模型，并进行相关实验。

第3章 基于空间维度距离度量和用户显性行为的推荐算法

对于使用神经网络构建的推荐模型，需要将用户与项目进行特征融合来得到二者的交互特征，以映射到预测评分。然而目前常用的特征拼接方法难以较好地表达用户与项目的交互性，从而使得模型收敛较慢，甚至难以获得令人满意的推荐效果。因此，本章提出了一种基于空间维度距离度量和用户显性行为的推荐算法（Recommendation Algorithm based on Spatial Dimension Distance Measurement and User Explicit Behavior, SDDM-UEB），以提高推荐性能。首先将可动态调整的关联窗口引入到 Item2Vec 中，以捕捉行为序列中获得不同评分的项目之间的差异，并由此得到项目特征向量；其次，将所提空间维度距离度量用于用户与项目的特征融合，通过度量用户与项目在潜在空间中不同维度上的距离来评估用户对项目的感兴趣程度；最后，针对推荐阶段的用户兴趣疲劳问题，采用基于余弦相似度的重排序法对 Top-K 列表进行排序调整，达到缓解兴趣疲劳的目的。在公开的 MovieLens 数据集上进行大量实验，验证了所提方法的有效性。

3.1 Item2Vec 的改进

Item2Vec 将项目名称映射到潜在空间，并通过计算相似度来捕捉项目之间的差异，与 Word2Vec 有着高度相似性。在 Item2Vec 中，用户的行为序列、交互项目分别与 Word2Vec 中的句子、词语相对应。

在 Word2Vec 中，存在时间窗口的概念，认为处于同一窗口内的词语有着高度的关联性。但是 Item2Vec 摒弃了时间窗口的概念，认为样本序列中的任意两个项目之间都存在着相关性，因此在 Item2Vec 中，对于任意项目 w_i ，其上下文是对应行为序列中除该项目以外的所有项目的集合。Item2Vec 的优化目标为：

$$L = \frac{1}{K} \sum_{i=1}^K \sum_{j \neq i}^K \log p(w_j | w_i) \quad (15)$$

式中：

K —行为序列长度；

$p(\cdot)$ —条件概率；

w_j, w_i —项目。

Item2Vec 将同一行为序列中的所有项目“平等”看待，忽略项目之间的差异性，然而这种方法只能适应于两种情况：

1) 适用于隐性行为序列。隐性行为没有正负反馈之分，或者说仅有正反馈，这种情况下适合以“一视同仁”的原则来对待序列中的所有项目；

2) 适用于偏好序列。偏好序列中的项目都是用户喜欢的项目，可以全部看作为正反馈项目，因此也适合“平等”看待。

但是，对于显性行为序列，里面一般既有正反馈项目，也有负反馈项目，而对于评分数据，由于评分等级划分较多甚至不能简单的仅用正负两种反馈来表示，这时候如果直接用原先的 Item2Vec 模型，认为行为序列中的任意两个项目都有相关性，则会严重影响生成项目特征向量的准确性。

为了使 Item2Vec 适应于同时含有多个等级的显性评分序列，对于同一评分序列，近似认为取得相同评分等级的项目之间具有一定的相似性，并在 Item2Vec 中引入随评分等级动态变化的窗口对项目特征进行训练。对于每个用户的评分记录，先对项目按照分值进行排序，得到序列 S_u 。假设序列中项目 w_i 的评分为 r_i ，所有评分为 r_i 的项目集合为 R_i ，对比式 (15)，目标函数可以调整为：

$$L = \frac{1}{K} \sum_{i=1}^K \sum_{j|r_j \in R_i, j \neq i} \log p(w_j | w_i) \quad (16)$$

式中：

K —行为序列长度；

$p(\cdot)$ —条件概率；

w_j, w_i —项目。

调整后，Item2Vec 的窗口移动过程如图 11 所示，窗口大小由集合 R_i 大小决定。





图 11 窗口移动过程

事实上，上述方法仍存在一个问题。以上图为例， r_1 与 r_2 大小非常接近，但是上述方法将所有评分为 r_1 的项目放到集合 R_1 ，评分为 r_2 的项目放到集合 R_2 ，在训练时 R_1 和 R_2 处于不同的窗口区分训练，从而无法捕捉到评分为 r_1 的项目与评分为 r_2 的项目在潜在空间的相似性。考虑到上述问题，将模型进一步改进。当对窗口里的项目集合 R_i 进行训练时，随机选取下一个相邻集合 R_{i+1} 中的 q 个项目组成的集合 Q_{i+1} 与 R_i 一起训练，当 R_{i+1} 不存在时， Q_{i+1} 为空集。由此，得到改进的 Item2Vec 最终优化目标函数：

$$L = \frac{1}{K} \sum_{i=1}^K \sum_{j|r_j \in (R_i \cup Q_{i+1}), j \neq i} \log p(w_j | w_i) \quad (17)$$

3.2 SDDM-UEB 模型与方法流程

SDDM-UEB 模型的总架构如图 12 所示，该模型的输入为用户显性行为序列，输入的行为序列经 Item2Vec 模块得到项目的 Embedding 特征（特征向量），而用户初步特征则根据其对应行为序列中的项目特征经过平均池化获得，并经神经网络深度学习后得到最终的用户特征。最后将用户特征与项目特征经过基于空间维度距离度量的方法进行特征融合，并经过全连接层映射到 1 维评分。



3.2.1 项目特征与用户初始特征表示

设所有用户的集合为 $U = \{u_1, u_2, u_3, \dots, u_{n-1}, u_n\}$ ，所有项目的集合为 $I = \{i_1, i_2, i_3, \dots, i_{m-1}, i_m\}$ ，则由用户 u 的所有评分行为组成的序列集合可以表示为：

$$S_u = \{S_u^1, S_u^2, S_u^3, \dots, S_u^{q-1}, S_u^q | S_u^i \in I, u \in U\} \quad (18)$$

式中：

S_u^i — 用户 u 对项目 i 的评分行为。

所有参与训练的序列集合为：

$$TS = \{S_{u_1}, S_{u_2}, S_{u_3}, \dots, S_{u_{n-1}}, S_{u_n}\} \quad (19)$$

经过 Item2Vec 训练迭代，得到所有含评分记录的项目的特征集合 $V(I) = \{V_{i_1}, V_{i_2}, V_{i_3}, \dots, V_{i_{m-1}}, V_{i_m}\}$ ，其中每个项目的特征都是密集向量，且维度为 j 。（对于所有项目特征向量，均需要进行规范化处理。）

结合项目特征与用户行为记录，将用户的行为记录转化为“特征矩阵”形式，

其中用户 u 的特征矩阵 N_u 表示为:

$$N_u = \begin{bmatrix} N_u^1 \\ N_u^2 \\ \vdots \\ N_u^q \end{bmatrix} = \begin{bmatrix} (N_u^1)_1 & (N_u^1)_2 & \cdots & (N_u^1)_j \\ (N_u^2)_1 & (N_u^2)_2 & \cdots & (N_u^2)_j \\ \vdots & \vdots & \ddots & \vdots \\ (N_u^q)_1 & (N_u^q)_2 & \cdots & (N_u^q)_j \end{bmatrix} \quad (20)$$

式中:

$N_u^i \in V(I)$ —表示项目 i 的特征向量。

对于每一个用户 u ，其初始特征由与其对应的特征矩阵 N_u 转化产生。但并非 N_u 中的所有特征向量都能用来表达用户的兴趣偏好，因为其中可能存在一些并未获得高分的项目。因此，只选取记录中获得了高分的项目的特征作为生成用户初始化特征的依据。设所有用户的特征向量为 $V(U) = \{V_{u_1}, V_{u_2}, V_{u_3}, \dots, V_{u_{n-1}}, V_{u_n}\}$ ，其中用户 u 的初始特征向量通过下式得到:

$$V_u = \frac{1}{t} \left(\sum_{i=1}^t (N_u^i)_1, \sum_{i=1}^t (N_u^i)_2, \dots, \sum_{i=1}^t (N_u^i)_j \right), t \leq q \quad (21)$$

式中:

t —用户 u 喜欢的项目总数;

q —用户 u 进行过评分的项目总数。

由于用户的特征向量是根据用户行为矩阵进行平均池化而得到的，因此用户特征向量与项目特征向量位于同一个潜在空间中。如图 13 所示。图中显示了一个 3 维特征空间，其中蓝色箭头表示用户行为序列中的两个项目的特征向量，红色箭头表示用户初始特征向量，它是由两个项目的特征向量平均池化而来。




图 13 潜在空间的特征向量

3.2.2 用户特征学习

虽然得到了用户的初始特征，但初始特征是通过平均池化得到，并不能准确表达出用户的真实偏好，如果使用用户初始特征与项目特征进行融合，则难以实现准确的预测。因此，在进行评分回归之前，加入全连接层模块，以增强用户的特征表示。该全连接层模块的输入即为用户的初始特征密集向量，输出为最终的用户向量。全连接的基本结构如图 14 所示。




图 14 全连接结构

为了使最终输出的用户特征与项目特征仍然处于同一潜在空间，因此，经过全连接处理的用户特征并不发生维度变化，特征维度保持为 j 。全连接层采用 Leaky ReLU 激活函数^[53]，该函数具有易求导、能够减缓梯度消失，且不会出现神经元死亡等优点，在实际训练中能够使模型较快地收敛而不会降低准确性，其表达式为：

$$f_{LReLU}(x) = \begin{cases} x, & x \geq 0 \\ ax, & x < 0 \end{cases} \quad (22)$$

式中：

a —预先定义取值的参数。

对于第 t 个隐层，设输入为 $X_t = (x_1, x_2, x_3, \dots, x_{j-1}, x_j)$ ，输出为 $Y_t = (y_1, y_2, y_3, \dots, y_{j-1}, y_j)$ ，在向前传播训练过程中，满足：

$$Y_t = f_{LReLU}(X_t \cdot W_t + B_t) \quad (23)$$

式中：

W_t —权重矩阵；

B_i —偏置矩阵。

在反向传播过程中，使用均方误差损失函数评估预测值与真实值之间的差异，以进行权重矩阵 W 与偏置矩阵 B 的更新，并使用 L2 正则化防止模型过拟合，损失函数表达式为：

$$L = \frac{1}{k} \left(\sum_{i=1}^k (y_i - \hat{y}_i)^2 + \sum_{l=1}^T \phi_{L2}(W_l) \right) \quad (24)$$

式中：

k —单批次训练的样本量；

y_i —真实评分值；

$\hat{y}_i$ —预测评分值；

T —网络层数目。

3.2.3 基于空间维度距离度量的特征融合

前面分别得到了项目特征与用户特征表示，接下来的工作是将二者进行特征融合并再次经过全连接层实现预测评分的输出。为了方便阐述，把由一个用户特征和一个项目特征融合后的特征称作一个交互特征。所有交互特征根据用户对项目的评分记录所产生。例如，根据用户 u 对项目 i 的评分，将二者进行特征融合，便可以得到交互特征 $T_u^{(i)}$ 。

由 3.2.1 节可知，用户特征向量与项目特征向量始终处于同一潜在空间。对于同一空间的用户特征与项目特征，它们所对应的向量的终点在各个维度上的距离在一定程度上显示着它们之间的差异，而距离的大小则是影响用户对项目评分大小的关键因素。然而，通过 Item2Vec 训练的项目特征并不满足这样的规则，原因是 Item2vec 产生的向量通过余弦夹角度量它们之间的差异，如果直接根据向量终点在各个维度上的距离来衡量用户与项目之间的差异，这样显然是不合理的。因此，对于所有由 Item2vec 产生的特征向量，均需进行规范化处理，经规范化处理后的向量起点为空间原点，模长为 1，由此，各向量的终点在各维度之间的距离能够直接用于度量特征之间的差异。对于向量 $v = (v_1, v_2, v_3, \dots, v_{n-1}, v_n)$ ，其规范化公式如下：

$$v' = \frac{1}{\sqrt{\sum_{c=1}^n v_c^2}} (v_1, v_2, v_3, \dots, v_{n-1}, v_n) \quad (25)$$

当用户 u 对项目 i 有评分记录时，设 u 的特征向量为 $V_u = (v_u^{(1)}, v_u^{(2)}, v_u^{(3)}, \dots, v_u^{(j-1)}, v_u^{(j)})$ ， i 的特征向量为 $V_i = (v_i^{(1)}, v_i^{(2)}, v_i^{(3)}, \dots, v_i^{(j-1)}, v_i^{(j)})$ ，将二者的特征向量利用空间维度距离度量进行融合：

$$T_u^{(i)} = \left(\left| v_u^{(1)} - v_i^{(1)} \right|, \left| v_u^{(2)} - v_i^{(2)} \right|, \left| v_u^{(3)} - v_i^{(3)} \right|, \dots, \left| v_u^{(j-1)} - v_i^{(j-1)} \right|, \left| v_u^{(j)} - v_i^{(j)} \right| \right) \quad (26)$$

式中:

$\left| v_u^{(k)} - v_i^{(k)} \right|$ —用户 u 的特征与项目 i 的特征在第 k 维上的距离 (或差异)。

基于空间维度距离度量的特征融合方式不同于一般的特征串联方法。特征串联导致特征向量维度的增加将消耗更多的计算资源, 而通过空间维度距离度量进行特征融合, 融合后的特征维度不发生改变, 并且更好的表达了用户与项目之间的交互性。

3.2.4 评分预测

得到用户与项目的交互特征 (融合特征) T_u^i 后, 接下来的步骤是进行评分预测。在矩阵分解算法中, 评分一般通过用户与项目特征向量的点乘得到, 即不需要生成交互特征向量, 但是点乘的方式往往不具备较好的特征表达能力和模型泛化能力。因此, 在这一部分中, 采用全连接映射的方式进行评分预测, 使交互特征经全连接层映射成 1 维评分值, 从整体上看, 这一部分的工作步骤与前面的用户特征学习环节基本相似, 因此不再赘述。

3.3 Top-K 排序优化

Top-K 列表是指在候选集中通过评分预测并进行排名, 把前 K 个项目呈现给用户的推荐列表。在常规的 Top-K 列表中, 往往排名靠前的项目更加贴合用户的特征, 并且在实际应用中, 一般把 Top-K 列表中靠前的项目展示在更加显眼的位置, 试图获得更高的点击率, 而在短视频推荐中, Top-K 中靠前的项目往往也优先被推荐。但是, 长期把过于贴合用户特征的项目排在前面, 并不一定能收获更高的点击率或更好的评价, 因为人的兴趣并不长期局限于同一类型的项目, 因此这种做法很容易引起兴趣疲劳。当然, 这种规律并不是绝对的, 对于采用神经网络的推荐模型, 由于其具有较强的泛化能力, 排名靠前的项目中也许存在少数并不完全贴合用户特征。

本小节通过计算用户特征与 Top-K 列表中所有项目特征的相似度来调整排序, 达到优化目的。考虑到在实际中难以预测用户是否已经产生兴趣疲劳, 因此在排序过程中, 采用交叉排序的方法, 即把与用户特征相似度高的电影和与用户特征相似度低的电影在列表中交叉呈现, 基本流程如图 15 所示。




图 15 排序流程

用户 u 与项目 i 的相似度表示为：

$$Similar(u, i) = \frac{1}{2} \left(\frac{V_u \cdot V_i}{\|V_u\| * \|V_i\|} + 1 \right) \quad (27)$$

式中：

V_u —用户 u 的特征向量；

V_i —项目 i 的特征向量。

上式基于余弦相似度所得，并将 u 与 i 之间的相似度取值映射在 $[0,1]$ 的范围内。

具体算法描述如算法 1 所示,其中 TK_List 为 Top-K 列表。

算法 1:Top-K 排序优化

输入：未调整排序的 TK_List

输出：调整后的 TK_List

1: **for each** i **in** TK_List **do**

2: $sim_u^i = similar(u, i)$;

3: **end for**

4: 根据相似度对 TK_List 列表从低到高进行排序;

5: $t = 0$; $K = length(TK_List)$;

6: **while** $t \leq K - 2$ **do**

7: $TK_List_K \rightarrow TK_List_{t+1}$ (把 TK_List 中的最后一个项目插入到 TK_List_{t+2} 前面);

8: $t = t + 2$;

9: **end while**

10: **return** TK_List

3.4 实验

3.4.1 数据集

实验使用了公开的电影评分数据集 MovieLens 100K 和 MovieLens 1M (数据集地址为: <https://grouplens.org/datasets/movielens/>), 其中 MovieLens 100K 包含了大约 950 用户对 1600 余电影的十万个评分, 该数据集的稀疏程度高达 93.7%, 而 MovieLens 1M 包含了大约 6000 用户对 4000 部电影的一百万个评分, 该数据集的稀疏程度高达 95.7%。两个数据集中的评分皆分为 5 个等级, 最低为 1 分, 最高为 5 分。其中每个用户至少对 20 部电影进行过评分。

在实验中, 数据集被按 8:2 的比例随机分割成训练集和测试集。

3.4.2 主要评估标准

本章所提算法的目的是实现评分预测, 预测评分越接近真实值, 则表明算法越优秀。因此在本章中, 度量预测值与真实值之间的偏差是一种简单而又有效的方法。常用的这类度量方法有 MSE、RMSE、MAE 等。本文选用 RMSE 和 MAE 作为主要评估标准, 对于这两个指标, 值越小, 表示推荐系统性能越好。后面将与其他一些经典算法根据这两个指标进行性能比较。

其中, RMSE 指标的计算公式如下:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (28)$$

MAE 指标的计算公式为:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (29)$$

上述两式中:

n —评分样本数量;

y_i —真实评分;

$\hat{y}_i$ —预测评分。

3.4.3 实验过程与分析

实验基于 Pytorch 深度学习框架进行, 并使用多线程方式加快训练速度, 实验硬件平台为: Intel i7-7700K, NVIDIA 1080ti, 64G RAM。

实验过程中，模型的学习率设置为 0.01，正则化系数为 0.015，最大训练批次为 500，根据训练损失的变化情况来控制迭代的终止，即当训练损失趋于稳定时终止迭代，并保存模型参数。下面，将从多个方面评估模型算法的性能。

1) 收敛性分析

在 Item2Vec 生成项目特征向量环节，生成的特征向量维数与后面的用户特征向量以及融合后的向量维数是相等的，向量维数标志着项目和用户在潜在空间的潜在因素数量，对模型性能有着重要的影响。因此，在实验过程中，分别在不同向量维数下进行了收敛性分析。图 16 为 MovieLens 1M 中 MSE 在不同特征向量维数下随迭代批次 (Epochs) 的变化情况，其中字母 d 代表特征维数。从图中可以看出，不同特征维数下模型的收敛性能存在差异，从收敛速度上看，特征维数为 96 时收敛效果最好。




图 16 不同特征维度下的收敛情况

为了验证本章提出的 SDDM-UEB 特征融合方法的有效性，在同等实验条件下与 Concatenate 特征拼接方法进行了对比实验，以 MovieLens 1M 为例，实验结果如图 17 所示。从图中可以看出，使用 SDDM-UEB 方法的收敛速度要优于 Concatenate 方法，这是由于 SDDM-UEB 方法直接将用户与项目在每个维度上对应的距离作为交互特征，体现了更强的交互性，而 Concatenate 方法则只是将用户特征与项目特征做串联操作，无法直接表达交互特性，因此，对于 Concatenate 方法，需要更多的学习代价才能捕捉到用户与项目之间的特征差异。





图 17 不同特征融合方法下的收敛情况


2) 回归表现分析

为了直观展现预测回归的性能表现,从测试集上随机抽取了 500 个样本进行预测并生成变化曲线,然后与真实值的变化曲线进行比较,如图 18 所示,该图分别展示了在 MovieLens 100k 数据集和 MovieLens 1M 数据集上的预测结果。

从图中可以看出,预测值的变化幅度相对于真实值来说较为平缓,这是由于在模型中加入了正则化参数,有效防止了过度拟合的问题,同时提升了泛化能力。通过多次实验结果发现,模型在 MovieLens 1M 上的表现要略好于在 MovieLens 100k 上的表现,这是由于 MovieLens 1M 上的样本数量更多,生成的用户特征与项目特征更加准确。



(a) MovieLens 100k 上的结果



(b) *MovieLens 1M* 上的结果

图 18 样本预测曲线

3) 算法性能对比

为了更好的验证算法性能，将本章所提方法与 BiasMF^[54]、SVD++^[10]、AutoSVD++^[55]、NNMF^[56]、FML^[57]、文献[58]中的算法在 RMSE 和 MAE 指标上进行了对比，对比结果如表 6 所示。从表中可以看出，所提算法略优于文献[58]所提的方法，较大程度上优于其他算法。

表 6 算法性能对比

算法模型	MovieLens 100K		MovieLens 1M	
	RMSE	MAE	RMSE	MAE
BiasMF[54]	0.901	0.709	0.847	0.663
SVD++[10]	0.896	0.703	0.839	0.657
AutoSVD++[55]	0.904	0.713	0.848	0.665
NNMF[56]	0.903	0.709	0.843	0.669
FML[57]	0.891	0.696	0.836	0.654
文献[58]	0.874	0.687	0.823	0.645
SDDM-UEB	0.867	0.677	0.820	0.641

3.5 本章小结

本章提出一种基于空间维度距离度量和用户显性行为的推荐算法 SDDM-UEB。首先介绍了原先的 Item2Vec 模型，并针对该模型的滑动窗口部分进行了改进，使其更加适应于显性评分序列中项目特征向量的学习，另外，通过多层神经网络对用户特征进行了深层映射。在特征融合过程中，将用户特征和项目特征通过 SDDM-UEB

方法进行融合，并经全连接层映射，实现了预测评分的输出。最后，提出了基于余弦相似度的 Top-K 列表重排序法，用来缓解用户的兴趣疲劳。

评估了所提 SDDM-UEB 算法在不同向量维数情况下的性能表现；通过曲线图的形式展示了模型在评分预测回归上的表现；对采用基于空间距离度量特征融合的方法与采用普通特征拼接的方法在收敛速度上进行了比较；为了进一步验证所提算法的有效性，与一些经典推荐算法进行了比较。

第 4 章 融合标签信息与用户隐性行为的推荐算法

在本章中，将针对用户行为序列中的隐性行为构建推荐算法模型。为了更好的得到用户的偏好特征，通过隐性行为中项目标签的出现频次统计来捕捉用户的兴趣，另外，考虑到用户的兴趣变化，引入时间衰减函数动态修改用户特征，使特征更接近于近期的偏好。最后通过神经网络将用户与项目的拼接特征进行映射，输出点击预估评分。

4.1 算法模型架构

模型的总架构如图 19 所示。




图 19 模型总架构

由于模型较为复杂，因此先对模型中的一些参数作解释说明（这些参数名词在

后面会多次出现)：

- 1) 用户 u 交互过的项目——即用户的隐性行为记录，记录中包含了该用户所有进行过隐性行为（如点击、浏览等）的项目。
- 2) 用户 u 的标签——类似于性别、年龄、职业之类的标签。
- 3) 项目标签统计——对用户交互过的项目所对应的标签进行统计，以便知道用户比较偏爱含有哪些标签的项目。
- 4) 衰减函数——用于确定项目标签统计中标签的权重。
- 5) 用户交互标签特征——是项目标签统计的结果，为稀疏向量形式。
- 6) 用户标签特征——用户标签的稀疏向量表示。
- 7) 项目 i 交互过的用户——所有与项目 i 有过交互行为的用户的集合。
- 8) 项目 i 的标签——以电影为例，类似于喜剧、爱情、战争之类的标签。
- 9) 用户标签统计——对项目交互过的用户所对应的标签进行统计，以便知道该项目一般受含有哪些标签的人青睐。
- 11) 项目交互标签特征——是用户标签统计的结果，为稀疏向量形式。
- 12) 项目标签特征——项目标签的稀疏向量表示。
- 13) Embedding 层——将稀疏向量映射为稠密向量。
- 14) Concatenate——特征拼接（串联）操作
- 15) Leaky ReLu——一种激活函数

该模型分为特征表示以及评分预测两部分。其中，生成用户特征的主要依据包括用户隐性行为记录中项目所对应的标签信息，以及用户自身的标签信息（如性别、年龄等），并且引入时间衰减函数对过去太久的项目进行标签“降权”操作。而生成项目特征的主要依据包括与该项目有过交互行为的所有用户所对应的标签信息，以及项目自身的标签信息。在评分预测过程中，使用全连接层进行映射。下面，将对该模型的方法流程进行更加详细的介绍。

4.2 方法流程

4.2.1 初始特征表示

设所有用户的集合为 U ，所有项目的集合为 I ，对于任意 $u \in U$ ， $i \in I$ ，若存在隐性交互行为，则将该行为记为 T_u^i ，因此，用户 u 的所有隐性行为的集合可以记作为：

$$T_u = \{T_u^{i_1}, T_u^{i_2}, T_u^{i_3}, \dots, T_u^{i_{n-1}}, T_u^{i_n}\} \quad (30)$$

设项目标签库中所有标签组成的集合为 L ，标签总数为 m ，对于项目 i ，可能同时对应多个标签，因此项目 i 的标签也用集合形式表示，即：

$$L_i = \{l_1, l_2, l_3, \dots, l_{j-1}, l_j \mid j \leq m\}, L_i \subseteq L \quad (31)$$

得到隐性行为的集合，并且已知集合中每个项目所对应的标签，接下来便可以将标签与行为相结合，生成行为标签集合，行为标签集合中记录了所有历史交互过的项目标签。对于用户 u ，其行为标签集合可以表示为：

$$T_u^L = \{T_u^{L_{i_1}}, T_u^{L_{i_2}}, T_u^{L_{i_3}}, \dots, T_u^{L_{i_{n-1}}}, T_u^{L_{i_n}}\} \quad (32)$$

行为标签集合虽然能在一定程度上反映用户的偏好，但是并不能直接输入到神经网络进行训练，因此，先对集合中所有标签的出现频次进行统计，并将统计结果转化成向量形式来表示“用户交互标签特征”。先以无时间衰减的情形为例，在该情形下，对于每一个交互的项目，其标签特征同样使用向量形式表示，其中，特征向量的每一个维度代表一个标签信息，如果项目存在某一标签，那么其特征中该标签所对应向量维度的取值为 1，否则为 0。而对于用户交互标签特征向量，则由行为序列中所有项目的特征向量在各个维度上的和得到。表 7 展示了用户 u 的隐性行为标签统计示例（以标签库中的标签总数 $m=6$ 、用户 u 的隐性交互项目个数等于 4 为例）。

表 7 用户 u 隐性行为中的标签统计

项目	标签					
	l_1	l_2	l_3	l_4	l_5	l_6
i_1	1	0	0	1	1	0
i_2	0	0	1	0	1	1
i_3	0	1	0	1	0	0
i_4	1	0	0	1	1	1
总计	2	1	1	3	3	2

根据上表，项目 i_1 的标签特征向量为 $v_{i_1} = (1, 0, 0, 1, 1, 0)$ ，用户 u 的交互标签特征向量为 $v_u = (2, 1, 1, 3, 3, 2)$ ，这些向量的维数均为项目标签库中的所有标签总数。

经过上述步骤已经计算出所有用户的交互标签特征以及所有项目的标签特征，用同样的方式，用户标签特征与项目交互标签特征也可以快速得到。

对于用户标签特征，一般来说包含多个方面，如性别、年龄、职业等，这些标

签可以有多种取值，比如性别类标签分为男、女两种取值，年龄和职业的取值范围更大。那么在对用户标签进行向量表示时，需要先按照不同的标签类别分别处理，即分别将性别、年龄、职业等转化为 one hot 向量形式（其中年龄也可以直接用具体数值表示），然后再对这些 one hot 向量进行串联操作，即可得到完整的用户标签特征（为稀疏特征）。

对于项目交互标签特征，同用户交互标签特征一样，通过“统计”方式得到。设与项目 i 进行过交互的用户的集合为 $T_i = \{u_1, u_2, u_3, \dots, u_{m-1}, u_m\}$ ，集合中的用户所对应的用户标签特征向量分别为 $v_{u_1}, v_{u_2}, v_{u_3}, \dots, v_{u_{m-1}}, v_{u_m}$ ，则项目交互标签特征由下式定义：

$$v_{T_i} = \frac{1}{m} \left(\sum_{x=u_1}^{u_m} v_x^{(1)}, \sum_{x=u_1}^{u_m} v_x^{(2)}, \sum_{x=u_1}^{u_m} v_x^{(3)}, \dots, \sum_{x=u_1}^{u_m} v_x^{(k-1)}, \sum_{x=u_1}^{u_m} v_x^{(k)} \right) \quad (33)$$

式中：

$v_x^{(j)}$ —向量 v_x 在 j 维上的取值；

k —向量 v_x 的维数。

4.2.2 融入时间衰减

上述用户交互标签特征是在无时间衰减情况下得到的，然而在现实中，用户的兴趣往往是动态变化的。以电影推荐场景为例，当某个用户在之前很长一段时间喜欢战争题材电影，而最近突然对喜剧类感兴趣，在没有引入时间衰减时，由于用户是最近才喜欢喜剧类电影，那么在用户的整个行为序列中，与“战争”相关的标签要远多于与“喜剧”相关的标签，因此模型会依然倾向于推荐战争类型电影，无法捕捉到用户近期的兴趣变化。基于上述原因，在模型中引入时间衰减函数，以提升对用户兴趣变化的适应能力。

在这里，通过引入指数衰减函数^[59]来改变不同时间段交互项目所对应的标签权重。在指数衰减中，项目标签权重的下降速度与该值呈一定比例。因此，标签权重可以由给定的衰减函数 $\varphi(t)$ 表示。在本章中， t 为用户当前交互行为的时间与用户第一次交互行为的间隔， $\varphi(t)$ 满足：

$$\frac{d\varphi(t)}{dt} = -\lambda\varphi(t) \quad (34)$$

式中：

$-\lambda$ —衰减参数。

对于上式，可以找到一个解为：

$$\varphi(t) = a_0 e^{-\lambda t}, a_0 > 0 \quad (35)$$

式中:

a_0 —权重系数。

从 $\varphi(t)$ 的表达式可以看出, 当 $\lambda > 0$ 时, 时间间隔 t 与 $\varphi(t)$ 呈反比关系。因此, 对于行为历史中距离当前时间越久的项目, 其标签权重值越低。根据文献[59], λ 的值可由 $\lambda = \frac{1}{T_0}$ 确定, T_0 为一个可自定义的可变化参数。

为了方便计算, 项目的标签权重以向量形式表示。以用户 u 为例, 对于某一时刻的交互项目 i , 其对应的所有标签权重相同, 均由衰减函数给定, 因此可设标签权重向量为:

$$w_u^i = (\varphi(t_u^i), \varphi(t_u^i), \varphi(t_u^i), \dots, \varphi(t_u^i), \varphi(t_u^i)) \quad (36)$$

该标签权重向量的维数为 m , 与标签总数相等。因此, 在生成用户交互标签特征的过程中, 项目 i 的标签特征向量先转换为:

$$v_i' = v_i \odot w_u^i \quad (37)$$

式中:

v_i —项目 i 的原始标签特征向量, $v_i = (l_1^i, l_2^i, l_3^i, \dots, l_{m-1}^i, l_m^i)$;

w_u^i —项目 i 的权重向量。

从而, 用户 u 的交互标签特征可以表示为:

$$v_u' = \frac{1}{n} \left(\sum_{i \in I_u} l_1^i \cdot \varphi(t_u^i), \sum_{i \in I_u} l_2^i \cdot \varphi(t_u^i), \sum_{i \in I_u} l_3^i \cdot \varphi(t_u^i), \dots, \sum_{i \in I_u} l_{m-1}^i \cdot \varphi(t_u^i), \sum_{i \in I_u} l_m^i \cdot \varphi(t_u^i) \right) \quad (38)$$

式中:

I_u —所有 u 交互过的项目的集合。

在上述引入时间衰减函数的过程中, 关于时间间隔 t 的取值, 事实上可以通过两种方式实现。第一种是直接计算时间差, 即以当前时间 T 为基准, 如果与项目 i 的交互时间点为 t_i , 那么在对项目 i 的标签权重计算中, 时间间隔取值为 $t = T - t_i$, 这种取值方式非常直观, 但是必须依赖时间记录信息, 即对于每一次隐性交互行为, 需要记录其时间戳。第二种是根据项目的交互顺序计算间隔 t , 即, 设当前距离最近一次交互的项目时间间隔为 1, 距离最远一次交互的项目时间间隔为 n , 那么对于交互序列 $T_u = (T_u^{i_1}, T_u^{i_2}, T_u^{i_3}, \dots, T_u^{i_{n-1}}, T_u^{i_n})$, 若 $T_u^{i_1}$ 表示最近的一次交互, $T_u^{i_n}$ 表示最远的一次交互, 则 T_u 中对应项目的时间间隔取值为 $(1, 2, 3, \dots, n-1, n)$ 。

对于融合时间衰减的模型, 过去太久的交互行为并不会对近期的推荐产生太大

的影响，而近期的交互行为是模型进行推荐的主要依据来源。另一方面，当用户某一次误触到不喜欢的项目，尽管此次行为在时间上有“优势”，但由于之前的绝大多数行为中的项目标签与此次交互的项目关联性较小，因此，并不会使得模型由于误触而产生错误的推荐。

4.2.3 特征的 Embedding 操作

由于前面所得到的用户标签特征、用户交互标签特征、项目标签特征、项目交互标签特征均为稀疏向量，因此需要对这些稀疏向量分别进行 Embedding 操作，得到稠密向量，然后再进行对应的串联拼接分别得到完整的“用户特征”和完整的“项目特征”，以用户特征为例，其 Embedding 过程如图 20 所示。




图 20 用户特征 Embedding

具体来说，Embedding 过程使用简单的全连接层来实现，用公式可以表示为：

$$v' = v \cdot W \quad (39)$$

式中：

v' —输出的稠密向量；

v —输入的稀疏向量；

W —权重矩阵。

4.2.4 评分预测

得到用户和项目的稠密特征向量后，将二者先经全连接层映射，然后再经过拼接（串联）操作得到 u, i 交互特征，接下来将 u, i 交互特征经全连接层即可映射到评分输出。在这部分的全连接映射中，把评分预测看作为一个回归问题，而非分类问题。虽然样本的标签只有 0 和 1 两种取值（分别代表没有过隐性交互行为和有过隐性交互行为），在神经网络模型中一般将此类问题归为分类问题，即在输出层使用 Softmax 函数进行概率输出，但是为了方便对 Top-k 推荐列表进行排序，因此将该模型构造为回归（拟合）模型，隐层使用 Leaky ReLu 激活函数（该激活函数在第 3 章已经进行过相关介绍，因此不再赘述），而在输出层不使用激活函数，最终将

预测评分输出在 $[0,1]$ 的区间内, 预测评分越靠近 1, 表明用户点击的可能性越大。在权重与偏置的调整过程中, 同第 3 章模型一样, 损失函数依然为 MSE 函数。

4.3 实验

4.3.1 数据集及预处理

实验数据集与第 3 章一样, 使用 MovieLens 100K 和 MovieLens 1M, 不同的是, 在本章的实验中, 使用到了数据集中电影的标签信息。两个数据集上的标签类型汇总如表 8 所示。

表 8 数据集中的电影标签汇总

数据集	电影标签
MovieLens 100K	未知、动作、冒险、动画、儿童、喜剧片、犯罪、纪录片、戏剧、幻想、黑色电影、恐怖、音乐剧、神秘、浪漫、科幻、惊悚片、战争、西部 (总计 19)
MovieLens 1M	动作、冒险、动画、儿童、喜剧片、犯罪、纪录片、戏剧、幻想、黑色电影、恐怖、音乐剧、神秘、浪漫、科幻、惊悚片、战争、西部 (总计 18)

本章的关注重点为用户行为序列中的隐性行为, 但是需要注意的是, MovieLens 100K 和 MovieLens 1M 都只有用户对电影的显性评分数据, 而不包含如点击、浏览之类的隐性行为数据。因此, 为了方便实验, 将所有评分行为视为隐性行为, 当用户 u 对电影 i 有评分行为时, 将该行为视为正样本 S_u^i , 且无论评分分值为多少, 样本值为 $S_u^i = 1$ 。按照这种设定, 那么原数据集中是没有负样本的, 因此, 采取随机方式生成负样本, 且保证正负样本数量均衡, 对于用户 u , 若正样本数为 n , 则随机从电影库中选取没有过交互行为的 n 个电影生成负样本, 负样本值为 $S_u^i = 0$ 。

另外, 由于本章的算法模型中引入了时间衰减函数, 因此, 需要应用到数据集上的时间戳信息。考虑到数据集上有些评分之间的时间间隔非常小, 因此, 对于数据集中的每一个用户, 先根据时间戳进行行为排序, 然后采用 4.2.2 节中所描述的第二种时间取值方式对每个行为计算时间间隔。

4.3.2 主要评估标准

本文采用召回率指标和 RMSE 指标对实验结果进行评估, 其中 RMSE 指标已经在第 3 章进行过介绍, 因此不再赘述。而关于召回率, 也是推荐系统中的常用评估指标, 在点击预测中, 召回率表示推荐列表中用户点击的项目占该用户所有点击项

目的比例，召回率越大，表明推荐效果越好。具体地，其计算公式为：

$$Recall = \frac{R \cap T}{T} \quad (40)$$

式中：

R — 推荐列表中所有项目的集合；

T — 用户交互项目集合。

4.3.3 实验过程与分析

实验硬件平台为 Intel i7-7700K, NVIDIA 1080ti, 64G RAM。

实验过程中，时间衰减的权重系数设为 $a_0=1$ ，学习率为 0.01，正则化参数（对权重矩阵采取正则化）为 0.015，最大训练批次为 500，根据训练损失的变化情况来控制迭代的终止，即当训练损失趋于稳定时终止迭代，并保存模型参数。

1) 时间衰减对模型性能的影响（以 MovieLens 1M 为例）

λ 值为时间衰减参数，它象征着时间惩罚力度。为了验证衰减函数对模型性能的影响，对不同 λ 取值情况下的收敛性进行了分析，结果如图 21 所示。图中，横轴为迭代批次，纵轴为 MSE 损失值，灰色线段为没有引入时间衰减的情形。从图中可以看出，当 $\lambda=0$ ，在计算用户交互特征时，项目的每个标签权重均为 1，因此这种情况下相当于没有引入时间衰减，此时的模型性能较差，当 $\lambda=0.04$ 时，收敛性最好，并且明显优于没有引入时间衰减的情况。但是并非 λ 取值越大性能越好，比如，对于一些喜欢怀旧的用户来说，时间惩罚力度太大反而会带来不利影响。事实上在实际中，在用户数据量大的情况下，可以对不同用户采取不同的时间衰减策略，以提高推荐性能。

为了更进一步地验证时间衰减函数的影响，分别取比例为 60%、70%、80% 的训练集（对应测试集分别为 40%、30%、20%）在 $\lambda=0$ 和 $\lambda=0.04$ 的条件下进行了 RMSE 性能比较，结果如图 22 所示。图中，横轴为测试集占比，纵轴为 RMSE 值。从整体结果可以看出，无论是否引入时间衰减，训练集比例越高，RMSE 值越低，模型性能越好，这是因为较高的训练集占比能够使模型更好的拟合真实值。另外，无论训练集比例为多少， $\lambda=0.04$ 时的 RMSE 值都低于 $\lambda=0$ 时的 RMSE 值，这表明了时间衰减的引入确实带来了更好的性能。

由于交互样本标签只有 0 和 1 两种取值，预测值的范围在 [0,1] 之内，因此可以看到，图 21 和图 22 中的 MSE 与 RMSE 值要低于第 3 章对应的 MSE 和 RMSE 值。




图 21 不同 λ 对收敛性的影响 (80%训练集大小)






图 22 时间衰减在测试集上的表现

2) 召回率评估

召回率能够直观的反应推荐系统在测试集上的表现，在这一部分中，分别在 MovieLens 100K 和 MovieLens 1M 数据集上对不同推荐列表长度 (K) 下的召回率进行评估。首先要验证的是时间衰减函数的引入对召回率的影响，结果如图所示。



(a) MovieLens 100K 上的结果



(b) MovieLens 1M 上的结果

图 23 时间衰减对召回率的影响

从两张图可以看出，召回率随着推荐列表长度的增大而增大，并且，引入时间衰减的情况下，召回率表现更好，另外，MovieLen 100K 上的结果要略好于 MovieLens 1M 上的结果，这是因为 MovieLens 100K 上的数据稀疏程度要低于 MovieLens 1M，且电影数据量也相对较少，因此在同等条件下召回的几率更大。

为了进一步验证模型的有效性，以 MovieLens 1M 为例，下面将本章所提算法与 SVD^[9]、RSVD^[60]、SVD++^[10]以及 BLS-SVD++^[61]等几种矩阵分解算法进行召回率比

较，具体如表 9 所示。从表中可以看出，SVD 算法表现相对较差，而本章所提算法与其他算法相比，性能表现均有提升，由此从侧面证明了基于神经网络构建的算法模型有着更强的特征表达能力，从而使得性能表现更优。

表 9 不同算法的召回率对比 (MovieLens 1M)

算法模型	推荐列表长度 K		
	50	100	150
SVD[9]	0.09	0.18	0.21
RSVD[60]	0.11	0.23	0.29
SVD++[10]	0.17	0.27	0.32
BLS-SVD++[61]	0.23	0.35	0.41
所提算法	0.25	0.37	0.42

4.4 本章小结

本章以用户隐性行为切入点，充分结合用户标签数据和项目标签数据，构建了神经网络点击预估模型。在对隐性行为的具体分析上，考虑了用户兴趣随时间动态变化的普遍规律，通过引入时间衰减函数降低过去行为中出现的项目标签权重，使推荐系统更加关注用户近期的兴趣方向，从而提高推荐系统的性能。最后，将所提算法在 MovieLens 100K 和 MovieLens 1M 数据集上进行了实验，并对时间衰减引入的影响进行了重点评估，验证了时间衰减对模型性能的提升作用。另外，将所提算法与一些经典推荐算法进行了比较，证明了算法的有效性。

第 5 章 电影推荐系统应用设计

在本章中，以 MovieLens 数据集为基础，根据第 3、4 章训练出的推荐系统模型，结合 PyQt 框架以及 MySQL 数据库设计了一个具有人机交互界面的电影推荐系统。该推荐系统中，客户端的界面、应用逻辑使用 Python 语言编写，服务器端的通信、数据处理等程序使用 C 语言编写，该系统能够收集用户的行为数据，并根据用户的偏好实现个性化电影推荐服务。

5.1 系统架构与需求分析

目前，已有大量计算机工作者对推荐系统进行了应用上的实现^[62-64]，本文对之前的一些工作进行了分析和研究，并重新对推荐系统的系统架构进行了设计，整体架构包括客户端和服务端两部分，具体如图所示：




图 24 系统整体架构

其中客户端是用户与电影推荐系统进行交互的平台，它的主要功能为：个性化推荐展现、用户行为偏好收集、用户个性化设置等。而服务端是数据存储和处理的平台，它的主要功能为：用户数据与电影数据存储、推荐系统模型训练与更新、用户请求处理等。下面将分别对客户端和服务端进行介绍。

客户端的主要功能需求如下：

- 1) 用户账号管理。账号是用户使用电影推荐系统的通行证，账号管理包括用户的登录、注册模块以及密码修改模块。
- 2) 用户偏好设置。具体包括性别、年龄、职业、爱好等个人信息设置，电影标

签偏好信息设置，以及推荐规则设置等。

3) 用户行为日志记录模块。该模块主要为用户提供历史记录以及所收藏的电影的展现，用户从日志记录可以迅速定位到对应的电影信息页面。

4) 用户评论、评分功能。用户通过该功能可以对任意的电影进行评论或评分，对于新的评论或评分数据，软件将上传至服务器。

5) 系统设置。包括开机启动、软件更新检查等。

6) 搜索模块。实现输入电影名称或演员名字进行搜索，并将搜索结果展现给用户。

7) 自动推荐模块。当用户打开软件后，软件自动联网并发送用户登录信息给服务器，然后接受服务器发来的推荐列表，并展示给用户。

8) 热门电影展现模块。该模块实现对当前流行的电影或新上线的电影以大海报的形式进行展现。

9) 条件推荐模块。该模块根据用户输入的条件生成推荐列表并进行展现，具体包含两种条件推荐方式。一种是根据用户输入的喜欢的电影，采用协同过滤和寻找相似电影的方式进行推荐；另一种是根据用户选择的电影标签，从电影库中进行标签匹配，从而实现推荐。

服务端的主要需求如下：

1) 请求处理。根据客户端发来的请求数据实行相应的处理，包括用户账户密码校验、推荐列表生成等。

2) 数据存储。实现用户数据、电影数据、用户-电影交互数据（用户行为日志）的存储。

3) 推荐模型训练。以服务器数据库中的用户与电影数据为基础，定期对推荐系统模型进行训练，并对模型参数进行保存，以实现后续的推荐应用。

5.2 系统设计

系统设计主要包含服务端数据库设计、服务端训练模型设计、服务端推荐列表生成模块设计、客户端设计等，其中训练模型部分使用了第 3 章和第 4 章中所提到的方法，本章不再赘述。

5.2.1 数据库存储设计

数据库存储选择 MySQL 关系型数据库，其有着高速、可靠等优点。在本章应用中，MySQL 用来实现用户信息与电影信息的存储。所有用户信息和电影信息均来自

与 MovieLens 数据集，电影海报图片来自于 IMDB 网站 (<https://www.imdb.com/>)。因为电影版权限制，电影信息部分并不包括电影本身，MySQL 中存储的电影基本信息字段如表 10 所示。

表 10 电影基本信息字段

字段名	类型	是否允许为空	是否为主键	注解
movie_id	int	否	是	电影编号 (ID)
movie_title	varchar(100)	否	否	电影标题
movie_type	varchar(100)	否	否	电影类型
movie_year	varchar(6)	否	否	电影上映年份
movieImg_url	varchar(120)	否	否	电影海报文件地址
movie_feature	text	否	否	电影特征向量

用户基本信息字段如表 11 所示。

表 11 用户基本信息字段

字段名	类型	是否允许为空	是否为主键	注解
user_id	int	否	是	用户账号 (ID)
user_psw	varchar(20)	否	否	用户密码
user_img	varchar(120)	否	否	用户头像地址
user_setting	varchar(100)	否	否	用户设置信息
user_gender	varchar(2)	否	否	用户性别
user_age	int	否	否	用户年龄
user_career	varchar(12)	否	否	用户职业
user_feature	text	否	否	用户特征向量

由于软件需要实现推荐功能，因此用户-电影交互记录非常重要，在数据库中，单独用一张表来存储这些交互记录，具体存储字段如表 12 所示。

表 12 用户-电影交互记录

字段名	类型	是否允许为空	是否为主键	注解
log_id	bigint	否	是	记录编号 (ID)
user_id	int	否	否	用户 ID
movie_id	int	否	否	电影 ID
rating	varchar(2)	否	否	评分值
timestamp	Varchar(15)	否	否	时间戳

由于本章数据库基于 MovieLens 建立，因此不包含评论、收藏等数据，在实际中，可以添加评论、收藏等字段，以提高推荐性能。

5.2.2 客户端设计

客户端是用户与电影的交互平台，在本章中，使用 PyQt 框架实现客户端界面的开发。由于每个用户的个性化偏好不一致，因此，为了方便对不同用户的偏好进行存储和管理，每个用户在正式使用软件前要先进行登录操作，登录界面如图 25 所示。在登录过程中，软件通过远程数据库对账号和密码进行验证，验证成功后即可进入软件。



图 25 软件登录界面

软件主界面是客户端的核心，主界面主要包含推荐列表展示模块、条件推荐功能模块、工具栏模块等，其界面样式如图 26 所示。





图 26 软件主界面

1) 推荐列表展示模块包括两部分,一部分是热门电影展示,另一部分是自动推荐展示。其中热门电影以大海报的形式展示在主界面上方,而自动推荐展示则位于软件下方右侧。当用户登录软件账号后,服务器根据用户特征信息,计算出用户可能喜欢的电影条目并生成推荐列表发送给客户端,客户端再将其展示在“猜你喜欢”栏目。

2) 条件推荐功能模块对应于软件界面中的“帮我推荐”栏目。该模块旨在按条件帮用户找出其可能喜欢的电影。条件输入方式包括两种,一种是根据输入用户看过的并且喜欢的电影实行推荐,这种方式使用了协同过滤思想,而另一种则是通过输入喜欢的电影标签,然后寻找与这些标签相对应的电影,并实行推荐。无论是上述哪种方式,推荐列表的计算生成都是通过服务器完成的。

3) 工具栏模块包括电影搜索、账号管理、设置、帮助等功能。其中电影搜索部分实现对输入的电影名称或演员名字进行搜索;账号管理部分实现密码修改、账号下线等功能;设置部分由电影偏好设置和系统偏好设置组成(电影偏好设置面板如图 27 所示,进行电影偏好设置有助于大大提高推荐准确率。);帮助部分实现版本信息的展示、软件反馈意见的收集等。



设置

电影偏好设置 系统偏好设置

个人信息:

性别: 男 生日: 2020 年 1 月 1 日

职业: 学生 爱好: 运动健身

感兴趣的标签:

☐ 动作	☒ 冒险	☒ 动画	☐ 儿童
☒ 喜剧	☐ 犯罪	☐ 记录	☐ 戏剧
☐ 幻想	☐ 黑色	☐ 恐怖	☒ 音乐
☐ 神秘	☐ 浪漫	☐ 科幻	☐ 惊悚
☐ 战争	☐ 西部	☐ 选择恐惧症	

推荐规律:

兴趣侧重: 短期兴趣 ————— 长期兴趣

兴趣疲劳缓解: 开

重置 保存

图 27 电影偏好设置面板

5.2.3 推荐列表生成模块

推荐列表的生成由服务器端完成，根据上文介绍，推荐列表的生成共包含三种情况，第一种是自动推荐列表生成，在用户登录上线后立即生成；第二种是根据用户输入的喜欢过的电影进行推荐列表生成；第三种是根据用户勾选的电影标签进行推荐列表生成。以自动推荐列表生成为例，其具体实现流程如图 28 所示。




图 28 自动推荐列表生成流程

上图中，由于新用户没有任何行为记录，也没有偏好设置信息，因此新用户第一次进入主页时，采用随机生成策略生成推荐列表。而对于老用户，则根据登录信息查询对应的用户特征，并采用第 3 章和第 4 章的推荐算法模型实现推荐列表的生成。

5.3 本章小结

本章中，使用 PyQt 框架、MySQL 数据库，并结合第 3 章和第 4 章所提的算法模型进行了电影推荐系统应用软件的开发。整个推荐系统包括客户端和服务端两部分，这两部分在本章中均进行了详细介绍，并通过编写程序进行了实现。

结 论

推荐系统是解决大数据时代信息过载问题的一种有效工具，本文以推荐应用领域中的用户行为数据为切入点，分别对显性行为和隐性行为构建推荐系统模型，并在真实数据集上进行了实验，验证了模型算法的有效性。总的来说，本文的创新点和研究内容包括以下几个方面：

1) 针对显性行为的研究。以显性行为中的评分预测为例，提出了一种基于空间维度距离度量与用户显性行为的推荐算法。在 Item2Vec 项目特征提取阶段，对原来的 Item2Vec 进行了改进，引入了随评分等级动态变化的窗口，使评分相似或相等的项目处于同一窗口内，从而提高了项目特征提取的准确度；而在用户与项目的特征融合阶段，采用了所提的空间维度距离度量方法进行特征融合，得到用户与项目的交互特征，并经全连接层模块映射实现了评分预测；在 Top-K 推荐阶段，针对用户兴趣疲劳问题，采用基于余弦相似度的重排序方法对 Top-K 列表进行调整，从而达到缓解该问题的目的。最后在 MovieLens 100K 和 MovieLens 1M 数据集上进行了实验，并与传统算法在 RMSE 和 MAE 指标上进行了比较，证明了所提方法的有效性。

2) 针对隐性行为的研究。结合用户标签、项目标签以及用户隐性行为记录，通过神经网络构建了用户点击预估模型。在这一部分工作中，将模型定义为回归模型，并通过引入时间衰减函数来捕捉用户的兴趣变化，使模型更倾向于关注用户的近期兴趣，从而提高了推荐性能。在 MovieLens 100K 和 MovieLens 1M 数据集上进行实验，证明了时间衰减引入的有效性，并与传统算法进行了比较，在召回率指标上取得了提升。

3) 结合所训练的模型，对电影推荐系统客户端和服务端进行了设计和实现。

本文通过结合用户行为与神经网络构建推荐系统模型，对于稀疏行为矩阵虽然有着不错的推荐效果，但是，这些工作中仍然存在一些不足之处：

1) 扩展性问题和冷启动问题仍然没有得到解决。扩展性问题和冷启动问题一直是推荐系统领域公认的难题，因此，下一步可以结合本文的推荐算法，对这些问题进行深入研究。

2) 在第 4 章引入时间衰减函数的过程中，没有进一步考虑不同用户在兴趣衰减速度上的差异性，因此在下一步研究中，可以对用户兴趣衰减速度的差异性进行深入分析，通过设计算法对衰减规律进行学习，以提高推荐性能。

参考文献

- [1] 于朝晖.CNNIC 发布《第 45 次中国互联网络发展状况统计报告》[J].网信军民融合,2020(05):26-27.
- [2] RESNICK P, VARIAN H R. Recommender systems[J]. Communications of the ACM, 1997, 40(3): 56-58
- [3] GOLDBERG D, NICHOLS D, OKI B M, et al. Using collaborative filtering to weave an information tapestry[J]. Communications of the ACM, 1992, 35(12): 61-70.
- [4] SCHAFER J B, FRANKOWSKI D, HERLOCKER J, et al. Collaborative filtering recommender systems[M]//The adaptive web. Springer, Berlin, Heidelberg, 2007: 291-324.
- [5] XUE G R, LIN C, YANG Q, et al. Scalable collaborative filtering using cluster-based smoothing[C]//Proceedings of the 28th annual international ACM SIGIR conference on Research and development in information retrieval, 2005: 114-121.
- [6] LIANG D, KRISHNAN R G, HOFFMAN M D, et al. Variational autoencoders for collaborative filtering[C]//Proceedings of the 2018 World Wide Web Conference, 2018: 689-698.
- [7] LI B, YANG Q, XUE X. Transfer learning for collaborative filtering via a rating-matrix generative model[C]//Proceedings of the 26th annual international conference on machine learning, 2009: 617-624.
- [8] LEMIRE D, MACLACHLAN A. Slope one predictors for online rating-based collaborative filtering[C]//Proceedings of the 2005 SIAM International Conference on Data Mining. Society for Industrial and Applied Mathematics, 2005: 471-475.
- [9] SARWAR B, KARYPIS G, KONSTAN J, et al. Application of dimensionality reduction in recommender system-a case study[R]. Minnesota Univ Minneapolis Dept of Computer Science, 2000.
- [10] KOREN Y. Factorization meets the neighborhood: a multifaceted collaborative filtering model[C]//Proceedings of the 14th ACM SIGKDD international conference on Knowledge discovery and data mining, 2008: 426-434.
- [11] JIAO J, ZHANG X, LI F, et al. A Novel Learning Rate Function and Its Application on the SVD++ Recommendation Algorithm[J]. IEEE Access, 2019, 8: 14112-14122.
- [12] KUMAR R, VERMA B K, RASTOGI S S. Social popularity based SVD++ recommender system[J]. International Journal of Computer Applications, 2014, 87(14).

- [13] PONGPAICHET S, UNPRASERT T, TUAROB S, et al. SGD-Rec: A Matrix Decomposition Based Model for Personalized Movie Recommendation[C]//2020 17th International Conference on Electrical Engineering/Electronics, Computer, Telecommunications and Information Technology (ECTI-CON). IEEE, 2020: 588-591.
- [14] KOREN Y. Collaborative filtering with temporal dynamics[C]//Proceedings of the 15th ACM SIGKDD international conference on Knowledge discovery and data mining, 2009: 447-456.
- [15] TORRES J, VACA C, TERÁN L, et al. Seq2Seq models for recommending short text conversations[J]. Expert Systems with Applications, 2020, 150: 113270.
- [16] ZHANG Z, WANG H, XU F, et al. Complex-valued convolutional neural network and its application in polarimetric SAR image classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2017, 55(12): 7177-7188
- [17] BANSAL T, BELANGER D, MCCALLUM A. Ask the gru: Multi-task learning for deep text recommendations[C]//Proceedings of the 10th ACM Conference on Recommender Systems. ACM, 2016: 107-114.
- [18] ZHENG L, NOROOZI V, YU P S. Joint deep modeling of users and items using reviews for recommendation[C]//Proceedings of the Tenth ACM International Conference on Web Search and Data Mining. ACM, 2017: 425-434.
- [19] LIU S, OUNIS I, MACDONALD C, et al. A Heterogeneous Graph Neural Model for Cold-Start Recommendation[C]//Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval, 2020: 2029-2032.
- [20] HE X, LIAO L, ZHANG H, et al. Neural collaborative filtering[C]//Proceedings of the 26th international conference on world wide web. International World Wide Web Conferences Steering Committee, 2017: 173-182.
- [21] WU S, TANG Y, ZHU Y, et al. Session-based recommendation with graph neural networks[C]//Proceedings of the AAAI Conference on Artificial Intelligence, 2019, 33: 346-353.
- [22] ZHOU Y, HUANG C, HU Q, et al. Personalized learning full-path recommendation model based on LSTM neural networks[J]. Information Sciences, 2018, 444: 135-152.
- [23] PYO S, KIM E. LDA-based unified topic modeling for similar TV user grouping and TV program recommendation[J]. IEEE transactions on cybernetics, 2014, 45(8): 1476-1490.
- [24] TORRES J, VACA C, TERÁN L, et al. Seq2Seq models for recommending short text conversations[J]. Expert Systems with Applications, 2020, 150: 113270.
- [25] BARKAN O, KOENIGSTEIN N. Item2vec: neural item embedding for collaborative

- filtering[C]//2016 IEEE 26th International Workshop on Machine Learning for Signal Processing (MLSP). IEEE, 2016: 1-6.
- [26] MIKOLOV T, SUTSKEVER I, CHEN K, et al. Distributed representations of words and phrases and their compositionality[C]//Advances in neural information processing systems, 2013: 3111-3119.
- [27] MIKOLOV T, CHEN K, CORRADO G, et al. Efficient estimation of word representations in vector space[J]. arXiv preprint arXiv:1301.3781, 2013.
- [28] CHENG H T, KOC L, HARMSSEN J, et al. Wide & deep learning for recommender systems[C]//Proceedings of the 1st workshop on deep learning for recommender systems, 2016: 7-10.
- [29] COVINGTON P, ADAMS J, SARGIN E. Deep neural networks for youtube recommendations[C]//Proceedings of the 10th ACM conference on recommender systems, 2016: 191-198.
- [30] YUAN Q, CONG G, MA Z, et al. Time-aware point-of-interest recommendation[C]//Proceedings of the 36th international ACM SIGIR conference on Research and development in information retrieval, 2013: 363-372.
- [31] YU J, LIU F. A short-term user interest model for personalized recommendation[C]//2010 2nd IEEE International Conference on Information Management and Engineering. IEEE, 2010: 219-222.
- [32] WU Y K, WANG Y, TANG Z H. A collaborative filtering recommendation algorithm based on interest forgetting curve[J]. International Journal of Advancements in Computing Technology, 2012, 4(10): 148-157.
- [33] SONG Y, ELKAHAY A M, HE X. Multi-rate deep learning for temporal recommendation[C]//Proceedings of the 39th International ACM SIGIR conference on Research and Development in Information Retrieval, 2016: 909-912.
- [34] CUI Q, WU S, HUANG Y, et al. A hierarchical contextual attention-based network for sequential recommendation[J]. Neurocomputing, 2019, 358: 141-149.
- [35] ZHOU G, ZHU X, SONG C, et al. Deep interest network for click-through rate prediction[C]//Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining, 2018: 1059-1068.
- [36] ZIEGLER C N, MCNEE S M, KONSTAN J A, et al. Improving recommendation lists through topic diversification[C]//Proceedings of the 14th international conference on World Wide Web,

- 2005: 22-32.
- [37] SHI Y, ZHAO X, WANG J, et al. Adaptive diversification of recommendation results via latent factor portfolio[C]//Proceedings of the 35th international ACM SIGIR conference on Research and development in information retrieval, 2012: 175-184.
- [38] WASILEWSKI J, HURLEY N. Intent-aware item-based collaborative filtering for personalised diversification[C]//Proceedings of the 26th Conference on User Modeling, Adaptation and Personalization, 2018: 81-89.
- [39] MEDO M, ZHANG Y C, ZHOU T. Adaptive model for recommendation of news[J]. EPL (Europhysics Letters), 2009, 88(3): 38005.
- [40] CANTADOR I, CASTELLS P. Multilayered semantic social network modeling by ontology-based user profiles clustering: Application to collaborative filtering[C]//International Conference on Knowledge Engineering and Knowledge Management. Springer, Berlin, Heidelberg, 2006: 334-349.
- [41] CHOWDHARY K R. Natural language processing[M]//Fundamentals of Artificial Intelligence. Springer, New Delhi, 2020: 603-649.
- [42] VAN DEN OORD A, DIELEMAN S, SCHRAUWEN B. Deep content-based music recommendation[C]//Advances in neural information processing systems, 2013: 2643-2651.
- [43] WANG J, HUANG P, ZHAO H, et al. Billion-scale commodity embedding for e-commerce recommendation in alibaba[C]//Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining, 2018: 839-848.
- [44] SCHAFER J B, FRANKOWSKI D, HERLOCKER J, et al. Collaborative filtering recommender systems[M]//The adaptive web. Springer, Berlin, Heidelberg, 2007: 291-324.
- [45] KARYPIS G. Evaluation of item-based top-n recommendation algorithms[C]//Proceedings of the tenth international conference on Information and knowledge management, 2001: 247-254.
- [46] AGARWAL A, CHAUHAN M. Similarity measures used in recommender systems: a study[J]. International Journal of Engineering Technology Science and Research IJETS, ISSN, 2017: 2394-3386.
- [47] SHEUGH L, ALIZADEH S H. A note on pearson correlation coefficient as a metric of similarity in recommender system[C]//2015 AI & Robotics (IRANOPEN). IEEE, 2015: 1-6.
- [48] KHOSHNESHIN M, STREET W N. Collaborative filtering via euclidean embedding[C]//Proceedings of the fourth ACM conference on Recommender systems, 2010: 87-94.

- [49] FENG Z, HUIYOU C. Employing BP neural networks to alleviate the sparsity issue in collaborative filtering recommendation algorithms[J]. Journal of Computer Research and Development, 2006, 43(4): 667.
- [50] CHEN X, XU H, ZHANG Y, et al. Sequential recommendation with user memory networks[C]//Proceedings of the eleventh ACM international conference on web search and data mining, 2018: 108-116.
- [51] LIU Q, WU S, WANG D, et al. Context-aware sequential recommendation[C]//2016 IEEE 16th International Conference on Data Mining (ICDM). IEEE, 2016: 1053-1058.
- [52] CASELLES-DUPRÉ H, LESAIN F, ROYO-LETELIER J. Word2vec applied to recommendation: Hyperparameters matter[C]//Proceedings of the 12th ACM Conference on Recommender Systems, 2018: 352-356.
- [53] MAAS A L, HANNUN A Y, NG A Y. Rectifier nonlinearities improve neural network acoustic models[C]//Proc. Icml, 2013, 30(1): 3.
- [54] KOREN Y, BELL R, VOLINSKY C. Matrix factorization techniques for recommender systems[J]. Computer, 2009, 42(8): 30-37.
- [55] ZHANG S, YAO L, XU X. AutoSVD++ An Efficient Hybrid Collaborative Filtering Model via Contractive Auto-encoders[C]//Proceedings of the 40th International ACM SIGIR conference on Research and Development in Information Retrieval, 2017: 957-960.
- [56] DZIUGAITE G K, ROY D M. Neural network matrix factorization[J]. arXiv preprint arXiv:1511.06443, 2015.
- [57] ZHANG S, YAO L, TAY Y, et al. Metric factorization: Recommendation beyond matrix factorization[J]. arXiv preprint arXiv:1802.04606, 2018.
- [58] 陈一然, 郑骏. 基于偏置度量分解与隐反馈的协同过滤推荐算法[J]. 计算机应用研究, 2020, 37(8): 2288-2291.
- [59] DING Y, LI X. Time weight collaborative filtering[C]//Proceedings of the 14th ACM international conference on Information and knowledge management, 2005: 485-492.
- [60] CIESIELCZYK M, SZWABE A. RI-based dimensionality reduction for recommender systems[C]//Proc. of 3rd International Conference on Machine Learning and Computing, IEEE Press, Singapore, 2011.
- [61] WANG S, SUN G, LI Y. SVD++ Recommendation Algorithm Based on Backtracking[J]. Information, 2020, 11(7): 369.
- [62] 贾忠涛. 基于协同过滤算法的电影个性化推荐系统设计与实现[J]. 软件导刊, 2015, 1: 86-88.

- [63] 王义, 马尚才. 基于用户行为的个性化推荐系统的设计与应用 ①[J]. 计算机系统应用, 2010, 19(8): 29-33.
- [64] 孟祥武, 胡勋, 王立才, 等. 移动推荐系统及其应用[J]. 软件学报, 2013, 1.

致 谢

时间如白驹过隙，两年半的读研生活已经接近尾声。在这两年半的研究生生涯里，对我来说，有付出但更有收获，有泪水但更有幸福。这两年多里，我又成长了许多，不仅仅是学识上的，更有精神上的。我的成长与进步，离不开那些在背后默默支持我的人，对我来说，他们是可爱的人，是值得尊敬的人，更是不能忘记的人。在此，我要向那些在我研究生生涯中给我鼓舞、助我进步、与我共度青春的老师、同学、朋友和亲人致以最真诚的谢意！

首先要感谢的是我的导师郝胜男、纪占林老师，是他们领我走进了科研的殿堂，让我拓展了科学视野，领会了我严谨的科学精神。另外，他们给我提供了优质的学习平台，使我能够在学术世界里无拘束地遨游；他们给我提供了精神上的鼓舞，使我能够更加积极地面对学习与生活上的难题。在这篇论文的完成过程中，他们给予了我很多的指导意见与帮助，我的顺利毕业离不开他们的教诲与支持。

其次要感谢的是我的所有同窗与朋友，他们同样给了我许多学习上的支持，感谢刘靖祎和涂冬景同学在学习上给予我的帮助，为我提供前进的动力，我不会忘记与他们一起度过的每一刻的快乐时光，他们见证了我生活的点点滴滴，他们是我青春路上的好战友，好伙伴。

最后要感谢的是我的父母，我的成长路上离不开他们辛勤的付出与操劳，他们是我人生中最伟大的助力者，亦是我生活中最亲近的人。

在学期间研究成果

在学期间发表论文和著作：

周雕，郝胜男. 一种用于推荐系统的分类训练方法[J]. 现代计算机（已录用）

科研成果和奖励：

政府间国际科技创新合作重点专项，基于按需服务和精准定向的泛在服务推荐系统原型和应用，2019 年 8 月至 2022 年 7 月，项目骨干。