

电子科技大学
UNIVERSITY OF ELECTRONIC SCIENCE AND TECHNOLOGY OF CHINA

博士学位论文

DOCTORAL DISSERTATION



论文题目 基于社交网络个体行为特征的信息推荐算法研究

学科专业 计算机软件与理论

学 号 201211060406

作者姓名 陈玲姣

指导教师 张翼成 教授

分类号_____密级_____

UDC^{注1}_____

学 位 论 文

基于社交网络个体行为特征的信息推荐算 法研究

(题名和副题名)

陈玲姣

(作者姓名)

指导教师_____张翼成_____教 授
电子科技大学_____成 都

(姓名、职称、单位名称)

申请学位级别_____博士_____学科专业_____计算机软件与理论

提交论文日期_____2018.03.26_____论文答辩日期_____2018.06.01

学位授予单位和日期_____电子科技大学_____2018年6月

答辩委员会主席_____高辉_____

评阅人_____

注1：注明《国际十进分类法UDC》的类号。

Information Recommendation Algorithms Based on Individual Behavioral Characteristics on Social Networks

A Doctor Dissertation Submitted to
University of Electronic Science and Technology of China

Major: Computer Software and Theory
Author: LingJiao Chen
Advisor: Prof. Yi-Cheng Zhang
School: School of Computer Science & Engineering

摘 要

互联网的高速发展和移动电子设备的普及，给人们的生活带来了前所未有的改变。人们可以突破时间和空间的限制，自由获取海量的在线信息资源。互联网在促进生活方便的同时，也给人们带来了信息过载的困扰。推荐系统应运而生，作为解决信息过载问题的最有效工具，被广泛的应用于生活的各方面。推荐系统不仅帮助在线用户从海量的信息中发掘有用的信息、发现潜在感兴趣的物品和服务，还帮助内容提供商和生产者提高物品的曝光度、增加销量和保持用户黏度。近几十年来，推荐系统在工业界取得了优秀的应用成果，同时吸引了计算机、物理、社会经济等不同领域许多科研人员的关注，推荐系统已经成为目前研究的热点。

关于推荐系统的一系列理论研究，很大程度上推动了其不断的革新发展和具体应用。然而，推荐系统的研究到目前为止仍然存在一些困难和挑战。推荐系统的“准确性和多样性困境”问题，一直以来都是推荐系统在长期运行后所要面临的难题。推荐系统过于注重推荐的准确性，而往往忽略推荐的多样性，这导致后续推荐给用户的物品越来越相似，可供系统推荐的物品列表越来越窄。另外，推荐系统还面临着冷启动问题。新用户和新物品进入系统后，由于缺少相应的历史评分信息，推荐系统容易给出不合理的推荐。一方面，考虑到大多数推荐算法是基于用户或物品之间的相似性计算，通过设计更为合理的节点相似性计算指标，有希望最大程度的平衡推荐结果的准确性和多样性。另一方面，考虑在推荐算法的设计中引入辅助信息，包括用户之间的社交关系和用户自身的兴趣标签等，利用辅助信息来提升推荐算法的性能和解决推荐系统的冷启动问题。

在解决推荐系统所面临的问题上，本文针对其中准确性和多样性两难问题以及冷启动问题展开研究。对准确性和多样性两难问题，首先，分析二部图上节点相似性指标对推荐结果的影响，提出一种新的节点相似性计算方法，基于此相似性的推荐算法同时提高准确性和多样性；其次，利用推荐系统中用户之间的信任关系作为辅助信息，在节点相似性的推荐算法和物质扩散推荐系统框架下，分别提出信任增强推荐算法，进一步提高算法的准确性和多样性。对冷启动问题，使用推荐系统中用户自身的标签信息，在引力模型框架下来计算用户对物品的偏好，提出一种基于标签的推荐算法，在解决推荐系统冷启动问题的同时，提高推荐结果的准确性和多样性。同时，从基于标签的推荐网络演化和用户对标签信息采纳

的传播动力学两方面，对标签信息的做了更深入的研究。本文的具体研究内容和主要创新点如下：

(1) 基于新型相似性的推荐算法研究。考虑基于相似性的推荐算法，分析了相似性的选择对推荐结果准确性、多样性和新颖性的影响。结果显示，基于余弦相似性的协同过滤推荐算法的准确性高，但多样性较差；基于资源分配相似性的推荐算法的多样性好，但准确性不足。通过混合余弦相似性和资源分配相似性指标，提出了一种新的相似性度量指标（CosRA）。进一步，在物质扩散的推荐系统框架下，提出了一种基于CosRA指标的推荐算法。在真实数据集上的实验结果显示，基于CosRA指标的推荐算法表现出更好的推荐结果准确性、多样性和新颖性。所提出的CosRA指标没有参数依赖，推广得到一般化的CosRA指标不能显著提升推荐算法效果，这表明CosRA指标已经是最优形式。作为一个普适的相似性度量方法，提出的CosRA指标在推荐系统的实际应用中更有优势。

(2) 基于信任增强的推荐算法研究。利用推荐系统中用户之间的信任关系作为辅助信息，将其引入到基于CosRA指标的推荐系统框架中，提出了一种基于信任增强的推荐算法。在资源分配过程中，将受信任用户的资源总量通过一个可调参数进行调整。结果显示，可调参数存在一个几乎不依赖于数据集的最优值，这时推荐算法表现出最高的准确性。由于可调参数控制着受信任用户资源总量的放大或缩小，这一结果表明，在推荐过程中适当考虑用户信任关系能提升推荐效果，但过分增强受信任用户的影响将会适得其反。进一步，在物质扩散推荐系统框架下考虑信任关系的作用，提出了一种基于信任关系的物质扩散推荐算法，分析了受信任用户在资源分配权重上的变化对推荐效果的影响。结果显示，适当的增强受信任用户在资源分配上的权重，能够显著提高推荐算法效果。

(3) 基于标签的推荐算法研究。针对推荐系统所面临的冷启动问题，标签信息体现用户的兴趣偏好和选择倾向，引入用户的标签信息进行辅助推荐。在引力模型框架下，结合用户的标签等辅助信息来预测用户可能感兴趣的物品，提出了基于标签的推荐算法。实验结果显示，提出的推荐算法相对于基准算法提高了准确性和多样性。尤其针对新加入物品的推荐，基于标签的推荐算法的时间复杂度不显著增加，有利于在实时推荐系统中的应用。随后，将用户的标签信息与引力机制模型相结合，分析了几种典型模型网络中用户属性和商品特征的演化规律。进一步，考虑用户对标签信息的采纳过程和信息传播规律，提出了一种基于非马尔科夫过程的多层网络标签信息传播模型，能够解释复杂的社会信息传播现象。

关键词：推荐系统，信息过滤，社会化标签，信息传播，用户信任

ABSTRACT

The advent of rapid development of Internet and ubiquity of electronic devices has brought unprecedented changes to daily lives. Nowadays, people can freely access to abundant online information and resources without the limitations of time and space. While the Internet makes our lives more convenient, it brings a serious problem of information overload. With applications been widely used in many aspects of our lives, recommendation systems have been thought to be the most effective tools to deal with the information overload problem. Recommendation systems not only help customers to dig out relevant information and potential interested articles and services, but also contribute to increase the visibility of products and maintain the loyalty of customers. In recent decades, many researches have been reported in the field of recommendation systems. It becomes a hot issue that people from a variety of disciplines such as economics, computers and social sciences have paid great attentions to recently.

Recent frontier theoretical studies have greatly promoted the innovativeness and real-world applications of recommendation systems. However, there are also some remained difficulties and challenges for the current studies. For instance, the apparent diversity-accuracy dilemma of recommendation systems has long been a main issue. Too much attention to the recommendation accuracy would decrease the diversity of recommended objects and narrow down the options of customers because of the larger similarity of recommended objects in the future. Furthermore, cold-start is another major problem faced by recommendation systems. The ability of recommendation system to deal with new coming users and products is weakened by the lack of corresponding review information in the system. Under this condition, the system would provide unreasonable recommendations. There are two potential solutions to these problems. On the one hand, since most of the recommendation systems are based on the calculation of similarities among users or objects, it is promising to balance accuracy and diversity by designing more reasonable similarity index. On the other hand, in terms of the cold-start problem, the performance of recommendation systems could be improved by introducing additional information such as the trust relations between users and the interest tags of users into the design of recommendation algorithms.

This thesis focuses on the diversity-accuracy dilemma and the cold-start problem. On addressing the diversity-accuracy dilemma, how vertex similarity for bipartite networks affect the recommendation performance is analyzed, and a novel vertex similarity index is proposed. The vertex similarity-based recommendation method improves both the recommendation accuracy and diversity. Then, by introducing additional trust relations information between users, two trust enhancement hybrid recommendation methods are proposed respectively under the similarity-based framework and resource-allocation framework. With the help of the additional information, both accuracy and diversity are significantly improved. On addressing the cold-start problem, user preferences to objects are calculated under the framework of the gravity model by taking into account the information of the user interest tags. The tag-based recommendation method not only improves the performance of recommendation system but also solves the cold-start problem. Meanwhile, we conducted further analyses on label information from two perspectives: the evolution of label-based recommendation networks, and the users' adoption of label information. The detailed analyses and the key points are summarized as follows:

1. Studies on the similarity-based recommendation method. For similarity-based recommendation methods, we explored how the selection of similarity index affects the accuracy, diversity, and novelty of recommendation results. Results showed that cosine similarity based recommendation methods bring high accuracy but relative low diversity. By comparison, resource-allocation based recommendation methods advantage diversity but weaken accuracy. Combing both the cosine similarity index and the resource-allocation index, we proposed a novel vertex similarity index, named CosRA index. We applied the CosRA into recommendation systems under the resource-allocation framework. Experimental results based on several real-world datasets showed that the CosRA-based recommendation method improves accuracy, diversity, and novelty at the same time. The CosRA index is parameter independent, and we found generalized CosRA index could not remarkably improve the recommendation performance, suggesting that the current form of the CosRA index is already optimal. According to our results obtained from empirical dataset, the proposed CosRA index has a significant advantage in applications of recommendation systems.

2. Studies on the trust relationship enhancement recommendation method. By using the trust relationships between users in the recommendation systems, we proposed the trust enhancement recommendation method. Specifically, in the resource-allocation

process of the CosRA-based method, the amount of resources received by the trusted users is adjusted by a tunable parameter before allocating to users. Experimental results suggested that there is an optimal value of the parameter for the higher accuracy, and the optimal parameter value is nearly identical among several datasets under different evaluation metrics. Considering that the tunable parameter controls whether the amount of resources users is enhanced or suppressed, our results showed that moderate amount of trust information could improve the performance of system while over amount of information would impair the performance. Furthermore, we applied the same idea under the framework of the resource-allocation recommendation systems. We proposed the trust enhancement resource-allocation recommendation method and analyzed how the amount of the trust relationships affect the recommendation performance. Experimental results suggested that enhancing the weight of trust users on reallocating resources can improve the performance.

3. Studies on the tag-based recommendation method. To address the cold-start problem, user interest tags are introduced as another complementary information. Interests tags refer to the information manifest user interests and preferences. We proposed an algorithm to predict the products which users may have interest on based on the tag information under the framework of the gravity model. Experimental results suggested that our method increased both accuracy and diversity compared to some benchmark recommendation methods. When recommending new products, the time complexity of the proposed tag-based recommendation method remains nearly constant. The time complexity advantage indicates our method has potential application in the synchronized recommendation system. Next, by combining the information of the user interest tags and the gravity model, we analyzed the evolution of the user attributes and the object properties under several classical network models. Further, we proposed a non-Markovian model to describe information spreading on multiplex social network by taking the utilization of tag information and information spreading patterns into consideration. Our model contributes to explain sophisticated social information spreading phenomenon.

Keywords: Recommender System, Information Filtering, Social Tag, Information Spreading, User Trust

目 录

第一章 绪论	1
1.1 研究工作的背景与意义	1
1.2 国内外研究现状	3
1.2.1 协同过滤推荐系统	3
1.2.2 基于网络拓扑结构的推荐系统	4
1.2.3 社会化标签推荐系统	5
1.2.4 信任增强推荐系统	6
1.3 本文主要的研究内容和框架	8
第二章 推荐系统基础简介	11
2.1 推荐系统应用	11
2.2 推荐系统面临的挑战	14
2.3 推荐算法的分类	17
2.3.1 基于内容的推荐算法	17
2.3.2 协同过滤推荐算法	19
2.3.3 基于知识的推荐算法	20
2.3.4 基于社区的推荐算法	21
2.3.5 基于网络拓扑结构的推荐算法	22
2.3.6 混合推荐算法	23
2.4 推荐算法的评价指标	23
2.4.1 准确性指标	23
2.4.2 多样性和新颖性指标	26
2.5 实验数据集介绍	27
2.5.1 推荐算法的常用数据集	27
2.5.2 常用数据集划分方式	28
2.6 本章小结	29
第三章 基于节点相似性的推荐算法研究	30
3.1 引言	30
3.2 符号和数据	31
3.3 评价指标	32
3.4 基于节点相似性的算法设计	33

3.5 实验结果	37
3.6 本章小结	41
第四章 基于信任增强推荐算法研究	42
4.1 引言	42
4.2 信用增强相似性的推荐算法	43
4.2.1 问题提出	43
4.2.2 数据和符号	44
4.2.3 评价指标	45
4.2.4 算法设计	46
4.2.5 实验结果	49
4.3 基于信任关系的资源分配推荐算法	56
4.3.1 问题的提出	56
4.3.2 算法设计	56
4.3.3 实验结果	59
4.4 本章小结	65
第五章 基于社会化标签的推荐算法研究	67
5.1 基于引力模型的推荐算法	67
5.1.1 问题提出	67
5.1.2 数据和符号	68
5.1.3 评价指标	69
5.1.4 基于引力模型的推荐算法	70
5.1.5 实验结果	72
5.2 对推荐算法的辅助研究	76
5.2.1 标签推荐系统的网络演化	77
5.2.1.1 基于引力机制的网络演化模型	77
5.2.1.2 数据和评价指标	77
5.2.1.3 网络特征	78
5.2.2 信息传播动力学研究	80
5.2.2.1 问题提出	81
5.2.2.2 符号和数据	82
5.2.2.3 算法设计	82
5.2.2.4 实验结果	88
5.3 本章小结	91
第六章 总结与展望	93

6.1 全文总结	93
6.2 未来展望	94
致 谢	96
参考文献	97
攻读博士学位期间取得的成果	113

第一章 绪论

1.1 研究工作的背景与意义

互联网的发展迎来了大数据时代^[1,2],信息出现爆发式增长。例如,新浪微博每天有2亿多的动态更新^[3];中国第一的C2C平台淘宝网上有5亿注册用户数,他们可选择的在线商品数超过了8亿^[4]。如此庞大的数据体量带来了信息过载的问题^[5]。互联网的发展具有两面性。一方面,人们受益于空前丰富的信息资源和获取渠道,享受着互联网给生活带来的便利;另一方面,从海量的数据已对个人寻找有用信息造成了困扰。个人已经无法从如此庞大的数据中进行筛选过滤。人们对解决信息过载(Information Overload)的问题的需求特别迫切^[6]。不仅仅是个人用户面临着信息过载问题,作为物品提供方的企业也面临着信息过载的困扰。如何准确地顺应顾客的需求,提供精准的服务和商品是现在企业脱颖而出的关键。

为解决信息过载的问题,出现了两种技术,搜索引擎和推荐系统。搜索引擎是一种对互联网资源整理分类,并存储在数据库中供用户检索的系统。推荐系统是一种采集用户的历史信息,并根据用户特征预测用户潜在需求的系统。两者的区别在于,搜索引擎是被动式的信息过滤技术,满足用户显式表达的兴趣^[7],推荐系统是主动式的信息过滤技术,满足用户未显式表达的兴趣^[8]。在用户需求不明确的情况下,推荐系统是用户最需要的工具。推荐系统定义为:向用户建议有用物品的软件工具和技术^[8]。作为一种解决信息过载问题的有效工具,推荐系统对每个用户的需求表达,都根据用户自身的特征,收集用户信息到自定义数据库。这些用户信息包括用户交易信息、物品信息和其他的信息等。推荐系统通过分析这些用户信息,根据不同的推荐算法向用户推荐内容。推荐的内容因用户个体之间的差异呈现出个性化,符合个体的实际需求。用户对推荐的内容,可以选择接受也可以选择不接受。用户的这些行为反馈给推荐系统,更新用户在数据库里的记录,并用于下一次对用户的推荐。推荐系统已经在多个领域获得应用,并创造了极大的应用价值。例如,Google为用户定制个性化广告;Amazon平台为用户推荐相似图书的清单^[9];今日头条根据用户偏好推荐新闻资讯等。

推荐系统的功能主要有以下几点:

- (1) 准确地预测。采集用户历史行为数据并录入数据库,分析已有数据并预测用户潜在感兴趣的内容,帮助用户准确地从海量的内容中找到感兴趣的资源。
- (2) 缓解信息过载。信息过载导致用户面对海量数据无从下手,有时候不能准确地用语言或者关键词描述个人的需求,或者返回的资源重复且不符合用户

所需。推荐系统为每个用户量身定制了推荐计划，根据用户特征返回准确的资源，为用户节约时间和精力。

(3) 提高站点的点击率和转化率。推荐系统由平台和站点推出，目的是为了服务于用户，对用户需求做出准确的预测，提高自己站点的资源的点击率。电子商务网站通常还预测用户的下一步计划，并尽可能吸引用户点击查看，增加物品被购买的机会。电子商务网站不仅预测大部分用户都会喜欢的相对流行的物品，还会推荐一些用户可能会喜欢但比较冷门的无法被用户发现的物品，提升销售额，增加转化率。

(4) 提供个性化服务。个性化推荐系统为用户量身定制的推荐服务，对不同用户的需求返回不同的结果，避免“千人一面”的情况。及时准确预测用户没有意识到的需求，给用户创造惊喜，提高用户对本站点的使用粘性，以此提高本站点的商业竞争力。

推荐系统的核心是推荐算法，也是推荐系统研究的重点，已被来自计算机、物理、经济等领域的众多学者们广泛关注，并产生了大量的研究成果^[10]。文献[11, 12]从不同方面总结了目前国内外的推荐系统研究的进展。尽管对推荐算法的研究已经有几十年，并且推荐算法在实际应用中取得了非常不俗的成绩，但是到目前为止，对推荐系统的研究中还存在一些未完全解决的问题，包括准确性问题、准确性多样性两难问题和冷启动问题等。

准确性和多样性两难问题是推荐系统经过一段时间的运行后出现的问题。准确性是推荐系统的立身之本^[10]。在推荐系统竞争激烈的现代社会，只有推荐的内容符合用户的期望，用户才会接受推荐的内容。判断推荐的物品是否被用户喜欢，最简单保险的方式是推荐特别流行的物品^[13]，用户有很大概率是喜欢的。早期的推荐系统的研究特别注重算法准确性而忽略多样性^[14]。这样的后果之一是用户的体验变差^[15]，现在线上线下都有众多的渠道去获取信息，尤其是流行物品，用户很有可能已经知晓或者选择过这些物品。后果之二是用户的推荐列表里物品的种类越来越少，而无法进一步发掘自己的需求^[16]。苹果公司创始人乔布斯曾经说过“消费者并不知道需要什么，直到我们拿出自己的产品，他们就发现，这是我要的东西。”^[17]很多用户其实并不真的知道自己需要的是什么，因为他们没法接触到那些无人问津而又可能是他们喜欢的物品。后果之三是平台的推荐范围变狭窄^[15]，营收降低。而亚马逊的成功，正是因为它推荐了长尾商品给用户，让那些无法上货架的冷门商品以更低的销售成本被顾客买走。因而对类似亚马逊这样的平台来说，多样性是不可缺少的重要评价指标。顺应平台和用户两者的需求，多样性是一个必然的趋势。Zhou等人^[14]明确指出了多样性对推荐系统的重要性。

但是往往推荐准确性和多样性互为矛盾。推荐冷门物品存在一定的风险, 过于推荐小众但不完全符合用户偏好的物品, 会让用户对推荐系统产生怀疑, 导致商家因此减少收益。这个问题, 对推荐系统的研究提出了考验。社会需求的是更加个性化的推荐服务。

冷启动的问题是大部分推荐系统都面临的问题。所谓冷启动, 针对的是新用户或者物品刚进入系统, 因为没有足够的信息导致产生不合理的推荐^[10]。当一个新用户进入到推荐系统, 用户对系统里的内容不熟悉, 暂时不知道自己的需求, 而系统中也没有此用户的信息, 因此推荐系统不能对用户进行精准推荐。反过来讲, 当一个新物品进入推荐系统, 由于交易或浏览记录有限, 新物品很难被推荐给需要它的人。冷启动的研究目前存在着若干难点, 第一个是数据缺失的问题, 对刚进入系统的人和物, 都没能有效建立起在系统中的画像, 导致推荐不准^[18]; 第二个是数据有偏, 系统可以采集到的信息并不能完全刻画了人或物的特征, 仅仅是人或物的特征的一部分, 从而导致推荐出现偏差^[10]; 第三个对新用户或新物品的信息采集, 相当于是小样本抽样, 并不能准确反映出整体的情况^[19]。鉴于此情况, 学者们提出了很多不错的方法。如利用额外文本信息^[20]、进行交叉推荐^[21]、推荐热门排行榜^[19]、标签推荐系统^[22-24]等提高推荐的多样性和新颖性^[14, 25]等。

1.2 国内外研究现状

推荐系统的研究经过几十年的发展, 吸引了不同学科不同领域的研究者, 不断涌现出新的学术成果, 慢慢形成了好几个流派。根据本文研究的内容, 给出此方向上的国内外的主要研究成果。

1.2.1 协同过滤推荐系统

协同过滤 (Collaborative Filtering, CF) 推荐系统是使用协同过滤算法为主要技术的推荐系统, 在使用集体智慧的基础上, 基于大众行为数据做出决策推荐。自从Resnick等人^[26]提出的协同过滤算法被用于新闻过滤系统GroupLens上, 协同过滤算法就一直是推荐算法研究的热点。协同过滤算法对用户和物品之间的交互信息建模并为用户提供个性化的推荐服务。自Netflix Prize大赛举行以来, 协同过滤算法在学术界和工业界已经得到了广泛的研究。常见的如最近邻的协同过滤方法 (简称KNN, 包括基于用户最近邻^[27]和基于物品的最近邻的方法^[28])、隐因子模型^[29]、聚类技术和决策树方法^[30]等等。基于用户最近邻的算法^[27]思想是通过对用户的历史数据 (如评分、购买、收藏和浏览等), 找到与用户有相似品味的

其他用户，将品味相似的其他用户所喜欢的物品推荐给用户。用通俗的话理解就是“人以群分”。基于项目最近邻的算法^[28]认为一个用户选择不同的物品，通常认为物品之间存在着某种关联，通过对不同的用户进行累积，得到物品之间的相似度，并将与用户过去感兴趣的物品相类似的物品推荐给用户。通俗理解为“物以类聚”。协同过滤算的举例参考图1-1。一般来说，基于项目最近邻的方法在准确性上比基于用户最近邻的方法更高，并且适用范围更广^[9]。对协同过滤系统的研究还有很多，如Das等人^[31]将矩阵降维技术应用于推荐系统中。Salakhutdinov等人^[32]在推荐系统中引入了玻尔兹曼机器学习方法，结合SVD算法提高推荐准确性。相比于以前推荐算法使用的显式反馈信息（如用户的评分等），Koren考虑了用户的隐式反馈信息（如浏览、点击等），认为这在一定程度上反映了用户的偏好^[33]。




图 1-1 协同过滤算法示意图

1.2.2 基于网络拓扑结构的推荐系统

网络科学的发展给推荐算法的研究带来了新的研究方向。由于推荐系统中，用户与物品的交互关系可以使用一个“用户-物品”的二部图表示。因此，基于二部图的推荐算法获得了广泛的研究，成为了推荐算法领域的重要分支，在解决推荐系统面临的问题上取得了非常优秀的成果^[14, 34-37]。基于二部图的推荐算法通常使用随机游走的方式获得对物品的预测值。目前此方面的研究已有很多。从Zhang等人^[38]在Physical Review Letters期刊上将热传导理论（Heat conduction, HC）应用于推荐系统开始，经过10年的研究，基于二部图的推荐算法研究已经硕果累累。根据Zhang等人^[38]的理论，HC算法采用了在“用户-物品”组成的二部图上进行热扩散过程的原理，如图1-2所示，将推荐系统视为一个二部图，在图1-2(a)中左边代表用户右边代表物品，对目标用户（橙色）选择的物品（橙色）

赋予初始能量1，物品的能量通过连边传递到用户，再从用户传递到物品。热传导过程中每一个节点下一个时间步的温度等于其所有邻居温度的平均值。最后将目标用户未选择的物品（灰色）按能量值降序排列，并选择前 L 个物品推荐给目标用户。随后，Zhou等人^[13]又提出了物质扩散的推荐算法。后续很多基于网络拓扑结构的推荐算法^[14, 39-42]在近几年掀起了一股研究的热潮。




图 1-2 热传导算法示意图

1.2.3 社会化标签推荐系统

社会化标签系统（Social Tagging System, STS）是新一代的网络应用，广泛存在于电子商务网站、视频音乐分享网站、新闻资讯平台和社交网络。STS 系统赋予了使用者发表和编辑内容的权利，用户生产分享一些表达自己观点的元数据，这些可分享的元数据为用户自由产生的关键字，被称之为标签。标签的出现给系统平台提供了额外的分类方式并且加深了对用户需求的了解，也给在线的用户提供了表达自己观点的机会并且在找寻志同道合的人和物上节约了时间和精力。标签带来了便利也带来了信息过载的问题，反而降低了用户内容检索和信息分享的能力。于是出现了社会化标签推荐系统。如分享书籍标签的Delicious 网站、分享音乐标签的Last.fm 平台、分享图片标签的Flickr^[43]和国内著名分享网站豆瓣^[44]等。

社会化标签推荐系统是新的研究热点，近年来引起了很多的重视，对此的研究成果^[45-47]不断的出现。有别于传统推荐算法使用的“用户-物品”的二元数据，社会化标签推荐系统将在“用户-物品-标签”组成的三元数据上完成。Symeonidis等人^[48]用稀疏矩阵来表示三元数据的关系，（如图1-3(a)所示），用1表示某个用户对某个资源使用了某个标签描述，0 表示没有操作。Rendle等人^[49]也借鉴了这种思路，在学习个性化标签排序的时候，区分了正/负样本和缺失值，（如图1-3(b)所示），利用最优分解来解决标签推荐这个特定问题。由于三元关系的数据不能直接应用于协同过滤算法中，Marinho等人^[50]将这种三元关系降

维到低维空间, 并使用协同过滤算法预测用户偏好。Tso-Sutter等人^[51]提出一种方法, 将标签扩展成“伪用户”和“伪资源”得到经典的“用户-资源”二元矩阵。Deshpande等人^[52]在基于物品的协同过滤算法基础上, 通过计算相同标签的出现次数预测用户对某个物品的兴趣度程度。Wetzker等人^[53]提出了类似的想法, 对概率潜在语义分析模型进行标签扩展做物品推荐。Zhang等人^[54]用超图表示三元关系, 见图1-4。




图 1-3 稀疏矩阵表示三元关系^[10]

对真实社会化标签系统的研究还有很多。Gemmell等人^[55]对有多种类型的标签和主题的数据进行了研究后发现, 在有明确主题的系统里单一主题比多主题的推荐效果更好, 并且在此类系统中, 主题选择是提高推荐效果的最佳策略。Shang等人^[54]在Delicious数据上, 使用基于网络拓扑结构的推荐算法, 使用标签信息有效地提高了个性化推荐的准确性。Song等人^[56]通过对标签进行聚类, 在CiteULike数据集和Delicious数据上进行试验, 发现搭建的框架能够高效并有效地制作标签推荐。测试文档的平均标签时间约为1秒, 超过88%的测试文档正确标记了推荐列表中的前九个标签。针对在线相册的盛行, Chen等人^[57]提出了一个名为SheepDog的系统, 在Flickr上为用户推荐合适的标签。Garg等人^[58]也对Flickr的个性化交互式标签推荐问题进行了针对研究, 并当用户为特定图片输入/选择新标签时, 系统会根据她或其他人以前使用过的标签向其建议相关标签。Sigurbjörnsson等人^[59]也对Flickr和Zoomr等在线照片服务平台进行研究, 提出更方便用户对照片进行标注的算法。


1.2.4 信任增强推荐系统

Web2.0的特征之一是协作、交互和信息共享。这些特征催生出了如博客(新浪博客、Twitter等)、维基(如Wikipedia这也统统添加编写内容的Web应用)、社交网站(如人人网、Facebook、车迷论坛等)等众多应用。研究显示, 人们更愿意信任朋友的推荐^[60]。随着社交网络的迅速发展和推荐系统应用于音乐分享、电



图 1-4 超图表示三元关系

子商务、新闻资讯等领域并取得了不俗的成绩，人们对信任增强推荐系统产生了越来越大的兴趣。信任增强推荐系统的典型例子是FilmTrust网站，该网站允许用户对熟悉的电影进行1至10之间的评分。另一个典型例子是Epinions电商网站，用户可以根据某些人对物品的点评选择对这些人信任或者不信任。推荐系统中的信任关系如图1-5所示，在基于协同过滤的推荐系统中，用户 a 和用户 b 因对某些物品 i_1 进行了相似的评分从而建立起了关联，用户 b 和 c 也建立了关联。协同过滤算法可以预测出用户 a 对物品 i_2 感兴趣。但因为用户 a 和 c 之间没有建立关联，所以推荐系统不能将物品 i_3 放进用户 a 可能感兴趣的物品列表里。当用户之间建立了信任网络后，情形就会变得不一样。如图中用户 a 信任用户 b ，用户 b 信任用户 c ，那么用户 a 在一定程度上会对用户 c 有较高的信任度，此时物品 i_3 对用户 a 来说可能是一个好的推荐，并且会被系统安排在用户 a 的推荐列表的靠前位置。

图 1-5 推荐系统中的信任关系^[10]

信任增强推荐系统由推荐技术和信任度构成。近年来研究表明,在某些情况下,利用社交网络的数据产生的推荐与使用历史数据产生的推荐相比,结果更加准确^[61],将社交网络数据与传统的推荐协同过滤算法进行结合能提高推荐结果的准确性^[62]。有些推荐系统^[63, 64]利用信任传播(基于用户之间的信任可传递性,如a信任b, b信任c, 计算a对c的信任值)和聚合算子(将几个信任评估合并为一个信任值),提高推荐系统性能。Richardson等人^[65]专注于计算应用中的信任(包含语义消息,如文献服务器)。Jamali等人^[66]提出了结合了信任关系的随机游走方法和基于物品的协同过滤方法。Shen等人^[67]利用集合了信任关系的协同过滤方法提出了两个用户信任模型。Ma等人^[68]提出了一个扩展的框架,这个框架将用户的喜好和用户朋友们的喜好融合在一起。Guo等人^[69]在用户的评分信息和信任关系的基础上提出了一种信任矩阵分解技术来提高推荐性能。Wang等人^[70]对基于扩算的推荐算法与信任关系进行研究,认为这方面的研究仍有不足,需要研究者利用多个社会信息资源进一步探索基于网络扩散的框架以设计更好的推荐算法。除了信任,用户之间也存在不信任关系,如Epinions网站上有不信任用户名单。不信任名单和信任名单都反映了用户的偏好,但从研究的角度看,不信任尽管作用巨大,但该领域目前的研究处于起步阶段^[71-73]。

1.3 本文主要的研究内容和框架

本文的章节关系如图1-6所示,对推荐系统面临的问题:准确性和多样性两难问题和冷启动问题,进行了针对性的研究。从网络结构上来说,本文研究的推荐算法涵盖了单模网络(用户信任关系-用户-物品)、二部分网络(用户-物品)和三部分网络(用户-标签-物品)的推荐算法研究。从研究内容上来说,本文提出了基于节点相似性的推荐算法;使用用户信任关系提出信任增强推荐算法;利用标签信息提出社会化标签推荐算法。从推荐算法性能上来说,本文研究的推荐算法不仅仅注重准确性同样也注重算法的多样性和新颖性。本文的具体组织结构安排如下:

第一章阐述了课题研究的背景与意义,介绍了推荐系统诞生的背景、功能和应用,讨论目前研究的难点以及研究的意义,重点介绍了协同过滤推荐系统、基于网络拓扑结构的推荐系统、信任增强推荐系统和社会化标签推荐系统在国内外研究现状。

第二章介绍了推荐系统的基本知识,首先对推荐系统的应用做了介绍,其次对推荐系统目前面临的挑战和难题进行了讲解,接着对推荐算法进行了分类,最后介绍研究推荐算法需要用到评价指标和常用的数据集。




图 1-6 论文结构

第三章主要研究基于节点相似度的推荐算法，分析了相似性指标的选择对推荐结果准确性、多样性和新颖性的影响。结果显示，基于余弦相似性的协同过滤推荐算法的准确性很高，但多样性较差；基于资源分配相似性的物质扩散推荐算法的多样性很好，但准确性不足。通过混合余弦相似性和资源分配相似性指标，提出了一种新的网络节点相似性度量指标（CosRA）。进一步在，在资源分配的框架下，提出了一种基于CosRA指标的推荐算法。实验结果显示，基于CosRA的推荐算法表现出更好的推荐准确性和多样性。所提出的CosRA指标没有参数依赖，非常适合作为普适的网络节点相似性计算方法，应用于推荐系统中。

第四章主要研究了信任增强推荐系统。将人与人之间的信任关系作为辅助信息，与基于CosRA相似度指标的推荐系统框架中，提出了一种信任增强的推荐算法。实验结果显示，通过参数调节算法中资源分配的方式，提高受信任用户的权重，对推荐算法的性能有很大的提升。并且参数存在一个不依赖于数据集的最优值。在接下来的研究中，在资源分配的框架下，充分利用信任关系，提出一种基于信任关系的资源分配算法。研究中分析了受信任用户在资源分配权重上的变化对推荐效果的影响。实验结果表明，适当增强受信任用户在资源分配上的权重，

能够显著提高推荐算法效果。

第五章主要研究了社会化标签推荐系统。针对推荐系统所面临的冷启动问题，本章选择标签信息作为研究的突破口。标签体现的是用户的对内容偏好和选择倾向等。实验在引力模型的框架上，提出基于引力模型的推荐算法，充分利用用户给物品标注的标签信息，计算用户与物品之间的相似性，预测用户感兴趣的物品。进一步，从理论层面研究引力模型算法的本质，从网络演化的方向研究基于引力模型的推荐算法的网络构造，分并与真实网络对比。结果表明，基于标签信息的引力模型构造的网络最接近真实网络，并且标签将用户在网络上的行为特征放大，因此使用标签对历史记录稀疏的用户来说非常重要。更进一步，从信息传播的方向，研究了双层网络上影响信息传播的因素。对规范化处理标签信息提供了有用的建议。

第六章是论文的总结和展望，对已有的工作进行了总结，分析现有工作的不足之处以及可改进的方向，并对未来的工作提出了展望。

第二章 推荐系统基础简介

互联网的快速发展给人类社会带来了非常大的影响，也极大地改变了人们的生活方式，很多社会活动从线下转移到线上。比如以前只能去影院等地方观赏电影，而现在在线就可以观看大部分电影。以前的资料内容只能通过纸质记载传播，而现在线上提供各种存储、传播、查看的服务。以前购买物品要去商城超市，而现在足不出户就可以买够绝大部分生活所需的物品。由于互联网的庞大的体量，在给人的资源获取带来了很大便利的同时，也带来了信息过载的困扰。例如Netflix上有成千上万的影视作品，Amazon上有百万本书籍可供选择，Delicious上更有无数的网页在个人最喜欢的清单上。很显然，人的精力是有限的，要从这么巨大的信息中选择自己想要的信息非常困难。并且人与人之间的差异性导致每人的需求也不一样，每个用户都需要更加个性化的服务。因此我们需要一有些方法和技术来帮我们处理这些问题。于是推荐系统应运而生，它通过分析用户历史的数据，可以帮助用户找到潜在感兴趣的信息。不同的平台和推荐算法为用户制定了更加个性化的服务需求。推荐系统在现代生活中用途广泛，已经在多个领域里做出了极大贡献。同时推荐系统被来自计算机、经济、物理等不同领域的专家学者们广泛关注，产生了大量的研究成果。本章节将介绍推荐系统的应用以及面临的挑战、推荐算法的分类、推荐系统常用的评价指标和数据集。

2.1 推荐系统应用

电子商务应用。推荐系统的诞生对电子商务来说是一个巨大的福音，它包含的理念是为服务对象提供适合的物品，同时还隐藏了另一个理念是为物品找到适合的服务对象。这两个理念极其符合电子商务的发展。因此推荐系统在电商的发展中起到了巨大的作用。电子商务也是最成功的应用推荐技术的代表^[74]。对电子商务公司来说，为客户提供准确多样的商品可以极大提高客户的购买力和粘性，并且将大量的处于长尾态的商品推荐给用户，提高了冷门物品的出售率。更进一步的，对每个客户展示与客户需求关系密切的商品或者促销活动，从而增加商品的曝光率和购买率。对客户来说，难以从如此庞大的体量中发现自己想要的商品，而推荐系统恰好解决了燃眉之需，对彼此都是一个双赢的结果。最开始应用这项技术的是Amazon。Amazon在推荐技术的应用上不仅起步最早，而且到现在也受惠于这项技术。其他的电子商务公司如京东、淘宝等也纷纷使用了推荐技术。当客户进入电子商务网站时，推荐系统通过对客户已有的浏览、关注、购买等行为

建模, 预测客户的需求并推荐给客户可能需要的商品。具体每个电子商务网站的推荐算法有很大差别。如在Amazon网站上, 当用户将某个商品添加进购物车后, 会向该用户推荐浏览过这个商品的其他用户所选择的商品。这是一种基于用户的协同过滤算法^[27]的思想。当结束这一次活动, 再次登录Amazon网站时, 推荐系统会根据当前用户已经购买或者已经浏览的商品记录, 向客户推荐与这些商品相关联的其他商品, 此时运用的是基于物品的协同过滤算法^[75]和关联规则算法的思想。淘宝和京东都为客户提供了对已经购买过的商品进行打分的功能, 通过评分反映客户对商品的满意程度。

社交网络的应用。最近十年社会化网络的应用体现到人们生活的方方面面。人们可以在互联网上自由创造内容, 对喜欢的内容打标签和分类, 对喜欢的人点赞和关注, 与其他用户进行交互。被社交网络吸引的数以亿计的用户, 在互联网上进行了大量的活动, 引起了“社交过载”的问题: 大量用户面临大量信息并参与了大量的交互。一方面用户面对过多的网站变得难以选择, 另一方面社交媒体如新浪微博、腾讯QQ等希望留住更多用户, 增加用户粘性。因此, 推荐系统应用于社交网络对双方都是一种共赢。社交媒体通过对推荐系统按照用户属性对用户进行分类, 分别对其提供精准的个性化的服务, 吸引新用户的到来并且留住更多的老用户。用户则选择为自己提供更精确服务的媒体, 在内容选择和分辨上节约更多的精力。在基于相似兴趣的网络(Twitter)^[76-79]上, 用户按照自己的兴趣、根据浏览的内容与其他用户建立关注关系, 推荐系统的运用可以显著缩短这一阶段的时间, 并且为用户提供了他可能感兴趣的用户和内容。新浪微博^[80, 81]是中国最大的最受欢迎的社交媒体之一, 微博上有很多的应用如个性推荐、精确营销、客户关系管理等。每天活跃在新浪微博上的用户上千万。在新浪微博上, 用户可以对内容浏览、转发、评论和点赞, 也可以对其他用户进行关注。用户的这些行为反馈给推荐系统, 推荐系统再对用户进行偏好分析, 预测用户会对哪些内容和人感兴趣, 并推荐给用户。

数字音频的应用。早在1985年美国学者尼尔·波兹曼在《娱乐至死》一书中表达过观点: “一切公众话语日渐以娱乐的方式出现, 并成为一种文化精神。”^[82]互联网发展到今天, 娱乐占据了网络的半壁江山。YouTube^[83-85]、Netflix、爱奇艺、哔哩哔哩、抖音等视频分享网站上活跃着数以亿计的用户, Last.fm、Pandora、网易云音乐等为在线用户提供了丰富多彩的音乐。在竞争激烈的今天, 越来越多的信息以视频音频的形式存在于网络上。各大视频类网站不仅购买电视电影等视频资源, 还自制各种类型的视频内容吸引和巩固用户。像电子商务网站一样, 视频音频类的网站也是最早引入推荐技术的网站之一。YouTube推荐具有时效性和多

样性，与用户最近的行为相关，采集用户在网站上的行为数据，通过多种协同过滤技术对数据进行扩展，将一些相关性的内容排序后展示给用户。在爱奇艺网站上，当用户点击并停留在某个视频画面时，网站为用户提供了“相关推荐”，并在画面下方出现了“猜你喜欢”的模块。“相关推荐”部分展示与目前观看的视频相关联的内容，可以通过关联规则和基于物品的协同过滤算法进行推荐。“猜你喜欢”部分，是网站将个人用户的观看记录输入系统数据库，后台分析并预测用户可能会喜欢的内容，并呈现在此版块中。网易云音乐是国内著名的音乐分享平台，与电子商务网站一样，网易云音乐也不仅仅提供了一种类型的推荐服务。当用户点击播放某首歌曲并查看评论时，右下角会出现相类似的歌曲。用户查看一首歌的评论，说明对这首歌非常感兴趣并且想要了解更多，此时进行推荐对用户来说是一个深度了解的机会。

新闻资讯的应用。网络的实时性极大地扩充了新闻媒体的展示方式，最新新闻资讯并不需要等到一定的时间从电视媒体获得，也不需要去报刊亭购买报纸查看。在线的社交网络上可以兼顾信息的传播，如新浪微博^[80, 81]，Twitter^[76]等，还有一些专门的社会化新闻聚合器如Digg，Google Reader等。在信息爆炸的时代，面对越来越多的选择，人们常常会无所适从。在这种情况下，推荐系统便开始展现出技术优势，发挥威力。推荐系统在新闻资讯上应用的主要挑战在于新颖性。一则新闻或者故事即使内容丰富并且符合用户的兴趣和偏好，但如果用户已经从其他渠道看过听过，那么给用户推荐这则新闻就是失败的。尤其是现在不仅新闻平台多，其他社交平台还兼具信息输出的功能，目前的解决方案是提高推荐算法的多样性。Reddit和Slashdot都允许用户在浏览新闻的同时进行评价。Digg除了通过投票决定将最热的资讯推送给用户之外，还允许用户提供新闻故事的链接，并对此进行投票和讨论。国内的新闻资讯如网易新闻、新浪新闻、今日头条等也都建立了相关的内容推荐。例如今日头条通过采集用户的新闻浏览记录，从海量的资讯里找到用户感兴趣的内容推送给用户。图2-1展示了用户进入今日头条后，今日头条将对用户的推荐内容置顶，根据用户的历史浏览记录在页面下方为用户推荐了7条相关的内容。

基于位置服务的应用。随着智能手机的普及和无线网络的大范围覆盖以及Web2.0技术的迅猛发展，基于地理位置的应用一度变得非常流行，例如Foursquare、Facebook Places、街旁、58同城等。文献[86]已对此现象做了总结，认为这是一种新的社会结构。基于位置的社交网络将线下的世界和线上世界结合起来，吸引了大量的用户，基于位置的平台得到了快速的发展。例如Foursquare的统计数据显示，累积到2015年，平台已经累计吸引了超过5000万的

图 2-1 今日头条的推荐服务^①

用户加入，收录了超过6000万的地点，签到次数更是突破了70亿。近两年来外卖的流行也是基于地理位置服务的平台快速发展的体现，例如本地生活平台的两大巨头饿了么和美团。

2.2 推荐系统面临的挑战

推荐系统发展至今已有几十年的时间，吸引了学术界众多研究者的关注并产生了许多研究成果，同时推荐系统也是学术和实践共同发展相辅相成的典范，已有众多实际的运用，详见2.1节。但是目前推荐系统也存在众多的问题，面临严峻的挑战。

多样性与精确性的两难问题。推荐系统推荐用户喜欢的物品，一个原则是准确。想要推荐用户喜欢的物品，最简单保险的方式是推荐特别流行的物品，用户有很大概率都会喜欢。但是这样做导致用户的体验变差。现在线上线下都有众多的渠道去获取信息，尤其是流行物品，用户很有可能已经知晓或者选择过这些物品。这样的推荐与用户的个性化需求相悖。从实际应用角度来说，系统因为用户选择的物品过于流行，而大部分小众的物品难以出现在用户面前，对收益不利。另一方面，发掘冷门的物品给用户，使用户产生惊喜的感觉，可提高用户对推荐系统的信任和粘性。研究已经表明，过度追求精确性会导致用户获得有用的信息变少，并且可选择的面越来越狭窄^[16]。因此顺应平台和用户两者的需求，多样性

^① <https://www.toutiao.com/>.

是一个必然的趋势。但是准确性和多样性之间存在着矛盾。对用户而言,如果推荐的物品过于小众但是符合自己偏好的物品变少,会对推荐系统产生怀疑。而商家也因此减少了收益。对这个两难的问题,很多时候只能二选一,注重准确性牺牲多样性或者注重多样性牺牲准确性。

对多样性与精确性的两难问题,目前一种可行的思路是处理用户的推荐列表^[15,25],提高列表内容的多样性。另一种可行的思路是利用社交网络做为辅助信息,对推荐算法进行增强。研究表明,相比起推荐系统,用户更加信赖来自朋友的推荐^[60],通过分析社交关系,可以提高网购物品的推荐准确度^[87]。所以对于社交关系如何运用于推荐系统^[88],提高推荐算法的性能,同时也建立更好的机制促进社交网络的推荐^[89,90],这些都是推荐系统需要考虑的问题。第四章将研究信任关系如何提高推荐算法的性能。

冷启动问题。冷启动问题出现在用户第一次加入到推荐系统中,用户的历史记录和个人描述文件基本空缺,导致无法给出精确的推荐。另一种冷启动现象是,新商品加入到平台后由于被选择的次数少,无法和其他的物品以及用户产生关联,导致新商品无法及时被用户发现。在基于文本信息的推荐系统中,通过收集提取物品的文本信息,利用物品之间的关联性进行推荐。在一些场景中,如音乐等,较难以获得物品的形象化描述,便难以利用物品相似性信息。

冷启动问题的解决思路,是通过收集用户的属性信息,如居住地点、受教育程度、职业、性别和年龄等,填补个人描述文件的空缺^[19]。例如一些推荐系统注册的时候要求填写个人信息。而基于社会化标签(Tagging Systems)的推荐系统为冷启动问题提供了一种解决方案^[22]。标签代表的是用户对物品的看法和喜好,例如最新上映的电影《红海行动》,有人对此的标签为“爱国”,有人打的标签是“战争”。虽然电影相同,但标签反应出用户的兴趣点不一样。虽然标签系统提供了一种解决方法,但对刚进入推荐系统的用户没有帮助。研究表明,对新用户最有效的策略是推荐流行度高的物品^[91]。冷启动问题的解决方案还可以从多维度交叉推荐这部分解决,如有些平台借鉴其他平台的用户描述文件和历史数据建立用户个人的推荐模型,例如支付宝和饿了么。在第五章中,我们将研究社会化标签推荐系统。

此外,人们的社交网络相互重叠涵盖了线上和线下。几乎每个人都不只参与一种社会网络,比如手机网络、微博网络、淘宝网络等。如果能将这些网络信息整合起来,将带来巨大的经济价值,并且有望彻底解决推荐系统的冷启动问题。目前的研究方向是通过“迁移学习”^[92],将一个领域的知识和习惯迁移到其他邻域。研究表明,学习在某些系统中的特定行为可以用于预测在其他系统中的特定行为^[93]。

数据稀疏性问题。数据稀疏性是指推荐系统中缺少有用的信息。系统的稀疏性可以用物品与用户的连边比例来衡量。现在的网络平台规模越来越大,用户和物品都是在千万以上。如果用户和物品之间的交互变少,或者用户选择变少,或者物品增多都有可能导致稀疏性。例如淘宝声称有8亿商品^[4]。数据稀疏会导致系统在计算用户之间的关联或者物品之间的关联时不准确,于是绝大部分基于关联分析的算法的推荐效果会比较差。稀疏性的问题是任何推荐系统都无法逃避的问题,并且也无法完全从根本上解决。研究人员为此提出了很多的解决方法,例如通过更科学的采样方法提高数据密度、采用扩散算法^[35]将基于共同评分和购买的一阶关联提高到二阶关联、使用随机游走算法^[42]结合网络的局部和全局信息、通过多步迭代提高信息利用程度^[94]、通过转移相似性以获得更过用户/物品之间的相似性^[95]、在评分矩阵中添加缺失物品的打分^[30]等。

推荐系统的脆弱性问题。一些电子商务类型的推荐系统,很容易受到一些心怀不轨的用户的攻击^[96]。这些用户做出一些虚假恶意的行为,增加某些商品被推荐的可能性,或者压制对手的商品的曝光率,损坏竞争对手利益,甚至破坏系统使其无法产生有效推荐^[10]。比如在基于协同过滤算法的推荐系统上,恶意建立起对流行物品关联,或恶意提高与大度用户的关联,以此提高某些物品被推荐的概率,影响系统的公正。仅文献[10]就罗列出了4大种类8种不同的攻击策略。因此,鲁棒性是推荐系统领域较关注的一种评价指标。目前,此方面的研究比较少,且缺乏系统性的分析。有代表性的解决办法是分析对比真实用户和疑似恶意用户之间行为模式的差异,提前进行判断,从而阻止恶意用户进入系统或降低恶意用户的影响力^[97-99]。

推荐系统效果评估问题。尽管对推荐系统的研究已有几十年,就如何评价推荐系统这一问题,学术界和工业界未能达成共识。常见的评估指标主要有准确度、多样性和新颖性,并且还有很多子指标,如准确性指标可分细分为预测评分准确度、预测评分关联、排序准确度和分类准确度四类。仅分类准确度就包括了AUC值、*RankingScore*值、准确率、准确率提高率、召回率、召回率提高率和 F_1 指标。朱等人^[100]总结出了推荐算法研究常用的指标。但是对于工业界关心的指标的研究非常少,如受推荐影响的转化率、购买率等^[101]。除此之外,针对用户体验的指标也是至今面临的难题。因此,对学术界指标和工业界指标达成共识,提出满足两者需求的指标和理论研究,对推荐系统的发展会有重大的推动作用。

用户隐私问题。用户隐私问题不仅仅存在于推荐系统,而且存在于整个互联网。由于推荐系统中需要用到用户的历史记录或者个人身份信息等隐私,如果这些信息没有得到保护,将会对个人造成很大影响,既会影响到用户对推荐系统的

信任，也会给不法之徒攻击用户和推荐系统的机会。用户在互联网上的很多网站上都留下了足迹，而且是时时刻刻都会产生不同的足迹，如基于地理位置的服务平台读取了用户的实时位置^[86]，电商的网络平台保留了用户的经济状况信息^[9]等。组合不同来源的用户信息甚至可以推出更多用户不愿透露的隐私^[102]。移动互联网时代的到来使得移动终端的隐私保护更加迫切和重要。

2.3 推荐算法的分类

推荐系统是一门涉及多学科的研究领域，现在取得的研究成果也是多个学科领域的学者共同努力的结果。信息科学、物理学、管理科学、运筹学等多门学科都对推荐系统的研究做出了贡献，特别是计算机科学领域，机器学习、数据挖掘、信息检索和人机交互都极大推动了推荐系统的发展。这些跨学科的研究成果使得对推荐算法的分类变得困难，有些推荐算法并不严格属于某一类。Ricci等人^[10]在《Recommender System Handbook》一书对算法进行了划分。本文按照计算方式的不同将算法大致分为以下六类。

2.3.1 基于内容的推荐算法

基于内容的推荐算法^[103]为用户推荐与该用户的兴趣相类似的物品，通过分析用户历史记录里的对物品的评分和描述，建立起物品的模型，或建立用户兴趣的结构化描述信息。基于内容的推荐系统的结构包含三个部分：内容分析器、信息学习器和过滤组件，如图2-2所示。

内容分析器的功能是将收集到的数据（如新闻、产品描述等）按照推荐系统自定义的格式存储，方便推荐系统进行下一阶段的处理。一般使用信息检索的技术^[104]处理数据，并抽取数据对象的特征向量。信息学习器使用机器学习技术^[105]泛化用户特征信息，这些特征信息表征了用户偏好。过滤组件部分在表示空间对前面生成的数据进行分析，将个人数据与物品数据进行匹配，基于个人信息推荐相关的物品。过滤组件使用某种相似度^[106]，输出一个相关性判断，根据实际情况，相关性判断可以是二元也可以是连续型的，最后生成潜在感兴趣的物品名单。根据反馈的方式不同算法分为显示反馈和隐式反馈两种。显示反馈通过三种方式收集用户对一个物品感兴趣的程度^[10]：（1）使用两分法将物品分成“相关”（感兴趣）和“不相关”（不感兴趣）两大类^[107]；（2）用离散数值表示对物品的评价，比如1分表示不喜欢，10分表示非常喜欢等；（3）展示详细物品的文本评论，利用情感计算技术自动执行。隐式反馈来自对用户的监控和分析，不需要任何活跃用户的参与^[108]。对于用户特征的分析，最有创新性和有趣的解决办法




图 2-2 基于内容的推荐系统结构^[10]

之一是语义分析与个性化模型的结合。例如语义分析与关键字向量空间模型的结合，使用基于文本实验观察结果的 $TF-IDF$ （词频-逆文档频率）^[109]度量特征向量的相似度。使用 $TF-IDF$ 函数表示物品 α 的特征向量，通过比较特征向量，寻找与该物品相类似的其他物品。首先选择描述物品 α 的一个关键词 t ，计算关键词 t 的 TF 值：

$$TF(t, \alpha) = \frac{f_{t, \alpha}}{\max_z f_{z, \alpha}}, \quad (2-1)$$

其中， $f_{t, \alpha}$ 表示对物品 α 的描述中，关键词 t 的出现次数， z 表示在对物品 α 的描述的所有关键词中词频最大的关键词， $\max_z f_{z, \alpha}$ 表示所有关键词 z 的出现次数。 $TF(t, \alpha)$ 越大，表示关键词 t 越能代表物品 α 。

当某个关键词在描述物品 α 中词频较高，但是在描述其他物品时出现概率较低，说明这个关键词与该物品最相关。因此，算法还需要 $TF-IDF$ 函数过滤常见的关键词，只保留相关性高的关键词。物品 α 的描述关键词 t 的 $TF-IDF$ 值为：

$$TF-IDF(t, \alpha) = TF(t, \alpha) \log \frac{N}{n_t}. \quad (2-2)$$

其中， N 表示物品数， n_t 表示使用关键词 t 描述过的物品数。

接着对物品的特征向量进行归一化处理,使所有物品用相同长度的向量表示。物品 α 用向量 $\{w_{1\alpha}, w_{2\alpha} \cdots w_{T\alpha}\}$ 表示, T 表示关键词的个数,其中

$$w_{t,\alpha} = \frac{TF - IDF(t, \alpha)}{\sqrt{\sum_{t=1}^T TF - IDF(t, \alpha)^2}}. \quad (2-3)$$

最后,通过使用相似度的计算方式计算两个物品的接近程度,余弦相似度是使用最广的相似度计算方式。计算两个物品 α 和 β 的相似度为:

$$sim_{\alpha,\beta} = \frac{\sum_{t=1}^T w_{t,\alpha} w_{t,\beta}}{\sum_{t=1}^T w_{t,\alpha}^2 \sum_{t=1}^T w_{t,\beta}^2}. \quad (2-4)$$

在使用基于内容的推荐系统中,用户和我物品信息都表示为带权重的关键词向量,因此,预测用户感兴趣的物品可通过余弦相似度计算得到。语义分析与基于关键词系统结合,产生了众多著名的推荐系统,如使用过滤工具来发现潜在感兴趣的信息的Amalthea^[103]、提供新闻过滤的NewT^[108]等。或者运用本体的语义分析进行推荐,如Informed Recommender^[110]基于消费者评论信息给出推荐建议,Interactive Digital Television^[111]借鉴语义网技术将用户偏好的物品推荐给用户。

2.3.2 协同过滤推荐算法

协同过滤(Collaborative Filtering, CF)算法^[75, 112-114]基于用户和物品之间的交互信息建模。算法计算用户之间或者物品之间的关联程度从而进行推荐服务。推荐系统的发展是受一个生活的常见现象的启发:人们在做决策时,通常会听取其他人的建议^[115]。例如,人们在选择看哪一本书时,会征求朋友们的推荐。雇主在寻找雇员的时候,也会参考雇员的推荐信。为了模拟这种行为,研究者提出了协同过滤算法^[26, 27]。自NetflixPrize大赛举行以来,协同过滤领域获得来自不同领域的研究人员的极大关注,并且该方法已应用于商业和学术研究中。从对待数据的方式上,协同过滤算法被划分成两种算法:隐语义模型和基于邻域的方法。

隐语义模型,研究重点在将物品和用户映射到相同的隐语义空间,通过用户的反馈推断出来的特征因子,分别描述用户和物品在特殊因子上的评分。代表算法有贝叶斯聚类算法(Bayesian Clustering)^[30]、潜在狄利克雷分布(Latent Dirichlet Allocation)^[116]、潜在语义分析(Latent Semantic Analysis)^[117]、玻尔兹曼机(Boltzmann machines)^[118]、支持向量机(Support Vector Machines)^[119]、最大熵(Maximum Entropy)^[120]和奇异值分解(Singular Value Decomposition)^[121]等。

基于邻域的方法,研究的重点在于计算用户之间的关联程度或者则物品之间的关联程度。这一领域的代表性算法是基于用户的协同过滤(User-based Collaborative Filtering, UCF)^[27]算法以及基于物品的协同过滤(Item-based

Collaborative Filtering, ICF) [75] 算法。UCF 算法寻找品味相似的其他用户, 根据相似度将其他用户选择的物品进行推荐, 越相似的用户所选择的物品越有可能被推荐。ICF 算法寻找与用户偏爱的物品相类似的其他物品, 并推荐给此用户。基于评分 ICF 算法 [52] 计算两个物品 α 和 β 的评分相似度如下:

$$sim_{\alpha,\beta} = \frac{\sum_{i \in U_{\alpha} \cap i \in U_{\beta}} (r_{i\alpha} - \bar{r}_{\alpha})(r_{i\beta} - \bar{r}_{\beta})}{\sum_{i=1}^M (r_{i\alpha} - \bar{r}_{\alpha})^2 (r_{i\beta} - \bar{r}_{\beta})^2}, \quad (2-5)$$

其中, M 表示总的用户数, $i \in U_{\alpha} \cap i \in U_{\beta}$ 表示用户 i 同时选择过物品 α 和 β , r 表示用户对物品的评分, $\bar{r}$ 表示物品被所有用户评分后的平均分。通过计算得到物品 α 和 β 之间相似度后, 结合用户 i 的历史评分, 计算用户 i 对物品 β 的评分如下:

$$r_{i,\beta} = \frac{\sum_{\alpha \in O_i} sim_{\alpha,\beta} r_{i\alpha}}{\sum_{\alpha \in O_i} |sim_{\alpha,\beta}|}. \quad (2-6)$$

其中 $\alpha \in O_i$ 表示物品 α 存在于用户 i 的选择列表中。最后计算用户 i 对所有物品的预测评分, 根据预测分值判断用户对物品的喜好程度。目前此类算法已广泛应用于 GroupLens [26] 和 Bellcore Video [122] 等系统和平台。

2.3.3 基于知识的推荐算法

基于知识的推荐算法 [123, 124] 是根据特定领域的知识进行推荐。知识包括了用户对物品的偏好和需求的理解、物品的特征是否与之符合以及如何确认是否推荐准确。传统的协同过滤推荐算法 [27, 75] 根据偏好相似进行推荐适用于如新闻、书籍等领域, 但在汽车销售、房屋租赁方面效果不佳。Felfernig 等人 [125] 为了解决这个问题提出了解决方法: 将用户的现实需求使用特定数据存入数据库, 与相同方式处理的产品领域的深度知识进行匹配。基于知识的推荐算法可以分为两类: 基于约束的推荐 [125, 126] 和基于样例的推荐 [127, 128]。区别在于推荐方案的计算方式不同。基于约束的推荐算法是建立在用户需求明确表达的基础上, 因此在对用户需求相关的知识获取上建立好规则是非常重要的事情。在收集用户的偏好信息上, 可以通过基于表达的偏好提取对话 [126]、使用自然语言处理技术收集用户偏好信息 [129]。目前这一类算法已应用于理财服务 [130], 电子生活消费品 [131] 等情景中。基于样例的推荐算法是通过计算物品和用户偏好的相似度来决定推荐内容的, 如使用相似函数估算用户需求与推荐内容的匹配度算法 [132, 133]; 而基于约束的推荐算法是要事先建立推荐知识库。知识库中包含用户的需求描述、与需求相关的物品特征描述以及两者的显示关联规则。通常知识库 [134] 包含有两个变量集合 (用户特征和物品特征) [135] 和三个约束集合 (客户需求约束、过滤条件和符合特征的物品) [136]。由于邻域专家和知识工程师在开发和维护知识库上存在差异, 知识库的开发是商

业应用上的难点^[126]。Felfernig等人^[126]建立的CWAdvisor系统减少了知识获取的难度，为邻域专家提供了技术支持，实现知识库开发和维护的流程自动化^[137]。

2.3.4 基于社区的推荐算法

基于社区的推荐算法^[61, 64, 68]利用用户的社会关系信息以及他们的历史行为数据等信息进行建模。研究表明，朋友们的建议比陌生人的建议更让人信赖^[60]。由于社交网络的普及，使得基于社区的推荐算法应用于越来越多的系统平台，通常这种推荐算法被称为社会化推荐算法^[138]。目前这类研究仍处于起步阶段，Donovan^[139]对此做了全面的报告。在某些情况下，使用社交网络数据相比使用用户资料相似度的数据，推荐的结果更加准确^[140]。社交网络与传统协同过滤推荐算法的结合能提高推荐算法的准确性^[68]。社会化信任网络是社会化网络中的一种，基于社会化信任网络的信任增强推荐算法已经得到广泛的运用，如Twitter、Facebook和Epinions等。Moleskiing等人^[63]利用信任传播（见图2-3(a)，基于用户之间的信任可传递，如a信任b，b信任c，计算a对c的信任值）将无直接关联的用户建立起虚拟的社会关系。Golbeck等人^[64]使用聚合算子（见图2-3(b)，将几个信任评估合并为一个信任值）对用户间的信任度重新进行计算。Ziegler等人^[141]使用用户之间的信任度代替他们之间的相似度，基于协同过滤算法计算用户*i*对物品 α 的预测分值：

$$p_{i\alpha} = \bar{r}_i + \frac{\sum_{j \in T_i} t_{i,j}(r_{j,\alpha} - \bar{r}_j)}{\sum_{j \in T_i} t_{i,j}}, \quad (2-7)$$

其中， $j \in T_i$ 表示用户*i*信任用户*j*， $t_{i,j}$ 表示用户*i*对*j*的信任度， $r_{j,\alpha}$ 表示用户*j*对物品 α 的打分， $\bar{r}_i$ 表示用户*i*对物品的平均打分。最后通过计算用户*i*对所有信任用户所选择过的物品的预测分值 p ，选择预测分值高的物品推荐给用户*i*。




图 2-3 传播实例和聚合实例^[10]

在使用到信任值时，一些推荐算法将信任分为二值：1表示信任，0表示不信任。一些学者研究信任对推荐算法的影响^[142-144]。Jamali等人^[66]提出了结合了信

任关系的随机游走方法和基于物品的协同过滤方法。Guo等人^[69]在用户的评分信息和信任关系的基础上提出了一种信任矩阵分解技术来提高推荐性能。除了信任,用户之间也存在不信任关系,但从研究的角度看,不信任尽管作用巨大,但该领域目前的研究仍处于起步阶段^[72, 73, 145]。另一些推荐算法^[146-148]认为信任值是一种渐进的现象,人们并不是对某人信任或者不信任,而是对他在一定程度上信任或者不信任。近年来渐进信任的方法得到广泛的应用,例如应用于网络上选择交流对象的管理机制^[149]、为语义网应用设计的模型^[148]等。除了建立起渐进信任的模型外,还有研究者对不信任模型进行了研究^[150-152]。也有一些研究者对两者同时出现的情况进行了研究^[153, 154]。

2.3.5 基于网络拓扑结构的推荐算法

最近网络科学的发展使得基于网络拓扑结构的推荐算法成为研究的新热点^[13, 14, 38]。Zhang等人提出的物质扩散算法(Mass Diffusion, MD)^[13]将用户和物品以及两者之间的连接描述成一个二部图结构,通过资源扩散的方式计算用户可能喜欢的物品,见图2-4。对目标用户(图2-4(a)左边橙色人物头像),赋予用户选择过的物品(图2-4(a)右边橙色书本图像)一个单位资源,资源均匀地从物品传递到用户,再从用户传到物品。在资源传递过程中,每个节点将资源均分后进行传递,总资源守恒。MD算法分为3步:

- (1) 对目标用户 u_i 选择的物品赋予一个单位的初始资源:

$$f_{i\alpha} = a_{i\alpha}, \quad (2-8)$$

(2) 资源通过用户与物品的连边均匀分配到所有选择过这些物品的用户中,假如用户 u_j 选择了物品 o_α ,而 o_α 是用户 u_i 选择过的物品,那么 u_j 从 o_α 这里得到的资源值为 $1/k_\alpha$, k_α 是产品 o_α 的度。对从不同物品分配的资源值进行累积,最终,用户 u_j 从用户 u_i 得到的资源为:

$$f_{ij} = \sum_{\alpha=1}^n \frac{a_{i\alpha} a_{j\alpha}}{k_\alpha}, \quad (2-9)$$

(3) 所有用户的资源值将均匀分配给他们选择的物品,分配方式参考第(2)步,其中物品 o_β 接收到从用户 u_j 的资源为 f_{ij}/k_j ,通过累积所有选择过物品 o_β 的用户资源值,物品 o_β 最终得到的资源值为:

$$f_{i\beta} = \sum_{j=1}^m \frac{a_{j\beta} f_{ij}}{k_j}, \quad (2-10)$$

通过对所有物品的资源值降序排列,选择前 L 个物品放入用户 u_i 的推荐列表中。

MD算法在准确性上高于传统的协同过滤算法^[26, 27]。类似的算法还有热传导 (Heat conduction, HC)^[38]算法。在此基础上衍生出了许多优秀的算法, 如有偏的物质扩散算法^[40]和有偏的热传导算法^[41]。在此类算法的研究中, Zhou等人^[155]通过改变初始资源的配置提高算法的性能, Jia等人^[156]在资源分配过程中为流行物品赋予了更高的权重, 也得到了很好的效果。




图 2-4 MD推荐算法

2.3.6 混合推荐算法

混合推荐算法^[157-160]是综合以上算法的优点, 将不同算法混合, 取各个算法的优势, 产生新的算法。例如冷启动的问题是协同过滤算法的短板, 而基于内容的算法不受此限制, 对物品的预测是基于物品的特征描述, 两者结合的新算法能适应更大的范围^[161]。物质扩散算法^[13]有极高的准确性, 热传导算法^[38]的多样指非常优秀, 两者的结合^[14]可以在准确性和多样性之间找到一个平衡, 以适应不同的环境。

2.4 推荐算法的评价指标

目前对推荐系统的研究已经有几十年, 但是如何评价推荐系统, 学术界和工业界未能达成共识。由于工业界关心的例如受推荐影响的转化率、购买率等没有完善的研究成果, 以下采用学术界常用的指标, 主要有准确度、多样性、新颖性, 并分析这些指标的优缺点以及适用环境。

2.4.1 准确性指标

推荐的准确度是评价推荐算法最基本的指标。它衡量的推荐算法对预测用户喜欢的物品的准确程度。也是目前推荐算法研究最常用的指标。准确度指标有很多种, 下面将对此进行详细介绍。

(1) **AUC指标**。用来测试推荐算法的全局预测的准确性。适用于没有明确二分喜好的推荐系统。AUC指标由于不受推荐列表长度 L 的影响，被广泛应用于评价推荐系统中。它表示ROC (Receiver Operator Curve)^[162]曲线下的面积，用来衡量推荐系统是否能够将用户喜欢和不喜欢的物品区分开来，但是ROC曲线绘制繁琐，在推荐系统研究中通常使用近似方法的AUC指标^[163]。AUC从整体上衡量算法的准确性，可以理解为目标用户的测试集中产品的分数比随机选择的一个产品（用户未选择）分数高的概率。对目标用户 i ，每次随机抽取测试集中的一个物品和一个既不在测试集也不在训练集中的物品进行比较，如果测试集中产品分数高，就加1分；如果分数相等就加0.5分，独立进行 $S^{(i)}$ 次比较后，加1分的情况出现 $S_1^{(i)}$ 次，加0.5分的情况出现 $S_2^{(i)}$ 次，则平均AUC计算为：

$$AUC = \frac{1}{m} \sum_{i=1}^m \frac{S_1^{(i)} + 0.5S_2^{(i)}}{S^{(i)}}, \quad (2-11)$$

在无算法并且所有的预测都是随机的情况下， $AUC=0.5$ 。AUC值最大可达到1。因此AUC值大于0.5的推荐算法才有准确性意义，数值越大表示推荐越准确。由于计算AUC值不依赖于推荐列表长度，并且表征了推荐算法的整体准确性，所以在推荐系统中运用非常广。但是AUC指标没有考虑到推荐的物品的排序，因此存在一定的局限性。

(2) **准确率**。准确率Precision^[100, 164]是常用的无序的评价指标，表示的是返回的结果中相关的内容所占的比例，不需要考虑返回结果的顺序。定义为推荐列表中符合用户喜好的物品所占的比例。用户的平均准确率为：

$$P(L) = \frac{1}{m} \sum_{i=1}^m \frac{d_i(L)}{L}, \quad (2-12)$$

其中用户 u_i 长度为 L 的推荐列表中有 $d_i(L)$ 个物品被预测准确，出现在用户 u_i 的测试集里。用户的推荐列表中完全没有预测准确的物品时 $P=0$ ，全部预测准确时 $P=1$ 。所以准确率越高，说明推荐效果越好，推荐列表越符合用户的实际情况。准确率依赖于用户的推荐列表的长度 L ，因此受推荐列表长度的影响。

(3) **召回率**。召回率Recall^[100, 164]是与准确性一体两面的评价指标，表示的是返回的推荐列表中相关内容占有所有相关内容的比例，不需要考虑返回结果的顺序。定义为用户在测试集中喜好的物品有多大的比例出现在推荐列表中。用户平均召回率为：

$$R(L) = \frac{1}{m} \sum_{i=1}^m \frac{d_i(L)}{D(i)}, \quad (2-13)$$

其中， $d_i(L)$ 表示共同存在于用户 u_i 长度为 L 的推荐列表和测试集中的物品的数目，

$D(i)$ 表示测试集中 u_i 选择的物品总数目。用户的推荐列表中完全没有预测准确的物品时 $R=0$ ，用户的测试集中的物品全部被预测准确时 $R=1$ 。所以召回率越高，说明推荐列表对用户喜欢的物品的覆盖率越高。召回率值依赖于用户推荐列表的长度 L 。由于每个用户的行为模式不一样，有些用户会选择非常多的物品，有些用户只选择了少量的物品，在用召回率计算推荐系统性能时，选择足够多物品的用户普遍召回率偏低，但这并不代表推荐效果差。

(4) F_1 指标。准确率和召回率都是依赖于推荐列表长度的评价指标，通常情况下，改变列表长度，这两者呈现此消彼长的关系。例如用户推荐列表中有10个物品，其中推荐准确的有1个物品，且用户的测试集中也只有1个物品，此时推荐准确率为0.1，召回率为1。为统一两者，学者提出了 F_1 指标^[100, 164]。 F_1 是一种同时考虑准确率和召回率从而比较全面地评价算法优劣的指标。 F_1 越高，算法准确性越好。定义如下：

$$F_1(L) = \frac{2 * P(L) * R(L)}{P(L) + R(L)}, \quad (2-14)$$

(5) MAP 指标。 AUC 指标、准确率、召回率和 F_1 值都是返回无序的结果，而实际展示给用户的推荐列表是有序的，排序靠前的物品吸引用户更多的注意力，因此需要考虑基于位置信息的准确性指标。 MAP (Mean Average Precision)^[165]值是近年来比较流行的评价指标，本质上就是平均准确率。 MAP 在准确率的基础上考虑了被推荐物品的排序。假设系统中有两个用户，用户1的测试集中有4个物品，用户2的测试集中有5个物品。推荐系统对于用户1给出的推荐列表中包含用户1在推荐系统中的4个物品，并且在推荐列表中的顺序为1, 2, 4, 7；对于用户2的推荐列表中也包含此用户在测试集中的3个物品，并在推荐列表中的顺序为1, 3, 5。对于用户1平均 MAP 值为 $S(1/1 + 2/2 + 3/4 + 4/7)/4 = 0.83$ 。对于用户2，平均 MAP 值为 $(1/1 + 2/3 + 3/5 + 0 + 0)/5 = 0.45$ 。则系统评价 $MAP = (0.83 + 0.45)/2 = 0.64$ 。平均 MAP 值定义如下：

$$MAP = \frac{1}{m} \sum_{i=1}^m \frac{1}{D(i)} \sum_{s=1}^{d_i(L)} \frac{s}{r_s}, \quad (2-15)$$

其中， m 为用户数目， $d_i(L)$ 表示共同存在于用户 u_i 长度为 L 的推荐列表和测试集中的物品的数目， $D(i)$ 表示测试集中物品的数目。 $r_s \in [1, L]$ 表示第 s 个共同商品在推荐列表中的排位。总的来说，系统推荐准确的物品在推荐列表中越靠前， MAP 的值就越高，算法越准确。如果系统没有推荐正确的物品，则 $MAP=0$ 。因此 MAP 值是依赖于用户推荐列表长度 L 的评价指标。

(6) RS 指标。除了 MAP 指标， RS (Ranking Score)^[166]也是基于排序的准确性指标。一个好的推荐算法应该把测试集中用户喜欢的物品排在推荐列表中靠

前的位置。比如一个用户在系统中有1000部电影没看过，这个用户喜欢《红海行动》，此电影出现在用户的推荐列表中的第10位，那么对此用户而言《红海行动》的 $RS = 10/1000 = 0.01$ 。对于任意一个用户 $u_i \in E^P$ ，假设他有 l_i 个物品是没有选择过的，推荐算法会将这 l_i 个物品按照算法得分进行排序，如果测试集中的物品 α （出现在测试集中的物品不会出现在训练集，相当于没有选择这个物品）在这个排序的位置是 p_α ，那么对所有用户遍历后的平均RS值定义如下：

$$RS = \frac{1}{|E^P|} \sum_{(i,\alpha) \in E^P} \frac{p_\alpha}{l_i}, \quad (2-16)$$

其中 $|E^P|$ 表示测试集。RS值越小，说明用户喜欢的物品排名越靠前，算法的排序准确性越好。值得注意的是，在数据集足够大的情况下， $AUC + RS \approx 1$ 。

(7) $nDCG$ 指标。 $nDCG$ (Normalized Discounted Cumulative Gain) ^[167]指标表示归一化折损累积增益，是一种考虑推荐物品位置和顺序的准确性指标，对被推荐的物品的相关性进行打分。推荐的物品与用户实际的选择越相关，被推荐物品的顺序越接近实际物品的顺序，则 $nDCG$ 值越高。首先考虑推荐列表中每一个物品的相关性，并对其进行累加得到累计增益 (Cumulative Gain, CG)，计算方法为 $CG = \sum_{i=1}^L rel_i$ ，其中 L 表示推荐列表的长度， rel_i 表示处于位置 i 的物品的相关性。其次考虑基于位置的累计增益 (Discounted Cumulative Gain, DCG)，降低相关性较弱但排序靠前的物品对推荐的影响，计算方式为 $DCG = \sum_{i=1}^L \frac{2^{rel_i} - 1}{\log_2(i-1)}$ 。分子部分 $2^{rel_i} - 1$ 表示物品相关性越强，DCG值越高，分母 $\log_2(i-1)$ 表示物品在推荐列表中越靠前，DCG值越高。为了在整体上衡量推荐算法的准确性，对DCG值进行归一化，得到 $nDCG$ 值， $nDCG = \frac{DCG}{IDCG}$ ，其中IDCG (Ideal Discounted Cumulative Gain) 是最理想的推荐列表排序结果，定义为 $IDCG = \sum_{i=1}^{|REL|} \frac{2^{rel_i} - 1}{\log_2(i-1)}$ ， $|REL|$ 表示文档按照相关性从大到小的顺序排序，取前 L 个文档组成的集合。最终， $nDCG$ 定义如下：

$$nDCG = \frac{\sum_{i=1}^L \frac{2^{rel_i} - 1}{\log_2(i-1)}}{\sum_{i=1}^{|REL|} \frac{2^{rel_i} - 1}{\log_2(i-1)}}, \quad (2-17)$$

2.4.2 多样性和新颖性指标

(1) 海明距离。海明距离 (Hamming Distance) ^[166]反映的是不同用户的推荐列表之间的差异程度。很显然，各个用户之间的推荐列表内容差异越大，说明推荐系统的个性化程度越高，体现推荐系统“千人千面”的特征。具体定义为：

$$H(L) = \frac{1}{m(m-1)} \sum_{i=1}^m \sum_{j=1}^m (1 - \frac{C(i,j)}{L}), \quad (2-18)$$

其中, $C(i, j) = |o_i^L \cap o_j^L|$ 是用户 u_i 和用户 u_j 的推荐列表中的共同物品的数目。海明距离依赖于用户推荐列表的长度 L , 当任意两个用户之间的推荐列表内容完全不一致时, 这两个用户的海明距离 $H = 1$, 内容完全一致时, $H = 0$ 。遍历所有用户后计算平均值。海明距离值越大, 说明推荐算法的多样性越高。

(2) **内相似性**。海明距离从整体上反映推荐系统的多样性, 另一个多样性指标内相似性 (Inter-similarity) [166] 反映的是单个用户的推荐列表中各个产品之间的差异性。内相似度一般使用余弦相似度计算物品之间的相似程度, 定义如下:

$$I(L) = \frac{1}{mL(L-1)} \sum_{i=1}^m \sum_{\substack{o_\alpha, o_\beta \in o_i^L \\ \alpha \neq \beta}} S_{\alpha\beta}^{Cos}, \quad (2-19)$$

其中 $S_{\alpha\beta}^{Cos}$ 是用户 u_i 的推荐列表中产品 o_α 和 o_β 的余弦相似度。内相似度被广泛应用于推荐算法的评价, 数值越小表示用户的推荐列表中物品的多样性越高, 物品越丰富。内相似度的值也依赖于用户推荐列表的长度 L 。

(3) **新颖性**。新颖性 (Novelty) [166] 是除了多样性指标外衡量推荐算法个性化程度的评价指标, 体现在要为用户推荐更冷门的物品, 避免推荐热门物品而与其他渠道的推荐撞车。本论文中使用的新颖性评价指标为流行度 (Popularity), 衡量用户推荐列表中物品的平均度, 定义如下:

$$N(L) = \frac{1}{mL} \sum_{i=1}^m \sum_{o_\alpha \in o_i^L} k_\alpha, \quad (2-20)$$

其中, o_i^L 是用户 u_i 的推荐列表, k_α 是推荐列表中物品 o_α 的度。新颖性值越小, 表示推荐的物品越冷门, 更能提供个性化的推荐内容。

2.5 实验数据集介绍

在学界和业界的共同努力下, 对推荐系统的研究已有几十年, 并且在实际应用中取得了不俗的成绩。许多企业为推荐系统的研究人员提供了众多的数据集。数据集的基本构成为: 用户、物品和用户对物品的评分。以下总结推荐算法研究中常用的数据集。

2.5.1 推荐算法的常用数据集

(1) **Delicious数据集**。Delicious数据集来自Delicious书签系统中的用户社交网络信息、书签信息和标签信息的合集。数据包含2009年11月20日至2010年11月10日期间来自1867名用户的105000条记录, 由第二届推荐系统异构性和融合技术国际研讨会发布。

(2) **Epinions数据集**。数据集由Paolo Massa在2003年从Epinions网站上收录, 时间跨度为期5周。Epinions网站的用户可以对网站上提供的商品进行比较、评论和打分, 也可以关注其他用户。Epinions数据集包含4066个用户、7649个物品、128794条用户对物品的评价记录和217072条用户之间的信任关系记录。

(3) **FriendFeed数据集**。FriendFeed是一个聚合时事摘要的在线服务工具。用户可以把自己常用的社会网络如Twitter、YouTube、Flickr等上面的更新信息进行聚合。数据集包含4148个用户、5700个物品、96942条用户对物品的评分和386804条用户对其他用户的信任关系记录。

(4) **MovieLens数据集**。MovieLens数据集是推荐算法最常使用的数据集, 数据包含100k, 1M和10M三种格式, 是明尼苏达大学的GroupLens研究组从MovieLens网站中收集整理的实验数据集。数据集中保证每名用户对至少观看过20部电影, 并按照1-5的评分标准进行了评分。此外, MovieLens数据集还包含用户对电影的标签数据, 如“excellent”, “based on a book”等, 这类信息适用于标签推荐系统。表2-1展示了MovieLens数据集的基本信息, 其中稀疏度是指网络中的实际连边占网络最大概率的连边的比例^[166]。

表 2-1 MovieLens数据集

数据集	用户	商品	连边	稀疏度	时间
MovieLens-100K	943	1682	100000	6.30×10^{-2}	1997 年9月至1998年4月
MovieLens-1M	6039	3952	1000209	4.19×10^{-2}	2000 年4月至2003年3月
MovieLens-10M	71567	10681	10000054	1.31×10^{-2}	1995年1 月至2009 年1月

(5) **Netflix数据集**。Netflix是一个电影租赁公司, 它在2006年举办Netflix Prize推荐系统大赛上提供了电影评分数据集。此数据集中包含480189个用户、17000部电影和一亿条用户对电影的评分。

(6) **RYM数据集**。RYM (Rate Your Music) 是一个音乐定制网站。允许用户添加专辑、EP、单曲和视频到数据库并对它们进行评分、添加标签。当评论音乐时, 网站的音乐/社会推荐可以推荐相似的音乐和类似有音乐偏好的用户。RYM数据集包含33786个用户、5381个音乐和676449条用户对音乐的评价记录。由2008年Zoltan Kuzsicsik获取, 并首次运用于2010年的文献[14]中。

2.5.2 常用数据集划分方式

为了衡量推荐算法的性能, 通常将数据集划分为训练集和测试集, 将训练集作为已知数据训练模型, 将测试集当做未知数据与推荐结果进行比较, 并评估推荐算法的性能。按照划分方式分为个体划分和整体划分法。个体划分是对每个个

体（用户）的数据按照一定比例（如90%）随机划分到训练集中，剩余划分到测试集。这种划分方式保证每个用户在训练集和测试集中都有数据，在评价算法性能的时候更加公平。整体划分法是将全部数据按照一定比例（如90%）随机划分到训练集中，剩余做测试集。这种方式有可能存在某些用户的数据全部在训练集或者测试集中的情况。所以一般使用交叉划分方式，并对划分的数据集得到的结果取平均值。如图2-5所示，是按照 k 折交叉验证法划分，将数据集等分成 k 份，每次实验轮流选取其中一份作为测试集，其余做训练集，重复 k 次实验后得到 k 份数据集，如图2-5所示。本文第三四章节实验部分数据集划分方式采用 k 折交叉验证法划分，其中 $k = 10$ 。




图 2-5 k 折交叉验证法示意图

2.6 本章小结

本章节首先介绍了推荐系统多个领域的应用情况以及面临的困难挑战。接着介绍了推荐算法的分类，然后讨论了研究推荐算法常用的评价指标，最后介绍了研究推荐算法的常用数据集以及数据集的划分方式。后续章节内容将参考本章节介绍的既有工作，并使用样本介绍的数据集作为实验的数据。

第三章 基于节点相似性的推荐算法研究

3.1 引言

互联网的急速发展产生了海量的资源，大大满足了人们不同的需求。同时海量的资源也带来了信息过载的问题。为解决信息过载的问题，出现了两种技术，搜索引擎和推荐系统。搜索引擎是一种对互联网资源整理分类，并存储在数据库中供用户检索的系统，是一种被动式的信息过滤技术，满足用户显式表达的兴趣^[7]。但是很多时候由于用户无法准确表达自己的需求，导致返回的结果不符合用户预期。推荐系统是一种主动式对用户需求进行预测的技术，对于需求不明朗而又面临信息过载问题的用户来说，是一个非常有用的工具。最近几十年里，推荐系统的研究一直是科研热点，吸引了包括计算机、物理、经济等多学科研究人员的注意。

从Resnick等人^[26]提出的协同过滤算法被用于新闻过滤系统GroupLens上，协同过滤算法就一直是推荐算法研究的热点，众多研究人员做过很多后续研究^[27, 29, 30]。很多协同过滤算法的研究都是基于余弦相似度^[168, 169]的基础上。如基于用户的协同过滤（UCF）算法^[27]、基于物品的协同过滤（ICF）算法^[28]等。与此同时，网络科学的兴起也给推荐系统的研究带来了新的方向。复杂网络经常用来研究不同对象之间相互连接而形成的系统^[170-172]。在推荐系统中，用户与物品之间存在直接的连边关系，可以描述为一个二部图结构。Zhang等人^[38]从物理学领域的热能传递中获得灵感，提出基于二部图结构的热传导推荐算法（Heat Conduction, HC），通过热能传递的方式得到用户可能感兴趣的物品。Zhou等人在HC算法基础上，提出资源分配的推荐算法（Resource Allocation, RA）^[173]，通过资源分配的方式得到两个物品节点之间的相似性，根据相似度判断用户对物品的感兴趣程度。

ICF和RA同为基于节点相似性的算法，但是节点相似性的计算理念不一样。ICF算法中，通常使用余弦相似度计算两个物品的相似程度。包含的理念是选择了两个不同物品的用户，认为这两个物品存在着隐式的关联，这种隐式的关联有很多原因，例如两个物品有共同的特征、两个物品有功能上的联系或者用户对这两个物品的需求是一致的等等。通过多次累积用户加给物品的隐式关联，得到群体上物品的相似性。资源分配算法计算的节点相似度，通过对用户连边的物品赋予初始资源值，被同一个用户选择的两个物品之间，通过用户形成一个隐式连接。其中用户充当一个传播者的角色，将其中一个物品的资源值传递给另一个物

品,通过计算传递的资源值得到两个物品之间的相似性。最后累积不同用户传递的资源,得到不同用户赋予两个物品的累积相似性。

同为基于相似性的推荐算法,ICF推荐算法和RA推荐算法在推荐效果上有很大的差别。协同过滤算法已被证实可以产生较好的预测效果,原因在于通过余弦相似性计算得到用户最可能感兴趣的物品这一过程,放大了物品之间因被同一个用户选择而被赋予的隐式相似性,并且是基于用户偏好的相似性。结果是基于物品的协同过滤算法的推荐准确性较高。基于资源分配的算法,使用的是RA相似性指标,在资源分配的过程中,个人用户充当的是一个资源传播者的角色,算法放大了群体上赋予物品的隐式相似性,导致的结果是推荐的内容更广泛,算法多样性更高。这两种相似度指标是互补的,基于两种相似性指标的推荐算法的效果各有侧重点。面对推荐系统面临的准确性和多样性两难的问题,本章结合了这两个互为补充的余弦相似度和RA相似性指标,提出一个全新的节点相似性度量指标(CosRA),并在CosRA指标的基础上提出推荐算法。

3.2 符号和数据

推荐系统通常使用“用户-物品”二部图表示,用 $U = \{u_1, u_2, \dots, u_m\}$ 表示用户集合, $O = \{o_1, o_2, \dots, o_n\}$ 表示物品集合和 $E = \{e_1, e_2, \dots, e_l\}$ 表示用户和物品的连边集合。推荐系统的二部图,也可用邻接矩阵 A 表示。矩阵中的元素 $a_{i\alpha} = 1$ 表示用户 i 与物品 α 存在连边, $a_{i\alpha} = 0$ 表示不存在连边。以下拉丁字母表示用户相关的标识,希腊字母表示物品相关的标识。

本实验使用的数据集有以下4个: RYM、Netflix、MovieLens-100K和MovieLens-1M。数据集的详细介绍参考第2.5节。其中RYM是10分制评价标准,在本实验只选择评价分数不低于6分,用户度和物品度不低于2的数据。Netflix和MovieLens是5分制评价标准,在本实验过滤掉评分小于3,用户度和物品度小于2的数据。详细的数据统计在表3-1中,其中网络稀疏度定义为网络中实际连边数与网络节点全连通情况下边数的比值。

表 3-1 数据集详细介绍

数据集	用户数(m)	物品数(n)	连边数(l)	网络稀疏度(S_l)
MovieLens-100K	943	1574	82520	5.56×10^{-2}
MovieLens-1M	6039	3628	836478	3.82×10^{-2}
Netflix	10000	5640	701947	1.24×10^{-2}
RYM	33197	5234	609792	3.51×10^{-3}

3.3 评价指标

本实验中共使用了8个评价指标。其中 AUC 、 MAP 、 $nDCG$ 、准确率(P)和召回率(R)考察算法的推荐准确性,海明距离(H)和内相似度(I)考察算法多样性,新颖性(N)考察算法推荐的物品是否是流行物品。详细的评价指标介绍参考第2.4节对推荐算法的评价指标的描述。本节仅对涉及到的指标简单介绍。

(a) AUC ^[163]用来测试推荐算法的全局预测的准确性。在无算法随机预测情况下, AUC 值在0.5左右。最大的 AUC 值为1。因此算法的 AUC 值越大,表明算法推荐准确性越好。

(b) MAP ^[165]值在准确率的基础上对所推荐的物品进行了排序。总的来说,系统推荐准确的物品在推荐列表中越靠前, MAP 值越高,如果系统中没有推荐准确的物品,则 $MAP = 0$ 。

(c) $nDCG$ ^[167]值反映的是返回的推荐列表中内容以及内容的顺序的相关程度。当用户的推荐列表中物品全部是用户测试集中物品时 $nDCG = 1$,所以 $nDCG$ 值越高,推荐列表的预测越准确。

(d) 准确率(P)^[166]用来测试用户推荐列表中预测正确的比例。当用户的推荐列表中完全没有预测准确的物品时 $P = 0$,全部预测准确时 $P = 1$,所以命中率越高,说明推荐列表越符合用户实际情况。

(e) 召回率(R)^[166]反映的是返回的推荐列表中预测正确内容占所有已知内容的比例。当用户的测试集中完全没有预测准确的物品时 $R = 0$,用户的测试集中的物品全部被预测准确时 $R = 1$,所以召回率越高,表示对用户喜欢的物品预测的越全面。

(f) 海明距离(H)^[166]反映的是不同用户的推荐列表间之间的差异程度。当任意两个用户之间的推荐列表内容完全不一致时,这两个用户的海明距离 $H = 1$,内容完全一致时, $H = 0$ 。海明距离值越大,说明推荐算法的多样性越高,对用户的推荐越个性化。

(g) 内相似度(I)^[166]反映的是单个用户的推荐列表中各个产品之间的差异性。 I 值越小表示用户的推荐列表中物品的多样性越高,物品越丰富。推荐系统应避免推荐内容的范围变狭窄。

(h) 新颖性(N)^[166]是考察推荐列表中物品的“冷门”程度的指标,数值越小说明推荐的物品越冷门,算法新颖性越高,更能体现个性化的推荐。推荐冷门物品能在一定程度上避免推荐用户可能选择过的物品。

3.4 基于节点相似性的算法设计

余弦相似性指标^[26]是推荐系统中常用的相似性指标之一，计算方法为两个向量的夹角的余弦值。在推荐系统中，用户所选择过的所有物品可以视为该用户节点的向量。同理，物品节点的反映的是选择过该物品的用户集。推荐系统中使用的余弦相似度通常用于刻画两个节点之间的相似程度。在本实验中，用于刻画两个物品之间的相似程度。定义如下：

$$S_{\alpha\beta}^{Cos} = \frac{1}{\sqrt{k_{\alpha}k_{\beta}}} \sum_{i=1}^m a_{i\alpha}a_{i\beta}, \quad (3-1)$$

其中， k_{α} 和 k_{β} 分别表示物品 α 和物品 β 的度， $a_{i\alpha}$ 和 $a_{i\beta}$ 分别表示用户 u_i 选择过物品 o_{α} 和 o_{β} 。

RA相似性指标是基于网络拓扑结构定义的相似度指标，是基于网络拓扑结构的推荐算法中常用的相似性指标之一。通过资源分配的过程^[173]，描述两个物品之间的相似程度。定义如下：

$$S_{\alpha\beta}^{RA} = \sum_{i=1}^m \frac{a_{i\alpha}a_{i\beta}}{k_i}, \quad (3-2)$$

其中， k_i 表示用户 i 的度。

基于这两个指标的优点，既要利用余弦相似性指标的反映的个体层面上的相似性，又要兼顾RA相似性指标反映的群体层面上的广泛性。本实验从两方面考虑，引入了“CosRA相似指数”。一方面利用大度的节点扩大范围；另一方面对小度的节点加大权重。物品 o_{α} 和 o_{β} 之间的CosRA相似指数定义如下：

$$S_{\alpha\beta}^{CosRA} = \frac{1}{\sqrt{k_{\alpha}k_{\beta}}} \sum_{i=1}^m \frac{a_{i\alpha}a_{i\beta}}{k_i}. \quad (3-3)$$

其中， k_i 为用户 u_i 的度， k_{α} 和 k_{β} 分别表示物品 o_{α} 和 o_{β} 的度。

基于CosRA相似度，本实验在资源分配的框架下提出基于CosRA相似度推荐算法。算法步骤如下：

(1) 对目标用户 u_i 所选择的物品 o_{α} 的初始资源设为：

$$f_{\alpha}^{(i)} = a_{i\alpha}, \quad (3-4)$$

其中， $a_{i\alpha} = 1$ 表示用户 u_i 选择了物品 o_{α} 。 $a_{i\alpha} = 0$ 表示用户 u_i 没有选择物品 o_{α} 。 $f^{(i)}$ 是用户 u_i 的一个 n 维的向量， $f_{\alpha}^{(i)}$ 表示物品 o_{α} 的资源值。

(2) 在资源分配框架下，物品 o_{α} 的资源通过用户进行分配，最终得到用户 u_i 的另一个 n 维的向量 $f'^{(i)}$ 。

$$f'^{(i)} = S^{CosRA} f^{(i)}, \quad (3-5)$$

其中, $f^{(i)}$ 表示资源分配终止时物品的资源, 代表用户 u_i 对此物品的喜好程度。对 $f^{(i)}$ 进行降序排列后, 选择前 L 个物品作为用户 u_i 的推荐列表。

基于RA相似性和CosRA相似度的算法示意图参考图3-1。其中图3-1(a-c)展示的是基于RA相似性的推荐算法步骤。算法共分为三步, 图3-1(a)表示第1步, 对目标用户(橙色)所选择的物品, 按照公式(3-4)初始化资源分配。图3-1(b)表示资源从物品节点传递到用户节点, 此时用户节点充当一个传播者在第三步将资源传递给物品节点, 见图3-1(c)。第2、3步骤的资源分配过程通过公式(3-5)刻画。CosRA算法的具体实现过程参考表3-2中的伪代码, 根据伪代码中描述, for循环的时间复杂度计算为 $O(n(mn + nm + m))$, 整个算法的时间复杂度为 $O(m^2n)$ (其中 m 为用户数, n 为物品数)。




图 3-1 推荐算法示意图

为测试算法效果, 本实验中的CosRA相似度算法将与6个基准算法包括全局算法 (GR) [174]、基于商品的协同过滤 (ICF) [28]、基于用户的协同过滤 (UCF) [27]、物质扩散 (MD) [13]、热传导方法 (HC) [38] 比较和基于一致性的推荐算法 (CBI) [175]。以上算法均不依赖于参数, 在参数调节下的改进算法不在本章内容中讨论。实验结果见表3-3。

(1) 在GR算法中, 用户推荐列表的构成按照所有未选择的物品的度降序排列, 因此, 越流行的物品越容易被推荐。对目标用户来说, 他对物品的预测分与物品的度成强正关联性。用户 u_i 对物品 o_α 的计算预测分为:

$$f_\alpha^{(i)} = k_\alpha, \quad (3-6)$$

表 3-2 CosRA算法伪代码

输入参数: $U, U.objects$		
// 用户集 U , 用户 U 选择的物品集		
输入参数: $O, O.users$		
// 物品集 O , 选择过物品 O 的用户集		
输出参数: $Recommender.i$		
// 用户推荐列表		
1:	for all $i \in U$	// 遍历用户, 选择目标用户 i
2:	for all $\alpha \in i.objects$	// 遍历用户 i 选择的所有物品
3:	$f'_\alpha = 1$	// 初始资源分配, $f'_\alpha = 1$ 表示物品 α 获得的资源值
4:	for all $j \in \alpha.users$	// 遍历选择过物品 α 的用户
5:	$f''_j \leftarrow f'_j + f'_\alpha \sqrt{k_\alpha} \sqrt{k_j}$	// f''_j 表示用户 j 获得的资源值
6:	for all $j \in U$	// 遍历所有用户, 选择目标用户 $j, j \neq i$
7:	for all $\beta \in j.objects$	// 遍历用户 j 选择的物品
8:	$f'''_\beta \leftarrow f'''_\beta + f''_j \sqrt{k_\alpha} \sqrt{k_j}$	// f'''_β 表示物品 β 最终的资源值
9:	for all $\beta \in O$	// 遍历所有物品
11:	if $\beta \in i.objects$	// 排除用户 i 已经选择过的物品
12:	continue	
13:	$List.i \leftarrow List.i + \beta$	// $List.i$ 表示目标用户 i 所有未选择的物品集合
14:	sort($List.i$) by descending	// 对物品按 f''' 值降序排列
15:	$Recommender.i \leftarrow \text{top-L of } List.i$	// 针对目标用户 i 的长度为 L 的推荐列表

(2) UCF算法寻找与目标用户相似的用户, 根据相似度将其他用户选择的物品进行推荐, 越相似的用户所选择的物品越有可能被推荐。这是一个“人以群分”的推荐算法。算法首先计算每一对用户的相似性, 两个用户 u_i 和 u_j 的相似性 S_{ij} 使用余弦相似度计算, 定义如下:

$$S_{ij}^{Cos} = \frac{1}{\sqrt{k_i k_j}} \sum_{\alpha=1}^n a_{i\alpha} a_{j\alpha}, \quad (3-7)$$

用户 u_i 对物品 α 的预测得分 $f_{i\beta}$ 通过累积所有与之相似的其他用户得到, 定义如下:

$$f_{\beta}^{(i)} = \frac{\sum_{j=1}^m S_{ij}^{Cos} a_{j\beta}}{\sum_{j=1}^m S_{ij}^{Cos}}, \quad (3-8)$$

(3) ICF算法寻找与用户过去的偏好更相似的物品, 并将这些物品推荐给用户。因此, 这是一个“物以类聚”的算法。ICF算法中物品之间的相似度用参考公式(3-1), 计算用户 u_i 对物品 o_β 的预测分 $f_{i\beta}$ 的定义如下:

$$f_{\beta}^{(i)} = \frac{\sum_{\alpha=1}^n S_{\alpha\beta}^{Cos} a_{i\alpha}}{\sum_{\alpha=1}^n S_{\alpha\beta}^{Cos}}, \quad (3-9)$$

(4) MD算法在“用户-物品”组成的二部图上进行资源分配的算法。在资源分配的过程中，总资源守恒。资源分配将通过 $f'^{(i)} = Wf^{(i)}$ 进行转换， W 是一个转换矩阵，而 $f'^{(i)}$ 是资源分配后用户 u_i 最终的资源向量，表示用户 u_i 对所有物品的预测评分，其中初始资源值参考公式(3-4)。MD算法的转换矩阵中的元素为：

$$w_{\alpha\beta} = \frac{1}{k_{\beta}} \sum_{i=1}^m \frac{a_{i\alpha}a_{i\beta}}{k_i}, \quad (3-10)$$

(5) HC算法是基于网络拓扑结构的推荐算法，利用热能传播的原理在“用户-物品”组成的二部图上，对目标用户选择的物品给与热能值，通过热能传播，得到用户对物品的预测分。在热能传播的过程中，总热能不守恒。热能传递通过 $f'^{(i)} = Wf^{(i)}$ 转换，初始热能资源参考公式(3-4)，最后得到用户 u_i 的最终能量值 $f'^{(i)}$ ，表示用户 u_i 对所有物品的预测评分，HC算法的转换矩阵元素为：

$$w_{\alpha\beta} = \frac{1}{k_{\alpha}} \sum_{i=1}^m \frac{a_{i\alpha}a_{i\beta}}{k_i}, \quad (3-11)$$

(6) CBI算法是反映用户喜好一致性的推荐算法，定义用户因对物品 o_{α} 的喜好而选择物品 o_{β} 的概率为 $w_{\alpha\beta}$ (3-10)。用户对物品的选择概率由 $f'^{(i)} = Rf^{(i)}$ 得到。初始 $f^{(i)}$ 值参考公式(3-4)。此时 R 中元素 $r_{\alpha\beta}$ 重新定义用户由物品 o_{α} 从而选择物品 o_{β} 的因果性概率：

$$r_{\alpha\beta} = w_{\alpha\beta} + \frac{w_{\beta\alpha}}{\sum_{\beta'=1}^n w_{\beta'\alpha}}, \quad (3-12)$$

CosRA相似度指标是刻画节点间相似度上的指标，并且指标本身没有参数。为了更深入分析CosRA相似性度量指标，本实验针对用户和物品，引入两个可调参数 η_1 和 η_2 ，将算法扩展到一般形式，考察参数对CosRA相似性算法的影响。扩展后的CosRA相似性度量指标定义如下：

$$S_{\alpha\beta}^{CosRA*} = \frac{1}{(k_{\alpha}k_{\beta})^{-\eta_2}} \sum_{i=1}^m \frac{a_{i\alpha}a_{i\beta}}{(k_i)^{-2\eta_1}}. \quad (3-13)$$

扩展后，算法中资源分配的步骤不变，但分配方式发生了改变。以算法示意图3-1为例，原步骤(a)中目标用户的物品的初始化资源值不发生改变，参考公式(3-4)。原步骤(b)和(c)中的分配方式由参数 η_1 和 η_2 确定。物品获得的最终资源值为：

$$f'^{(i)} = S^{CosRA*} f^{(i)}. \quad (3-14)$$

注意到，原始CosRA指标是扩展后CosRA指标在 $\eta_1 = \eta_2 = -0.5$ 的特殊形式。

3.5 实验结果

表3-3展示了上述7种算法在4个真实数据集上的推荐算法效果。共包含8个评价指标值,其中 AUC 不依赖于推荐列表长度 L , MAP 值、 $nDCG$ 值、准确率(P)、召回率(R)、海明距离(H)、内相似度(I)和新颖性(N)的值均受到推荐列表长度 L 的影响。本实验中,推荐列表长度取值 $L = 50$ 。8种评价指标值均取10次独立运行后各的平均值,5种基准算法与CosRA算法对比,t检验结果 $p < 0.05$ 。表3-3对每个指标的最优值进行加粗加黑标注。

从准确性上来说,CosRA算法在所有四个数据集上都具有最高准确性指标值。 AUC 值,命中率 P 和召回率 R 都明显高于其他算法。CosRA算法的 AUC 值在数据集MovieLens-100K、MovieLens-1M、Netflix和RYM分别达到了0.9085、0.8499、0.9499和0.9522。准确率已非常高,每提高一点都非常困难。对于排序准确性指标 MAP 、 $nDCG$ 、 P 和 R ,CosRA相似度算法显著高于其他算法。再回到多样性指标上。海明距离 H 和内相似度 I 指标最优的算法是HC算法,CosRA相似度算法比HC算法和ICF算法略差,比GR算法、UCF算法和MD算法稍好。在新颖性上也是HC算法最高,但是HC算法的准确性并不太高。CosRA相似度算法与除HC算法外的其他算法相比较,多样性和新颖性都是都比较高的。

为了更好的理解CosRA相似度算法的机制,本节从被推荐的物品上进行研究。对MD算法、HC算法和CosRA相似度算法计算一次结果后,对所有用户的推荐列表中的物品进行统计,计算不同度的物品在所有被推荐物品中的概率分布。图3-2展示了在RYM、Netflix、MovieLens-100K和MovieLens-1M数据集上,MD算法、HC算法和CosRA相似度算法的推荐列表中物品的度分布,由于推荐物品的度的大小和所占比例差异巨大,坐标轴选为双对数坐标。实验中使用两种不同的推荐列表长度($L = 10$ 和 $L = 50$),图中的蓝色方块和红色三角分别对应于推荐列表长度 $L = 10$ 和 $L = 50$ 时的结果。

从图中看到,虽然推荐列表的长度会影响被推荐的物品,但长度的改变不影响被推荐的物品的度分布趋势。从表3-3中看到,MD算法的准确性较高而多样性较差,HC算法的多样性较好而准确性较差。图3-2的结果解释了这个现象。在MovieLens-100K数据集上,MD算法推荐最多的物品的度在300左右,此时HC算法推荐的大部分物品的度在10以下。这就是为什么MD算法的准确性较高而多样性较差,HC算法的多样性较好而准确性较差的原因。CosRA相似度算法在推荐物品上比MD算法和HC算法更平衡,既由于推荐了流行的物品提高了准确性,又因为推荐了冷门的物品提高了多样性。我们注意到一个有趣的现象,图3-2中的数据从MovieLens-100K到MovieLens-1M再到Netflix,数据集都采用5分制评分标

表 3-3 推荐算法效果统计表

MovieLens- _{100K}	<i>AUC</i>	<i>MAP</i>	<i>nDCG</i>	<i>P</i>	<i>R</i>	<i>H</i>	<i>I</i>	<i>N</i>
GR	0.8632	0.2083	0.2143	0.0575	0.3579	0.3952	0.4079	255
UCF	0.8870	0.3148	0.3124	0.0700	0.4759	0.5502	0.3945	242
ICF	0.8806	0.1381	0.1540	0.0540	0.3260	0.7775	0.1144	104
MD	0.8977	0.3249	0.3360	0.0751	0.5274	0.6175	0.3551	230
HC	0.8420	0.0365	0.0473	0.0210	0.1230	0.8576	0.0560	23
CBI	0.9040	0.3525	0.3423	0.0796	0.5475	0.7474	0.1043	191
CosRA	0.9085	0.3805	0.3679	0.0821	0.5752	0.7241	0.3347	204
MovieLens- _{1M}	<i>AUC</i>	<i>MAP</i>	<i>nDCG</i>	<i>P</i>	<i>R</i>	<i>H</i>	<i>I</i>	<i>N</i>
GR	0.8559	0.1438	0.1474	0.0528	0.2223	0.4028	0.4147	1660
UCF	0.8720	0.1763	0.1812	0.0609	0.2634	0.4582	0.4150	1640
ICF	0.8914	0.0747	0.1075	0.0514	0.2305	0.6698	0.1290	932
MD	0.8845	0.1879	0.2011	0.0660	0.2970	0.5043	0.4028	1618
HC	0.8814	0.0525	0.0652	0.0343	0.1621	0.8609	0.0451	198
CBI	0.9003	0.2025	0.2158	0.0720	0.3337	0.6016	0.1300	1504
CosRA	0.8949	0.2229	0.2418	0.0744	0.3500	0.5981	0.3872	1541
Netflix	<i>AUC</i>	<i>MAP</i>	<i>nDCG</i>	<i>P</i>	<i>R</i>	<i>H</i>	<i>I</i>	<i>N</i>
GR	0.9329	0.1612	0.1802	0.0426	0.3705	0.3565	0.3741	2416
UCF	0.9391	0.1959	0.2171	0.0467	0.4106	0.4056	0.3751	2385
ICF	0.9006	0.0045	0.0080	0.0036	0.0238	0.6445	0.0021	58
MD	0.9480	0.2069	0.2278	0.0484	0.4255	0.4262	0.3684	2369
HC	0.8889	0.0017	0.0066	0.0013	0.0237	0.7963	0.0040	15
CBI	0.9323	0.1995	0.1961	0.0472	0.3914	0.6378	0.0772	1822
CosRA	0.9499	0.2289	0.2488	0.0507	0.4488	0.4822	0.3606	2298
RYM	<i>AUC</i>	<i>MAP</i>	<i>nDCG</i>	<i>P</i>	<i>R</i>	<i>H</i>	<i>I</i>	<i>N</i>
GR	0.8545	0.0569	0.0791	0.0055	0.1600	0.0687	0.1429	1245
UCF	0.9186	0.1753	0.2188	0.0149	0.4166	0.7595	0.1671	1124
ICF	0.9206	0.0565	0.0974	0.0104	0.3260	0.9122	0.0490	226
MD	0.9412	0.2092	0.2519	0.0176	0.4711	0.7889	0.1546	1089
HC	0.9326	0.1300	0.1456	0.0136	0.3612	0.9493	0.0568	214
CBI	0.9470	0.2227	0.2448	0.0181	0.4614	0.8683	0.0223	800
CosRA	0.9522	0.2918	0.2838	0.0189	0.4821	0.8791	0.1441	819

准，分数从高往低数据集越来越稀疏。MD算法的、HC算法以及CosRA相似度算法的推荐列表中物品的度分布均越来越陡峭。说明数据越稀疏，算法特征体现的越明显。到了最稀疏且评分制为10分的RYM数据集，CosRA算法的推荐列表中物品的度分布近乎成了直线。物品被推荐的概率与物品的度的相关性最小。这说明，




图 3-2 被推荐物品的度分布

CosRA相似性度量指标准确地抓住了物品之间的相似性，避免过多受制于度的大小。

为了验证本算法是否最优，考察扩展后的算法。本实验设置参数 η_1 和 η_2 的取值范围为 $[-2,2]$ ，取值间隔为0.05。对扩展后的算法准确性进行研究，分别在4个数据集上计算7个算法评价指标。算法结果为10次独立运行后平均值。详细的结果见图3-3。

图3-3分别展示了扩展算法在数据集MovieLens-100K，MovieLens-1M，Netflix以




图 3-3 扩展参数下算法的准确性

及RYM上的4个准确性指标的结果。实验结果显示，扩展后CosRA算法在4个准确性指标中均呈现出一致的趋势。相比于参数 η_1 ，4个准确性指标沿 y 轴的变化更剧烈，受参数 η_2 的影响更多。有趣的是， η_2 是作用于用户的可调参数。所以物品之间的相似度的衡量的重点在于“选择它们的用户赋予它们的隐式相似性有多高”。




图 3-4 扩展参数下算法的多样性和新颖性

而与物品被多少人选择的相关性较弱。在图3-3中, 扩展后CosRA算法的所有准确性指标值在所有数据集上均存在一个“峰值”(纵横方向上的虚线交汇处)。“峰值”对应的参数在 $\eta_1 = \eta_2 = -0.5$ 附近, 此时算法退化为原始CosRA算法。这说明CosRA算法是扩展形式下的唯一最优解。

本实验还对多样性和新颖性指标展开研究, 扩展后的CosRA算法的多样性和新颖性指标展示在图3-4中。海明距离 H 和内相似性 I 受参数 η_1 和 η_2 影响很明显, 当 η_1 和 η_2 均小于 -0.5 时, 扩展形式CosRA算法多样性更高。对新颖性 I 而言, 受参数 η_1 的影响不明显。参数 $\eta_2 \approx -0.5$ 是一个分水岭。 $\eta_2 < -0.5$ 时, 被推荐物品普遍冷门。综合而言, 扩展后的CosRA算法并没有在原始CosRA算法基础上进一步提升算法性能。

3.6 本章小结

本章节运用网络科学的思想, 将推荐系统映射为二部图。针对基于相似性的推荐算法, 分析了二部图中节点相似性指标的选择对推荐效果的影响。结果发现, 基于余弦相似性(Cosine)的协同过滤推荐算法准确性高, 但多样性差; 基于资源分配相似性(RA)的资源分配推荐算法多样性好, 但准确性不足。结合这两种指标的优势, 本章节提出了一种全新的节点相似性度量指标(CosRA)。在CosRA相似性度量指标的基础上, 在资源分配的框架下提出基于CosRA指标的推荐算法。实验结果表明, 在同样的数据集上, CosRA算法比经典的协同过滤算法、物质扩散算法、热传导算法和流行度算法取得更好的推荐效果。究其原因在于, 相比起MD算法倾向于推荐较流行的物品和HC算法倾向于推荐较冷门的物品, 基于CosRA指标的推荐算法在物品选择上达到了一种平衡, 同时推荐流行和冷门的物品, 因此有更高的准确性和多样性。

本实验还将CosRA指标扩展到更一般的形式。结果发现, 扩展后的推荐算法的准确性指标最高时, 参数对应于CosRA指标, 证明基于CosRA指标的推荐算法已经是扩展算法的最优解; 并且CosRA指标没有参数, 作为普适的节点相似性计算方法, 适合应用于推荐系统中。

第四章 基于信任增强推荐算法研究

第三章结合了余弦相似度（Cosine）和资源分配（RA）相似度指标的优点，提出了全新的节点相似性的度量指标（CosRA），并在资源分配的框架下提出了基于CosRA指标的推荐算法。实验结果表明CosRA推荐算法不仅在准确性上表现的更好，在多样性上也存在一定优势。进一步对CosRA推荐算法进行扩展，扩展后的CosRA推荐算法并没有在推荐效果上比CosRA推荐算法更好，证明CosRA推荐算法已经是扩展算法的最优解。本章将针对推荐系统的准确性和多样性两难问题进一步研究，分两步进行：第一步，在第三章提出的CosRA推荐算法的基础上，引入用户信任关系网络，通过信任关系改变资源分配的方式；第二步，在基于网络拓扑结构的推荐算法上，引入信任关系，对受信任的用户增加资源值，提高推荐算法的准确性和多样性。

4.1 引言

自web2.0时代^[176]的到来，协作、交互和信息共享成为了时代的选择。这些特征也诞生了博客（微博，twitter等即时分享的在线日志），维基（Wikipadia，百度百科等允许人们共同添加编辑内容的web应用），社交网站（人人网，Facebook等有共同兴趣的人进行交互的虚拟社区）。研究显示相比于陌生人，人们更倾向于他们信任朋友的推荐^[60]。社交网络的普及使得人们在网络上成为朋友并付出信赖，诞生了基于社区的推荐系统，并受到越来越多的关注。这种推荐系统被称之为社会化推荐系统^[64]，根据用户的个人资料和用户之间的关系作出预测。

推荐系统常用于精确预测一个用户对某一特别物品的喜欢程度。常见的推荐系统有基于内容的推荐^[20]和基于协同过滤推荐^[75, 112-114]。推荐算法的研究也从协同过滤（CF，以下UCF表示基于用户的协同过滤算法^[27]，ICF表示基于物品的协同过滤算法^[75]）算法到跨领域算法，如近年来从物理领域借鉴的动力学思想而诞生的基于网络拓扑结构的推荐算法，如物质扩散（MD）^[13]和热传导（HC）算法^[41]，以及混合加权算法^[14, 40, 177, 178]。基于内容的推荐方法倾向于把推荐内容限制在和用户选择过的物品很近似的范围内。如一个用户选择了古典音乐，那么系统将推荐类似类型的音乐，不会推荐其他用户可能感兴趣的音乐，从而导致推荐越来越狭窄，多样性降低。而使用基于用户的协同过滤算法可以显著改进推荐系统的推荐效果。这种方式要求识别某一用户和哪些用户具有相似品味，然后基于这些相似的用户的行为来做出预测，将相似用户的偏好物品进行推荐。但是通

常UCF推荐算法在准确性上低于ICF推荐算法。使用传统协同过滤算法会面临多样性下降的问题, 如果通过寻找品味相似用户或者类似物品的方式给用户推荐内容, 会导致用户的推荐列表的内容范围越来越狭窄。

协同过滤推荐方法主要是在“用户-产品”组成的二部图上完成, 通过采集用户对物品的收集信息, 根据用户之间的相似度或者物品的相似度推荐相应的内容。但现实生活中大量的线上系统都不是单纯的人与物之间的关系。人的社交属性决定了人无时无刻不受到他人的影响。研究表明我们对物品的偏好或者信息的采用很有可能收到我们社交网络的影响^[179, 180]。针对准确性和多样性两难的困难, 解决思路之一是使用额外的辅助信息。例如使用社交关系网络辅助推荐。现实生活中非常多的推荐系统, 其网络结构并不是单纯的用户和物品组成的网络, 还存在着用户的社交网络。如Epinions网站上, 用户除了对物品进行点评选择外, 还可以与网站上的其他用户建立信任关系或者不信任关系。

研究表明, 相比起推荐系统, 用户更加信赖来自朋友的推荐^[60], 并且基于社会影响力的推荐比基于用户历史行为的相似性的推荐更加重要^[181], 例如通过分析社交关系, 可以提高网购物品的推荐准确度^[68]。很多推荐系统都基于社交关系做推荐, 原因有两个: 一个是增加销售如下载阅读等^[182], 另一个是提高用户对物品的评价^[183]。豆瓣网是国内书籍阅读分享平台, 豆瓣网的数据显示来自朋友的推荐非常有效, 朋友推荐的书本被接受的程度较高并且容易获得高分评价^[183]。并且还有证据显示, 在淘宝网上, 朋友的推荐也会提高淘宝的商品销售^[184]。目前社会推荐存在的挑战有三类: 一是如何将社会信息引入到推荐系统中^[88]; 二是如何利用社会关系提高推荐的性能^[87]; 三是如何建立更好的机制以促进社会推荐^[89, 90]。

本章节从两个方面研究信任增强推荐系统。第4.2节将人与人之间的信任关系作为辅助信息, 与基于CosRA相似度指标的推荐系统框架中, 提出了一种信任增强的推荐算法。通过参数调节算法中资源分配的方式, 提高受信任用户的权重。第4.3节在资源分配的框架下, 充分利用信任关系, 提出一种基于信任关系的资源分配算法。分析受信任用户在资源分配权重上的变化对推荐效果的影响。

4.2 信用增强相似性的推荐算法

4.2.1 问题提出

第三章提到基于相似度的推荐算法在运行过一段时间后, 针对用户的推荐内容会越来越趋同, 导致推荐多样性下降, 对用户来说可能导致重复推荐和无法进一步发掘自己需求的问题, 对推荐系统来说会导致推荐范围变狭窄, 点击率下

降。用户之间的信任网络对此问题提供了一个研究的方向，信任关系会扩大用户的接触面，增加可推荐物品的范围，受信任的用户所偏好的物品也有可能出现在用户的推荐列表后备名单中。因此充分利用社交网络（如用户信任网络等），是解决推荐系统面临的准确性和多样性两难困境的一个突破口。

推荐技术和信任度构成了信任增强系统的两大支柱。对信任增强推荐的研究已有很多，例如根据用户的信任网络选择排在较靠前位置的物品，或者选择可信任的朋友的推荐^[63, 64, 72, 88, 185]。这些推荐系统的主要优势是利用了信任传播，主要原理是信任的传递：已知用户 a 到用户 b 的信任值和用户 b 到用户 c 的信任值来计算用户 a 对用户 c 的信任值（传播）。除了信任，用户间自然也能产生不信任。例如Epinions网站首先提出了把用户放进信任名单（基于他们的作为评论者的质量），然后增加不信任名单。最终的推荐效果根据信任和不信任两个名单进行个性化推荐。从研究角度上，不信任虽然对推荐系统的研究起很大作用，但目前对此的研究还处于起步阶段^[73, 145, 185, 186]。

到目前为止，一些最近的工作已经将信任关系整合到推荐系统^[88, 187]中。例如Jamali等人^[66]提出了结合了信任关系的随机游走方法^[188]和基于物品的协同过滤方法。Ma等人^[68]提出了一个一般化的框架将用户的喜好和用户朋友们的喜好融合在一起。Shen等人^[67]利用集合了信任关系的协同过滤方法提出了两个用户信任模型。Guo等人^[69]在用户的评分信息和信任关系的基础上提出了一种信任矩阵分解技术来提高推荐性能。邓小方等人^[189]耦合了“用户-物品”二部图和“用户-用户”信任网络，提出一种物质扩散框架下的推荐算法，提高算法的准确性。然而，关于将信任关系整合到基于扩散的方法的研究仍然不足^[70]，这就要求我们利用多个社会信息资源进一步探索更好的推荐算法。

本节在CosRA算法^[190]的基础上提出了一种基于信任的推荐方法，CosRA+T，将用户之间的信任关系引入到原始的CosRA算法中。在CosRA+T算法的资源分配过程中，由信任参数调节受信任用户获得的资源，通常并不是所有受信任的用户都与目标用户有共同物品，因此信任关系可以扩大用户的可推荐范围，提高算法的多样性。同时，CosRA相似度指标作为一个无参数的相似度算法，在提高算法准确性上表现优秀。因此CosRA相似度算法和信任关系的结合，对提高推荐算法的准确性和多样性很有帮助。

4.2.2 数据和符号

推荐系统通常被描述为一个“用户-物品”的二部图 $G(U, O, E)$ ，其中 $U = \{u_1, u_2, \dots, u_m\}$ 是用户集合， $O = \{o_1, o_2, \dots, o_n\}$ 是物品集合， $E = \{e_1, e_2, \dots, e_l\}$ 是

评分集合。“用户-物品”二部图也可以表示为一个邻接矩阵 A ，其中元素 $a_{i\alpha} = 1$ 表示用户 u_i 选择了物品 o_α ，否则 $a_{i\alpha} = 0$ 。整个信任网络用一个邻接矩阵 B 表示，其中的元素 $b_{ij} = 1$ 表示用户 u_i 信任用户 u_j ， $b_{ij} = 0$ 则表示用户 u_i 不信任用户 u_j 。以下拉丁字母表示用户，希腊字母表示物品。推荐算法的目的是为用户 u_i 提供一个长度为 L 的推荐列表 o_i^L 。

本实验中使用两个数据集Epinions和FriendFeed，用于测试算法性能。其中Epinions是一个普通消费者评论分享网站，人们可以通过撰写主观评论来评价产品。FriendFeed是一个社交和书签定制网站，人们可以在这里评价和分享订阅。这两个数据集都使用了一个5分制的评分系统，从1到5表示从最差到最好。在本实验中，用于构建“用户-物品”的二部图使用的评分数值不低于3，用户和物品的度不低于2。筛选之后，Epinions的数据集包含4066个用户，7649个物品和154122个评分记录，网络稀疏度 $S_R = 4.96 \times 10^{-3}$ 。FriendFeed的数据集包含4148个用户，5700个物品和96942个评分记录，网络稀疏度 $S_l = 4.10 \times 10^{-3}$ ，参考表4-1。

表 4-1 数据集详细介绍

数据集	用户数(m)	物品数(n)	评分数(l)	稀疏度(S_l)	信任连边数(t)	连边稀疏度(S_t)
Epinions	4,066	7,649	154,122	4.96×10^{-3}	217,071	1.31
FriendFeed	4,148	5,700	96,942	4.10×10^{-3}	386,804	2.25

两个数据集还包含了社交网络，即用户之间的信任关系。在该网络中，用户之间的连接为有向无权连接。用户 u_i 信任用户 u_j ，则用户 u_i 对用户 u_j 的连边权重为1，否则为0。Epinions数据集包含217,071条信任记录，网络密度 $S_T = 1.31 \times 10^{-2}$ 。FriendFeed包含386,804条信任记录，网络密度 $S_T = 2.25 \times 10^{-2}$ 。更详细的信息记录在表4-1中。

4.2.3 评价指标

实验中共使用了9个评价指标。其中 AUC 、Ranking Score(RS)、 $nDCG$ 、准确率(P)、召回率(R)和 F_1 考察算法的推荐准确性，海明距离(H)和内相似度(I)考察算法多样性，新颖性(N)考察算法推荐的物品是否是流行物品。其中 RS 、 P 、 R 、 F_1 、 H 、 I 和 N 都依赖于推荐列表长度。详细的评价指标介绍参考第2.4节对推荐算法的评价指标的描述。本节仅对涉及到的指标简单介绍。

(a) AUC ^[163]用来测试推荐算法的全局预测的准确性。在无算法随机预测情况下， AUC 值在0.5左右。最大的 AUC 值为1。因此算法的 AUC 值越大，表明算法推荐准确性越好。

(b) $RS^{[166]}$ 值在准确率的基础上对所推荐的物品进行了排序。系统推荐准确的物品在推荐列表中越靠前, RS 值越低, 说明用户喜欢的物品排名越靠前, 算法的排序准确性越好。

(c) $nDCG^{[167]}$ 值反映的是返回的推荐列表中内容以及内容的顺序的相关程度。当用户的推荐列表中物品全部是用户测试集中物品时 $nDCG = 1$, 所以 $nDCG$ 值越高, 推荐列表的预测越准确。

(d) 准确率(P)^[166]用来测试用户推荐列表中预测正确的比例。用户的推荐列表中完全没有预测准确的物品时 $P = 0$, 全部预测准确时 $P = 1$, 所以命中率越高, 说明推荐列表越符合用户实际情况。

(e) 召回率(R)^[166]反映的是用户测试集中的物品被准确预测的比例。用户的测试集中完全没有预测准确的物品时 $R = 0$, 用户的测试集中的物品全部被预测准确时 $R = 1$, 所以召回率越高, 对用户喜欢的物品预测的越全面。

(f) F_1 指标^[166]是一种同时考虑准确率和召回率从而比较全面地评价算法的优劣的指标。 F_1 值越高, 说明算法准确性越好。

(g) 海明距离(H)^[166]反映的是不同用户的推荐列表之间的差异程度。当任意两个用户之间的推荐列表内容完全不一致时, 这两个用户的海明距离 $H = 1$, 内容完全一致是, $H = 0$ 。海明距离值越大, 说明推荐算法的多样性越高。

(h) 内相似度(I)^[166]反映的是用户的推荐列表中各个物品之间的差异性。 I 值越小表示用户的推荐列表中物品的多样性越高, 物品越丰富。

(i) 新颖性(N)^[166]也是考察推荐列表中物品的“冷门”程度的指标, 数值越小说明推荐的物品越冷门, 算法新颖性越高, 更能体现个性化的推荐。

4.2.4 算法设计

文中涉及到的五个基础推荐算法, 它们分别是全局排名算法 (GR)^[174]、基于用户的协同过滤算法 (UCF)^[27]、热传导算法 (HC)^[38]、物质扩散算法 (MD)^[13]和基于顶点相似性的网络扩散算法 (CosRA)^[190]。GR 算法是基于物品流行度的算法, 也是最简单的推荐算法。它通过对所有用户没有选择过的物品的度进行降序排列, 选择出最流行, 被最多人选择过的物品推荐给用户。UCF 算法通过寻找与用户品味相似的用户, 并将这些相似用户的偏好的物品推荐给用户, 与 UCF 算法相对的还有基于物品的协同过滤算法 (ICF)^[28], 推荐与用户过去选择的物品相类似的物品。MD 和 HC 算法是基于网络拓扑结构的资源分配算法。具体算法计算参考第 4.3.2 节。

CosRA算法是本论文第三章提出的基于节点相似性的推荐算法，它结合了余弦相似度和资源扩分配相似度^[173]的优点，提高了推荐算法的准确性和多样性。对于物品 α 和 β ，CosRA算法表示它们的相似性为：

$$S_{\alpha\beta}^{CosRA} = \frac{1}{\sqrt{k_{\alpha}k_{\beta}}} \sum_{i=1}^m \frac{a_{i\alpha}a_{i\beta}}{k_i}. \quad (4-1)$$

在CosRA中，用户 u_i 对物品 o_{α} 的初始资源向量表示为 $f_{\alpha}^{(i)} = a_{i\alpha}$ 。然后资源通过 $f^{(i)} = S^{CosRA} f'^{(i)}$ 进行转换，其中 $f^{(i)}$ 是一个 n 维的最终资源向量。通过对 $f^{(i)}$ 的资源值进行降序排列，排除用户 u_i 已经选择过物品，选择前 L 个物品作为用户 u_i 的推荐列表。

对推荐系统的多样性和准确性两难问题，可行的方法是充分利用辅助信息。在本实验中，数据集不仅有用户与物品的连接关系，还有用户与用户的信任关系。通过将信任关系引入到CosRA算法中，建立了基于信任的CosRA+T^[191]算法。CosRA+T算法背后的原理是，用户的信任连接是有向边，对其他用户的信任一定程度上说明对受信任的用户的行为的认可。这些行为包含了用户的偏好行为。所以选择信任某一用户，表示一定程度上对某一用户所选物品的认可。不仅物品或用户之间的相似性可以帮助预测用户对物品的偏好，信任关系也可能影响用户在选择物品时的决策。为了探究信任关系在增强或抑制推荐性能方面所起的作用，本实验在CosRA+T方法加入了“用户-用户”的信任网络（参见图4-1(b)）。用户间的信任关系用虚线箭头表示，图中用户（橙色）信任用户（绿色）。

CosRA+T算法分为三个步骤进行：

第一步，对一个给定的目标用户 u_i ，他所选择的物品 o_{α} 获得的资源由公式(4-2)初始化分配。

$$f'_{\alpha}^{(i)} = a_{i\alpha}, \quad (4-2)$$

其中 $a_{i\alpha} = 1$ 如果用户 u_i 选择了物品 o_{α} ，否则 $a_{i\alpha} = 0$ 。

第二步，资源分配只能通过实线连边进行从物品到用户的操作。用户 u_i 的邻居用户 u_j （与用户 u_i 选择有共同的物品，与拥有初始资源的物品有实线连边）将收到来自物品的资源值如下：

$$f_j^{(i)} = \sum_{\alpha=1}^n \frac{a_{j\alpha}}{\sqrt{k_j k_{\alpha}}} f'_{\alpha}^{(i)}, \quad (4-3)$$

其中 k_{α} 和 k_j 分别是物品 o_{α} 和用户 u_j 的度， n 是物品的总数目。

第三步，在考虑目标用户的信任关系后，用户将资源重新分配给所有连接的物品。具体来说，如果用户 u_j 得到用户 u_i 的信任，用户 u_j 的资源在重新分配给所

选物品之前被一个可调参数 θ 调节；否则，用户 u_j 的资源将按照CosRA算法中的方式被直接重新分配到连接的物品中。最终，物品 o_β 获得的资源计算如下：

$$f_\beta^{m(i)} = \sum_{j=1}^m \frac{a_{j\beta}}{\sqrt{k_j k_\beta}} (b_{ij} f_j^{n(i)\theta} + (1 - b_{ij}) f_j^{n(i)}), \quad (4-4)$$

其中， $b_{ij} = 1$ 表示用户 u_i 信任用户 u_j ；否则 $b_{ij} = 0$ 。 θ 是一个可调参数。 m 是网络中用户的总数目。在经过了三步资源分配后，按照物品所得的资源进行降序排列，排除目标用户已经选择过的物品，最终目标用户拥有一个长度为 L 的推荐列表。

算法过程的举例参考图4-1关于CosRA+T算法的示意图。图中用户（人物头像）与物品之间（书本图像）之间的连接用实线表示。用户与用户之间的有向连边用虚线箭头表示。




图 4-1 CosRA+T算法示意图

第一步，对于目标用户（橙色人像），将他所选的物品（橙色书本）进行资源初始化，获得资源值1，参考公式(4-2)。

第二步，所有物品的资源传递到与物品有连边的用户中，资源传递参考公式(4-3)。图中连接橙色书本的用户有3个（包括目标用户在内）。物品的资源值通

过用户和物品之间的实践进行分配，用户获得的资源进行累积，直到当所有物品的资源值分配完，物品资源值清零。

第三步，资源以第二步的分配方式从用户到物品。在此之前，针对目标用户的信任网络，找出目标用户所信任的其他用户（绿色人像）。对受信任的用户，资源分配方式受参数 θ 控制。用 f_j 表示受信任用户 u_j 在第二步后获得的资源值。使用参数 θ 后，受信任用户 u_j 的资源值为 f_j^θ 。受信任用户的资源分配给所选择的物品（绿色书本）。参数 θ 将确定信任关系对推荐算法的增强还是抑制的程度。随着参数 θ 取值从0增加到1，信任关系在CosRA+T方法中的影响力逐渐减少。在 $\theta = 0$ 的情况下，如图4-1（g-i）所示，受信任用户的资源会变成1，不管他们实际收到多少资源，而不受信任的用户的资源在重新分配之前保持不变。在 $\theta = 0.5$ 的情况下，如图4-1（d-f）所示，由于信任用户的资源小于1，在这种情况下，信任用户的资源值增多了，所选物品（绿色书本）更有可能出现在目标用户的推荐列表里。在 $\theta = 1$ 时，如图4-1（a-c）所示，信任关系对资源分配过程没有任何影响，而CosRA+T则会退化为原始的CosRA方法。具体算法的实现过程参考表4-2的伪代码，根据伪代码中描述，for循环的时间复杂度计算为 $O(n(mn + nm + m))$ ，整个算法的时间复杂度为 $O(m^2n)$ （其中 m 为用户数， n 为物品数）。

4.2.5 实验结果

本实验使用10折交叉验证方法来评估算法性能，参考第2.5.2节。具体来说，每个数据集分为10个大小相等的子样本，选择其中1个子样本做测试集剩余9个子样本做训练集。接下来，再选择其中1个数据集做测试集，剩余9个子样本做训练集，如此重复10次。实验数据取10次独立实验的平均值。

在CosRA+T算法中，可调参数 θ 用于扩展被信任用户在重新分配之前收到的资源。用户信任关系对资源分配过程的影响随着参数从1到0的变化而增加。为了探究参数对CosRA+T方法的推荐性能的影响，本节将参数 θ 选取从0到1，间隔为0.025。使用了3个准确性指标 AUC 、 RS 和 F_1 ，在Epinions和FriendFeed数据集上对它进行了评估，结果展示在图4-2上。图中(a-c)和(d-f)分别是数据Epinions和FriendFeed上的结果。在垂直坐标轴上，使用了3个准确性指标，包括 AUC 、 RS 和 F_1 （从左到右列）。在水平轴上，可调参数 θ 从0到1。垂直的红色虚线表示参数最优值 θ^* ，准确性指标达到最大值。计算 F_1 时推荐列表的长度设置为 $L = 10$ 。

注意到，3个准确性指标在参数 θ 下都存在最优值，并在Epinions和FriendFeed数据集上结果具有一致性。 AUC 和 F_1 的值随着 θ 值的增加而逐渐增加，在 θ^* 之后则

表 4-2 CosRA+T算法伪代码

输入参数: $U, U.objects, U.users$

// 用户集 U , 用户 U 选择的物品集, 用户 U 的受信任用户集

输入参数: $O, O.users$

// 物品集 O , 选择过物品 O 的用户集

输出参数: $Recommender.i$

// 用户推荐列表

```

1:   for all  $i \in U$                                      // 遍历用户, 选择目标用户 $i$ 
2:     for all  $\alpha \in i.objects$                          // 遍历用户 $i$ 选择的物品
3:        $f'_\alpha = 1$                                        // 初始资源分配,  $f'_\alpha = 1$ 表示物品 $\alpha$ 获得的资源值
4:       for all  $j \in \alpha.users$                        // 遍历选择过物品 $\alpha$ 的用户
5:          $f''_j \leftarrow f'_j + f'_\alpha \sqrt{k_\alpha} \sqrt{k_j}$  // 用户 $j$ 获得的资源值
6:       for all  $j \in U$                                    // 遍历所有用户, 选择目标用户 $j, j \neq i$ 
7:         if  $j \in i.users$                                // 判断信任关系, 用户 $i$ 信任用户 $j$ 
8:            $f''_j \leftarrow (f''_j)^\theta$                  // 受信任的用户 $j$ 的资源值改变
9:         for all  $\beta \in j.objects$                        // 遍历用户 $j$ 选择的物品
10:           $f'''_\beta \leftarrow f'''_\beta + f''_j \sqrt{k_\alpha} \sqrt{k_j}$  //  $f'''_\beta$ 表示物品 $\beta$ 最终的资源值
11:        for all  $\beta \in O$                                // 遍历所有物品
12:          if  $\beta \in i.objects$                          // 排除用户 $i$ 已经选择过的物品
13:            continue
14:           $List.i \leftarrow List.i + \beta$                //  $List.i$ 表示目标用户 $i$ 所有未选择的物品集合
15:        sort( $List.i$ ) by descending                     // 对物品按 $f'''$ 值降序排列
16:         $Recommender.i \leftarrow \text{top-}L \text{ of } List.i$  // 针对目标用户 $i$ 的长度为 $L$ 的推荐列表

```

逐渐下降。对Epinions来说, 这一数字约为0.70 (图4-2(a)和4-2(c)), FriendFeed约为0.65 (图4-2(d)和4-2(f))。对于RS的先降后升, 最优值参数Epinions约为0.7 (图4-2(b)), FriendFeed约为0.65 (图4-2(e))。

为了研究最优值参数 θ^* , 更好地确定它的临界值, 本节使用了三个依赖于推荐列表长度 L 的准确性值指标准确率 P 、召回率 R 和 F_1 值, 见图4-3。(a-c)和(d-f)分别表示Epinions和FriendFeed数据上的结果。在(a)和(d)中, 垂直轴分别是基于推荐列表长度 L 的准确性指标 P 和 R 。图(b)和(e)中, 指标结果是 F_1 值。在(c)和(f)中, 给




图 4-2 参数对推荐结果的影响

出了每一个准确性指标的平均最优值对于的参数 θ 值，并给出了标准误差。通过对推荐列表长度 L 的改变，研究 P 、 R 和 F_1 在两个数据集上的结果。图4-3(a-b,d-e)中结果表明，最佳参数 θ^* 对推荐列表的长度 L 不敏感。对于Epinions和FriendFeed，图4-3(a)和4-3(d)显示最佳参数分别是0.70和0.65。同样的趋势也出现在 F_1 指标上(图4-3(b)和图4-3(b))。此外，在图4-3(a)和4-3(d)中，本实验还确定了依赖于推荐列表长度的准确性指标 P 、 R 和 F_1 的最优参数值 θ^* ，在Epinions和FriendFeed上的结果。同时，也确定了不依赖于 L 的准确性指标(AUC 和 RS)的结果。最终确定最优参数值 $\text{Epinions}(\theta^*) \approx 0.70$ ， $\text{FriendFeed}(\theta^*) \approx 0.65$ 。5个准确性指标下的最优参数值都非常的接近，这说明最优参数下的推荐算法CosRA+T的普遍性。说明信任关系确实可以提高推荐效果。




图 4-3 可调参数的最优值

接下来进一步对所提出的CosRA+T方法进行比较全面的评估,并将其性能与5种基准算法(GR、UCF、HC、MD和CosRA)进行比较,算法详细介绍参考第3.4节。本实验应用了6个准确性评估指标,其中两个不依赖于 L 的指标(AUC 和 RS)和三个依赖 L 的指标($nDCG$, P , R 和 F_1),两个依赖 L 的多样性度量指标(H 和 I)和一个依赖 L 新颖性度量指标 N 。在实验中,所有依赖 L 的指标均设置 $L = 10$,并在后面分析 L 对推荐结果的影响。在与基准测试方法的比较中,CosRA+T方法在所有的评估指标中使用每个数据集的最优参数值 θ^* (Epinions上取 $\theta^* = 0.70$, FriendFeed上取 $\theta^* = 0.65$),运算结果取10次独立运算后的平均值。详细信息在表4-3中。表中结果均进行t检验(5种基准算法与CosRA+T算法对比),除了UCF算法的 $nDCG$ 值低于CosRA+T算法的结果不显著($p > 0.05$),所有结果均显著($p < 0.05$)。

如表4-3中的前2-7列所示,新算法CosRA+T的效果在Epinions和FriendFeed数据集上优于所有5个基准测试算法。CosRA+T算法比GR算法、HC算法和UCF算法有显著的优势。CosRA+T算法的 AUC 值在数据集Epinions和FriendFeed上分别

表 4-3 推荐算法效果

Epinions	AUC	RS	$nDCG$	P	R	F_1	H	I	N
GR	0.6974	0.3006	0.0222	0.0094	0.0315	0.0144	0.1338	0.1389	308
UCF	0.8141	0.1844	0.0385	0.0170	0.0537	0.0259	0.5748	0.1317	262
MD	0.8256	0.1735	0.0421	0.0189	0.0590	0.0286	0.6753	0.1140	235
HC	0.7845	0.2161	0.0103	0.0052	0.0153	0.0077	0.9742	0.0245	5
CosRA	0.8356	0.1641	0.0470	0.0221	0.0629	0.0327	0.9472	0.0900	107
CosRA+T	0.8382	0.1616	0.0484	0.0226	0.0651	0.0335	0.9544	0.0917	101
FriendFeed	AUC	RS	$nDCG$	P	R	F_1	H	I	N
GR	0.6058	0.3921	0.0150	0.0050	0.0215	0.0081	0.0739	0.0935	172
UCF	0.8869	0.1133	0.0456*	0.0155	0.0661	0.0252	0.8857	0.1616	92
MD	0.8925	0.1077	0.0468	0.0163	0.0683	0.0263	0.9422	0.1195	73
HC	0.8833	0.1182	0.0238	0.0088	0.0370	0.0142	0.9907	0.0542	11
CosRA	0.8978	0.1028	0.0436	0.0167	0.0633	0.0265	0.9895	0.0890	35
CosRA+T	0.9007	0.1000	0.0472	0.0175	0.0693	0.0280	0.9899	0.1008	35

^A 带*号数据 $p > 0.05$ 。

是0.8382和0.9007。对于依赖 L 指标, CosRA+T算法的性能比这些基准测试方法更好。例如, CosRA+T算法在数据集Epinions和FriendFeed上的 P 和 R 值是所有算法中最高的。CosRA+T算法的 F_1 值也非常有竞争力。在Epinions数据集上, 相比于UCF算法的 $F_1=0.0259$ 和MD算法的 $F_1=0.0286$, CosRA+T算法还将 F_1 值提高到了0.0335。此外, 在基于排序的准确值指标 RS 上, CosRA+T算法的 RS 是所有算法中的最低值, 同时CosRA+T算法的 $nDCG$ 值高于5个基准测试算法, 这表明CosRA+T算法在排序准确性上是所有6个算法中效果最好的。注意到CosRA+T算法在Friendfeed数据集上的 $nDCG$ 值不显著 ($p > 0.05$), 这说明推荐算法对数据集依赖较高, 对于实际应用的推荐算法, 应综合考虑准确性、多样性、新颖性以及推荐列表长度等, 因地制宜根据数据特点选用合适的推荐算法, 为用户提供个性化服务。表4-3的第8、9列显示了多样性指标 H 和 I 的结果。注意到, 根据Epinions和FriendFeed的数据集上的测试成果显示, HC算法的多样性高于本实验的所有算法。同时也在新颖性上高于所有算法。CosRA+T算法虽然没有在多样性和新颖性上优于HC算法, 仍然优于其它四种基准测试算法。CosRA+T算法的 H 值是除HC算法外的最大值, 并且与HC算法的 H 值仅相差2.04% (Epinions数据集) 和0.08% (FriendFeed数据集)。CosRA+T算法的 I 值是除HC算法外的最小值, 与HC算法的 I 值相差0.0672 (Epinions 数据集) 和0.0466 (FriendFeed数据集)。总的来说, CosRA+T算法在准确性、多样性和新颖性上领先。

推荐列表的长度 L 也有可能影响基于 L 的评价指标结果, 包括3个准确性指标 P , R 和 F_1 、2个多样性指标 H 和 I , 以及1个新颖性指标 N 。以下将探讨推荐列表长度 L 如何影响推荐方法的性能。对 L 取值从1到100, 将CosRA+T与其它5个算法进行对比, 见图4-4和图4-5。图4-4和图4-5中的(a-c)和(d-f)分别是Epinions和FriendFeed数据集。在垂直轴上, 分别显示了3个准确性指标、2个多样性指标和新颖性指标。在水平轴上, 推荐列表的长度从1增加到100。在CosRA+T算法中, θ 的参数值被设置为每个数据集的最优值对应的参数 (Epinions数据集上 $\theta^* = 0.70$, FriendFeed数据集上 $\theta^* = 0.65$)。

注意到, 随着推荐列表的长度 L 的增加, P 的值将会减少 (参见图4-4(a)和图4-4(d)), 而 R 的值增加 (参见图4-4(b)和图4-4(e))。 F_1 值先增加后减少, 最大 F_1 值出现在 $L \approx 10$ 的Epinions数据集上和 $L \approx 5$ 的FriendFeed数据集上 (参见图4-4(c) 和图4-4(f))。CosRA+T算法的性能在不同的 L 中比其他的基准方法有优势, 尤其是当 L 取值在最优值附近的时候, 例如Epinions数据集上取 $L^* \approx 10$, 的FriendFeed数据集上取 $L^* \approx 5$ 。并且CosRA+T算法与原来的CosRA算法相比也有一个相对的改进, 在所有6个算法中, CosRA+T算法在准确性指标上表现最好。

在准确性指标上表现最差的是HC算法和GR算法。




图 4-4 推荐结果的准确性受列表长度的影响

图4-5展示了多样性指标和新颖性指标受推荐列表长度 L 的影响。 H 值会随着 L 在Epinions和FriendFeed上的增加而缓慢降低（参考图4-5(a)和图4-5(d)）。




图 4-5 推荐结果的多样性和新颖性受列表长度的影响

HC算法的海明距离 H 值最高，其次是CosRA和CosRA+T算法。MD算法和UCF算法接近，最差的是GR算法。对于内相似度 I 来说，会随着 L 的增加而迅速增加随后缓慢下降（参考图4-5(b)和图4-5(e)）。此指标上，UCF算法的 I 值最高，推荐列表丰富性最差。CosRA+T算法在数据集Epinions上的结果要好于FriendFeed数据集。HC算法则在两个数据集上都有最低的 I 值。对于新颖性来说， N 的值随列表长度 L 的增加而降低（参考图4-5(c)和4-5(f)）。整体上，6个算法中，在多样性和新颖性指标上，HC算法是表现最好的，其次是不分伯仲的CosRA+T和CosRA算法。此外，当推荐列表长度超过30后，多样性和新颖性指标对列表长度 L 不再敏感。总体来说，CosRA+T算法具有相对较高的多样性和更好的新颖性。




图 4-6 被推荐物品的度分布

为了更好地理解CosRA+T算法的机制，本节进一步关注了所有用户的推荐列表中物品的度分布，见图4-6，为便于比较，实验中还参考了另外三种基准算法（HC、MD和CosRA）在Epinions和FriendFeed数据集上推荐列表中物品的度分布。实验中使用两种不同的推荐列表长度（ $L=10$ 和 $L=50$ ），图中的蓝色方块和红色三角分别对应于推荐列表长度 $L=10$ 和 $L=50$ 时的结果。在CosRA+T算法中，参数 θ 的值被设置为每个数据集的最优值（Epinions数据集上 $\theta=0.7$ ，Friendfeed数据集上 $\theta=0.65$ ）。图4-6分别展示了Epinions和FriendFeed的结果。HC算法中度分布陡峭，度为10左右的物品被推荐的次数最多，算法倾向于推荐小度物品（参考图4-6(a)和图4-6(e)）。相比之下，MD算法中度分布成“N”字造型，度为10左右和200-600范围的物品出现在用户推荐列表中最频繁，算法倾向于推荐大度物品（参考图4-6(b)和4-6(f)）。这些结果显示了HC和MD算法有潜在的偏向性，导致一些缺陷，如HC算法的低准确性和MD算法的低多样性。通过采用新颖的相似性指数，CosRA算法通过同时推荐大度和小度物品来达到推荐的准确性和多样性之

间的平衡（图4-6(c)和图4-6(g)）。主要原因在于，CosRA指数削弱了大度用户的影响，提高了小度用户的影响。CosRA+T算法通过扩大受信任用户所获得的资源改进了算法性能，提高CosRA算法的准确性和多样性，同时在度分布上保留了CosRA算法的度分布特性，在物品推荐上兼顾小度和大度物品，并更倾向于小度物品（参考图4-6(d)和4-6(h)）。

4.3 基于信任关系的资源分配推荐算法

4.3.1 问题的提出

网络科学的发展给推荐系统的研究提供了一个新方向，将推荐系统视为“用户-物品”的二部图，提出了很多基于网络拓扑结构的推荐算法，如物质扩散（MD）^[13]和热传导（HC）算法^[38]等。在此基础上，也衍生出很多优秀的推荐算法^[14, 40, 41, 173]。面对推荐系统多样性和准确性两难的问题，第4.2节已经提供了一个研究的方向，利用用户的社交关系对用户偏好数据进行补充。并且已有许多学者都对此有研究^[10]，将信任增强推荐系统的研究作为准确性和多样性两难问题的突破口。本章第4.2节也在第三章的基础上提出了信任增强的推荐算法，并由可调参数控制信任用户的资源分配。由于可调参数控制着受信任用户物质总量的放大或缩小，实验结果表明，在推荐过程中适当增强用户信任关系能提升推荐效果，但过分增强受信任用户的影响将会适得其反。在本节中，将继续对此进行研究，在物质扩散推荐系统框架下考虑信任关系的作用，提出了一种基于信任关系的资源分配推荐算法^[87]，分析了受信任用户在资源分配权重上的变化对推荐效果的影响。

4.3.2 算法设计

本实验中使用到的符号的详细信息参考第4.2.2节。以下文中出现的物品相关的指标均用希腊字母表示，用户相关的指标均用拉丁字母表示。

基于网络拓扑结构的推荐算法中，物质扩散（MD）算法^[13]和热传导（HC）算法^[38]是非常经典的算法，奠定了整个基于网络拓扑结构的推荐算法的研究的基础。在此算法基础上，诞生了非常多优秀的算法^[166]。标准的MD算法分为3个步骤：

- （1）对目标用户 u_i 选择的物品赋予一个单位的初始资源：

$$f_{\alpha}^{(i)} = a_{i\alpha}, \quad (4-5)$$

(2) 资源通过用户与物品的连边均匀扩散到所有选择过这些物品的用户中, 假如用户 u_j 选择了物品 o_α , 而 o_α 是用户 u_i 选择过的物品, 那么 u_j 从 o_α 这里得到的资源值为 $1/k_\alpha$, k_α 是产品 o_α 的度。用户的资源值对从不同物品扩散出资源进行累积, 最终, 用户 u_j 从用户 u_i 得到的资源为:

$$f^{ij} = \sum_{\alpha=1}^n \frac{a_{i\alpha}a_{j\alpha}}{k_\alpha}, \quad (4-6)$$

(3) 所有用户的资源值将均匀分配给他们选择的物品, 分配方式参考第(2)步, 其中物品 o_β 接收到从用户 u_j 的资源为 f_{ij}/k_j , 通过累积所有选择过物品 o_β 的用户资源值, 物品 o_β 最终得到的资源值为:

$$f_{\beta}^{m(i)} = \sum_{j=1}^m \frac{a_{j\beta}f_{ij}}{k_j}, \quad (4-7)$$

其中, k_i 是用户 u_i 选择的物品数目。最终得到所有物品的资源值, 将用户 u_i 已经选择过的物品排除, 对余下的物品按资源值降序排列, 并取排名靠前的 L 个物品, 以此给用户 i 建立一个推荐长度为 L 的推荐列表。

与MD算法不同的是, HC算法在热能传递过程中热能总量不守恒。算法定义如下:

(1) 对目标用户 u_i 选择的产品赋予一个单位的初始热能值:

$$f_{\alpha}^{(i)} = a_{i\alpha}, \quad (4-8)$$

(2) 热能通过用户与物品的连边从物品传递到用户。传递过程热能不守恒。假如用户 u_i 和用户 u_j 都选择了物品 o_α , 而 o_α 拥有初始热能值, 物品 o_α 传递给用户 u_j 的热能值为 $1/k_j$, 既能量值的传递与被传递的节点的度成反比。通过累积不同物品的热能值, 最终用户 u_j 从用户 u_i 得到的热能为:

$$f^{ij} = \sum_{\alpha=1}^n \frac{a_{i\alpha}a_{j\alpha}}{k_j}, \quad (4-9)$$

(3) 所有用户的热能值重新传递到他们选择的物品中, 传递方式参考第(2)步, 其中用户 u_j 分配给所选择的物品 o_β 的热能为 f_{ij}/k_β , 通过累积所有选择过物品 o_β 的用户的热能值, 最终物品 o_β 得到的热能值为:

$$f_{\beta}^{m(i)} = \sum_{j=1}^m \frac{a_{j\beta}f_{ij}}{k_\beta}, \quad (4-10)$$

通过公式可以看出, MD和HC算法在资源传递的过程中, 传递方式不同。这种不同导致推荐算法的效果差别极大, 就MD算法而言, 度大的节点容易积累更多的资源值, HC算法则相反, 度小的物品会获得较多的热能值。Zhou等人^[14]在

物质扩散算法和热传导算法的基础上, 提出了一种混合算法 (Hybrid Algorithm, HA), 结合了这两种传递方式的特点, 定义如下:

(1) 对目标用户 u_i 选择的产品赋予一个单位的初始资源:

$$f_{\alpha}^{(i)} = a_{i\alpha}, \quad (4-11)$$

(2) 资源通过用户与物品的连边从物品传递到用户。传递的资源受传播节点和接收节点共同的影响, 由参数 λ 调节。假如用户 u_i 和用户 u_j 都选择了物品 o_{α} , 而 o_{α} 拥有初始资源值, 物品 o_{α} 传递给用户 u_j 的能量值为 $1/k_j^{1-\lambda}k_{\alpha}^{\lambda}$ 。通过累积不同物品的资源值, 最终用户 u_j 从用户 u_i 得到的资源为:

$$f^{ij} = \sum_{\alpha=1}^n \frac{a_{i\alpha}a_{j\alpha}}{k_{\alpha}^{\lambda}k_j^{1-\lambda}}, \quad (4-12)$$

(3) 所有用户的资源值重新传递到他们选择的物品中, 传递方式参考第 (2) 步, 其中用户 u_j 分配给所选择的物品 o_{β} 的资源为 $f_{ij}/k_j^{1-\lambda}k_{\alpha}^{\lambda}$, 通过累积所有选择过物品 o_{β} 的用户的资源值, 最终物品 o_{β} 得到的资源值为:

$$f_{\beta}^{m(i)} = \sum_{j=1}^m \frac{a_{j\beta}f_{ij}}{k_{\alpha}^{\lambda}k_j^{1-\lambda}}, \quad (4-13)$$

当 $\lambda = 1$ 时, HA 算法表述为 MD 算法; 当 $\lambda = 0$ 时, HA 算法表述为 HC 算法。

事实上, f_{ij} 可以用来计算用户 i 和 j 之间的相似性。本节将用户的信任关系引入到 HA 算法中, 补充用户的相似性信息, 提出一种基于信任关系的新算法 (Trust-based Hybrid Algorithm, THA), 采用线性组合的方式将资源扩散和信任关系结合起来, 定义如下:

(1) 对目标用户 u_i 选择的产品赋予一个单位的初始资源:

$$f_{\alpha}^{(i)} = a_{i\alpha}, \quad (4-14)$$

(2) 资源通过用户与物品的连边从物品传递到用户。资源传播的方式参考 HA 算法第 (2) 步的公式 (4-12)。在此步骤上结合信任关系。假如用户 u_i 不信任用户 u_j , $b_{ij}=0$ 。此时, 用户 u_j 获得从物品 o_{α} 传递传递的资源值为 $1/k_j^{1-\lambda}k_{\alpha}^{\lambda}$ 。用户 u_i 信任用户 u_j , $b_{ij}=1$ 。此时用户 u_j 获得的资源值, 在所有物品的资源传递完成后, 受信任的用户 u_j 的资源值额外增加信任权重 θ 。最终用户 u_j 从用户 u_i 得到的资源为:

$$f^{ij} = \theta b_{ij} + \sum_{\alpha=1}^n \frac{a_{i\alpha}a_{j\alpha}}{k_{\alpha}^{\lambda}k_j^{1-\lambda}}, \quad (4-15)$$

(3) 所有用户的资源值重新传递到他们选择的物品中, 传递方式参考第(2)步, 用户 u_j 传递给所选择的物品 o_β 的资源值为 $f_{ij}/k_j^{1-\lambda}k_\alpha^\lambda$, 通过累积所有用户的资源值, 最终物品 o_β 得到的资源值为:

$$f_\beta^{m(i)} = \sum_{j=1}^m \frac{a_{j\beta} f_{ij}}{k_\alpha^\lambda k_j^{1-\lambda}}, \quad (4-16)$$

THA算法中有两个参数, 当 $\theta = 0$ 时, 算法退化为HA算法; $\lambda = 1$ 、 $\theta = 0$ 时, 是MD算法; $\lambda = 0$ 、 $\theta = 0$ 时, 则是HC算法。算法示意图参考图4-7, 算法步骤如下:




图 4-7 THA算法示意图

第1步, 目标用户(橙色人像)所选物品(橙色书本)的初始资源为1;

第2步, 参考公式(4-15)将资源从物品传递到用户, 同时对受信任的用户(绿色人像)获得的资源增加资源 θ 。

第3步, 用户的资源以第(2)步中的方式传递到物品。对信任的用户(绿色人像), 资源在传递前的数值增加 θ 。 θ 是一个可调参数, 数值从0增加到1表示对信任用户的信任程度逐渐增加。在 $\theta = 0$ 、 $\lambda = 0.5$ 的情况下, THA算法退化为HA算法, 见图4-7(a)。图4-7(b)展示的是 $\theta = 1$ 、 $\lambda = 0.5$ 的情况下的THA算法步骤。THA算法的伪代码展示在表4-4中, 算法的时间复杂度为 $O(m^2n)$ (其中 m 为用户数, n 为物品数)。

4.3.3 实验结果

评价指标和实验所用数据参考第4.2.3节, 本节不做过多介绍。实验过程在

表 4-4 THA算法伪代码

输入参数: $U, U.objects, U.users$		
// 用户集 U , 用户 U 选择的物品集, 用户 U 的受信任用户集		
输入参数: $O, O.users$		
// 物品集 O , 选择过物品 O 的用户集		
输出参数: $Recommender.i$		
// 用户推荐列表		
1:	for all $i \in U$	// 遍历用户, 选择目标用户 i
2:	for all $\alpha \in i.objects$	// 遍历用户 i 选择的物品
3:	$f'_\alpha = 1$	// 初始资源分配, $f'_\alpha = 1$ 表示物品 α 获得的资源值
4:	for all $j \in \alpha.users$	// 遍历选择过物品 α 的用户
5:	$f''_j \leftarrow f''_j + f'_\alpha \sqrt{k_\alpha} \sqrt{k_j}$	// 用户 j 获得的资源值
6:	for all $j \in U$	// 遍历所有用户, 选择目标用户 $j, j \neq i$
7:	if $j \in i.users$	// 判断信任关系, 用户 i 信任用户 j
8:	$f''_j \leftarrow (f''_j) + \theta$	// 受信任的用户 j 的资源值改变
9:	for all $\beta \in j.objects$	// 遍历用户 j 选择的物品
10:	$f'''_\beta \leftarrow f'''_\beta + f''_j \sqrt{k_\alpha} \sqrt{k_j}$	// f'''_β 表示物品 β 最终的资源值
11:	for all $\beta \in O$	// 遍历所有物品
12:	if $\beta \in i.objects$	// 排除用户 i 已经选择过的物品
13:	continue	
14:	$List.i \leftarrow List.i + \beta$	// $List.i$ 表示目标用户 i 所有未选择的物品集合
15:	sort($List.i$) by descending	// 对物品按 f''' 值降序排列
16:	$Recommender.i \leftarrow \text{top-L of } List.i$	// 针对目标用户 i 的长度为 L 的推荐列表

两个真实的数据集: Epinions和FriendFeed上进行, 并分别与5个基准推荐算法进行比较, GR^[174]、UCF^[192]、MD^[13]、HC^[38]和混合算法 (Hybrid Algorithm, HA)^[14]。图4-8和4-9展示了THA算法在Epinions和FriendFeed数据集上的6个指标结果, 推荐列表长度 $L = 10$ 。

参数 λ 对THA算法的影响很大。在图4-8中, 当 $\theta = 0$ 时, THA算法在Epinions数据集上的3个准确性指标 AUC 、 P 和 R 上取得最大值时对应参数 $\lambda = 0.5$, 此时算法退化为HA算法。参数 θ 体现的是信任权重对推荐结果的影响。在图4-8中, 当 $\theta > 0$ 的时候, 准确性指标 AUC 、 P 和 R 的值都比 $\theta = 0$ 的时候高, 并且都存在一个明显




图 4-8 THA算法在两个数据集上的准确性指标值

的峰值。这说明信任关系对提高推荐准确性有积极的影响。在Epinions数据集上（见图4-8(a)），AUC峰值对应的最优值参数为 $\lambda = 0.5$ 、 $\theta = 0.05$ 。在FriendFeed数据集上（见图4-9(a)），AUC峰值对应最优值参数为 $\lambda = 0.5$ 、 $\theta = 0.075$ 。对于目标用户，当 $\theta > 0$ 时，被信任的用户将被分配更多的资源，导致被信任的用户和目标用户之间相似性更高，从而更容易推荐已选择过的产品给目标用户，这也和现实中信任的出发点是一致的，会对受信任的朋友推荐的物品多一份信任。




图 4-9 THA算法在两个数据集上的多样性指标值

更详细的最优值参数情况下的THA算法结果展示在表4-5中，并与GR算

法、HC算法、MD算法、UCF算法和HA算法进行比较。在表4-5中，THA算法在FriendFeed数据集上取最优值参数 $\lambda = 0.5$ 、 $\theta = 0.075$ ，Epinions数据集取最优值参数 $\lambda = 0.5$ 、 $\theta = 0.05$ 。依赖于推荐列表长度的指标对应 $L = 10$ ，加粗字体对应于评价指标的最优值。表4-5的第2-6列分别是准确性指标 AUC 、 $nDCG$ 、 P 、 R 和 F_1 值。在Epinions数据集上，HA算法在准确性上要优于MD、HC、GR以及UCF算法，并且THA算法在HA算法的基础上将 AUC 、 $nDCG$ 、 P 、 R 和 F_1 值分别提高了0.98%、9.1%、5.4%、10%和6.6%。这说明了本实验将信任关系作为一种辅助特征与基于网络拓扑结构的算法进行结合是非常有效且合理的。在FriendFeed数据集上，THA算法也在准确性上领先于其余5个推荐算法。在多样性上，HC算法的 H 值最高， I 值最低，多样性最好。同样在新颖性上，HC算法也是所有6个推荐算法中最优。以上结果均进行t验证（5种基准算法与THA算法对比），实验结果均显著（ $p < 0.05$ ）。

表 4-5 六种推荐算法结果比较

Epinions	AUC	$nDCG$	P	R	F_1	H	I	N
GR	0.6974	0.0222	0.0094	0.0315	0.0144	0.1338	0.1389	308
HC	0.7845	0.0103	0.0052	0.0153	0.0077	0.9742	0.0245	5
MD	0.8256	0.0421	0.0189	0.0590	0.0286	0.6753	0.1140	235
UCF	0.8141	0.0385	0.0170	0.0537	0.0259	0.5748	0.1317	262
HA	0.8356	0.0470	0.0221	0.0629	0.0327	0.9472	0.0900	107
THA	0.8438	0.0513	0.0233	0.0692	0.0349	0.9447	0.0912	107
FriendFeed	AUC	$nDCG$	P	R	F_1	H	I	N
GR	0.6058	0.0150	0.0050	0.0215	0.0081	0.0739	0.0935	172
HC	0.8833	0.0238	0.0088	0.0370	0.0142	0.9907	0.0542	11
MD	0.8925	0.0468	0.0163	0.0683	0.0263	0.9422	0.1195	73
UCF	0.8869	0.0456	0.0155	0.0661	0.0252	0.8857	0.1616	92
HA	0.8978	0.0436	0.0167	0.0633	0.0265	0.9895	0.0890	35
THA	0.9056	0.0520	0.0184	0.0762	0.0296	0.9810	0.1053	43

推荐列表的长度 L 也有可能影响基于 L 的评价指标结果，包括3个准确性指标 P 、 R 和 F_1 ，两个多样性指标 H 和 I ，以及一个新颖性指标 N 。以下，将探讨 L 如何影响推荐方法的准确性。对 L 取值从1到100，THA算法在FriendFeed数据集上取最优值参数 $\lambda = 0.5$ 、 $\theta = 0.075$ ，Epinions数据集取最优值参数 $\lambda = 0.5$ 、 $\theta = 0.05$ ，

并将THA和其它5个算法进行对比，见图4-10。




图 4-10 推荐准确性受推荐列表长度 L 的影响

在Epinions和FriendFeed数据集上，图4-10给出了3个准确性指标 P 、 R 和 F_1 的结果。注意到，随着推荐列表的长度 L 的增加， P 值（见图4-10(a)）将会减少， R 值（见图4-10(b)）持续增加， F_1 值（见图4-10(c)）先增后减。在Epinions数据集上 $L \approx 10$ 时 F_1 取得最大值，在FriendFeed是 $L \approx 5$ 。THA算法与其他算法比，在准确性上有明显优势，尤其是在最优 L 值附近，如FriendFeed上 $L=5$ 。THA算法与原来基准算法HA相比较，在准确性指标上也有一个相对的改进。

图4-11展示THA算法的多样性指标和新颖性指标的结果， L 取值范围为 $[1, 100]$ ，THA算法在FriendFeed数据集上取最优值参数 $\lambda = 0.5$ 、 $\theta = 0.075$ ，Epinions数据集取最优值参数 $\lambda = 0.5$ 、 $\theta = 0.05$ 。结果显示，在数据集Epinions和FriendFeed上， H 值（见图4-11(a)）会随着 L 的增加而缓慢降低。HC算法的 H 值最高，其次是HA和THA算法。MD算法和UCF算法接近，最差的是GR算法。对于 I 值（见图4-11(b)）来说，会随着 L 的增加而迅速增加随后缓慢下降。此指标上，UCF算法的 I 值最高，推荐列表丰富性最差。HC算法则在两个数据集上都有最低的 I 值。对于新颖性来说， N 值（见图4-11(c)）的值随列表长度 L 的增加而降低。总体来说，HC算法是多样性和新颖性最高的算法。

为了进一步了解算法机制，图4-12展示了MD、HC、HA和THA算法在数据




图 4-11 推荐结果的多样性和新颖性受推荐列表长度的影响

集Epinions和FriendFeed上的推荐列表的度分布。实验中设置了不同的推荐列表长度 $L = 10$ 和 $L = 50$ 。从图中看到，虽然推荐列表的长度会影响被推荐的物品，但长度的改变不影响被推荐的物品的度分布趋势。并且在不同数据集上的度分布趋势一致。结果显示MD算法主要推荐度大的物品，被推荐最多的物品的度在100到1000之间，见图4-12(b,f)。而HC算法倾向于推荐度小的物品，度小于10的




图 4-12 被推荐物品的度分布

物品被推荐最多, 见图4-12(a,e)。这就是为什么MD算法的准确性较高而多样性较差, HC算法的多样性较好而准确性较差的原因。HA算法综合了MD和HC算法的优点, 既推荐流行的物品又推荐冷门的物品, 来达到推荐的准确性和多样性之间的平衡, 见图4-12(c,g)。THA算法继承了HA算法的优点, 在准确性和多样性上优于HA算法。图4-12(d,h)中, THA算法的度分布与HA算法一致。说明, 合理用户的信任关系作为辅助信息, 可以提高推荐算法的准确性和多样性, 但并没有改变推荐算法在推荐物品上的偏好。

4.4 本章小结

本章在第4.2节探讨了用户之间的信任关系在基于协同过滤的算法上提高推荐性能的作用。通过将信任关系加入到CosRA算法中, 提出了一种基于信任的推荐算法CosRA+T算法, 对受信任的用户接受到的资源由可调参数进行缩放后再分配到他们选择的物品中去, 这一过程增加了接收到资源的物品数。实验结果表明, 适当增加受信任用户获得在资源值, 可以有效提高算法的准确性和多样性。通过对两个真实网络记录的数据集(Epinions和FriendFeed)进行大量的实验后, 结果发现, 与其它基础算法相比较, 信任增强的CosRA+T推荐算法更高准确性、多样性和新颖性。同时准确性最高时对应的参数不依赖于数据集, 说明CosRA+T算法参数可以简单复现。本实验还研究了推荐列表长度对推荐算法的影响, 实验结果发现, 列表长度对算法的性能有一定影响, 但在同一数据集上对算法的影响是一致的。对于推荐列表长度的选择, 只与数据集有关, 与参数无关。最后, 通过研究推荐列表的度分布进一步认识推荐算法的机制。结果表明, CosRA和CosRA+T算法在推荐内容上很好地兼顾了大度和小度物品的平衡, 从而达到了较好的推荐效果。

本章在第4.3节探讨了用户之间的信任关系在基于网络拓扑结构的算法上对推荐算法性能的提高作用。本算法在MD算法和HC算法的混合算法(HA)的基础上, 充分利用信任网络, 提出一种新的信任增强算法THA算法。由可调参数对受信任用户获得的资源进行增强, 提高受信任用户获取的资源数, 扩大受信任用户在物品选择上的影响力。实验结果显示, 与其他基于网络拓扑结构的推荐算法相比, THA算法在准确性、多样性和新颖性上表现更好。进一步分析THA算法机制后发现, 与CosRA+T算法类似, 在内容推荐上, THA算法同时兼顾“流行”和“冷门”的物品, 既提高了算法的准确性又提高了算法的多样性。

本章节主要贡献在于: (1) 充分利用社会关系提高推荐算法的效果, 对带社会关系的推荐系统提供了思路和方法; (2) 算法在计算过程中, 与原算法相比较,

仅仅增加一次线性计算，提高了原算法的准确性、多样性和新颖性，没有增加时间复杂度。（3）在一定程度上解决了用户评分稀少导致的推荐不准确问题。

受数据集和建模所限，CosRA+T算法和THA算法的结果存在一些限制。推荐算法对数据集依赖较高，对于实际应用的推荐算法，应综合考虑准确性、多样性、新颖性以及推荐列表长度等，因地制宜根据数据特点选用合适的推荐算法，为用户提供个性化服务。实验过程中使用到的数据集，仅代表了大量真实在线评分系统的一个缩影。如果推荐算法能够在不同的数据集，甚至在真正的在线平台上进行全面的测试和比较，不同的推荐算法会如何长期影响在线平台的长期发展^[101]，将会是非常好研究方向。CosRA+T算法和THA算法是利用信任关系对信任用户进行相似度增强的混合算法。后续也可以在不同的框架下进行信任增强研究。此外，不仅社交关系，用户的特征（如用户的信誉^[193, 194]）等信息也对推荐系统至关重要。在未来工作中，将会把用户信誉度和社会信任关系结合起来，进一步提高个性化推荐算法那在实际应用中的效果。

第五章 基于社会化标签的推荐算法研究

现实中推荐系统的应用非常广，尤其是在电子商务和社交网络中。这部分推荐系统的结构并不仅限于二部图网络。有些系统平台赋予使用者发表和编辑内容的权利，这些可分享的元数据是用户自由产生的关键字，被称之为标签。标签的出现给系统平台提供了额外的分类方式并且对更深刻地了解了用户需求。标签也给在线的用户提供了表达自己观点的机会，让他们在找寻志同道合的人和物上节约了时间精力。这类的网络平台有Delicious、豆瓣等。标签与推荐系统的结合对解决推荐系统面临的冷启动问题有很大帮助。本章提出了基于引力模型的推荐算法，通过用户对标签的使用情况预测用户的偏好。为了对进一步改进推荐算法提供帮助，需要对标签推荐系统有更深刻的理解。本章从网络演化的角度分析了标签网络的特征。考虑到标签是用户自定义的，用户之间的差异导致对标签的理解和使用方式不同。自定义标签产生了大量的内容，降低了内容检索和信息分享的能力。因此考虑由推荐系统推广部分标签，降低推荐系统中的信息熵。标签的推广过程，可以描述为一种信息传播^[195]的过程。从信息传播的方向研究影响用户对信息采纳的关键因素，根据研究结果指导推荐算法的研究。

5.1 基于引力模型的推荐算法

5.1.1 问题提出

随着电子化设备更加廉价易得、通信设施更加完善和互联网本身的开放性，在更加自由开放民主的Web2.0时代，网络已经是生活中密不可分的一部分。面对网络迅速发展带来的信息过载问题，传统的二部图推荐系统已经无法满足人的交互需求。物品的种类越来越多、分类越来越细以及人的选择面的扩大，使得单纯通过偏好相似的用户推荐所起的作用越来越有限。另外刚刚进入系统的新用户，在系统中没有足够的多的行为数据，在以行为相似性为算法导向的推荐系统中，没有足够数据导致对用户的行为特征的计算不准确，导致产生了不合理的推荐。这是典型的推荐系统的冷启动问题。同时刚刚进入推荐系统的物品也会遇见同样的冷启动困境。很多不同的推荐系统平台通过增加一些社会化信息提高人对物品的信息的掌握，提高推荐系统对人的偏好的掌握，以提供更加准确的服务。

标签的出现是一个契机。在社会化标签系统里，人被赋予了重要的角色。不仅可以选

签，对不同的物品提供个性化标注，方便用户分类查找。同时对现有物品提供更多描述，为其他用户提供方便，降低用户沟通、分享和获取的成本。标签代表着用户的最直观的偏好的内容和分类，也为推荐系统提供了更多个人特质数据。例如对同样的一部电影《红海行动》，有的用户对此标注“战争”、“爱国”等，有的用户标注“杜江”、“林超贤”等。这些标签反映出用户对内容和分类上的偏好。

目前的标签的应用有很多，例如Delicious.com上可以分享图书标签、Last.fm上分享音乐标签、在豆瓣上分享电影标签等。由此形成了标签推荐系统（Tagging Systems）。标签系统的广泛应用，对于推荐系统的冷启动问题带来了一些解决的可能方案^[22]。标签的出现带来了机遇也带来了挑战。一些独立的内容提供者以不可控的方式产生了大量的内容，从而降低了内容检索和信息分享的能力。这也对传统的二部图结构的推荐系统提出了难题。由于标签的引入，将传统广泛采用的用户-对象的二元关联转变为“用户-对象-标签”组成的三元关联。如图5-1所示。近年来，很多学者从应用层面出发，将标签信息应用到推荐系统中来进行个性化推荐工作^[23, 196-198]。实际上是将标签作对内容个性化信息的一种补充。

考虑到标签信息是一种用户自发产生的数据，与用户对物品的选择一样，反映的是用户的特征。同时标签也反映了物品的特征。用户和物品具有相同的特征是标签推荐系统区别于其他推荐系统的地方。因此，本节通过引力模型使用共同的标签特征刻画用户和物品之间的相似程度，提出基于引力模型的个性化推荐算法^[199]。




图 5-1 用户-对象-标签组成的三元关联图

5.1.2 数据和符号

推荐系统用一个二部图 $G(U, O, E)$ 表示，其中用户 $U = \{u_1, u_2, \dots, u_m\}$ ，产品 $O = \{o_1, o_2, \dots, o_n\}$ 和链接 $E = \{e_1, e_2, \dots, e_l\}$ 。标签推荐系统用 $T = \{t_1, t_2, \dots, t_r\}$ 来

表示标签集合。标签既可以作为用户对物品赋予的个性化的描述,又可以作为物品的分类信息描述。比如,一个用户 u_1 选择了物品 o_1 并且给这个物品打了2个标签 t_1 和 t_2 。那么产品 o_1 的标签有 t_1 和 t_2 。使用两个邻接矩阵 A^{uo} 和 A^{ot} 分别表示“用户-物品”的关系和“物品-标签”的关系。对矩阵 A^{uo} 而言,如果用户 u_i 选择过物品 o_α ,那么矩阵的元素 $a_{i\alpha}^{uo}=1$,否则 $a_{i\alpha}^{uo}=0$ 。同理,如果物品 o_α 被打过标签 t_k ,那么 $a_{\alpha k}^{ot}=1$,否则 $a_{\alpha k}^{ot}=0$ 。此外,本实验还引入了两个加权矩阵 B^u 和 B^o ,分别表示用户和物品的标签信息。其中, b_{ik}^u 表示用户 u_i 对标签 t_k 的使用次数,而 b_{ik}^o 则表示商品 o_α 被标注为 t_k 的次数。

本实验中使用两个包含标签信息的数据集:MovieLens和Delicious。其中MovieLens数据集是研究推荐算法的代表性数据,网站上用户可对物品设置标签并对物品进行从1到5的评分。本实验中只考虑评分大于2的数据。Delicious数据集中的标签信息来自于平台上用户为不同的图书设置。表5-1展示了Delicious数据集和MovieLens数据集的基本统计信息,包含用户数、物品数、“用户-物品”网络的稀疏度(定义为用户与物品之间的连边数占用户与物品全连通情况下边数的比例)、数据集上总标签数和用户使用标签的次数。

表 5-1 数据集详细介绍

数据集	用户数(m)	物品物(n)	网络稀疏度(S_l)	标签数(r)	用户标注数(B_t)
Delicious	4,902	36,224	1.1×10^{-3}	10,584	192,487
MovieLens ₁	648	1,590	9.5×10^{-3}	1,382	9,749
MovieLens ₂	1,741	3,259	3.5×10^{-3}	2,277	32,507

5.1.3 评价指标

为了测试算法的推荐性能,本实验引入4个评价指标: AUC ^[163]、 RS (Ranking Score)^[166]、准确率(Precision,以下简称 P)^[166]和内相似度(Inter-Similarity,以下简称 I)^[166]。详细的评价指标介绍参考第2.4节对推荐算法的评价指标的描述。本节仅对涉及到的指标简单介绍。

(a) AUC 用来测试推荐算法的全局预测的准确性。在随机预测情况下, AUC 值在0.5左右。最高的 AUC 值能达到1。因此算法的 AUC 值越大,表明算法推荐准确性越好。

(b) RS 值在准确率的基础上对所推荐的物品进行了排序。系统推荐准确的物品在推荐列表中越靠前, RS 值越低,说明用户喜欢的物品排名越靠前,算法的排序准确性越好。

(c) 准确率 (P) 用来测试用户推荐列表中预测正确的比例。用户的推荐列表中完全没有预测准确的物品时 $P = 0$, 全部预测准确时 $P = 1$, 所以命中率越高, 说明推荐列表越符合用户实际情况。

(d) 内相似度 (I) 反映的是用户的推荐列表中各个物品之间的差异性。 I 数值越小表示用户的推荐列表中物品的多样性越高, 物品越丰富。内相似度的值也依赖于用户推荐列表的长度 L 。

5.1.4 基于引力模型的推荐算法

在标签推荐系统中, 用户对物品标注了标签。用户的特征向量有两个, 一个是表示物品特质的向量, 一个是表示标签特质的向量。物品也具有两个特征向量, 用户特征向量和标签特征向量。用户与物品之间还因标签而建立起间接的关联。标签反映的是用户对物品的观点和喜好, 所以充分利用标签信息对理解用户的偏好有积极的意义。本实验中, 设计推荐算法需要考虑的如下几点:

- (1) 考虑到用户与物品之间关系。
- (2) 考虑到用户与标签的关系, 物品与标签的关系。
- (3) 考虑到用户因使用标签而产生的对物品的隐式关系。

考虑到以上三点后, 本实验提出基于引力模型 (Gravity Model, GM) 的推荐算法^[199]。引力模型已经应用于多个领域, 例如人口迁移方面^[200, 201]、人类出行规律^[202]、交通流研究^[203, 204]和经济贸易^[205]等。引力模型的突出特点是, 综合考虑节点的属性以及节点之间的关联。本实验中, 基于引力模型的推荐算法将同时使用用户的标签特征和物品的标签特征。

以下目标用户用 u_i 表示, 物品用 o_α 表示, 经过算法计算后物品的得分用 f 表示。使用 $m_i = \sum_{l=1}^r b_{il}^u$ 来计算用户的质量, 实际意义为用户 u_i 对标签的使用频次, 表示用户对某种分类或者内容上偏好的权重。物品的质量用 $m_\alpha = \sum_{l=1}^r b_{\alpha l}^o$ 表示。实际意义为物品 o_α 被不同标签标注的次数, 表示物品的隐式分类和内容。用户和物品的质量分别代表用户与标签的关系、物品与标签的关系。用户与物品的共同特征反映在标签上, 因此标签可以用来计算用户与物品的相似度。本实验使用距离 $d = \frac{1}{C_{i\alpha} + \theta}$ 表示用户和物品之间的相似性, 其中 $C_{i\alpha} = \sum_{l=1}^r c_{i\alpha}^l$, 当 $b_{il}^u b_{\alpha l}^o \neq 0$ 时, $c_{i\alpha}^l = 1$, 否则的话, $c_{i\alpha}^l = 0$ 。 $C_{i\alpha}$ 是用户与物品共同的标签数, 不考虑每个标签的使用频次。实际意义为用户对物品标注的标签越多, 越能表示用户与物品之间的关联。 θ 是一个可调参数, 用于调节标签带给用户与物品的相似的权重。对目标用户 u_i , 基于引力模型计算他对物品 o_α 的预测得分为:

$$f_{i\alpha}^{GM} = \frac{m_i m_\alpha}{d^2}, \alpha = 1, 2, \dots, n, \quad (5-1)$$

$f_{o_\alpha}^{GM}$ 表示目标用户对物品 o_α 的预测得分,在计算所有用户没有选择过的物品的预测得分后,按照预测得分降序排列,取前 L 个物品加入目标用户的推荐列表。

算法的具体计算步骤如下:

(1) 遍历所有用户和物品,根据 m_i 和 m_α 分别计算用户的质量和物品的质量。

(2) 遍历所有用户,计算目标用户与每个物品的 d 值。结合第(1)步得到的用户和物品的质量,根据公式(5-1)计算目标用户与每个物品的相似度得分 $f_{i\alpha}^{GM}$,排除用户已经选择过的物品,并对剩余物品按照得分降序排列,取前 L 物品加入目标用户的推荐列表。基于引力模型的推荐算法的具体实现参考表5-2的GM算法伪代码,根据伪代码中描述,for循环的时间复杂度计算为 $O(nr + mr + nmr)$,整个算法的时间复杂度为 $O(nmr)$ (其中 m 为用户数, n 为物品数, r 为标签数)。

作为对比,本实验中选取了两个其他的基于标签的算法,分别是基于标签的物质扩散算法(I)^[198]和算法(II)^[22]相比较。

算法(I)的计算过程分为3步:

(1) 对于一个给定的目标用户 u_i ,对 u_i 选择过的所有物品都赋予一个单位资源,其中物品 o_α 获得的资源值为 $a_{i\alpha}^{uo} = 1$;

(2) 接着所有物品将自己的资源平均分配给它连接的标签,其中标签 t_l 接收到来自物品 o_α 的资源值为 $1/k_\alpha$,通过累计不同的物品的资源值,最终标签 t_l 获得的总资源值为:

$$f_{il}^{(I)} = \sum_{\alpha=1}^n \frac{a_{i\alpha}^{uo} a_{\alpha l}^{ot}}{k_\alpha}, \quad (5-2)$$

第(2)步完成后,物品的资源值清零;

(3) 所有标签的资源值通过第(2)步的资源分配方式,全部分配到物品中。其中标签 t_l 传递给它标注过一个物品 o_α 的资源值为 $f_{il}^{(I)}/k_l$ 。通过累计物品获得的资源值,最终物品 o_β 的资源值为:

$$f_{i\beta}^{(I)} = \sum_{l=1}^r \frac{a_{\beta l}^{ot} f_{il}^{(I)}}{k_\beta}, \quad (5-3)$$

其中, $k_l = \sum_{\alpha=1}^n a_{\alpha l}^{ot}$ 表示被标签 t_l 标记的物品数目, $k(\beta) = \sum_{l=1}^r a_{\beta l}^{ot}$ 是物品 o_β 被标记的标签数目。

算法(II)的初始资源与方法(I)不同,计算过程分以下几步:

(1) 对目标用户 u_i 使用过的所有标签分配一定量的资源,资源与标签的使用频次成正比。其中标签 t_l 获得的初始资源为:

$$f_{il}^{(II)} = b_{il}^u, \quad (5-4)$$

(2) 接着将每个标签的资源平均分配到所有连接的物品中。标签 t_l 分配给它标注过的物品 o_α 的资源值为 $f_{il}^{(II)}/k_l$ 。通过累计物品获得的资源值，最终物品 o_β 的资源值为：

$$f_{i\alpha}^{(II)} = \sum_{l=1}^r \frac{a_{\alpha l}^{ot} f_{il}^{(II)}}{k_l}, \quad (5-5)$$

其中， $k_l = \sum_{\alpha=1}^n a_{\alpha l}^{ot}$ 表示被标签 t_l 标记的物品数目。

因用户与用户之间的差异，对每个用户来说，物品得分的计算结果都与其他用户不一样，这就是所谓的个性化推荐。当用户的物品得分列表计算完毕后，排除用户已经选择过的物品，将剩余物品按得分降序排列，并选择其中排名靠前的 L 个物品组成一个推荐列表。

以上三种推荐方法中，算法（I）只考虑标签与物品间的联系，忽略用户与标签的联系；算法（II）只考虑“用户-标签”的权重，忽略“用户-物品”之间的权重；GM算法同时考虑到用户、物品和标签三者间的两两关系，不仅计算了用户和物品的度，同时也计算了用户和物品之间的相似度。

5.1.5 实验结果

图5-2展示了GM算法的排序准确性的结果。GM算法的 RS 值随着参数 θ 的增大， RS 值逐渐增高，并在两端出现两个稳态。在本实验中，GM算法中的参数 θ 取值0.001。实验结果是算法独立运行50次后取结果的平均值。




图 5-2 GM算法的 RS 值

为了更深刻理解GM算法的本质，本节将GM算法的公式(5-1)变形后改写为：

$$f_{i\alpha}^{GM} = (C_{i\alpha} \sqrt{m_i m_\alpha} + \theta \sqrt{m_i m_\alpha})^2 \quad (5-6)$$

表 5-2 GM算法伪代码

输入参数: $U, U.objects, U.tags$

// 用户集 U , 用户 U 选择的物品集, 用户 U 选择的标签集

输入参数: $O, O.users, O.tags$

// 物品集 O , 选择过物品 O 的用户集, 物品 O 的标签集合

输入参数: $T, T.users, T.objects$

// 标签集 T , 选择过标签 T 的物品集, 被标签 T 标注的物品集

输入参数: B^u, B^o

// 用户对标签的使用次数, 物品对标注的次数

输出参数: $Recommender.i$

// 用户推荐列表

1: for all $i \in U$	// 遍历用户, 选择目标用户 i
2: for all $l \in i.tags$	// 遍历用户 i 的标签 l
3: if ($b_{il}^u > 0$)	// b_{il}^u 表示用户 i 使用标签 l 的次数, 是矩阵 B^u 中元素
4: $m_i \leftarrow m_i + b_{il}^u$	// 根据用户使用标签情况计算用户 i 的质量
5: for all $\alpha \in O$	// 遍历物品, 选择目标物品 α
6: for all $l \in \alpha.tags$	// 遍历物品 α 的标签
7: if ($b_{\alpha l}^o > 0$)	// $b_{\alpha l}^o$ 表示物品 α 被标签 l 标注的次数, 是矩阵 B^o 中元素
8: $m_\alpha \leftarrow m_\alpha + b_{\alpha l}^o$	// 根据物品被标注的情况计算物品 α 的质量 m_α
9: for all $i \in U$	// 遍历用户, 选择目标用户 i
10: for all $\alpha \in O$	// 遍历物品, 选择目标物品 α
11: for all $l \in \alpha.tags$	// 遍历标签, 选择目标标签 l
12: if ($(b_{il}^u > 0) \&\& (b_{\alpha l}^o > 0)$)	// 判断用户 i 和物品 α 是否都有标签 l
13: $C_{i\alpha} \leftarrow C_{i\alpha} + 1$	// 计算用户 i 和物品 α 共同的标签数 $C_{i\alpha}$
14: $f_{i\alpha} = m_i m_\alpha (C_{i\alpha} + \theta)^2$	// 根据公式 5-5 计算用户 i 对物品 α 的预测得分 $f_{i\alpha}$
15: if $\alpha \in i.objects$	// 排除用户 i 已经选择过的物品
16: continue	
17: $List.i \leftarrow List.i + \alpha$	// $List.i$ 表示目标用户 i 所有未选择的物品集合
18: sort($List.i$) by descending	// 对物品按 f 值降序排列
19: $Recommender.i \leftarrow \text{top-L of } List.i$	// 针对目标用户 i 的长度为 L 的推荐列表

注意到, 当数据集确定时, $C_{i\alpha}$, m_i 和 m_α 都是确定的。对公式(5-6)而言存在以下几种情况:

(1) 当 $\theta \gg C_{i\alpha}$ (且存在有限值) 时, $f_{i\alpha}^{GM}$ 的值完全由 $\sqrt{m_i m_\alpha}$ 决定。在推荐算法中, m_i 不变, GM算法倾向于推荐流行商品, 此时退化为全局算法 (GR) [174];

(2) 当 $\theta \rightarrow \infty$ 时, $f_{i\alpha}^{GM} \rightarrow \infty$ 。所有的物品的得分都一样, 系统的推荐物品将随机挑选, 此时GM算法将退化为随机算法;

(3) 当 $\theta \rightarrow 0$ 时, $f_{i\alpha}^{GM}$ 为 $C_{i\alpha}$ 和 $\sqrt{m_i m_\alpha}$ 的混合形式。此时, $f_{i\alpha}^{GM}$ 值由 $C_{i\alpha}$ 和 $\sqrt{m_\alpha}$ 共同决定。

表5-3给出GM算法、单纯使用 m_o 和 C_{uo} 计算物品得分的GM 算法和基于物质扩散的标签算法 (I-II) 的AUC值。其中, GM算法中的参数取值 $\theta = 0.001$, m_o 表示使用GM算法中的物品质量计算用户和物品相似度, 定义如下:

$$f_{i\alpha}^{m_o} = m_\alpha. \quad (5-7)$$

C_{uo} 表示使用GM算法中的共同标签数计算用户和物品相似度。计算用户 u_i 对物品 o_α 的相似度为:

$$f_{i\alpha}^{C_{uo}} = C_{i\alpha}. \quad (5-8)$$

实验结果显示, 单独使用 m_o 时AUC值较低, 而使用 C_{uo} 则比使用 m_o 时效果更好。在MovieLens₁数据集上, 同时考虑 m_o 和 C_{uo} 后的GM算法是五种算法里面AUC值最高的。

表 5-3 AUC值统计表

Data	I	II	m_o	C_{uo}	GM
Delicious	0.791	0.804	0.612	0.744	0.797
MovieLens ₁	0.870	0.877	0.706	0.882	0.889

图5-3展示了准确率 (P) 和内相似度 (I) 与推荐链表长度 L 的相关性, 参数 $\alpha = 0.001$, 实验结果取50次独立运行后的平均值。实验结果显示, 在MovieLens₁数据集和Delicious数据集上, 参数 $\alpha = 0.001$ 时, 在准确率指标上, 基于引力模型的推荐算法高于其余两个算法, 尤其是当推荐列表长度较小时。事实上, 现实生活中由于界面限制, 推荐列表长度往往有限。因此, 相比起算法 (I) 和 (II), GM算法更有实际应用价值。在算法的时间复杂度上, GM算法有明显的优势。当有新物品加入时, 可以通过单独的运算得到得分值, 从而快速加入推荐系统的计算中。由于引力模型推荐算法可以事先将算法中的数据计算出来, 对于现在网络

上的实时推荐非常有优势。现在的网络更新速度大幅提高，新商品加入频繁，引力模型推荐算法能对其单独计算推荐权值，使其快速进入推荐系统。




图 5-3 准确率 P 和内相似度 I 与推荐链表长度 L 的相关性

此外，针对推荐系统的冷启动问题，常用的解决方案是多维度获取用户数据，包括用户特征、用户行为、用户兴趣等。标签推荐系统在这方面有天然优势，标签反映的是用户和物品两个维度上的特征。我们在MovieLens₂数据集上对本算法进行了实验，将用户分类成度小用户和度大用户，并分别计算两类用户的 RS 值。 $\langle RS \rangle$ 表示所有用户平均 RS 值， $\langle RS \rangle_{k_u < 10}$ 表示度小于10用户的平均 RS 值， $\langle RS \rangle_{k_u > 10}$ 表示度大于10用户的平均 RS 值。算法 I 的整体 RS 值最低，但 $k_u < 10$ 时， m_o 算法的准确性最好。但是 m_o 算法过无差别推荐流行物品提高算法准确性，而越流行的物品越有可能用户已经无需推荐，GM算法的 $\langle RS \rangle_{k_u < 10}$ 值只稍微高于 m_o 算法。因此对冷启动问题，GM算法优于算法 I 和 II 。

对GM算法进行分析，从用户层面上看，标签反映了用户的兴趣和用户对物品的分类和认知。从物品层面上看，标签反映了物品的特征和在用户眼中的分类。标签推荐系统在面对新用户时，能更多更快地了解到新用户的兴趣，同时对新加入的物品的特征掌握的更全面，从而更准确地预测用户潜在感兴趣的物品，

表 5-4 RS 值统计表

	I	II	m_o	C_{uo}	GM
$\langle RS \rangle$	0.2512	0.3265	0.3294	0.3287	0.3294
$\langle RS \rangle_{k_u < 10}$	0.3252	0.3456	0.2951	0.3457	0.2952
$\langle RS \rangle_{k_u > 10}$	0.2357	0.3224	0.3365	0.3251	0.3365

同时标签也扩大了用户可选的物品范围，对提高推荐多样性有积极意义。

5.2 对推荐算法的辅助研究

本实验针对推荐系统所面临的冷启动问题进行研究，充分利用标签信息作为解决冷启动问题的突破口，并提出了基于引力模型的GM推荐算法。与另外两种基于物质扩散的标签推荐算法相比，GM算法在MovieLens₁数据集上的全局准确性值是所有算法中的最优值，并且在基于推荐列表长度的准确率和多样性上，也有不错的表现。GM算法在Delicious数据集上，全局准确性稍弱于基于物质扩散的标签推荐算法，但是在基于推荐列表长度的准确率和多样性上，优势比较明显。

虽然GM推荐算法的效果比较好，目前算法也存在两个问题：一个问题是算法并没有真正解决冷启动的问题。当一个新用户进入系统，GM算法也需要获取所选物品和标签信息才能更准确地对用户进行推荐，获取的用户的物品和标签信息越多，对用户的偏好的掌握越深刻。在视频网站上，标签信息作为语义信息，使得用户对物品的理解更直观和简单。相比起非标签系统，用户能更快速地对物品进行理解并选择，从而使系统更快掌握用户的偏好。第二个问题是对推荐算法的研究还停留在应用层面。通过增加辅助信息，提高推荐算法的性能。只有对推荐系统有更深刻的理解，才能帮助进一步改进推荐算法。

在网络演化方向上看，标签推荐系统的本质是“用户-物品”网络向着推荐系统的预期方向演化。影响“用户-物品”网络演化的因素有很多。第三章在“用户-物品”二部图上是用户的属性（个人属性、偏好等）和物品的属性（内容、形式等）；在第四章提到的信任增强网络推荐系统中，除了用户和物品的属性，还有用户与用户的信任关系，信任关系扩大了用户可能的连边范围以及连边概率；在本章的标签推荐系统中，除了用户和物品的属性，标签从网络结构上将“用户-物品”二部图改变为“用户-标签-物品”三部图，如图5-4所示。图5-4(a-c)分别是二部图推荐系统（第三章），信任增强推荐系统（第四章）和标签推荐系统（第五章）的网络结构示意图。

图5-4(a)中是基于节点相似性的推荐算法示意图，对目标用户（左边第一个人像）而言，只能被推荐《红海行动》（右边第三个物品）。当引入了信任关系后，见图5-4(b)，目标用户通过受信任的用户（左边第二个人像）扩大了可推荐的范围，《肖生克的救赎》（右边第二个物品）也能以一定概率推荐给目标用户。当推荐系统中引入标签信息后，见图5-4(c)，用户之间的相似性或者物品之间的相似性，不需要通过用户的历史记录计算。通过标签可以计算用户与物品的相似度，只要他们之间有共同的标签信息。从结构上，标签推荐系统改变了传统推荐系统




图 5-4 推荐系统示意图

的网络结构。从应用层面上，将标签作为辅助信息是合理有效的。并且，标签作为可读性极强的元数据信息，相比起信息内敛的物品（如电影），更容易让用户理解和接受。为了进一步理解基于引力模型的推荐算法，本节将从网络演化方向研究引力模型下用户网络的演化。

5.2.1 标签推荐系统的网络演化

5.2.1.1 基于引力机制的网络演化模型

在研究网络演化时，保留基于引力模型的推荐算法的特征。网络中的所有用户定义为节点，将标签定义为节点的属性，网络中用户节点具有 N 维属性，记为 $V_i = \{v_{i1}, \dots, v_{it}, \dots, v_{iN}\}$ 。使用引力模型（Gravity Model，简称GM）^[199]进行网络重构时，用 $m_i = \sum_t v_{it}$ 表示节点的质量。节点 i 和 j 的连边概率 $p_{ij} \propto m_i m_j$ 。根据公式(5-9)计算任意两个节点之间存在路径的概率。

$$f_{ij} = \frac{m_i m_j}{d^2}, \quad (5-9)$$

m_i 和 m_j 表示节点 i 和 j 的质量， $d = \frac{1}{C_{ij} + \theta}$ 表示两者之间的连边概率。其中 $C_{ij} = \sum c_{ij}^t$ 是节点 i 和 j 的共同属性，当 $v_{it} v_{jt} \neq 0$ 时， $c_{ij}^t = 1$ ，否则 $c_{ij}^t = 0$ 。其中， θ 是可调节参数。

5.2.1.2 数据和评价指标

将使用引力模型重构的网络，与真实的网络进行对比。首先，构建静态网络（Static Network，简称ST）网络，作为与真实网络最接近的参考网络。ST网络构建为单模网络，将推荐系统中的用户视为节点，对有共同物品选择的用户之间进行连边。用户使用过的标签作为属性向量。将推荐系统中所有使用的标签编号，按照每个用户使用标签的频次进行生产属性向量。本实验中使用开源带属性标

注的网络数据: MovieLens₁。详细数据介绍在第5.1.2节中。经此处理,得到一个静态ST网络,包含有648个节点和20952条连边,并且每个节点都包含一个1382维的属性向量。作为对比,另外选择了连边机制最为接近的ER(Erdős-Rényi)模型^[206]和BA(Barabási-Albert)模型^[172]与GM模型^[199]进行比较,观察网络生成的过程。ER模型是在1959年有两位著名数学家Paul Erdős和Rényi提出并以他们名字命名的随机网络模型。BA模型根据Barabási和Albert在1998年分析万维网的无标度属性得到的无标度网络模型。ER、BA和GM网络都以ST网络结构为基础,包含648个节点。当网络中连边数到达20952条时停止构建网络。不同的网络构建规则如下:

(a) ER模型。随机选择网络中任意两个未连边的节点进行连边。

(b) BA模型。全部初始节点的度设置为1。在建模过程中,以概率 $\frac{k_i}{\sum k_i}$ 选择任意两个未连边的节点进行连边。

(c) GM模型。任意两个未连边的节点的连边概率参考公式(5-9)。

为了定量评价GM网络,本节选用了5个经典的网络评价指标刻画网络的结构属性,分别为:

(1) 最大连通子图(N_c)^[173]。无向图网络中最大连通子图表示任意两点存在连接路径的最大的网络结构,并且结果不唯一,用于表述网络中节点的连通程度。

(2) 簇系数(c)^[207]。簇系数解释为网络中全连通三元组的数目占三元组数目的比例。衡量网络节点聚类的情况。

(3) 同配性(r)^[208]。同配性衡量属性接近的节点之间连接的概率,既大度节点倾向于连接大度节点,小度节点倾向于连接小度节点。

(4) 网络平均距离(d)^[209]。用于描述网络中节点的分离程度。定义两点之间的距离从一个节点到另一个节点所经过最少的节点的连边数,网络平均距离是所有节点之间的距离的平均值。

(5) 异质性(h)^[171]。异质性衡量网络中节点的连边的均衡性。例如无标度网络中各节点的连接情况具有严重的不均匀性分布。

5.2.1.3 网络特征

表5-5中列出了上述四种模型生成的网络属性。由于静态ST网络是从真实网络中提取出来,所以最接近真实网络。以ST网络为基准,对比其他模型的网络。在最大连通子图上,ER网络和GM网络的 N_c 值为633,与真实ST网络的 N_c 值641比较接近。在同配性指标(r)上,ER网络与ST网络相差巨大,BA网络与ST网络也存在较大差异。在簇系数指标 c 上,与ST网络最接近的也是GM网络。在网络平

表 5-5 网络拓扑指标统计表

	N_c	c	r	d	h
ER	633	0.094	0.006	1.898	1.009
BA	627	0.241	-0.042	1.988	1.570
GM	633	0.592	-0.453	1.913	2.201
ST	641	0.698	-0.302	2.021	2.390

均距离指标 (d) 上, 4个网络的 d 值都相差不大, BA网络与GM网络最为接近。另外在异质性 (h) 上, GM网络与ST网络最接近, 其他网络与ST网络相差较大。总的来说, GM网络是最接近真实世界演化的模型。

图5-5中, 展示了这五种指标的动态变化过程。GM模型综合考虑了节点自身属性 (标签属性) 和节点流行性 (选择相同物品的用户之间会有连边), 生成了更加紧密连接的网络 (N_c 值较大)。GM模型在连边过程中, 网络拓扑指标迅速接




图 5-5 网络演化趋势图

近ST网络,说明GM模型的网络特征不依赖于网络密度,在网络构建初期既表现出网络的特征。在连接了20%的连边后,GM网络中 N_c 接近ST网络,此时网络的簇系数 c 也有一个上升的趋势,平均距离 d 和异质性 h 都迅速降低接近ST网络,并且同配性 r 下降到低于ST网络。

ST网络中同配性 $r=-0.302$,说明网络中度大的节点倾向于与度小的节点连边。也就是说度,小度的用户和大度的用户会选择同一物品,但是在小度的用户之间,连边概率比较低。GM网络的 r 值下降,说明标签放大了这一特征,更能反映用户的偏好。异质性 h 的下降也说明了,GM网络构建之初通过度大的节点优先连边,从而对全网络进行连通,导致 N_c 增高,同时簇系数 c 上升,说明标签在网络构建中起到“物以类聚,人以群分”的作用。总体上,用户在选择物品上,选择过较少物品的用户倾向于选择和选择过很多物品的用户一样的物品,同时选择物品较少的用户之间各有各的偏好。这对推荐算法有很大的启发意义。通常流行的物品被认为是受欢迎的。向用户推荐流行的物品,用户有很有可能会喜欢。但推荐“流行”的物品使得用户的推荐列表的多样性受限,推荐较“冷门”的物品考验推荐算法的准确性。因此充分利用标签信息,对用户的偏好有更深刻的理解,对推荐算法是一个可行的改进方向。

5.2.2 信息传播动力学研究

标签信息反映的是用户对物品的分类、认知以及兴趣偏好等内容。本章提出的基于引力模型的推荐算法利用标签信息计算用户与物品之间的相似性进行推荐。为了更好研究基于引力模型的推荐算法,第5.2.1节从网络演化的角度对引力模型进行了深入研究。实验结果表明,引力模型塑造的网络非常接近真实的网络。同时也发现了有趣的现象,小众用户在物品的选择上更遵从自己的偏好。由于小众用户对物品的选择更少,给推荐带来很大的难度。标签推荐系统的优势是在用户历史行为数据较少时,标签可以作为额外的辅助信息,既可以描述用户的属性和特征,又可以描述物品的属性和特征,对计算用户的偏好上有非常大的辅助作用。

由于标签是用户自发产生的轻量数据,用户之间的差异导致对标签的创造和选择上差别巨大,过多的自定义标签给用户偏好信息采集带来了噪声,反而降低了推荐系统内容检索的能力。因此,由推荐系统对物品提供一部分规范化标签,降低信息提取过程中的噪声,对于计算用户偏好有重要意义。考虑到标签作为一种信息,当用户使用现有标签作为物品描述时,对标签的使用相当于对标签信息的接收。因此这是一个信息传播过程^[195]。本节也对信息传播进行了相应研究。

5.2.2.1 问题提出

推荐系统是为人们提供服务的系统。对人提供服务的过程，可以描述为一个信息传播过程。例如在今日头条上，系统预测出用户的偏好后，给用户推荐最新的新闻资讯。用户面临着两种选择，对此感兴趣的选择点击浏览，不感兴趣的忽略这条内容。当用户在别的渠道再次获知相同的内容时，未浏览但对此有一定兴趣用户很有可能查看。信息被用户接受是存在一定概率的，这个概率和用户的兴趣偏好有关，也和社会强化有关。在传播的过程中，多次出现的信息对用户的选择会造成一定影响，尤其是新产品新内容等。这种现象在标签系统中非常常见，如用户对电影《红海行动》进行标注，常用的标签如“爱国”、“战争”等，也有一些用户另辟蹊径选择用“杜江”描述这部电影。在对标签的接受采纳的过程中，多次关联到的标签如“杜江”、“林超贤”等，会让用户对此信息反复确认，增加被用户采纳的概率。这种类型的标签被使用的次数取决于用户的偏好，也取决于这种标签出现在用户眼中的次数。新信息、新技术、新产品从出现到被接受是一个动态传播的过程。

传播是一个热门的研究领域，目前已有很多的研究成果^[210-212]。在传播中，社会强化是一种固有的“特征”。Centola^[213]针对在线网络中的强化行为做了研究，发现个人接收到多个信号后更容易做出反馈。关于社会强化的研究还有很多，诞生出很多成功的模型用来表述复杂网络中的社会强化效应，这其中Watts阈值模型（以下简称Watts模型）是最有名的^[214]。在Watts模型中，假定每个节点都有活动和不活动两种状态。只有当其中一个不活跃的节点的邻居们的数量大于一个给定的阈值时，这个不活跃的节点才会变成活跃节点。最终活跃的节点占比持续不断地增加然后后再非连续性地减少。最近，一些非马尔科夫链的传播研究成为热点^[215-217]。研究表明，最终的转变率与信息扩散概率可以展示为连续或者不连续的增长模式，并且可以被结构参数和动力学改变^[215]。

许多研究发现，网络结构可以显著的影响复杂网络上的传播^[210, 218, 219]。从宏观的角度看，异质性可以改变相变的类型^[215, 220, 221]。异质性越强，信息越难以传播。并且，社区结构，集群系数和度相关性等都会影响最终的采纳规模和相变^[222-224]。事实上，人的活动范围和环境并不是单一的，对信息的接收也不总是来自同一个环境。因此很多科学家对多层网络上的传播^[216, 225-228]进行了研究。研究表明，根据Watts模型，每一层都在传播过程中有不同的作用^[225]。假设每个受影响的节点都是由其每一层的累积接收信息决定的，并且发现一旦增加了一个层的采用率，就会改变增长模式。Wang等人^[216]在分层网络上提出了一种非马尔科夫的扩展阈值模型。他们假定每个受影响的节点都是由其每一层的累积接收

信息决定的, 并且发现一旦增加了一个层的采用率, 就会改变增长模式。之前的研究认为社会强化作用来自于邻居, 然而邻居在传播过程中只提供有限的信息传播可能性。实际上, 用户不仅仅活跃在某一个社交网络, 对信息的获取也不是来自某一个平台。社会强化作用不仅自于同一个社交圈里的邻居节点, 也来自于不同平台。为了确保信息传播的有效性和可靠性, 一个易受感染的节点应同时考虑来自不同层和邻居的强化。在本实验^[229]中, 选择双层网络考虑来自不同层和邻居的共同强化作用。

5.2.2.2 符号和数据

在介绍双层强化模型之前, 首先介绍算法中涉及到的符号和数据。每个节点代表个体, 用拉丁字母表示, 如 i 、 j 等。考虑到在实际生活中, 人有多个社交圈子, 也有多个信息获取渠道, 本实验中使用双层网络, 分别用 A 和 B 表示。许多在线社交网络都是无标度网络^[230]。本实验中, 选用两种类型的网络, 随机网络(ER)^[206]和无标度网络(BA)^[172]。随机网络, 又称随机图, 是指通过随机过程制造出的复杂网络。无标度网络, 是指度分布与网络规模无关的网络。设置网络中节点数为 $N = 10^4$ 。平均度 $\langle k_A \rangle = \langle k_B \rangle = 10$ 。ER网络服从泊松分布构造, 度分布为 $P(k) = e^{-\langle k \rangle} \frac{\langle k \rangle^k}{k!}$, BA网络服从幂律分布, 度分布为 $P(k) = \zeta k^{-\gamma_D}$, 其中 $\zeta = 1 / \sum_k k^{-\gamma_D}$, γ_D 是BA网络的度指数。

双层网络使用独立的度分布 $P_A(k_A)$ 和 $P_B(k_B)$ 构建, 联合度分布为 $P(\vec{k}) = P_A(k_A)P_B(k_B)$ 。节点 i 的度分布为 $\vec{k}_i = (k_i^A, k_i^B)$, k_i^A 和 k_i^B 分别表示节点 i 在 A 和 B 层的度分布。双层网络上每个个体节点的采纳阈值用 T_A 和 T_B 表示, 用于表示愿意继续扩散的概率。 T_A 和 T_B 越大, 表示社会强化效用越大。用 ρ_0 表示活跃态节点的种子数(信息源)。在传播过程中, 每条边在双层网络上的传播概率分别为 λ_A 和 λ_B 。用 m^X 表示当前在 $X \in \{A, B\}$ 层的节点的累计感染行为数, 每次传播成果后, 累计感染行为数+1。同时, 每个采纳态的节点的恢复概率为 γ 。具体符号信息见表格5-6。

实验模拟过程中, $\gamma_D = 3.0$ 。以下实验将对两种网络两两组合, 实验中生成30个网络, 且对每个结果, 取30个网络上共2000次平均值。实验设置信息扩散条件 $\lambda_A = \lambda_B$ 。

5.2.2.3 算法设计

本算法模型建立在一个双层网络上。信息在传播过程中, 接收了信息的人有可能会传播信息, 但不会向同一个用户传播多次。同时一个用户可能从多渠道获取信息, 被多个用户传播信息。为描述网络上的信息传播过程, 使用一种通用

表 5-6 主要符号说明

符号	说明
$P_A(k_A), P_B(k_B)$	网络A和B的度分布
$P(\vec{k}) = P_A(k_A)P_B(k_B)$	联合度分布
k_i^A, k_i^B	网络中节点 <i>i</i> 在A层和B层的度分布
$\vec{k}_i = (k_i^A, k_i^B)$	网络中节点 <i>i</i> 的联合度分布
T_A, T_B	A层和B层网络的采纳阈值
ρ_0	初始种子数
m^A, m^B	A层和B层网络的累计感染数
γ	节点恢复概率
λ_A, λ_B	A层和B层网络上边的传播概率
γ_D^A, γ_D^B	A层和B层网络度指数

的“易感态-采纳态-恢复态”(Susceptible-Adopted-Recovered, SAR)模型,模型中个体采纳某种行为的概率取决于它收到不同邻居节点传递给它的信息次数。此模型中个体有三种状态,易感态(S),采纳态(A)和恢复态(R)。处于易感态的个体表示没有受到信息传播的影响。处于采纳态的个体表明已经受到信息传播的影响,并且将会把行为信息传递给邻居。处于恢复态的个体则表示已经对信息传播失去兴趣,且不再参与后续的传播行为。

最初,随机选择 ρ_0 个活跃态节点作为种子(采用态),剩下的非活跃态节点处于易感态。在每一时间步,每个活跃态节点*i*分别以概率 λ_A 和 λ_B 在A和B层将行为传播给它的非活跃态邻居节点*j*。一旦扩散成功,在 $X \in \{A, B\}$ 层的节点*j*接收到的累积感染行为 m_j^X 将增加1, $m_j^X \leftarrow m_j^X + 1$ 。将 m_j^X 与 T_X 进行比较,如果 $m_j^A \geq T_A$ 并且 $m_j^B \geq T_B$,那么节点*j*将被感染。最终,每个采纳态节点以概率 γ 变成恢复态节点。不失普遍性, γ 被设置为 $\gamma = 1.0$ 。当网络中没有采纳态节点时,信息传播停止。

具体过程见图5-6。红色线表示一段信息通过。在双层AB网络上,节点2被选择为种子节点。(a)在时间步 $t = 1$ 时刻,节点2首先在A层以概率 $\lambda_A = 0.5$ 将信息传递给节点3和5,之后恢复的概率为 $\gamma = 0.6$ 。(b)在时间步 $t = 2$ 时刻,节点2在B层以概率 $\lambda_B = 0.5$ 将信息传递给节点3,并以概率 $\gamma = 0.5$ 恢复。此时节点在A层和B层采纳阈值分别是 $T_A = 1$ 和 $T_B = 1$,所以节点3成功地接收了信息,转变为采纳态。(c)在时间步 $t = 3$ 时刻,节点3没有传递信息给其他节点。(d)在时

间步 $t = 4$ 时刻，网络中没有处于采纳态的节点，信息传播终止。表5-7中展示了本实验算法的伪代码，for循环的时间复杂度计算为 $O(n(nn + nn))$ ，整个算法的时间复杂度为 $O(n^3)$ （其中 n 为单层网络节点数，A层B层网络规模一致）。




图 5-6 双层网络传播示意图

以上的传播过程中，模型特点如下：

(1) 传播中的动力学是一个非马尔可夫的过程，因为一个易受感染的节点后续的状态变化依赖于它积累的行为信息。

(2) 社会强化存在于不同的层面，因为我们可以从每一层中的邻居获得感染可能。

本实验中使用5.2.2.3节中的理论来求解上述复杂网络上的社会传播动力学模型。定义 $\theta_X(t) (X \in \{A, B\})$ 为在 t 时刻的 X 层，随机选择一条边没有传递消息给邻居的概率。对一个度为 $\vec{k}_i = (k_i^A, k_i^B)$ 的节点 i ，在 t 时刻接收到来自 A 和 B 层 m_A 和 m_B 条信息的概率分别为

$$\phi_{m_A}^A(k_A, t) = \binom{k_A}{m_A} \theta_A(t)^{k_A - m_A} (1 - \theta_A)^{m_A}, \quad (5-10)$$

和

$$\phi_{m_B}^B(k_B, t) = \binom{k_B}{m_B} \theta_B(t)^{k_B - m_B} (1 - \theta_B)^{m_B}. \quad (5-11)$$

表 5-7 算法伪代码

输入参数: $A, B, S.neighbor$	// A 层节点, B 层节点, 以及节点的邻居
输入参数: $\rho_0, \lambda, \gamma, T$	// 种子数, 信息传播概率, 节点恢复概率, 采纳阈值
输出参数: p_A, p_B	// A 层恢复态节点占比, B 层恢复态节点占比
1: $Q_{1A} \leftarrow \rho$	// 种子节点加入感染队列 Q_{1A} , Q_{1A} 中存放 A 层受感染节点
2: $Q_{1B} \leftarrow \rho$	// 种子节点加入感染队列 Q_{1B} , Q_{1B} 中存放 B 层受感染节点
3: while $Q_{1A} \neq 0 \ \&\& \ Q_{1B} \neq 0$	// 判断双层网络上是否有感染节点
4: for all $i \in Q_{1A}$	// 遍历 A 层感染节点, 选择目标节点 i
5: for all $j \in i^A.neighbor$	// 感染节点 i 向 A 层邻居 j 传播信息
6: if j get information by ratio λ^A	// A 层节点 j 成功接收信息, 概率为 λ^A
7: $m_j^A \leftarrow m_j^A + 1$	// 节点 j 接收信息, A 层节点 j 累计感染数增加
8: if $m_j^A > T^A \ \&\& \ m_j^B > T^B$	// 同时比较 A 和 B 层的节点 j 的传播阈值和累积感染数的大小, 判断是否成为感染节点
9: $Q_{2A} \leftarrow j$	// 节点 j 成为新的感染节点, 加入感染队列 Q_{2A}
10: $Q_{1A} \leftarrow Q_{1A} - i$	// 节点 i 完成信息传播, 脱离感染节点队列
11: $R_A \leftarrow R_A + i$	// 节点 i 成为恢复态节点, 并不再参与后续传播
12: $Q_{1A} \leftarrow Q_{1A} + Q_{2A}$	// 新感染的节点集 Q_{2A} 加入感染队列 Q_{1A}
13: for all $i \in Q_{1B}$	// 遍历 B 层感染节点
14: for all $j \in i^B.neighbor$	// 感染节点 i 向 B 层邻居 j 传播信息
15: if j get information by ratio λ^B	// B 层节点 j 成功接收信息, 概率为 λ^B
16: $m_j^B \leftarrow m_j^B + 1$	// 节点 j 接收信息, B 层节点 j 累计感染数增加
17: if $m_j^A > T^A \ \&\& \ m_j^B > T^B$	// 同时比较 A 和 B 层的节点 j 的传播阈值和累积感染数的大小, 判断是否成为感染节点
18: $Q_{2B} \leftarrow j$	// 节点 j 成为新的感染节点, 加入感染队列 Q_{2B}
19: $Q_{1B} \leftarrow Q_{1B} - i$	// 节点 i 完成信息传播, 脱离感染节点队列
20: $R_B \leftarrow R_B + i$	// 节点 i 成为恢复态节点, 并不再参与后续传播
21: $Q_{1B} \leftarrow Q_{1B} + Q_{2B}$	// 新感染的节点集 Q_{2B} 加入感染队列 Q_{1B}
22: $p_A \leftarrow R_A/A, p_B \leftarrow R_B/B$	// p_A 表示 A 层网络中恢复态节点占 A 层节点的比例

根据第5.2.2.3节中描述的传播机制, 当易感节点*i*接收到来自*A*和*B*层的累积计数分别为 m_A 和 m_B 条信息小于采纳阈值 T_A 和 T_B , 即 $m_A < T_A$ 或者 $m_B < T_B$, 那么节点*i*仍然保持易感态。此时概率为:

$$s(\vec{k}, t) = (1 - \rho_0) \left[1 - \left(1 - \sum_{m_A=0}^{T_A-1} \phi_{m_A}^A(k_A, t) \right) \left(1 - \sum_{m_B=0}^{T_B-1} \phi_{m_B}^B(k_B, t) \right) \right], \quad (5-12)$$

其中, $(1 - \rho_0)$ 是网络中没有发生状态变化的概率。

公式 $\sum_{m_X=0}^{T_X-1} \phi_{m_X}^X(k_X, t)$ 表示一个节点到*t*时刻接收到 m_X 条来自*X*层信息的概率。遍历所有的节点, 此时易感态节点的占比为:

$$S(t) = \sum_{\vec{k}} P(\vec{k}) s(\vec{k}, t) = (1 - \rho_0)(\eta_A + \eta_B - \eta_A \eta_B), \quad (5-13)$$

其中

$$\eta_A = \sum_{k_A} P_A(k_A) \sum_{m_A=0}^{T_A-1} \phi_{m_A}^A(k_A, t),$$

和

$$\eta_B = \sum_{k_B} P_B(k_B) \sum_{m_B=0}^{T_B-1} \phi_{m_B}^B(k_B, t)$$

分别表示度为 k_A 和 k_B 的节点到*t*时刻为止, 接收到来自*A*和*B*层的信息数少于 m_A 和 m_B 条。此时, 易感节点没有变为其他状态, $P(\vec{k}) = P_A(k_A)P_B(k_B)$ 。

信息传播结束的临界点定义为*A*或*B*层接收到的信息比采纳阈值低1个单位, 此时 $m_A = T_A - 1$ 或者 $m_B = T_B - 1$ 。随机选择一个节点是临界态的概率为

$$\Upsilon(t) = (1 - \rho_0) \sum_{k_A} \sum_{k_B} P_A(k_A) P_B(k_B) [\phi_{T_A-1}^A(k_A, t) + \phi_{T_B-1}^B(k_B, t)]. \quad (5-14)$$

根据 $\theta_X(t)$ 的定义, 一条边可以连向一个易感态、采纳态或恢复态邻居。此时

$$\theta_X(t) = \xi_S^X(t) + \xi_A^X(t) + \xi_R^X(t), \quad (5-15)$$

其中 $\xi_S^X(t)$, $\xi_A^X(t)$ 和 $\xi_R^X(t)$ 分别表示连向的节点在*t*时刻处易感态、采纳态和恢复态, 且这条边没有继续传播消息的概率。

来自*A*层的易感节点 j_A 此时只能接收邻居的信息扩散。节点*i*在空穴状态下不能传递信息给它的邻居。在*t*时刻, 节点*j*分别接收到来自*A*层和*B*层的 n_A 和 n_B 条信息, 概率分别是 $\phi_{n_A}^A(k'_A - 1, t)$ 和 $\phi_{n_B}^B(k'_B - 1, t)$, 节点*j*到*t*时刻任然处于易感态的概率分别为

$$\Theta_A(\vec{k}, t) = 1 - \left[1 - \sum_{n_A=0}^{T_A-1} \phi_{n_A}^A(k'_A - 1, t) \right] \left[1 - \sum_{n_B=0}^{T_B-1} \phi_{n_B}^B(k'_B - 1, t) \right], \quad (5-16)$$

和

$$\Theta_B(\vec{k}, t) = 1 - [1 - \sum_{n_A=0}^{T_A-1} \phi_{n_A}(k'_A, t)][1 - \sum_{n_B=0}^{T_B-1} \phi_{n_B}(k'_B - 1, t)]\Theta \quad (5-17)$$

考虑到多层网络的度分布 $P(\vec{k})$, X 层的一条边与易感态邻居连接的概率是

$$\xi_S^X(t) = (1 - \rho_0) \frac{\sum_{\vec{k}} k_X P(\vec{k}) \Theta_X(k_X, t)}{\langle k_X \rangle}, \quad (5-18)$$

其中, $k_X P(\vec{k}) / \langle k_X \rangle$ 表示连接到 X 层度为 k_X 的邻居。如果信息通过一条 X 层的边扩散概率为 λ_X , $\theta_X(t)$ 减少。此时,

$$\frac{d\theta_X}{dt} = -\lambda_X \xi_A^X. \quad (5-19)$$

根据5.2.2.3中模型描述, 如果一个采纳态节点在成为恢复态之前没有传递信息给邻居, 那么连接到易感态邻居的概率 $\theta_X(t)$ 增加。演化方程如下:

$$\frac{d\theta_X}{dt} = -\lambda_X \xi_A^X. \quad (5-20)$$

联立公式(5-18)和(5-20), 进一步得到

$$\xi_R^X(t) = \frac{\gamma[1 - \theta_X(t)](1 - \lambda)}{\lambda}. \quad (5-21)$$

因此, 各个状态个体的比例演化方程分别为

$$\frac{dA(t)}{dt} = -\frac{dS(t)}{dt} - \gamma A(t), \quad (5-22)$$

和

$$\frac{dR(t)}{dt} = \gamma A(t). \quad (5-23)$$

根据公式(5-13), (5-22)和(5-23), 可以得到双层网络上各个状态的节点随时间的演化情况。

当 $t \rightarrow \infty$, 时间趋于无限大时, 没有处于采纳态的节点。此时 $d\theta_X(t)/dt = 0$ 。公式(5-20)转变为

$$\theta_X(\infty) = (1 - \rho_0) \frac{\sum_{\vec{k}} k_X P(\vec{k}) \Theta_X(k_X, \infty)}{\langle k_X \rangle} + \frac{\gamma[1 - \theta_X(\infty)](1 - \lambda)}{\lambda} \Theta \quad (5-24)$$

在临界态, 满足条件

$$\frac{\partial f_A(\theta_A(\infty), \theta_B(\infty))}{\partial \theta_B(\infty)} \frac{\partial f_B(\theta_A(\infty), \theta_B(\infty))}{\partial \theta_A(\infty)} = 1, \quad (5-25)$$

其中 $f_X(\theta_A(\infty), \theta_B(\infty))$ 是公式(5-24)的右边。

接下来讨论一个简单的情况 $T_A = T_B = 1$ 。在这总情况下，公式(5-16)和(5-17)分别变成了

$$\Theta_A(\vec{k}, t) = \theta_A(\infty)^{k'_A-1} + \theta_B(\infty)^{k'_B} - \theta_A(\infty)^{k'_A-1} \theta_B(\infty)^{k'_B}, \quad (5-26)$$

和

$$\Theta_B(\vec{k}, t) = \theta_A(\infty)^{k'_A} + \theta_B(\infty)^{k'_B-1} - \theta_A(\infty)^{k'_A} \theta_B(\infty)^{k'_B-1} \Theta \quad (5-27)$$

插入公式(5-24)，分别得到

$$\begin{aligned} \theta_A(\infty) = & (1 - \rho_0)[G_A^1(\theta_A(\infty)) + G_B^0(\theta_B(\infty)) - G_{AB}^{1,0}(\theta_A(\infty), \theta_B(\infty))] \\ & + \frac{\gamma[1 - \theta_A(\infty)](1 - \lambda)}{\lambda}, \end{aligned} \quad (5-28)$$

和

$$\begin{aligned} \theta_B(\infty) = & (1 - \rho_0)[G_A^0(\theta_A(\infty)) + G_B^1(\theta_B(\infty)) - G_{AB}^{0,1}(\theta_A(\infty), \theta_B(\infty))] \\ & + \frac{\gamma[1 - \theta_B(\infty)](1 - \lambda)}{\lambda}, \end{aligned} \quad (5-29)$$

其中 $G_A^0(x) = \sum_{k_A} P_A(k_A) x^{k_A}$ 是度分布 $P_A(k_A)$ 的生成函数， $G_A^1(x) = \frac{\sum_{k_A} k_A P_A(k_A) x^{k_A-1}}{\langle k_A \rangle}$ 是它的余度分布的生成函数。 $G_B^0(x) = \sum_{k_B} P_B(k_B) x^{k_B}$ 是度分布 $P_B(k_B)$ 的生成函数， $G_B^1(x) = \frac{\sum_{k_B} k_B P_B(k_B) x^{k_B-1}}{\langle k_B \rangle}$ 是它的余度分布的生成函数。 $G_{AB}^{1,0}(x, y) = \frac{1}{G'_{A0}(1)} \frac{\partial G_{AB}^{0,0}(x, y)}{\partial x}$ ， $G_{AB}^{0,1}(x, y) = \frac{1}{G'_{B0}(1)} \frac{\partial G_{AB}^{0,0}(x, y)}{\partial y}$ 和 $G_{AB}^{0,0}(x, y) = \sum_{k_A, k_B} P_A(k_A) P_B(k_B) x^{k_A} y^{k_B}$ 是 $P(\vec{k})$ 的生成函数。将公式(5-28)和(5-29)插入公式(5-25)，得到临界条件。

5.2.2.4 实验结果

实验过程使用双层ER网络，每层网络采用泊松分布构造， A 和 B 层的度分布分别为 $P_A(k_A) = e^{-\langle k_A \rangle} \frac{\langle k_A \rangle^{k_A}}{k_A!}$ 和 $P_B(k_B) = e^{-\langle k_B \rangle} \frac{\langle k_B \rangle^{k_B}}{k_B!}$ 。平均度 $\langle k_A \rangle = \langle k_B \rangle = 10$ ， A 和 B 层的网络规模 $N = 10^4$ 。 A 层网络上的采纳阈值设置为 $T_A = 1$ ，此时观察对 T_B 的影响，见图5-7。以下图中点状线条表示实际结果，线状表示理论结果。

在图5-7(a)中发现， T_B 越大，最终的采纳规模 $R(\infty)$ 越小。此时 T_B 越大意味着 B 层中的易感个体需要接收更多的信息完成采纳态转变。并且， T_B 值越大对最终恢复态个体的规模 $R(\infty)$ 影响越明显。理论预测（图5-7(a)中的实线）和实证模拟（图5-7(a)中的点状线条）的结果一致。在图5-7(c)中通过研究临界状态 $\Upsilon(\infty)$ 可以更清晰理解这样的增长模式。当 $T_B = 1$ 时， $\Upsilon(\infty)$ 随着 λ 减少而降低。当 $T_B = 2$ 和3时， $\Upsilon(\infty)$ 迅速下降。非连续的下降临界点可以通过波动方差^[231]来确定

$$\chi = \frac{\langle R(\infty) - \langle R(\infty) \rangle \rangle^2}{\langle R(\infty) \rangle^2}, \quad (5-30)$$




图 5-7 双层ER网络恢复态节点占比与传播概率的关系

其中, $\langle \dots \rangle$ 表示平均值。在图5-7(b)中所示, χ 出现了一个最大值。

接下来, 进一步研究了初始种子比例和信息传播概率对传播的影响, 见图5-8。在图5-8中发现 $R(\infty)$ 随着 ρ_0 规模增加而增长。在图5-8(a)中观察到, 对采纳阈值 $T_B = 1$ 的情况, 在信息传播概率 λ 很小的情况下, 初始种子比例 ρ_0 越高, 传播的范围越广, 并且当信息传递概率大于临界值时, 无论初始种子比例多小, 都会导致全局感染的发生。但是在图5-8(b)中发现, 对采纳阈值 $T_B = 3$ 的情况, 当初始种子比例 ρ_0 始终小于临界值 ρ_0^* , 在任何信息传递概率的情况下都不会触发全局感染。只有当 $\rho_0 \geq \rho_0^*$ 时, 才会发生全局感染。

我们进一步研究ER-BA网络和BA-BA网络上平均度为 $\langle k_A \rangle = \langle k_B \rangle = 10$ 的扩散现象, 见图5-9。在ER-BA网络上的A层是一个ER随机网络, 度分布服从泊松分布 $P_A(k_A) = e^{-\langle k_A \rangle} \frac{\langle k_A \rangle^{k_A}}{k_A!}$, B层是一个BA无标度网络, 度分布服从幂律分布 $P_B(k_B) = \zeta_B k_B^{-\gamma_D^B}$, 其中 $\zeta_B = 1 / \sum_k k_B^{-\gamma_D^B}$, γ_D^B 是B层的度指数。实验模拟过程中, $\gamma_D^B = 3.0$ 。图5-9(a)中显示, $R(\infty)$ 随着 T_B 的减少而减少。更重要的是, $R(\infty)$ 随着 λ 快速增长, 当 T_B 取值偏大的时候。此时, 模拟数据和理论一致。图5-9(b)中显示ER-BA网络的扩散。层A和B的度分布分别是 $P_A(k_A) = \zeta_A k_A^{-\gamma_D^A}$ 和 $P_B(k_B) = \zeta_B k_B^{-\gamma_D^B}$, 其中 $\zeta_A = 1 / \sum_k k_A^{-\gamma_D^A}$, $\zeta_B = 1 / \sum_k k_B^{-\gamma_D^B}$, γ_D^A 和 γ_D^B 分别表示A和B层的度指数。图5-9(b)中注意到 $R(\infty)$ 在大数值 T_B 条件下增长更快。我们的理论与数值模




图 5-8 双层ER网络初始种子比例与信息传播概率对传播的影响

拟一致。

在图5-10中，我们继续研究了ER-BA网络和BA-BA网络上种子大小对扩散的影响。在 $T_A = T_B = 1$ 条件下，图5-10(a)中，ER-BA网络上种子取任何值都会引发全局扩散。但是，当 $T_B = 3$ 的时候，存在一个临界 ρ_0^* 值，低于这个值就不会发生全局扩散（图5-10(c)）。同样在BA-BA双层网络，不管种子取值如何，当 $T_B = 1$ ，都很有可能变成全局感染（图5-10(b)）。但是当 $T_B = 3$ 的时候，如图5-10(d)，控制种子大小在 ρ_0^* 以下，任何信息传播概率都不会触发全局感染。




图 5-9 双层ER-BA和BA-BA网络恢复态节点占比与传播概率的关系

本实验研究双层网络上的信息传播规律，提出了一种非马尔可夫的复杂传染模型，并进行了广义的推广。分别在ER-ER网络、ER-BA网络和BA-BA网络上进

行了大量的模拟实验。从这三个网络的研究中发现，信息最终被采纳的比例与信息传播概率的关系。传播概率越高，最终接受信息的人越多。此外，最终采纳人数占比还与种子规模（信息源）有关。种子规模存在一个临界值，当采纳阈值较高而种子规模在临界值以下时，信息在传播过程中无法到达全局。采纳阈值越小，则无论初始种子规模多大都会导致信息全局接收。




图 5-10 双层ER-BA网络和BA-BA网络初始种子规模与传播概率的关系

以上研究信息传播的规律，是希望对标签推荐系统中由于标签信息驳杂导致的推荐不准确的问题有所帮助。从实验结果看，想要一个标签尽可能为大众所知并使用，最好的办法是增加标签的初始使用人数。同时，采纳阈值较高时，信息传播过程中，需要更多的强化才能使信息扩散到全局。因此，当信息在多平台、多用户间传播时，用户对此的接收能力更强。

还有一个有趣的现象，信息传播与传播概率有关。在推荐系统中，有一类推荐系统在此方面非常有优势，就是第四章提到的信任增强推荐系统。研究表明用户更加信赖来自朋友的推荐^[60]。充分利用信任关系对用户的影响力，以及标签在描述用户需求 and 偏好上的优势，并且对自发性的标签给与一定的引导，对解决推荐系统面临的困境有很大的借鉴意义。

5.3 本章小结

本章在第5.1节针对大部分推荐系统都面临的冷启动问题进行了研究，从标签系统着手，通过分析用户的标签，在用户的历史行为数据缺少的情况下，对用户的偏好有进一步的了解。首先分析标签系统的特征后发现：用户与物品之间存

在拓扑关系；用户属性包含标签偏好属性和物品偏好属性，物品的特征信息包括选择该物品的用户列表和被标注的标签列表；用户对物品除了直接关联，还通过共同的标签包含隐式的关联。基于这些特性，提出了基于引力模型（GM）的推荐算法，并与另外两个在物质扩散框架下的基于标签的推荐算法比较。实验结果证明，GM推荐算法在全局准确性上表现较好，尤其是当推荐列表长度较小时，GM算法能提供一个推荐准确且物品种类丰富的推荐列表。

本章第5.2节分析GM推荐算法在标签推荐系统中的不足。第一个不足是并没有完全解决冷启动的问题。对于无任何记录的用户，GM推荐算法也无法根据用户需求进行推荐，但是标签信息可以加快系统对用户需求的掌握。第二个不足是对标签系统的进行了应用层面的研究。没有深入分析标签系统的网络特征和用户特征，针对这些特征开发有针对性的推荐算法。

第5.2.1节研究GM模型的网络演化。模拟结果发现，基于标签信息构建的GM网络，与随机网络（ER）和无标度网络（BA）相比，最接近标签推荐系统的静态用户网络（ST）。ST网络和GM网络在同配性上和异质性上的表现，展示了一个有趣的现象：总体上，用户在选择物品上，选择物品较少的用户倾向于与选择过很多物品的用户有共同的物品，而选择物品较少的用户之间则各有各的偏好。标签信息的使用也放大了这一特征，并在网络构建中起到了“物以类聚，人以群分”的作用。鉴于标签信息是用户自发产生的可分享的轻量数据，但众多的标签对推荐算法提出了更高的要求。由系统或者部分用户构建的标签，如果能获得用户的认可而推广开来，对推荐系统而言，能更好地理解用户的偏好，并做出更符合用户需求的推荐。

由于用户有多个信息获取渠道，本章第5.2.2节对双层网络上的信息传播规律进行了研究。模拟结果显示，双层网络上的信息传播受信息传播概率、种子规模和社会强化作用的影响。传播概率、种子规模和社会强化作用越大，信息传播的越广。这对标签推荐算法的研究的有启示意义。对标签推荐系统中，标签信息驳杂导致的推荐不准确的问题，提高初始使用规范化标签的人数是一个解决问题的方向，同时也需要多平台多渠道和多用户分享扩散信息。另外，第四章研究的信任关系在一定程度上对信息传播有积极意义，充分利用信任关系与标签信息，对解决推荐系统面临的困境有很大的借鉴意义。

第六章 总结与展望

6.1 全文总结

计算机和互联网的创造发展是彻底改变了人们的生活方式，人们对线上和线下结合的生活方式越来越适用，带来的问题之一是信息过载。为解决这个问题，人们提出了推荐系统并为此进行了几十年的研究。推荐系统在生活中已经不可缺少，帮助用户解决信息过载的难题，从繁杂冗余的信息中寻找用户感兴趣的信息，节约用户的时间和精力。另一方面，推荐系统也为系统本身提供了良好的展示渠道，从众多信息物品中寻找有用的信息推荐到用户面前。推荐系统如此重要，对此的研究一直是科研的热点。但是目前推荐系统仍然面临这一些难题和挑战。本论文从以下几个方面对此进行了研究：

(1) 针对多样性与精确性的两难问题，本论文第三章从混合算法的角度，分析余弦相似度和资源分配相似度的优缺点。结果显示，基于余弦相似性的协同过滤推荐算法的准确性高，但多样性较差；基于资源分配相似性的物质扩散推荐算法的多样性好，但准确性不足。通过结合余弦相似度和资源分配相似度，提出全新的CosRA相似度指标，并在物质扩散的推荐系统系统框架下，提出了一种基于CosRA指标的推荐算法。在真实数据集上的实验结果显示，基于CosRA指标的推荐算法表现出更好的推荐结果准确性、多样性和新颖性。所提出的CosRA指标没有参数依赖，非常适合作为一个普适的相似性度量方法，应用于推荐系统。将CosRA指标推广得到一般化的CosRA指标不能显著提升推荐算法效果，这表明CosRA指标已经是最优形式。

(2) 在第三章的CosRA相似度算法的基础上，本论文第四章充分利用推荐系统中已存在的社交关系网络，提出CosRA+T算法，并用参数对受信任用户的获得资源进行扩大和缩小。有意思的是，本实验找到了可调参数的最优值以获得最佳的推荐准确性。同时在不同的数据集之间进行实验的其他评价指标也显示该参数最优。实验表明，适当地将受信任用户的资源进行扩大，能有效提高推荐算法的性能。在两个真实的数据集Epinions和FriendFeed上，全面测试了CosRA+T方法的性能，并与其他五个基础推荐算法进行比较，结果显示CosRA+T方法确实能提供一个高准确性、丰富多样性和新颖性的推荐列表。本论文第四章还在物质扩散(MD)算法和热传导(HC)算法的混合算法(HA)的基础上，充分利用信任网络，提出一种新的信任增强算法THA算法。对受信任的用户赋予更多的资源值，增加受信任用户在物品推荐上的影响力。实验结果显示，THA算法在推荐内容上

兼顾了“流行”和“冷门”的物品，提高了算法的准确性和多样性。CosRA+T算法和THA算法在内容推荐上，与传统的基于物品相似度的算法相比，并不局限于用户已经选择的物品类型，拓宽了用户的选择范围。从实验结果看，信任增强算法的研究，强调了社会信任关系在增强基于信任的推荐方法的算法性能方面所起的作用。

(3) 对大部分推荐系统都面临的冷启动问题，本论文第五章从标签系统着手，分析标签系统的特征。标签系统有三个特点：(a) 用户与物品之间有直接关联；(b) 用户有两个属性：一个是物品属性，反映的是用户偏好的结果，一个是标签属性，反映的是用户偏好的内容；(c) 标签不仅反映出了用户的偏好的内容和范围，更反映出用户对物品的认识和分类。基于标签系统的三个特点，第五章提出了基于引力模型(GM)的推荐算法。实验结果显示，与其他在物质扩散框架下的基于标签的推荐算法相比，GM推荐算法在准确性和多样性上有一定提升。对新加入系统的用户和物品，GM推荐算法在时间复杂度上有明显优势。为了对推荐算法的理解更深刻，本论文第五章也从理论层面上对推荐系统进行了研究。首先从网络演化的方向，使用GM模型构建了标签推荐系统的用户网络，模拟结果显示相比于ER和BA模型，GM网络模型是最接近标签推荐系统的静态用户网络(ST)的模型。分析GM网络和ST网络的特征，结果显示ST网络上度小的用户倾向于与度大的用户选择同一物品，度小的用户与用户之间各有各的偏好。从基于标签信息的GM网络的特征来看，标签放大了ST网络上的这一特征，在网络构建中起到了“物以类聚，人以群分”的作用。考虑到标签是一种自发的语义信息，为了对标签有更统一的认识和使用，更方便地运用于推荐算法中，本论文第5.2.2节也对双层网络上信息的传播规律进行了研究。结果显示，传播概率、种子规模和社会强化作用越大，信息传播的越广，用户对信息的接收程度越高。这给推荐算法带来的启发是，针对标签信息驳杂导致的推荐不准确的问题，可以通过提高初始使用规范化标签的人数，并且通过多平台和多用户对信息进行传播。另外，用户的信任关系对于信息接收有正面积极的作用。因此，充分利用推荐系统的辅助信息，如社交关系和标签信息，对解决目前推荐算法的困难有很大的帮助。

6.2 未来展望

本文从实用的角度出发，针对推荐系统面临的两个难题：多样性与精确性的两难问题和冷启动问题，分别进行了算法改进，取得了一定进展，在一定程度上将对此类的问题的研究向前推进一点。但是仍然存在着一些不足之处，结合本文的工作，列出需要改进的部分以及后续的研究安排：

(1) 本文中使用的推荐算法是基于静态系统的算法,受数据集和建模所限,对数据集依赖较高。现实生活中的推荐系统都是实时推荐,新用户和新物品随时能进入推荐系统,数据库也是实时更新,对推荐算法的可计算能力有很高的要求,同时也要充分考虑到平台的数据特点、评价指标的选择、推荐列表的长度等条件,因地制宜地建立合适的推荐算法。本文第三章和第四提到的算法对新加入的用户和物品进行推荐时,需要进行全局计算。对于一个用户量和物品量庞大的系统来说,最好的算法是仅对更新的用户和物品等信息进行计算推荐,降低操作的时间,例如第五提出的基于引力模型(GM)的推荐算法,但GM算法需要使用到的标签信息。如何使得推荐算法更加适合在线系统,是未来可以改进的地方。

(2) 对推荐系统面临的问题中,本文针对其中的多样性与精确性的两难问题和冷启动问题做了相关研究。第三章通过提出新的相似度指标提高算法的准确性;第四章充分利用用户的社交网络信息做辅助,扩大用户可推荐物品的范围,提高了推荐算法的准确性和多样性;第五章使用标签信息作为增补项,对信息稀少的用户和物品增加描述信息,使得针对这类用户和物品的推荐更加准确。以上算法都在一定程度上将对此类问题的研究进行了推进,但是并没有完全解决这些问题。同时,第2.2节中介绍了目前推荐系统面临的一些挑战,本文只针对其中的两个进行了相关研究。其他的挑战如数据稀疏问题、用户隐私问题、推荐系统脆弱性等问题是目前推荐系统急需解决的问题。尤其是用户隐私问题关系到使用推荐系统的千千万万的用户的隐私安全。这些问题都是未来需要继续攻克的难题。

(3) 在第五章中对推荐系统进行了一些辅助性的分析,分别从网络演化和信息传播方向做了研究,并获得了推荐算法改进的经验和方向。但是并没有将这些经验应用于推荐算法。后续的研究可以从多方面继续分析推荐系统的特征,获取更多对推荐算法有改进意义的建议。如何基于这些建议,提出更普适性的个性化推荐算法,是下一步研究的重点。

致 谢

回首硕博连读的生活，感慨良多。在这期间遇见了学业和生活上的困难和问题，都大家的帮助支持下都逐一解决，并且完成这篇博士毕业论文。在此我要非常感谢一直给我学术上指引和支持的我的老师同学们、在我生活上给与帮助我的家人朋友们，诚挚地感谢你们。

记得导师给我看第一篇论文的时候，我震惊地发现，我不仅可以知道是什么，我还可以研究为什么。震惊和兴奋过后，对未来充满了期待。在第一篇论文写作时没有经验，投稿被拒后，痛定思痛，像老师同学们求取经验，重做实验，细心修改了一轮又一轮，终于论文被接受了，而时间已经过去了好几年。这几年与老师同学们朝夕相处，耳濡目染，累积了一点学术经验。我由衷的希望这篇论文成为我科研的新起点，更由衷希望上一句能实现。

我首先感谢我的国家，让我接受九年义务教育。我要感谢我的硕士导师高辉教授，给我打开学术的大门。我要特别感谢我的博士导师张翼成教授，在我博士期间给我细心的指导和帮助。对基础较差的我不抛弃不放弃，用他渊博的知识和极高的学术素养为我指引一条学术道路，对我犯的低级错误也给予细心的指导。我还要感谢周涛教授，他对学术的严谨的态度、极高的学术素养、幽默的性格、风趣的语言像一道光照亮了在实验室里辛苦而又沮丧的我们。我感谢张子柯教授，为我定制文献阅读方案，提高我的学术素养。我还要特别感谢实验室的黄俊铭老师、荣智海教授、蔡世民副教授和张千明老师，不辞辛苦对我进行指导和帮助。还有实验室的刘金虎、杨慧、高磊、高见、王伟、杨丹、苗丽莉，我们在学习上一一起成长，在生活中相互帮助，谢谢你们的陪伴和支持。

我要感谢我的爱人张嵩，给我生活上巨大的支持，让我无后顾之忧地往学术道路上继续走下去。感谢我去年出生的女儿给我带来了巨大的喜悦和前行的动力。感谢我的弟弟，殷勤照顾父母和爷爷奶奶。感谢所有关心支持我的朋友和亲人。

最后，我要评阅我博士论文的各位专家评审们，谢谢你们百忙之中抽出时间，谢谢！

参考文献

- [1] 高见, 周涛. 大数据揭示经济发展状况[J]. 电子科技大学学报, 2016, 45(4):625–633
- [2] J. Gao, B. Jun, A. Pentland, et al. Collective learning in China's regional economic development[J]. arXiv:1703.01369, 2017
- [3] 李文俊. 时间感知的推荐算法研究[D]. 成都: 电子科技大学, 2017, 1–11
- [4] 刘宁. 浅议淘宝网站营销策略[J]. 读书文摘, 2017, 10:80
- [5] P. Maes. Agents that reduce work and information overload[J]. Readings in Human–computer Interaction, 1995, 37:811–821
- [6] A. Edmunds, A. Morris. The problem of information overload in business organisations: A review of the literature[J]. International Journal of Information Management, 2000, 20:17–28
- [7] M. Morita, Y. Shinoda. Information filtering based on user behavior analysis and best match text retrieval[C]. Proceedings of the 17 Annual International ACM-SIGIR Conference on Research and Development in Information Retrieval, London, 1994, 272–281
- [8] F. Ricci, L. Rokach, B. Shapira. Introduction to recommender systems handbook[M]. Recommender systems handbook, 2011, 1–25
- [9] X. Chen, X. W. Gong, L. Yang, et al. Amazon in the white space: social recommendation aided distributed spectrum access[J]. IEEE/ACM Transactions on Networking, 2017, 25(1):536–549
- [10] F. Ricci, L. Rokach, B. Shapira. Recommender systems handbook[M]. New York: Springer, 2011
- [11] 王国霞, 刘贺平, et al. 个性化推荐系统综述[J]. 计算机工程与应用, 2012, 48(7):66–76
- [12] J. Bobadilla, F. Ortega, A. Hernando, et al. Recommender systems survey[J]. Knowledge-Based Systems, 2013, 46:109–132
- [13] T. Zhou, J. Ren, M. Medo, et al. Bipartite network projection and personal recommendation[J]. Physical Review E, 2007, 76(4):046115
- [14] T. Zhou, Z. Kuscsik, J.-G. Liu, et al. Solving the apparent diversity-accuracy dilemma of recommender systems[J]. Proceedings of the National Academy of Sciences of the United States of America, 2010, 107:4511–4515
- [15] B. Smyth, P. McClave. Similarity vs. diversity[C]. International Conference on Case-Based Reasoning, London, UK, UK, 2001, 347–361
- [16] S. M. McNee, J. Riedl, J. A. Konstan. Being accurate is not enough: How accuracy metrics have hurt recommender systems[C]. Proceedings of the CHI'06 Conference on Human Factors in Computing Systems, New York, USA, 2006, 1097–1101

- [17] 艾萨克森. 史蒂夫·乔布斯传[M]. 北京: 中信出版社, 2011
- [18] A. Schein, A. Popescul, L. H. Ungar, et al. Methods And Metrics For Cold-Start Recommendations[C]. Proceedings Of The 25Th Annual International Acm Sigir Conference On Research And Development In Information Retrieval, Tampere, Finland, 2002, 253–260
- [19] P. Cremonesi, Y. Koren, R. Turrin. Performance of recommender algorithms on top-N recommendation tasks[C]. Proceedings of the 4th ACM Conference on Recommender Systems, Barcelona, BCN, Spain, 2010, 39–46
- [20] R. Royi, K. Noam, Z. Elad, et al. Selecting content-based features for collaborative filtering recommenders[C]. Proceedings of the 7th ACM Conference on Recommender Systems, Hong Kong, China, 2013, 407–410
- [21] 张亮, 柏林森, 周涛. 基于跨电商行为的交叉推荐算法[J]. 电子科技大学学报, 2013, 42(1):154–160
- [22] Z.-K. Zhang, C. Liu, Y.-C. Zhang, et al. Solving the cold-start problem in recommender systems with social tags[J]. Europhysics Letters, 2010, 92(2):28001
- [23] Z.-K. Zhang, T. Zhou, Y.-C. Zhang. Tag-aware recommender systems: A state-of-the-art survey[J]. Journal of Computer Science and Technology, 2011, 26(5):767–777
- [24] D. Yin, S. Guo, B. Chidlovskii, et al. Connecting comments and tags: Improved modeling of social tagging systems[C]. Proceedings of the 6th ACM International Conference on Web Search and Data Mining, Rome, ROM, Italy, 2013, 547–556
- [25] C. N. Ziegler, S. M. McNee, J. A. Konstan, et al. Improving recommendation lists through topic diversification[C]. Proceedings of the 14th International Conference on World Wide Web, Chiba, CHB, Japan, 2005, 22–32
- [26] J. A. Konstan, B. N. Miller, D. Maltz, et al. GroupLens: Applying collaborative filtering to Usenet news[J]. Communications of the ACM, 1997, 40(3):77–87
- [27] D. Goldberg, D. Nichols, B. M. Oki, et al. Using collaborative filtering to weave an information tapestry[J]. Communications of the ACM, 1992, 35(12):61–70
- [28] B. Sarwar, G. Karypis, J. Konstan, et al. Item-based collaborative filtering recommendation algorithms[C]. Proceedings of the 10th International Conference on World Wide Web, Hong Kong, 2001, 285–295
- [29] R. Salakhutdinov, A. Mnih, G. Hinton. Restricted boltzmann machines for collaborative filtering[C]. Proceedings of the 24th International Conference on Machine learning, Corvalis, Oregon, USA, 2007, 791–798

- [30] J. S. Breese, D. Heckerman, C. Kadie. Empirical analysis of predictive algorithms for collaborative filtering[C]. Proceedings of the Fourteenth Conference on Uncertainty in Artificial Intelligence, Madison, Wisconsin, 1998, 43–52
- [31] A. S. Das, M. Datar, A. Garg, et al. Google news personalization: Scalable online collaborative filtering[C]. Proceedings of the 16th International Conference on World Wide Web, Banff, Alberta, Canada, 2007, 271–280
- [32] R. Salakhutdinov, A. Mnih. Probabilistic matrix factorization[C]. Proceedings of the 20th International Conference on Neural Information Processing Systems, Vancouver, British Columbia, Canada, 2008, 1257–1264
- [33] Y. Koren. Collaborative filtering with temporal dynamics[C]. Proceedings of the 15th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, Paris, France, 2009, 447–456
- [34] F. Fouss, A. Pirotte, J. M. Renders, et al. Random-walk computation of similarities between nodes of a graph with application to collaborative recommendation[J]. IEEE Transactions on Knowledge and Data Engineering, 2007, 19(3):355–369
- [35] Z. Huang, H. Chen, D. Zeng. Applying associative retrieval techniques to alleviate the sparsity problem in collaborative filtering[J]. ACM Transactions on Information Systems, 2004, 12:116–142
- [36] H. Ma, I. King, M. R. Lyu. Effective missing data prediction for collaborative filtering[C]. Proceedings of the 30th Annual International ACM SIGIR Conference on Research and Development in Information Retrieval, Amsterdam, The Netherlands, 2007, 39–46
- [37] W. Zeng, A. Zeng, M.-S. Shang, et al. Information filtering in sparse online systems: Recommendation via semi-local diffusion[J]. PLoS ONE, 2013, 8(11):e79354
- [38] Y.-C. Zhang, M. Blattner, Y. K. Yu. Heat conduction process on community networks as a recommendation model[J]. Physical Review Letters, 2007, 99(15):154301
- [39] A. Nematzadeh, E. Ferrara, A. Flammini, et al. Optimal network modularity for information diffusion[J]. Physical Review Letters, 2014, 113(8):088701
- [40] A. Nematzadeh, E. Ferrara, A. Flammini, et al. Information filtering via preferential diffusion[J]. Physical Review Letters, 2014, 113(8):088701
- [41] J.-G. Liu, T. Zhou, Q. Guo. Information filtering via biased heat conduction[J]. Physical Review E, 2011, 84(2):037101
- [42] W. Zeng, A. Zeng, M. S. Shang, et al. Information filtering in sparse online systems: Recommendation via semi-Local diffusion[J]. PLoS ONE, 2013, 8(11):e79354

- [43] R. R. Shah, A. Samanta, D. Gupta, et al. PROMPT: Personalized user tag recommendation for social media photos leveraging personal and social contexts[C]. Proceedings of 2016 IEEE International Symposium on Multimedia, San Jose, CA, USA, 2017, 486–492
- [44] S. Zhong, K. Lei, X. Huang, et al. Topic representation: A novel method of tag recommendation for text[C]. Proceedings of IEEE 2nd International Conference on Big Data Analysis, Beijing, China, 2017, 671–676
- [45] J. Robert, M. Leandro, H. Andreas, et al. Tag recommendations in social bookmarking systems[J]. AI Communications, 2008, 21(4):231–247
- [46] A. Shepitsen, J. Gemmell, B. Mobasher, et al. Personalized recommendation in social tagging systems using hierarchical clustering[C]. Proceedings of the ACM Conference on Recommender Systems, Lausanne, Switzerland, 2008, 259–266
- [47] H. Lu, C. Chen, M. Kong, et al. Social recommendation via multi-view user preference learning[J]. Neurocomputing, 2016, 216:61–71
- [48] P. Symeonidis, A. Nanopoulos, Y. Manolopoulos. Tag recommendations based on tensor dimensionality reduction[C]. Proceedings of the 2008 ACM Conference on Recommender Systems, Lausanne, Switzerland, 2008, 43–50
- [49] S. Rendle, L. Balby Marinho, A. Nanopoulos, et al. Learning optimal ranking with tensor factorization for tag recommendation[C]. Proceedings of the 15th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, Paris, France, 2009, 727–736
- [50] L. B. Marinho, L. Schmidt-Thieme. Collaborative tag recommendations[C]. Data Analysis, Machine Learning and Applications, Berlin, Heidelberg, 2008, 533–540
- [51] K. H. Tso-Sutter, L. B. Marinho, L. Schmidt-Thieme. Tag-aware recommender systems by fusion of collaborative filtering algorithms[C]. Proceedings of the 2008 ACM symposium on Applied Computing, Fortaleza, Ceara, Brazil, 2008, 1995–1999
- [52] M. Deshpande, G. Karypis. Item-based top-N recommendation algorithms[J]. ACM Transactions on Information Systems, 2004, 22(1):143–177
- [53] R. Wetzker, W. Umbrath, A. Said. A hybrid approach to item recommendation in folksonomies[C]. Proceedings of the WSDM’09 Workshop on Exploiting Semantic Annotations in Information Retrieval, Barcelona, Spain, 2009, 25–29
- [54] M.-S. Shang, Z.-K. Zhang. Diffusion-based recommendation in collaborative tagging systems[J]. Chinese Physics Letters, 2009, 26(11):118903
- [55] J. Gemmell, M. Ramezani, T. Schimoler, et al. The impact of ambiguity and redundancy on tag recommendation in folksonomies[C]. Proceedings of the third ACM Conference on Recommender Systems, New York, USA, 2009, 45–52

- [56] Y. Song, Z. Zhuang, H. Li, et al. Real-time automatic tag recommendation[C]. Proceedings of the 31st Annual International ACM SIGIR Conference on Research and Development in Information Retrieval, Singapore, Singapore, 2008, 515–522
- [57] H.-M. Chen, M.-H. Chang, P.-C. Chang, et al. SheepDog: Group and tag recommendation for flickr photos by automatic search-based learning[C]. Proceedings of the 16th ACM International Conference on Multimedia, Vancouver, British Columbia, Canada, 2008, 737–740
- [58] N. Garg, I. Weber. Personalized, interactive tag recommendation for flickr[C]. Proceedings of the 2008 ACM Conference on Recommender Systems, Lausanne, Switzerland, 2008, 67–74
- [59] B. Sigurbjörnsson, R. Van Zwol. Flickr tag recommendation based on collective knowledge[C]. Proceedings of the 17th International Conference on World Wide Web, Beijing, China, 2008, 327–336
- [60] R. R. Sinha, K. Swearingen. Comparing recommendations made by online systems and friends[C]. 2001
- [61] I. Guy, N. Zwerdling, D. Carmel, et al. Personalized recommendation of social software items based on social relations[C]. Proceedings of the third ACM Conference on Recommender Systems, New York, USA, 2009, 53–60
- [62] G. Groh, C. Ehmig. Recommendations in taste related domains: Collaborative filtering vs. social filtering[C]. Proceedings of the 2007 International ACM Conference on Supporting Group Work, Sanibel Island, Florida, USA, 2007, 127–136
- [63] P. Avesani, P. Massa, R. Tiella. Moleskiing. IT: A trust-aware recommender system for ski mountaineering[J]. International Journal for Infonomics, 2005, 20(35):1–10
- [64] J. Golbeck. Generating predictive movie recommendations from trust in social networks[C]. International Conference on Trust Management, Pisa, Italy, 2006, 93–104
- [65] M. Richardson, R. Agrawal, P. Domingos. Trust management for the semantic web[C]. International semantic Web conference, Sanibel, FL, USA, 2003, 351–368
- [66] M. Jamali, M. Ester. Trustwalker: A random walk model for combining trust-based and item-based recommendation[C]. Proceedings of the 15th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, Paris, France, 2009, 397–406
- [67] X. Shen, H. Long, C. Ma. Incorporating trust relationships in collaborative filtering recommender system[C]. Proceedings of the 16th IEEE/ACIS International Conference on Software Engineering, Artificial Intelligence, Networking and Parallel/Distributed Computing, Takamatsu, Japan, 2015, 1–8
- [68] H. Ma, I. King, M. R. Lyu. Learning to recommend with explicit and implicit social relations[J]. ACM Transactions on Intelligent Systems and Technology, 2011, 2(3):1–19

- [69] G. Guo, J. Zhang, N. Yorke-Smith. A novel recommendation model regularized with user trust and item ratings[J]. IEEE Transactions on Knowledge and Data Engineering, 2016, 28(7):1607–1620
- [70] X. Wang, Y. Liu, G. Zhang, et al. Diffusion-based recommendation with trust relations on tripartite graphs[J]. Journal of Statistical Mechanics: Theory and Experiment, 2017, 8(8):083405
- [71] R. Guha, R. Kumar, P. Raghavan, et al. Propagation of trust and distrust[C]. Proceedings of the 13th International Conference on World Wide Web, New York, NY, USA, 2004, 403–412
- [72] P. Victor, C. Cornelis, M. De Cock, et al. Key figure impact in trust-enhanced recommender systems[J]. AI Communications, 2008, 21(2-3):127–143
- [73] C.-N. Ziegler, G. Lausen. Propagation models for trust and distrust in social networks[J]. Information Systems Frontiers, 2005, 7(4-5):337–358
- [74] T. Nathanson, E. Bitton, K. Goldberg. Eigentaste 5.0: Constant-time adaptability in a recommender system using item clustering[C]. Proceedings of the 2007 ACM Conference on Recommender Systems, Minneapolis, MN, USA, 2007, 149–152
- [75] M. D. Ekstrand, J. T. Riedl, J. A. Konstan. Collaborative filtering recommender systems[J]. Foundations and Trends in Human-Computer Interaction, 2011, 4(2):81–173
- [76] S. Valenzuela, T. Correa, H. G. Zúñiga. Ties, likes, and tweets: Using strong and weak ties to explain differences in protest participation across Facebook and Twitter use[J]. Political Communication, 2018, 35(1):117–134
- [77] A. Z. Khan, M. Atique, V. Thakare. Combining lexicon-based and learning-based methods for Twitter sentiment analysis[J]. International Journal of Electronics, Communication and Soft Computing Science & Engineering, 2015:89–91
- [78] Q. Yuan, G. Cong, K. Zhao, et al. Who, where, when, and what: A nonparametric bayesian approach to context-aware recommendation and search for twitter users[J]. ACM Transactions on Information Systems, 2015, 33(1):1–33
- [79] P. Gupta, V. Satuluri, A. Grewal, et al. Real-time twitter recommendation: Online motif detection in large dynamic graphs[J]. Proceedings of the VLDB Endowment, 2014, 7(13):1379–1380
- [80] X. Liu, T. Xia, Y. Yu, et al. Cross social media recommendation[C]. Proceedings of the tenth International AAAI Conference on Web and Social Media, Washington, US, 2016, 221–230
- [81] D. Yang, Y. Xiao, H. Tong, et al. An integrated tag recommendation algorithm towards weibo user profiling[C]. Proceedings of the International Conference on Database Systems for Advanced Applications, Hanoi, Vietnam, 2015, 353–373
- [82] 波兹曼. 娱乐至死[M]. 北京: 中信出版社, 2015

- [83] Y. Portilla, A. Reiffers, E. Altman, et al. A study of youtube recommendation graph based on measurements and stochastic tools[C]. Proceedings of the 8th International Conference on Utility and Cloud Computing, Limassol, Cyprus, 2015, 430–435
- [84] D. K. Krishnappa, M. Zink, C. Griwodz, et al. Cache-centric video recommendation: an approach to improve the efficiency of youtube caches[J]. ACM Transactions on Multimedia Computing, Communications, and Applications, 2013, 11(4):261–270
- [85] Z. Deng, M. Yan, J. Sang, et al. Twitter is faster: Personalized time-aware video recommendation from twitter to youtube[J]. ACM Transactions on Multimedia Computing, Communications, and Applications, 2014, 11(2):1–23
- [86] Y. Zheng, X. Zhou. Computing with Spatial Trajectories[M]. New York: Springer, 2011
- [87] L. J. Chen. Information filtering via trust relationship for better personalized recommendation[C]. Proceedings of the 5th International Conference on Mechanics, Simulation and Control, Xi'an, China, 2017, 2729–2732
- [88] A. Goswami, P. Dwivedi, V. Kant. Trust-Enhanced Multi-criteria Recommender System[C]. 2017, 439–448
- [89] M. Medo, Y.-C. Zhang, T. Zhou. Adaptive model for recommendation of news[J]. Europhysics Letters, 2009, 88(3):38005
- [90] T. Zhou, M. Medo, G. Cimini, et al. Emergence of scale-free leadership structure in social recommender systems[J]. PLoS ONE, 2011, 6(7):e20648
- [91] C.-J. Zhang, A. Zeng. Behavior patterns of online users and the effect on information filtering[J]. Physica A, 2012, 391(4):1822–1830
- [92] S. J. Pan, Q. Yang. A survey on transfer learning[J]. IEEE Transactions on Knowledge and Data Engineering, 22(10):1345–1359
- [93] N. Nori, D. Bollegala, M. Ishizuka. Exploiting user interest on social media for aggregating diverse data and predicting interest[J]. Artificial Intelligence, 2011, 109(B3):241–248
- [94] J. Ren, T. Zhou, Y.-C. Zhang. Information filtering via self-consistent refinement[J]. Europhysics Letters, 2008, 82(5):58007
- [95] D. Sun, T. Zhou, J.-G. Liu, et al. Information filtering based on transferring similarity[J]. Physical Review E, 2009, 80(1):017101
- [96] J. Gao, Y.-W. Dong, M.-S. Shang, et al. Group-based ranking method for online rating systems with spamming attacks[J]. Europhysics Letters, 2015, 110(2):28003
- [97] S. Lam, D. Frankowski, J. Riedl. Do you trust your recommendations? An exploration of security and privacy issues in recommender systems[J]. Emerging Trends in Information and Communication Security, 2006:14–29

- [98] P. Resnick, R. Sami. The influence limiter: Provably manipulation-resistant recommender systems[C]. Proceedings of the 2007 ACM Conference on Recommender Systems, Minneapolis, MN, USA, 2007, 25–32
- [99] H. Yu, C. Shi, M. Kaminsky, et al. DSybil: Optimal sybil-resistance for recommendation systems[C]. Proceedings of the 30th IEEE Symposium on Security and Privacy, Berkeley, CA, USA, 2009, 283–298
- [100] 朱郁筱, 吕琳媛. 推荐系统评价指标综述[J]. 电子科技大学学报, 2012, 41(2):163–175
- [101] D.-D. Zhao, A. Zeng, M.-S. Shang, et al. Long-term effects of recommendation on the evolution of online systems[J]. Chinese Physics Letters, 2013, 30(11):118901
- [102] N. Ramakrishnan, B. J. Keller, B. J. Mirza, et al. Privacy risks in recommender systems[J]. IEEE Internet Computing, 2001, 5(6):54–62
- [103] A. Moukas. Amalthaea information discovery and filtering using a multiagent evolving ecosystem[J]. Applied Artificial Intelligence, 1997, 11(5):437–457
- [104] T. M. Mitchell. Machine learning[J]. McGraw-Hill, 1997
- [105] J. J. Rocchio. Relevance feedback in information retrieval[M]. The SMART retrieval system: Experiments in automatic document processing, 1971, 313–323
- [106] J.-G. Liu, L. Hou, X. Pan, et al. Stability of similarity measurements for bipartite networks[J]. Scientific Reports, 2016, 6:18563
- [107] S. Papne, jaKapil SharmaEmail, authorNitesh Khilwani. Context aware personalized content recommendation using ontology based spreading activation[J]. International Journal of Information Technology, 2018, 10(2):133–138
- [108] B. Sheth, P. Maes. Evolving agents for personalized information filtering[C]. Proceedings of the Ninth Conference on Artificial Intelligence for Applications, Orlando, FL, USA, USA, 1993, 345–352
- [109] G. Salton. Automatic text processing[M]. Boston: Addison-Wesley, 1988
- [110] S. Aciar, D. Zhang, S. Simoff, et al. Informed recommender: Basing recommendations on consumer product reviews[J]. IEEE Intelligent Systems, 2007, 22(3):39–47
- [111] Y. Blanco-Fernandez, J. J. Pazos-Arias, A. Gil-Solla, et al. Providing entertainment by content-based filtering and semantic reasoning in intelligent recommender systems[J]. IEEE Transactions on Consumer Electronics, 2008, 54(2):727–735
- [112] B. Yang, Y. Lei, J. Liu, et al. Social collaborative filtering by trust[J]. International Joint Conference on Artificial Intelligence, 2013, 39:2747–2753
- [113] Y. Shi, M. Larson, A. Hanjalic. Collaborative filtering beyond the user-item matrix: A survey of the state of the art and future challenges[J]. ACM Computing Surveys, 2014, 47(1):1–45

- [114] N. Rao, H.-F. Yu, P. K. Ravikumar, et al. Collaborative filtering with graph information: Consistency and scalable methods[C]. 2015, 2107–2115
- [115] T. Mahmood, F. Ricci. Improving recommender systems with adaptive conversational strategies[C]. Proceedings of the 20th ACM Conference on Hypertext and Hypermedia, Torino, Italy, 2009, 73–82
- [116] D. M. Blei, A. Y. Ng, M. I. Jordan. Latent dirichlet allocation[J]. Journal of Machine Learning Research, 2003, 3:993–1022
- [117] T. Hofmann. Collaborative filtering via gaussian probabilistic latent sementic analysis[C]. Proceedings of the 26th Annual International ACM SIGIR Conference on Research and Development in Informaion Retrieval, Toronto, Canada, 2003, 259–266
- [118] R. Salakhutdinov, A. Mnih, G. Hinton. Restricted Boltzmann machines for collaborative filtering[C]. Proceedings of the 24th International Conference on Machine Learning, Corvalis, Oregon, USA, 2007, 791–798
- [119] M. Grčar, B. Fortuna, D. Mladenič, et al. kNN Versus SVM in the Collaborative Filtering Framework[J]. Springer Berlin Heidelberg, 2006:251–260
- [120] C. L. Zitnick, T. Kanade. Maximum entropy for collaborative filtering[C]. Proceedings of the 20th Conference on Uncertainty in Artificial Intelligence, Banff, Canada, 2004, 636–643
- [121] Y. Koren. Factorization meets the neighborhood: a multifaceted collaborative filtering model[C]. Proceedings of the 14th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, Las Vegas, Nevada, USA, 2008, 426–434
- [122] W. Hill, L. Stead, M. Rosenstein, et al. Recommending and evaluating choices in a virtual community of use[C]. Proceedings of the SIGCHI Conference on Human Factors in Computing Systems, Denver, Colorado, USA, 1995, 194–201
- [123] F. Ricci, D. Cavada, N. Mirzadeh, et al. Case-based travel recommendations[M]. Destination recommendation systems: Behavioural foundations and applications, 2006, 67–93
- [124] Z. Cheng, N. Hurley. Effective diverse and obfuscated attacks on model-based recommender systems[C]. Proceedings of the third ACM conference on Recommender systems, New York, New York, USA, 2009, 141–148
- [125] A. Felfernig, R. Burke. Constraint-based recommender systems: Technologies and research issues[C]. Proceedings of the 10th International Conference on Electronic Commerce, Innsbruck, Austria, 2008, 1–10
- [126] A. Felfernig, G. Friedrich, D. Jannach, et al. An integrated environment for the development of knowledge-based recommender applications[J]. International Journal of Electronic Commerce, 2006, 11(2):11–34

- [127] R. Burke. Knowledge-based recommender systems[J]. 2000, 20:180–200
- [128] F. Lorenzi, F. Ricci. Case-based recommender systems: A unifying view[C]. Proceedings of the 2003 International Conference on Intelligent Techniques for Web Personalization, Acapulco, Mexico, 2005, 89–113
- [129] M. Zanker, M. Fuchs, W. Höpken, et al. Evaluating recommender systems in tourism - a Case study from austria[J]. Information and Communication Technologies in Tourism, 2008:24–34
- [130] A. Felfernig, A. Kiener. Knowledge-based interactive selling of financial services with FSAdvisor[C]. Proceedings of the National Conference on Artificial Intelligence, Pittsburgh, Pennsylvania, 2005, 1475–1482
- [131] D. Jannach. Advisor suite - a knowledge-based sales advisory-system[C]. Proceedings of the 16th European Conference on Artificial Intelligence, Valencia, Spain, 2004, 720–724
- [132] Y. Gil, E. Motta, V. R. Benjamins, et al. The semantic web – ISWC 2005[C]. Proceedings of the 4th International Semantic Web Conference, , 2005, 6–10
- [133] D. Jannach, U. Bundgaard-Joergensen. SAT: A web-based interactive advisor for investor-ready business plans[C]. 2007, 99–106
- [134] A. Felfernig, K. Isak, T. Kruggel. Testing knowledge-based recommender systems[J]. Oesterreichische Gesellschaft fuer Artificial Intelligence, 2005, 4:12–18
- [135] T. Mahmood, F. Ricci. Learning and adaptivity in interactive recommender systems[C]. Proceedings of the 9th International Conference on Electronic Commerce, Minneapolis, MN, USA, 2007, 75–84
- [136] E. P. K. Tsang. Foundations of constraint satisfaction[M]. DBLP, 1993, 188–224
- [137] M. Burnett. HCI research regarding end-user requirement specification: A tutorial.Knowledge-Based Systems[J]. Knowledge-Based Systems, 2003, 16(7-8):341–349
- [138] S. Marsh, P. Briggs. Examining trust, forgiveness and regret as computational concepts[J]. Computing with Social Trust, 2009:9–43
- [139] P. Victor, C. Cornelis, M. D. Cock, et al. Trust- and distrust-based recommendations for controversial reviews[J]. IEEE Intelligent Systems, 2011, 26(1):48–55
- [140] P. Massa, P. Avesani. Trust metrics in recommender systems[J]. Computing with Social Trust, 2010:259–285
- [141] C. N. Ziegler, J. Golbeck. Investigating interactions of trust and interest similarity[J]. Decision Support Systems, 2007, 43(2):460–475
- [142] S. D. Kamvar, M. T. Schlosser, H. Garcia-Molina. The eigentrust algorithm for reputation management in P2P networks[C]. Proceedings of the 12th International Conference on World Wide Web, Budapest, Hungary, 2003, 640–651

- [143] J.-P. Qiu, L.-C. Chen. Trust management for semantec web[C]. Proceedings of the International Conference on Computer Science and Software Engineering, Hubei, China, 2008, 778–781
- [144] I. Zaihrayeu, P. P. da Silva, D. L. McGuinness. IWTrust: Improving user trust in answers from the web[C]. Proceedings of the Third International Conference on Trust Management, Paris, France, 2005, 384–392
- [145] R. Guha, R. Kumar, P. Raghavan, et al. Propagation of trust and distrust[C]. Proceedings of the 13th international conference on World Wide Web, New York, USA, 2004, 403–412
- [146] Golbeck, Ann J. Computing and applying trust in web-based social networks[D]. USA: University of Maryland at College Park, 2005
- [147] P. Massa, P. Avesani. Trust-aware collaborative filtering for recommender systems[J]. Lecture Notes in Computer Science, 2004, 3290:492–508
- [148] C. N. Ziegler, G. Lausen. Propagation models for trust and distrust in social networks[J]. Information Systems Frontiers, 2005, 7(4-5):337–358
- [149] W. Tang, Y.-X. Ma, Z. Chen. Managing trust in peer-to-peer networks[J]. Journal of Digital Information Management, 2005, 3(2):58–63
- [150] M. Lesani, S. Bagheri. Applying and inferring fuzzy trust in semantic web social networks[J]. Semantic Web & Beyond, 2006, 2:23–43
- [151] R. Levien. Attack-resistant trust metrics[M]. Computing with social trust, 2009, 121–132
- [152] L. Mui, M. Mohtashemi, A. Halberstadt. A computational model for trust and reputation[J]. 2002
- [153] A. Constantinople. An eriksonian measure of personality development in college students[J]. Developmental Psychology, 1969, 1(4):357–372
- [154] R. J. Lewicki, D. J. McAllister, R. J. Bies. Trust and distrust: New relationships and realities[J]. Academy of Management Review, 1998, 23(3):438–458
- [155] T. Zhou, L.-L. Jiang, R.-Q. Su, et al. Effect of initial configuration on network-based recommendation[J]. Europhysics Letters, 2008, 81(5):58004
- [156] C.-X. Jia, R.-R. Liu, D. Sun, et al. A new weighting method in network-based recommendation[J]. Physica A, 2008, 387:5887–5891
- [157] Y. Zhang, M. Chen, D. Huang, et al. iDoctor: Personalized and professionalized medical recommendations based on hybrid matrix factorization[J]. Future Generation Computer Systems, 2017, 66:30–35
- [158] C. di Sciascio. Advanced user interfaces and hybrid recommendations for exploratory search[C]. Proceedings of the 22nd International Conference on Intelligent User Interfaces Companion, Limassol, Cyprus, 2017, 221–224

- [159] R. N. Laveti, J. Ch, S. N. Pal, et al. A hybrid recommender system using weighted ensemble similarity metrics and digital filters[C]. Proceedings of the 23rd International Conference on High Performance Computing Workshops, Hyderabad, India, 2016, 32–38
- [160] W. Zeng, A. Zeng, H. Liu, et al. Uncovering the information core in recommender systems[J]. Scientific Reports, 2014, 4:6140
- [161] R. Burke. The adaptive web[J]. 2007, 4321
- [162] J. A. Swets. Information retrieval systems[J]. Science, 1963, 141(3577):245–250
- [163] J. A. Hanley, B. J. McNeil. The meaning and use of the area under a receiver operating characteristic of ROC curve[J]. Radiology, 1982, 143(1):29–36
- [164] 刘建国, 周涛, 郭强, et al. 个性化推荐系统评价方法综述[J]. 复杂系统与复杂性科学, 2009, 6:1–10
- [165] Y. Yisong, F. Thomas, R. Filip, et al. A support vector method for optimizing average precision[C]. Proceedings of the 30th Annual International ACM SIGIR Conference on Research and Development in Information Retrieval, New York, NY, USA, 2007, 271–278
- [166] L. Lü, M. Medo, C. H. Yeung, et al. Recommender systems[J]. Physics Reports, 2012, 519(1):1–49
- [167] J. Kalervo, K. Jaana. IR Evaluation Methods for Retrieving Highly Relevant Documents[C]. Proceedings of the 23rd Annual International ACM SIGIR Conference on Research and Development in Information Retrieval, New York, NY, USA, 2010, 41–48
- [168] C. Keunho, S. Yongmoo. A new similarity functionfunction for selecting neighbors for each target item in collaborative filtering[J]. Knowledge-Based Systems, 2013, 37:146–153
- [169] S. Bagchi. Performance and quality assessment of similarity measures in collaborative filtering using mahout[J]. Procedia Computer Science, 2015, 50:229–234
- [170] D. J. Watts, S. H. Strogatz. Collective dynamics of ‘small-world’ networks[J]. Nature, 1998, 393(6684):440–442
- [171] R. Albert, A.-L. Barabási. Statistical mechanics of complex networks[J]. Reviews of Modern Physics, 2002, 74(1):47–97
- [172] A.-L. Barabási, R. Albert. Emergence of scaling in random networks[J]. Science, 1999, 286:509–512
- [173] T. Zhou, L. Lü, Y.-C. Zhang. Predicting missing links via local information[J]. European Physical Journal B, 2009, 71(4):623–630
- [174] Y.-C. Zhang, M. Medo, J. Ren, et al. Recommendation model based on opinion diffusion[J]. Europhysics Letters Association, 2007, 80:68003

- [175] X. Zhu, H. Tian, P. Zhang, et al. Personalized recommendation based on unbiased consistence[J]. *Europhysics Letters*, 2015, 111(4):48007
- [176] T. O'Reilly. What is web 2.0[M]. *Online Communication and Collaboration: A Reader*, 2005
- [177] Q. Guo, R. Leng, K. Shi, et al. Heat conduction information filtering via local information of bipartite networks[J]. *European Physical Journal B*, 2012, 85(8):286
- [178] J.-G. Liu, Q. Guo, Y.-C. Zhang. Information filtering via weighted heat conduction algorithm[J]. *Physica A*, 2011, 390(12):2414–2420
- [179] J. Yuan, Q.-M. Zhang, J. Gao, et al. Promotion and resignation in employee networks[J]. *Physica A*, 2016, 444:442–447
- [180] D. Centola. The spread of behavior in an online social network experiment[J]. *Science*, 2010, 329(5996):1194–1197
- [181] M. J. Salganik, P. S. Dodds, D. J. Watts. Experimental study of inequality and unpredictability in an artificial cultural market[J]. *Science*, 2006, 311(5762):854–856
- [182] J. Leskovec, L. A. Adamic, B. A. Huberman. The dynamics of viral marketing[C]. 2006, 228–237
- [183] J. Huang, X.-Q. Cheng, H.-W. Shen, et al. Exploring social influence via posterior effect of word-of-mouth recommendations[C]. *Proceedings of the 5th ACM International Conference on Web Search and Data Mining*, Seattle, Washington, USA, 2012, 573–582
- [184] S. Guo, M. Wang, J. Leskovec. The role of social networks in online shopping: Information passing, price of trust, and consumer choice[C]. *Proceedings of the 12th ACM conference on Electronic Commerce*, San Jose, California, USA, 2011, 157–166
- [185] R. V. Guha. Open rating systems[J]. *Workshop on Friend of A Friend Social Networking & the Semantic Web*, 2003, 7(4):595–599
- [186] Patricia Victor, Chris Cornelis, M. Cock, et al. Gradual trust and distrust in recommender systems[J]. *Fuzzy Sets & Systems*, 2009, 160:1367–1382
- [187] F. E. Walter, S. Battiston, F. Schweitzer. A model of a trust-based recommendation system on a social network[J]. *Kluwer Academic Publishers*, 2008, 16:57–74
- [188] R. Andersen, C. Borgs, J. Chayes, et al. Trust-based recommendation systems: An axiomatic approach[C]. *Proceedings of the 17th International Conference on World Wide Web*, Beijing, China, 2008, 199–208
- [189] 邓小方, 钟元生, 吕琳媛, et al. 融合社交网络的物质扩散推荐算法[J]. *山东大学学报(理学版)*, 2017, 52(3):51–59
- [190] L.-J. Chen, Z.-K. Zhang, J.-H. Liu, et al. A vertex similarity index for better personalized recommendation[J]. *Physica A*, 2017, 466:607–615

- [191] L.-J. Chen, J. Gao. A trust-based recommendation method using network diffusion processes[J]. *Physica A*, 2018, 502:679–691
- [192] J. B. Schafer, D. Frankowski, J. Herlocker, et al. *The adaptive web*[M]. Berlin, Heidelberg: Springer, 2007, 291–324
- [193] H. Liao, A. Zeng, R. Xiao, et al. Ranking reputation and quality in online rating systems[J]. *PLoS ONE*, 2014, 9(5):e97146
- [194] J. Gao, T. Zhou. Evaluating user reputation in online rating systems via an iterative group-based ranking method[J]. *Physica A*, 2017, 473:546–560
- [195] J. Gao, T. Zhou, Y. Hu. Bootstrap percolation on spatial networks[J]. *Scientific Reports*, 2015, 5:14662
- [196] 魏建良, 朱庆华. 基于社会化标注的个性化推荐研究进展[J]. *情报学报*, 2010, 29:625–633
- [197] A. K. Milicevic, A. Nanopoulos, M. Ivanovic. Social tagging in recommender systems: A survey of the state-of-the-art and possible extensions[J]. *Artificial Intelligence Review*, 2010, 33:187–209
- [198] Z.-K. Zhang, T. Zhou, Y.-C. Zhang. Personalized recommendation via integrated diffusion on user-item-tag tripartite graphs[J]. *Physica A*, 2010, 389(1):179–186
- [199] J.-H. Liu, Z.-K. Zhang, L.-J. Chen, et al. Gravity effects on information filtering and network evolving[J]. *PLoS ONE*, 2014, 10(3):e91070
- [200] D. Karemera, V. I. Oguledo, B. Davis. A gravity model analysis of international migration to North America[J]. *Journal of Applied Economics*, 2000, 32(13):1745–1755
- [201] R. Weisbrod. *The Geography of Transport Systems*[J]. *Journal of Urban Technology*, 2013, 18(2):127–127
- [202] J. Q. Stewart. The development of social physics[J]. *American Journal of Physics*, 1950, 18(5):239–243
- [203] W. S. Jung, F. Z. Wang, S. Havlin, et al. Volatility return intervals analysis of the Japanese market[J]. *European Physical Journal B*, 2008, 62(1):113–119
- [204] J. de Dios Ortúzar, L. G. Willumsen. *Modelling Transport*[M]. West Sussex: Wiley, 2011, 182–193
- [205] J. Westerlund, F. Wilhelmsson. Estimating the gravity model without gravity using panel data[J]. *Journal of Applied Economics*, 2011, 43(6):641–649
- [206] P. E. . A. Rényi. On random graphs[J]. *Publicationes Mathematicae*, 1959, 6(4):290–297
- [207] D. J. Watts, S. H. Strogatz. Collective dynamics of 'small-world' networks[J]. *Nature*, 1998, 393(6684):440–442

- [208] M. E. J. Newman. Assortative mixing in networks[J]. Physical Review Letters, 2002, 89(20):208701
- [209] J. Bouttier, P. D. Francesco, E. Guitter. Census of planar maps: From the one-matrix model solution to a combinatorial proof[J]. Nuclear Physics B, 2002, 645(3):477–499
- [210] R. Pastor-Satorras, C. Castellano, P. V. Mieghem, et al. Epidemic processes in complex networks[J]. Reviews of Modern Physics, 2015, 87(3):925
- [211] L. Wang, X. Li. Spatial epidemiology of networked metapopulation: An overview[J]. Chinese Science Bulletin, 2014, 59(28):3511–3522
- [212] D. Guilbeault, J. Becker, D. Centola. Complex contagions: A decade in review[J]. arXiv:1710.07606, 2017
- [213] D. Centola. The spread of behavior in an online social network experiment[J]. Science, 2010, 329(5996):1194–1197
- [214] J. W. Duncan. A simple model of global cascades on random networks[J]. Proceedings of the National Academy of Sciences, 2002, 99(9):5766–5771
- [215] W. Wang, M. Tang, H.-F. Zhang, et al. Dynamics of social contagions with memory of nonredundant information[J]. Physical Review E, 2015, 92(1):012820
- [216] W. Wang, M. Cai, M. Zheng. Social contagions on correlated multiplex networks[J]. Physica A, 2017, 499:121–128
- [217] P. S. Dodds, K. D. Harris, C. M. Danforth. Limited imitation contagion on random networks: Chaos, universality, and unpredictability[J]. Physical Review Letters, 2013, 110(15):158701
- [218] L. Wang, Z. Wang, Y. Zhang, et al. How human location-specific contact patterns impact spatial transmission between populations?[J]. Scientific Reports, 2013, 3:1468
- [219] W. Wang, M. Tang, H. E. Stanley, et al. Unification of theoretical approaches for epidemic spreading on complex networks[J]. Reports on Progress in Physics, 2017, 80(3):036603
- [220] Y.-X. Zhu, W. Wang, M. Tang, et al. Social contagions on weighted networks[J]. Physical Review E, 2017, 96(1):012306
- [221] X. Chen, R. Wang, M. Tang, et al. Suppressing epidemic spreading in multiplex networks with social-support[J]. Physics and Society, 2013, 3(1468)
- [222] J. P. Gleeson, D. J. Cahalane. Seed size strongly affects cascades on random networks[J]. Physical Review E, 2007, 75(5):056103
- [223] D. E. Whitney. Dynamic theory of cascades on finite clustered random networks with a threshold rule[J]. Physical Review E, 2010, 82(6):066110
- [224] J. P. Gleeson. Cascades on correlated and modular random networks[J]. Physical Review E, 2008, 77(4):046117

- [225] O. Yağan, V. Gligor. Analysis of complex contagions in random multiplex networks[J]. Physical Review E, 2012, 86(3):036103
- [226] K.-M. Lee, J. Y. Kim, W. Kuk Cho, et al. Correlated multiplexity and connectivity of multiplex random networks[J]. New Journal of Physics, 2012, 14(3):033027
- [227] C. D. Brummitt, K.-M. Lee, K.-I. Goh. Multiplexity-facilitated cascades in networks[J]. Physical Review E, 2012, 85(4):045102
- [228] K.-M. Lee, C. D. Brummitt, K.-I. Goh. Threshold cascades with response heterogeneity in multiplex networks[J]. Physical Review E, 2014, 90(6):062816
- [229] L.-J. Chen, X.-L. Chen, M. Cai, et al. Complex contagions with social reinforcement from different layers and neighbors[J]. Physica A, 2018, 502:516–525
- [230] J. Scott. Social network analysis[M]. Sage Publications, 2017
- [231] W. Chen, M. Schröder, R. M. D' Souza, et al. Microtransition cascades to percolation[J]. Physical Review Letters, 2014, 112(15):155701

攻读博士学位期间取得的成果

发表论文：

- [1] **Ling-Jiao Chen**, Zi-Ke Zhang, Jin-Hu Liu, Jian Gao, Tao Zhou. A vertex similarity index for better personalized recommendation[J]. Physica A, 2017, 466:607–615 (SCI,IDS:ED0QU)
- [2] **Ling-Jiao Chen**, Xiao-Long Chen, Meng Cai, Wei Wang. Complex contagions with social reinforcement from different layers and neighbors[J].Physica A, 2018, 502:516-525(SCI)
- [3] **Ling-Jiao Chen**, Jian Gao. A trust-based recommendation method using network diffusion processes [J]. Physica A, 2018, 502:679-691(SCI)
- [4] 陈玲姣, 蔡世民, 张千明, 周涛, 张翼成. 基于信任关系的资源分配推荐算法改进研究[J]. 电子科技大学学报, 2018, 已录用 (EI)
- [5] **Ling-Jiao Chen**. Information filtering via trust relationship for better personalized recommendation[C]. International Conference on Mechanics, Simulation and Control (ICMSC 2017:2729-2732)
- [6] Jin-Hu Liu, Zi-Ke Zhang, **Ling-Jiao Chen**, Chuang Liu, Chengcheng Yang Xueqi Wang. Gravity effects on information filtering and network evolving[J]. PLoS ONE, 2014, 9(3):e91070 (SCI,IDS:AC9HN)

科研项目：

- [1] 流模式下人类行为数据时空特性可视化分析研究，2016，国家自然科学基金青年科学基金项目，项目编号：61502083，项目角色：参与.
- [2] 二进制递归网络的多故障容错性分析，2014，国家自然科学基金青年科学基金项目，项目编号：61300018，项目角色：参与.
- [3] 社会化标签系统的结构、功能和应用研究，2012，国家自然科学基金青年科学基金项目，项目编号：11105024，项目角色：参与.